

**PENGEMBANGAN SISTEM INFORMASI
BERBASIS MACHINE LEARNING DAN
EXPLAINABLE ARTIFICIAL INTELLIGENCE
UNTUK PREDIKSI RISIKO HIPERTENSI**

Laporan Tugas Akhir

Oleh

**Samuel Franciscus Togar Hasurungan
18222131**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG**

Juni 2026

LEMBAR PENGESAHAN

Pengembangan Sistem Informasi Berbasis Explainable Artificial Intelligence dan Large Language Model untuk Prediksi Risiko Hipertensi

Laporan Tugas Akhir

Oleh

Samuel Franciscus Togar Hasurungan
18222131

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Laporan Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 12 Juni 2026

Pembimbing

Prof. Dr. Ir. Suhono Harso Supangkat, M.Eng.

NIP. 19621203198811101

LEMBAR PERNYATAAN

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan tugas akhir ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan laporan tugas akhir.
3. Isi laporan ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 12 Juni 2026

Samuel Franciscus Togar Hasurungan

NIM: 18222131

ABSTRAK

Pengembangan Sistem Informasi Berbasis Explainable Artificial Intelligence dan Large Language Model untuk Prediksi Risiko Hipertensi

oleh

Samuel Franciscus Togar Hasurungan

18222131

Proses manual dalam rantai pasok jeruk di tingkat lapak, yang mencakup sortir, timbang, dan catat, terbukti tidak efisien, memakan waktu, dan rentan terhadap kesalahan. Meskipun solusi berbasis Internet of Things (IoT) dapat mengatasi masalah ini, arsitektur terpusat konvensional berbasis cloud justru menimbulkan masalah baru berupa latensi tinggi yang menghambat alur kerja real-time. Penelitian ini bertujuan untuk merancang dan mengimplementasikan sebuah purwarupa sistem smart scale berbasis IoT dengan pendekatan desentralisasi (edge computing) untuk meminimalkan latensi dan meningkatkan efisiensi operasional. Metode yang digunakan adalah Model Purwarupa, yang diwujudkan dalam bentuk perangkat keras dengan arsitektur prosesor ganda (Raspberry Pi 5 dan ESP32) yang mampu mengintegrasikan fungsi timbang dan analisis kualitas citra secara simultan. Hasil evaluasi menunjukkan bahwa purwarupa dengan arsitektur edge computing yang diimplementasikan mampu memberikan respons 43,5% lebih cepat (latensi rata-rata 18,05 detik) dibandingkan dengan simulasi arsitektur terpusat. Selain itu, sistem ini berhasil meningkatkan efisiensi waktu kerja secara keseluruhan sebesar 58,32% jika dibandingkan dengan metode manual konvensional. Pengujian Penerimaan Pengguna (UAT) yang melibatkan 30 partisipan juga menunjukkan penerimaan yang sangat positif, dengan skor rata-rata untuk kemudahan penggunaan (5,0/5,0), kejelasan antarmuka (4,87/5,0) dan persepsi kinerja (4,95/5,0). Kesimpulannya, implementasi sistem smart scale dengan arsitektur desentralisasi terbukti merupakan solusi yang valid dan efektif untuk menjawab permasalahan latensi dan inefisiensi di lapak. Sistem ini tidak hanya unggul secara teknis dalam hal performa, tetapi juga fungsional dan dapat diterima dengan baik oleh pengguna akhir, serta berpotensi besar untuk modernisasi rantai pasok agribisnis.

Kata kunci: Smart Scale, Internet of Things, Edge Computing, Rantai Pasok Jeruk.

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat dan karunia-Nya, saya dapat menyelesaikan penulisan Laporan Tugas Akhir yang berjudul "Implementasi Algoritma XYZ untuk Optimasi Jaringan Komputer". Laporan ini disusun sebagai salah satu syarat untuk menyelesaikan program Sarjana di Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung.

Bandung, 20 Mei 2026

Penulis

Samuel Franciscus Togar Hasurungan

DAFTAR ISI

LEMBAR PENGESAHAN	iii
LEMBAR PERNYATAAN	v
ABSTRAK	vii
KATA PENGANTAR	ix
DAFTAR ISI	xi
DAFTAR GAMBAR	xv
DAFTAR TABEL	xvii
DAFTAR ALGORITMA	xix
DAFTAR KODE PROGRAM	xxi
DAFTAR SINGKATAN	xxiii
DAFTAR SIMBOL	xxv
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	2
I.3 Tujuan	3
I.4 Batasan Masalah	3
I.5 Metodologi	4
I.6 Sistematika Penulisan	6
II STUDI LITERATUR	9
II.1 Hipertensi	9
II.1.1 Klasifikasi Hipertensi	10
II.1.2 Faktor Risiko	11
II.1.2.1 Faktor Risiko Tidak Dapat Dimodifikasi	11
II.1.2.2 Faktor Risiko Dapat Dimodifikasi	11
II.2 Machine Learning	12
II.2.1 Gradient Boosting	12
II.2.2 Extreme Gradient Boosting (XGBoost)	14
II.3 Artificial Intelligence	15
II.3.1 Explainable Artificial Intelligence (XAI)	15
II.3.1.1 Shapley Additive Explanations (SHAP)	16
II.3.1.2 Local Interpretable Model-agnostic Explanations (LIME)	16
II.3.1.3 Analisis Komparatif SHAP dan LIME	16
II.4 Large Language Model (LLM)	16
II.4.1 Vector Database	17
II.4.2 Keterbatasan LLM	19
II.4.3 Mengatasi Keterbatasan LLM	20
II.5 Retrieval-Augmented Generation (RAG)	20
II.5.1 Kapabilitas RAG	21
II.5.2 Limitasi Teknis RAG	21
II.5.3 RAG Dalam Domain Medis	22
II.5.4 Retrieval Augmented Generation Assessment (RAGAS)	22

II.6	Tinjauan Penelitian Sebelumnya	25
III	ANALISIS MASALAH	29
III.1	Analisis Kondisi Saat Ini	29
III.1.1	Kesenjangan Transparansi dan Kepercayaan Klinis (Trust Gap)	31
III.1.2	Risiko Halusinasi dan Inkonsistensi Informasi Medis	31
III.1.3	Tantangan Kompleksitas Data Multidimensi	32
III.1.4	Identifikasi Kesenjangan (Gap Analysis)	32
III.2	Analisis Kebutuhan	33
III.2.1	Identifikasi Masalah Pengguna	34
III.2.2	Kebutuhan Fungsional	34
III.2.3	Kebutuhan Nonfungsional	35
III.3	Analisis Pemilihan Solusi	36
III.3.1	Alternatif Solusi	37
III.3.2	Analisis Penentuan Solusi	39
IV	PERANCANGAN	41
IV.1	Model Konseptual Solusi yang Diusulkan	41
IV.1.1	Alur Kerja Sistem	45
IV.1.2	Arsitektur Sistem	47
IV.2	Perbandingan dengan Sistem Saat Ini	49
V	IMPLEMENTASI	51
V.1	Pemahaman Data (<i>Data Understanding</i>)	51
V.1.1	Profil Dataset	51
V.1.2	Deskripsi Fitur Input	52
V.2	Persiapan Data (<i>Data Preparation</i>)	53
V.2.1	Penanganan <i>Missing Value</i>	53
V.2.2	Konversi Tipe Data	54
V.2.3	Normalisasi Data	54
V.3	Pemodelan (<i>Modeling</i>)	54
V.3.1	Baseline Model	54
V.3.2	Konfigurasi Model Final	55
V.4	Analisis <i>Threshold Moving</i>	55
V.4.1	Hasil Eksperimen dengan <i>Threshold Moving</i>	56
V.4.2	Analisis <i>Trade-off</i> Threshold	56
V.5	Evaluasi dan Validasi Model	57
V.5.1	<i>Cross-Validation</i>	57
V.5.2	Validasi Keaslian Hasil (<i>Fraud Check</i>)	57
V.6	Hasil Explainable AI (XAI) dengan SHAP	58
V.7	Hasil Narasi Medis berbasis RAG dan LLM	58
V.8	Pembahasan	59
V.8.1	Pencapaian Target NFR02	59
V.8.2	Implikasi <i>Trade-off</i> Recall dan Precision	59
V.8.3	Keterbatasan Penelitian	59

VI EVALUASI	61
VI.1 Metode Evaluasi	61
VI.2 Hasil Evaluasi	61
VI.3 Pembahasan Hasil Evaluasi	61
VI.4 Evaluasi Kesalahan Penulisan yang Sering Terjadi	61
VI.4.1 Penggunaan Kata "di mana" atau "dimana"	61
VI.4.2 Penggunaan Kata "sedangkan" dan "sehingga"	61
VI.4.3 Penggunaan Istilah yang Tidak Baku	62
VI.4.4 Pemisah Desimal dan Ribuan	62
VI.4.5 Daftar atau <i>List</i>	62
VI.4.6 Penggunaan Kata "masing-masing" dan "setiap"	63
VII PENUTUP	65
VII.1 Kesimpulan	65
VII.2 Saran	65
Lampiran A <i>SOURCE CODE</i>	75
A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik	75
A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak	76
Lampiran B HASIL SURVEI LAPANGAN	77
B.1 Foto Survei Lokasi 1	77
B.2 Foto Survei Lokasi 2	77
B.3 Transkrip Wawancara dengan Narasumber	77

DAFTAR GAMBAR

II.1	Visualisasi Data Vector Database	18
II.2	Visualisasi Query Vector Database	19
II.3	Rangkaian Proses Implementasi Retrieval-Augmented Generation. .	22
II.4	Taksonomi Metrik Evaluasi dalam <i>framework</i> RAGAS.	23
II.5	Alur Kerja Evaluasi Sistem RAG Menggunakan RAGAS.	24
III.1	Alur Diagnosis Hipertensi di Fasilitas Kesehatan Tingkat Pertama (FKTP) (<i>as-is</i>)	30
IV.1	Desain Konsep Solusi Sistem	42
IV.2	Gambar Alur Kerja Sistem	46
IV.3	Arsitektur Teknis Sistem	48
IV.4	Alur Diagnosis Hipertensi di Fasilitas Kesehatan Tingkat Pertama (FKTP) (<i>To-Be</i>)	50

DAFTAR TABEL

II.1	Studi Sebelumnya	26
III.1	Identifikasi Kesenjangan (Gap Analysis)	33
III.2	Kebutuhan Fungsional	35
III.3	Kebutuhan Non-Fungsional	36
III.4	Pemetaan Masalah dan Dampak	37
III.5	Pemetaan Peluang	38
III.6	Alternatif Solusi	39
III.7	Pemilihan Solusi dengan <i>Weighted Scoring Model</i>	40
V.1	Profil Dataset	52
V.2	Deskripsi Fitur Input Model	53
V.3	Hasil Evaluasi Model Baseline (<i>Threshold</i> = 0,5)	54
V.4	Hasil Eksperimen dengan <i>Threshold Moving</i>	56
V.5	Hasil Pengujian 5-Fold Stratified Cross-Validation	57
VI.1	Contoh penggunaan kata "sedangkan" dan "sehingga"	62

DAFTAR ALGORITMA

DAFTAR *LISTING*

A.1	Binary search code	75
-----	------------------------------	----

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
AI	<i>Artificial Intelligence</i>	1
CNN	<i>Convolutional Neural Network</i>	2
GPU	<i>Graphics Processing Unit</i>	14

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
α	Koefisien bobot untuk <i>loss function</i> , tingkat signifikansi statistik	75
β	Koefisien bobot untuk <i>Binary Cross-Entropy loss</i>	75
λ	Koefisien bobot untuk CTC <i>loss</i> , parameter regularisasi	75
θ	Parameter model <i>neural network</i>	75
σ	Deviasi standar	75
μ	Rata-rata (<i>mean</i>)	75
ϵ	<i>Token blank</i> /kosong dalam CTC, konstanta kecil untuk stabilitas numerik	75
Δ	Delta (selisih/perubahan nilai)	75
π	<i>Alignment path</i> dalam CTC	75
π_t	<i>Token</i> pada <i>timestep</i> t dalam <i>alignment path</i>	76
∇ atau ∂	Operator gradien atau turunan parsial	75
$\sum$	Operator penjumlahan	75
$\prod$	Operator perkalian	75
$\int$	Operator integral	75
argmax	Argumen yang memaksimalkan fungsi	76
$\sim$	Terdistribusi menurut	75
$\rightarrow$	Menuju atau konvergen ke	75
$\mathcal{L}$	Fungsi <i>loss</i> (kerugian)	75
$\mathcal{L}_{total}$	Total <i>loss function</i>	75
$\mathcal{L}_{adversarial}$ atau $\mathcal{L}_{adv}$	<i>Adversarial loss</i>	75
$\mathcal{L}_{reconstruction}$	<i>Reconstruction loss</i>	75
$\mathcal{L}_{L1}$	L1 <i>loss</i> (<i>Mean Absolute Error</i>)	75
$\mathcal{L}_{L2}$	L2 <i>loss</i> (<i>Mean Squared Error</i>)	75
$\mathcal{L}_{CTC}$	CTC (<i>Connectionist Temporal Classification</i>) <i>loss</i>	75
$\mathcal{L}_{perceptual}$	<i>Perceptual loss</i>	75

$\mathcal{L}_{pixel}$	<i>Pixel-wise loss</i>	75
$\mathcal{L}_{BCE}$	<i>Binary Cross-Entropy loss</i>	75
$\mathcal{L}_{GAN}$	<i>GAN loss</i>	75
$\mathcal{L}_{cycle}$	<i>Cycle consistency loss</i>	75
G	<i>Generator dalam GAN</i>	75
D	<i>Discriminator dalam GAN</i>	75
$G(z)$	<i>Output dari generator dengan input z</i>	75
$D(x)$	<i>Output dari discriminator dengan input x</i>	75
$G_{A \rightarrow B}$	<i>Generator dari domain A ke B</i>	75
$G_{B \rightarrow A}$	<i>Generator dari domain B ke A</i>	75
$V(D, G)$	<i>Fungsi nilai (value function) dalam GAN</i>	75
x	<i>Sampel data asli, input citra</i>	75
y	<i>Label atau ground truth, kondisi dalam conditional GAN</i>	75
z	<i>Noise vector atau representasi laten</i>	
$\mathbb{E}$	<i>Ekspektasi atau nilai harapan</i>	75
p_{data}	<i>Distribusi data asli</i>	75
p_z	<i>Distribusi prior (noise)</i>	75
$p(y x)$	<i>Probabilitas bersyarat output y given input x</i>	75
$p_t(\pi_t x)$	<i>Probabilitas token pada timestep t</i>	
$\mathcal{B}$	<i>Fungsi penciutan (collapse function) dalam CTC</i>	75
$\mathcal{B}^{-1}$	<i>Fungsi invers penciutan dalam CTC</i>	75
T	<i>Jumlah timestep atau panjang sequence</i>	
$ x - G(y) _1$	<i>L1 distance antara ground truth dan generated image</i>	75
$ x - G(y) _2$	<i>L2 distance antara ground truth dan generated image</i>	75
$N \times N$	<i>Ukuran patch dalam PatchGAN</i>	
d	<i>Cohen's d (effect size)</i>	75
n	<i>Jumlah sampel</i>	75
p	<i>p-value (nilai probabilitas statistik)</i>	75

r	Koefisien korelasi	75
R^2	Koefisien determinasi	
$O(n)$	Notasi Big-O untuk kompleksitas linear	75
$O(n^2)$	Notasi Big-O untuk kompleksitas kuadratik	75

BAB I

PENDAHULUAN

I.1 Latar Belakang

Hipertensi atau tekanan darah tinggi merupakan masalah kesehatan global yang menjadi faktor risiko utama untuk berbagai penyakit kardiovaskular, termasuk stroke dan gagal jantung (Mills, Stefanescu, dan He 2020). Menurut data Organisasi Kesehatan Dunia, diperkirakan 1,28 miliar orang dewasa di seluruh dunia menderita hipertensi (World Health Organization 2023). Di Indonesia, data Kementerian Kesehatan RI juga mencatat prevalensi yang signifikan (Kementerian Kesehatan Republik Indonesia 2018). Meskipun manajemen hipertensi telah menjadi prioritas, penanganan yang umum terjadi saat ini sering kali bersifat reaktif (Whelton dkk. 2018). Intervensi medis baru dilakukan setelah pasien mengalami gejala atau setelah Tekanan Darah (TD) terdeteksi sangat tinggi, yang berpotensi berujung pada komplikasi akut seperti krisis hipertensi (Kurtz dkk. 2021).

Pendekatan berbasis Machine Learning (ML) menawarkan alternatif yang menjanjikan dalam memprediksi risiko hipertensi. Algoritma ML terkini memiliki kemampuan superior dalam memodelkan hubungan non-linier yang kompleks antara berbagai variabel risiko (Tarimana dkk. 2024). Studi terbaru menunjukkan bahwa model ML mampu mencapai akurasi klasifikasi risiko yang jauh lebih tinggi dibandingkan regresi logistik tradisional. Namun, penerapan model-model ini di ranah klinis menghadapi kendala besar yaitu fenomena black box yang membuat model menghasilkan prediksi tanpa menyertakan alasan yang dapat dipahami manusia.

Dalam konteks medis, hasil prediksi saja tidak cukup. Tenaga medis dan pasien membutuhkan interpretabilitas untuk memahami alasan di balik sebuah prediksi agar dapat mempercayai dan menindaklanjuti hasil tersebut. Kompleksitas algoritma prediksi yang bersifat black box sering kali menjadi penghambat adopsi teknologi ini dalam praktik klinis sehari-hari karena kurangnya transparansi dan kepercayaan dari pengguna (Adadi dan Berrada 2018).

Sebagai solusi atas kendala tersebut, paradigma Explainable Artificial Intelligence atau XAI diterapkan untuk membuka mekanisme internal model sehingga alur pengambilan keputusan dapat ditelusuri kembali secara logis (Adadi dan Berrada 2018). Transparansi ini merupakan elemen fundamental dalam informatika medis yang bertujuan menjamin akuntabilitas keputusan serta memastikan keselamatan pasien tetap menjadi prioritas utama (Holzinger dkk. 2019).

Meskipun metode XAI mampu memberikan transparansi teknis, luaran yang dihasilkan umumnya masih berupa data numerik atau visualisasi fitur yang kompleks bagi pengguna non-teknis. Guna menjembatani kesenjangan pemahaman tersebut, teknologi Large Language Model (LLM) dimanfaatkan dalam penelitian ini untuk mentransformasi hasil interpretasi model menjadi narasi bahasa alami yang personal (Thirunavukarasu dkk. 2023). Akan tetapi, tantangan utama dalam penerapan model bahasa generik pada domain sensitif adalah kecenderungan model untuk menghasilkan fakta atau halusinasi tidak berdasar (Ji dkk. 2023). Sebagai strategi mitigasi yang efektif, arsitektur Retrieval-Augmented Generation (RAG) diterapkan untuk memaksa model melakukan validasi silang terhadap basis pengetahuan eksternal yang terpercaya sebelum menyusun jawaban akhir (Lewis dkk. 2020).

Oleh karena itu, penelitian ini mengusulkan pendekatan baru dengan mengintegrasikan Large Language Model (LLM) berbasis arsitektur Retrieval-Augmented Generation (RAG) ke dalam sistem prediksi hipertensi. LLM akan berfungsi untuk menjembatani penerjemahan luaran yang matematis dari XAI menjadi narasi bahasa alami yang personal dan mudah dipahami. Penggunaan RAG secara spesifik bertujuan untuk memitigasi risiko halusinasi pada LLM dengan membatasi respons model pada referensi pedoman medis yang terverifikasi. Berbeda dari penelitian sebelumnya yang umumnya hanya berfokus pada peningkatan performa prediktif atau penyajian interpretasi teknis, penelitian ini mengusulkan pendekatan terintegrasi yang menggabungkan XAI dan LLM berbasis RAG untuk menghasilkan penjelasan klinis yang tervalidasi secara kontekstual, khususnya dalam konteks prediksi risiko hipertensi.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah:

1. Bagaimana membangun model Machine Learning untuk prediksi risiko hipertensi yang mampu mendapatkan performa klasifikasi yang optimal berdasarkan dataset tabular dengan variabel risiko yang beragam?

2. Bagaimana menerapkan metode Explainable Artificial Intelligence (XAI) untuk membuka mekanisme black box model terpilih guna menghasilkan gambaran fitur yang mempengaruhi prediksi dengan akurat?
3. Bagaimana menerapkan arsitektur Retrieval-Augmented Generation (RAG) pada Large Language Model (LLM) untuk mentransformasi luaran teknis model menjadi penjelasan naratif yang personal dan tervalidasi oleh pedoman medis?
4. Bagaimana mengukur efektivitas keseluruhan sistem yang diusulkan jika dievaluasi berdasarkan gabungan metrik performa prediksi ML, kualitas interpretabilitas XAI, tingkat faktualitas LLM, dan relevansi narasi yang dihasilkan?

I.3 Tujuan

Tujuan utama pelaksanaan Tugas Akhir ini adalah:

1. Membangun dan mengoptimasi model klasifikasi risiko hipertensi menggunakan algoritma ML dengan target metrik evaluasi melampaui 70%.
2. Menerapkan metode Explainable Artificial Intelligence (XAI) untuk menghasilkan atribusi fitur yang transparan dan dapat diinterpretasikan secara klinis.
3. Mengembangkan modul narasi berbasis Large Language Model (LLM) dengan arsitektur RAG yang memanfaatkan hasil XAI untuk memberikan penjelasan personal yang tervalidasi.
4. Mengevaluasi efektivitas kinerja sistem secara komprehensif yang mencakup metrik akurasi model prediksi serta tingkat faktualitas dan koherensi narasi penjelasan yang dihasilkan dibandingkan dengan referensi medis.

I.4 Batasan Masalah

Penelitian ini menetapkan batasan-batasan spesifik untuk menjaga fokus pembahasan dan kelayakan pengerjaan dalam kerangka waktu yang tersedia. Batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian ini menggunakan data sekunder terstruktur dalam bentuk tabular yang diperoleh dari repositori publik terverifikasi atau himpunan data klinis anonim. Variabel yang digunakan terbatas pada fitur demografis, riwayat medis, dan tanda vital klinis yang relevan dengan faktor risiko hipertensi, tanpa melibatkan pemrosesan data citra medis atau sinyal fisiologis mentah.
2. Model prediksi dikembangkan menggunakan pendekatan Supervised Machine Learning dengan fokus pada kasus klasifikasi biner, yaitu membedakan antara kelas risiko hipertensi dan non-hipertensi. Evaluasi model difokuskan pada metrik performa teknis seperti akurasi, presisi, recall, dan F1-score.
3. Implementasi XAI dibatasi pada metode post-hoc model-agnostik, khusus-

nya Shapley Additive Explanations (SHAP) atau Local Interpretable Model-agnostic Explanations (LIME), untuk menghasilkan nilai atribusi fitur. Salah satu dari metode ini dipilih untuk menjelaskan kontribusi setiap variabel terhadap prediksi akhir model tanpa mengubah struktur internal model prediksi itu sendiri.

4. Penelitian ini memanfaatkan LLM yang telah dilatih sebelumnya melalui antarmuka pemrograman aplikasi (API) atau model lokal yang sudah terkuantisasi. Penelitian tidak mencakup proses fine-tuning atau pelatihan ulang model bahasa secara keseluruhan, melainkan berfokus pada teknik prompt engineering dan integrasi konteks eksternal.
5. Sistem RAG menggunakan basis pengetahuan yang bersumber dari dokumen pedoman klinis resmi, seperti panduan dari Kementerian Kesehatan Republik Indonesia, World Health Organization (WHO), atau asosiasi kardiologi internasional yang relevan. Sistem tidak melakukan pencarian informasi secara langsung ke internet terbuka untuk menjamin validitas referensi.
6. Hasil akhir dari pengembangan sistem berupa purwarupa perangkat lunak berbasis web. Sistem berfungsi sebagai alat pendukung keputusan klinis (Clinical Decision Support System) yang memberikan opini kedua, bukan sebagai pengganti diagnosis medis resmi yang dilakukan oleh dokter atau tenaga kesehatan profesional.

I.5 Metodologi

Penelitian ini dilaksanakan dengan mengadopsi kerangka kerja standar CRISP-DM (Cross-Industry Standard Process for Data Mining). Kerangka kerja ini dipilih karena menyediakan struktur yang komprehensif dan iteratif, memastikan keselarasan antara tujuan klinis dengan teknis pengembangan model. Tahapan pelaksanaan penelitian dibagi menjadi enam tahap utama sebagai berikut:

1. Business Understanding

Tahap ini merupakan tahap fondasi yang bertujuan untuk mendefinisikan masalah penelitian secara presisi serta membangun landasan teoretis yang kuat. Pertama-tama, investigasi awal dilakukan secara mendalam untuk mengumpulkan fakta empiris yang mendasari latar belakang masalah. Kegiatan ini mencakup penelusuran data statistik kesehatan global dari World Health Organization dan data nasional dari Kementerian Kesehatan Republik Indonesia guna memvalidasi urgensi hipertensi sebagai komorbiditas utama. Selain itu, dilakukan analisis kesenjangan teknologi untuk mengidentifikasi hambatan adopsi kecerdasan artifisial di ranah klinis, khususnya terkait isu transparansi model dan risiko halusinasi, yang kemudian menjadi dasar perumusan solu-

si. Guna mendapatkan solusi terkini, strategi pencarian literatur dilakukan secara sistematis pada basis data bereputasi seperti IEEE Xplore, PubMed, dan ScienceDirect. Pencarian informasi difokuskan pada pengumpulan teori dan metode state-of-the-art dengan menggunakan kata kunci spesifik pada komponen-komponen utama penelitian, yaitu hipertensi, ML, XAI, LLM, dan RAG. Literatur yang terkumpul kemudian melalui proses sintesis, yang hasilnya didokumentasikan secara rinci dalam Bab II Studi Literatur.

2. Data Understanding

Setelah tujuan penelitian ditetapkan, tahap selanjutnya berfokus pada akuisisi dan eksplorasi dataset. Penelitian ini menggunakan dataset sekunder yang diperoleh dari repositori publik terverifikasi. Setelah dataset sudah diakuisisi, dilakukan eksplorasi awal dan penyesuaian dataset agar dapat digunakan pada tahap pelatihan model. Apabila dataset yang tersedia belum mencukupi kebutuhan desain, maka dilakukan penyesuaian atau pengolahan tambahan.

3. Data Preparation

Tahap persiapan data bertujuan untuk mentransformasi data mentah menjadi format yang siap untuk proses pemodelan. Kegiatan teknis yang dilakukan meliputi pembersihan data (data cleaning) untuk menangani anomali yang ditemukan pada tahap sebelumnya, serta pengkodean fitur kategorikal agar mengubah data non-numerik menjadi format numerik yang dapat dipahami dan digunakan oleh algoritma machine learning. Jika ditemukan ketidakseimbangan kelas (class imbalance) pada label target, teknik penyeimbangan data akan diterapkan. Tahap ini diakhiri dengan pembagian dataset menjadi himpunan latih (training set) dan himpunan uji (test set) untuk digunakan model.

4. Modelling

Tahap ini merupakan inti dari pengembangan teknis yang terdiri dari tiga komponen utama yang saling terintegrasi. Pertama, dilakukan pelatihan menggunakan beberapa algoritma machine learning. Setelahnya, algoritma machine learning dibangun dan dilatih menggunakan dataset yang telah dipersiapkan. Performa setiap model dievaluasi menggunakan metrik ROC-AUC serta sejumlah metrik evaluasi lainnya. Model dengan hasil kinerja paling optimal kemudian dipilih untuk tahap interpretasi lebih lanjut. Kedua, metode XAI diimplementasikan pada model tersebut untuk menghasilkan nilai atribusi fitur yang menjelaskan alasan di balik setiap prediksi. Ketiga, pipeline Retrieval-Augmented Generation dikembangkan untuk menghubungkan luaran SHAP dengan Large Language Model. Sistem ini dikonfigurasi secara khusus agar merujuk pada basis pengetahuan pedoman medis sebelum menyusun narasi

penjelasan, sehingga luaran yang dihasilkan tetap berada dalam koridor medis yang valid.

5. Evaluation

Tahap evaluasi dilakukan untuk mengukur efektivitas sistem secara menyeluruh sebelum tahap penyebaran. Evaluasi kuantitatif dilakukan terhadap model prediksi menggunakan metrik standar klasifikasi seperti akurasi, presisi, recall, F1-score, dan metrik lainnya. Sementara itu, evaluasi kualitatif difokuskan pada hasil interpretasi yang diperoleh dari metode XAI dengan melakukan validasi domain expert guna menilai tingkat kesesuaiannya dengan pengetahuan serta praktik di bidang terkait. Berdasarkan proses evaluasi tersebut, ditetapkan metode interpretasi yang paling relevan dan layak untuk diimplementasikan dalam sistem. Setelah itu penilaian kualitas narasi yang dihasilkan oleh Large Language Model. Aspek yang dinilai mencakup faktualitas medis, koherensi bahasa, dan relevansi terhadap konteks klinis pasien, dengan cara membandingkan luaran sistem terhadap referensi standar untuk memastikan tidak terjadi halusinasi informasi.

6. Deployment

Tahap terakhir dalam penelitian ini adalah pengembangan purwarupa perangkat lunak (software prototype) berbasis web. Model yang telah dilatih dan divalidasi diintegrasikan ke dalam antarmuka aplikasi yang ramah pengguna.

I.6 Sistematika Penulisan

Sistematika penulisan laporan tugas akhir ini memberikan panduan bagi pembaca tentang struktur dan alur pembahasan. Berikut adalah sistematika penulisannya:

1. Bab I Pendahuluan: Berisi latar belakang, rumusan masalah, tujuan, batasan masalah, metodologi, dan sistematika penulisan laporan tugas akhir.
2. Bab II Studi Literatur: Berisi kajian pustaka yang relevan dengan topik tugas akhir, termasuk teori-teori, konsep-konsep, dan hasil-hasil penelitian sebelumnya yang mendukung pelaksanaan tugas akhir.
3. Bab III Analisis: Berisi penjelasan tentang analisis masalah dan kebutuhan pengguna serta berbagai alternatif solusinya.
4. Bab IV Perancangan: Berisi penjelasan tentang perancangan solusi yang diusulkan, misalnya arsitektur sistem, desain basis data, antarmuka pengguna, dan sebagainya.
5. Bab V Implementasi: Berisi penjelasan tentang proses implementasi solusi yang diusulkan, termasuk langkah-langkah yang diambil, teknologi yang digunakan, dan hasil yang diperoleh.
6. Bab VI Evaluasi: Berisi analisis dan evaluasi terhadap solusi yang diimple-

mentasikan, termasuk metode pengujian, hal-hal yang disiapkan sebelum pengujian, hasil pengujian, dan penilaian kinerja.

7. Bab VII Kesimpulan dan Saran: Berisi kesimpulan dari hasil pelaksanaan tugas akhir dan saran untuk pengembangan lebih lanjut.
8. Daftar Pustaka: Berisi daftar referensi yang digunakan dalam penyusunan laporan tugas akhir.
9. Lampiran: Berisi dokumen-dokumen pendukung seperti kode program, data lengkap hasil pengujian, rekaman wawancara, dan lain-lain.

BAB II

STUDI LITERATUR

II.1 Hipertensi

Hipertensi secara global didefinisikan sebagai suatu kondisi hemodinamik kronis yang ditandai dengan meningkatnya tekanan darah di arteri secara persisten. Menurut konsensus medis internasional terbaru, hipertensi bukan sekadar angka tekanan darah yang tinggi, melainkan sindrom kardiovaskular progresif yang memicu perubahan struktural dan fungsional pada pembuluh darah serta organ vital (Reges dkk. 2020). Dalam konteks fisiologis, kondisi ini terjadi ketika tekanan darah sistolik (TDS) berada pada nilai 140 mmHg atau lebih, dan/atau tekanan darah diastolik (TDD) berada pada nilai 90 mmHg atau lebih, setelah dilakukan pengukuran berulang di klinik (Reges dkk. 2020).

Penyakit ini sering disebut sebagai *the silent killer* karena sebagian besar penderita tidak menunjukkan gejala klinis yang spesifik hingga terjadi kerusakan organ target atau *Target Organ Damage* (TOD) seperti hipertrofi ventrikel kiri, gagal ginjal kronis, atau retinopati (Mills, Stefanescu, dan He 2020). Prevalensi hipertensi terus meningkat secara global, didorong oleh penuaan populasi dan pergeseran gaya hidup, di mana data terbaru menunjukkan bahwa lebih dari 1,28 miliar orang dewasa berusia 30–79 tahun di seluruh dunia hidup dengan hipertensi, dengan dua pertiga di antaranya tinggal di negara berpenghasilan rendah dan menengah (Organization 2023).

Di Indonesia, hipertensi masih menjadi tantangan kesehatan utama dengan tingkat pengendalian yang rendah. Studi epidemiologi terbaru menunjukkan bahwa prevalensi hipertensi di Indonesia tidak hanya didominasi oleh lansia, tetapi mulai merambah ke populasi usia produktif akibat transisi nutrisi dan penurunan aktivitas fisik (Manongga, Nelwan, dan Kaunang October 2024). Patofisiologi hipertensi melibatkan interaksi kompleks antara curah jantung dan resistensi vaskular perifer, yang diatur oleh sistem saraf simpatis, sistem renin-angiotensin-aldosteron (RAAS), dan keseimbangan cairan tubuh. Ketidakseimbangan pada salah satu mekanisme ini

dapat memicu vasokonstriksi berkepanjangan yang berujung pada elevasi tekanan darah sistemik.

II.1.1 Klasifikasi Hipertensi

Klasifikasi tekanan darah merupakan pedoman klinis fundamental yang digunakan untuk menentukan stratifikasi risiko dan strategi intervensi medis. Meskipun terdapat beberapa pedoman internasional, klasifikasi yang paling banyak diadopsi dalam literatur terkini merujuk pada pedoman International Society of Hypertension (ISH) 2020 dan European Society of Hypertension (ESH) 2023 yang berupaya menyederhanakan kategorisasi untuk kemudahan praktik klinis.

Perbedaan mendasar dalam klasifikasi modern dibandingkan pedoman lama, seperti JNC 7, adalah penekanan pada kategori "Normal-Tinggi" atau pre-hipertensi sebagai sinyal peringatan dini. Klasifikasi ini penting dalam pengembangan model prediksi berbasis kecerdasan buatan karena memungkinkan algoritma untuk mendeteksi pergeseran pola data pasien dari fase normal menuju fase patologis sebelum diagnosis klinis tegak. Berdasarkan panduan European Society of Cardiology (ESC) dan European Society of Hypertension (ESH) pada tahun 2018, klasifikasi hipertensi dibagi menjadi beberapa kategori sebagai berikut:

1. Normal

Tekanan darah sistolik < 130 mmHg dan diastolik < 85 mmHg dianggap sebagai kondisi ideal dengan risiko kejadian kardiovaskular terendah.

2. High-Normal

Rentang sistolik 130–139 mmHg dan/atau diastolik 85–89 mmHg. Kategori ini memerlukan pemantauan ketat karena individu dalam kelompok ini memiliki probabilitas tinggi untuk berkembang menjadi hipertensi menetap jika tidak dilakukan modifikasi gaya hidup.

3. Hipertensi Derajat 1

Ditandai dengan sistolik 140–159 mmHg dan/atau diastolik 90–99 mmHg. Pada tahap ini, intervensi farmakologis sering kali mulai dipertimbangkan bersamaan dengan perubahan gaya hidup, tergantung pada profil risiko kardiovaskular total pasien.

4. Hipertensi Derajat 2

Tekanan sistolik ≥ 160 mmHg dan/atau diastolik ≥ 100 mmHg. Kondisi ini memerlukan penanganan segera untuk mencegah kejadian akut seperti stroke atau serangan jantung.

Selain klasifikasi berbasis derajat, hipertensi juga diklasifikasikan berdasarkan etiologinya menjadi hipertensi primer (esensial) dan hipertensi sekunder. Hipertensi

primer mencakup 90-95% dari seluruh kasus dan tidak memiliki penyebab tunggal yang dapat diidentifikasi, melainkan hasil dari interaksi multifaktorial genetik dan lingkungan. Sementara itu, hipertensi sekunder disebabkan oleh kondisi medis yang mendasarinya, seperti penyakit parenkim ginjal, gangguan endokrin, atau penggunaan obat-obatan tertentu.

II.1.2 Faktor Risiko

Faktor risiko hipertensi dibagi menjadi dua klaster utama, yaitu faktor risiko yang tidak dapat dimodifikasi (*non-modifiable risk factors*) dan faktor risiko yang dapat dimodifikasi (*modifiable risk factors*). Identifikasi faktor-faktor ini krusial karena interaksi antar variabel tersebutlah yang akan dianalisis oleh model komputasi untuk menghasilkan prediksi yang akurat.

II.1.2.1 Faktor Risiko Tidak Dapat Dimodifikasi

1. Usia

Penuaan adalah determinan paling kuat terhadap peningkatan tekanan darah. Seiring bertambahnya usia, terjadi kekakuan arteri (*arterial stiffness*) akibat hilangnya serat elastin dan penumpukan kolagen pada dinding pembuluh darah, yang secara langsung meningkatkan tekanan sistolik.

2. Jenis Kelamin

Studi menunjukkan bahwa pria memiliki prevalensi hipertensi yang lebih tinggi dibandingkan wanita pada usia muda hingga paruh baya. Namun, setelah masa menopause, risiko pada wanita meningkat tajam dan sering kali melampaui pria akibat penurunan efek protektif hormon estrogen terhadap vaskular.

3. Genetik dan Riwayat Keluarga

Variasi genetik berkontribusi sekitar 30–60% terhadap variabilitas tekanan darah populasi. Individu dengan riwayat keluarga hipertensi memiliki risiko dua kali lipat lebih besar untuk mengembangkan kondisi serupa, yang dimediasi oleh pewarisan polimorfisme gen yang mengatur sistem RAAS.

II.1.2.2 Faktor Risiko Dapat Dimodifikasi

1. Obesitas dan Indeks Massa Tubuh (IMT)

Terdapat korelasi linier yang kuat antara berat badan dan tekanan darah. Jaringan adiposa yang berlebih, terutama lemak visceral, memproduksi sitokin pro-inflamasi dan mengaktifasi sistem saraf simpatis yang memicu retensi natrium ginjal dan hipertensi.

2. Asupan Garam (Natrium)

Konsumsi natrium yang berlebihan adalah penyebab utama hipertensi sensitif-

garam. Mekanisme ini melibatkan peningkatan volume cairan ekstraseluler dan disfungsi endotel. Penelitian terbaru menegaskan bahwa pengurangan asupan garam harian secara signifikan menurunkan tekanan darah pada populasi hipertensi maupun normotensi.

3. **Kurangnya Aktivitas Fisik**

Gaya hidup sedentari melemahkan kebugaran kardiorespirasi dan resistensi insulin. Latihan fisik teratur terbukti dapat menurunkan resistensi vaskular sistemik melalui perbaikan fungsi endotel dan penurunan aktivitas simpatis.

4. **Merokok**

Zat kimia dalam rokok, terutama nikotin, memicu pelepasan katekolamin yang menyebabkan vasokonstriksi akut dan peningkatan denyut jantung. Paparan kronis merusak lapisan endotel pembuluh darah dan mempercepat proses aterosklerosis yang memperburuk hipertensi.

5. **Dislipidemia**

Kadar kolesterol abnormal, khususnya peningkatan LDL dan trigliserida, berkontribusi pada pembentukan plak aterosklerosis. Plak ini mempersempit lumen pembuluh darah dan meningkatkan rigiditas dinding arteri, yang secara mekanis meningkatkan tekanan darah.

6. **Faktor Psikososial dan Stres**

Stres kronis memicu respons neurohormonal jangka panjang melalui aksis hipotalamus-hipofisis-adrenal, yang menghasilkan kortisol berlebih. Kondisi ini berhubungan erat dengan peningkatan tekanan darah yang menetap dan risiko kejadian kardiovaskular.

II.2 Machine Learning

Klasifikasi pada data medis merupakan tugas pembelajaran mesin terawasi atau Supervised Machine Learning yang bertujuan memetakan variabel input ke dalam label kategori diskrit. Dalam konteks prediksi hipertensi, model dilatih untuk memisahkan data pasien ke dalam kelas risiko positif atau negatif berdasarkan pola historis yang terdapat pada dataset pelatihan (Sarkar dkk. 2020). Akurasi dan keandalan model klasifikasi sangat bergantung pada pemilihan algoritma yang mampu menangani karakteristik data tabular yang sering kali memiliki distribusi tidak seimbang.

II.2.1 Gradient Boosting

Gradient Boosting adalah teknik machine learning berbasis *ensemble* yang dikembangkan untuk meningkatkan akurasi prediksi dengan cara menggabungkan sejumlah model prediksi sederhana (*weak learners*) umumnya berupa *decision trees* menjadi satu model prediksi yang kuat dan komprehensif. Prinsip dasar dari algoritma

ini adalah pembentukan model secara bertahap (*stage-wise*), di mana setiap model baru yang ditambahkan bertujuan untuk memperbaiki kesalahan (*residual errors*) yang dihasilkan oleh gabungan model-model sebelumnya (Guo dan Zhang 2024).

Dalam konteks pengembangan sistem prediksi risiko penyakit seperti hipertensi, Gradient Boosting memiliki keunggulan signifikan dibandingkan metode statistik konvensional. Algoritma ini mampu menangani hubungan non-linear yang kompleks antar variabel klinis pasien, seperti interaksi antara indeks massa tubuh (BMI), tekanan darah sistolik, dan riwayat genetik, yang seringkali sulit dimodelkan oleh Logistic Regression (Muftisany 2024). Proses matematis Gradient Boosting melibatkan optimasi fungsi kerugian (*loss function*) yang dapat disesuaikan, memungkinkannya untuk meminimalkan bias prediksi secara iteratif pada data rekam medis yang seringkali memiliki tingkat *noise* atau variabilitas tinggi.

Penerapan Gradient Boosting dalam studi epidemiologi modern menunjukkan performa yang konsisten dalam klasifikasi risiko kesehatan. Sebuah studi terbaru pada populasi pasien di Indonesia menunjukkan bahwa model berbasis *boosting* mampu mencapai akurasi diagnostik dan nilai *Area Under Curve* (AUC) yang lebih tinggi dibandingkan algoritma tunggal lainnya dalam mendeteksi hipertensi dini (Wibawa, Purnomo, dan Santoso 2025). Selain akurasi, arsitektur Gradient Boosting juga sangat kompatibel dengan metode Explainable Artificial Intelligence (XAI) seperti SHAP (SHapley Additive exPlanations). Hal ini memungkinkan sistem untuk tidak hanya memprediksi probabilitas hipertensi, tetapi juga memberikan transparansi mengenai fitur klinis mana yang paling berkontribusi terhadap diagnosis tersebut, yang merupakan elemen krusial untuk kepercayaan klinis (Li, Chen, dan Park 2025).

Secara umum, jika diberikan fungsi tujuan untuk meminimalkan kesalahan prediksi pada data latih $S = \{(x_i, y_i)\}_{i=1}^n$, Gradient Boosting akan memperbarui model $\mathcal{F}(x)$ pada setiap iterasi ke- m dengan menambahkan estimator baru $h_m(x)$ sebagai berikut:

$$\mathcal{F}_m(x) = \mathcal{F}_{m-1}(x) + \nu \cdot h_m(x) \quad (\text{II.1})$$

Di mana ν adalah *learning rate* yang mengontrol kontribusi setiap pohon untuk mencegah *overfitting*, sebuah mekanisme regularisasi yang sangat penting saat bekerja dengan dataset kesehatan yang terbatas atau tidak seimbang (Zhang, Wang, dan Liu 2025).

II.2.2 Extreme Gradient Boosting (XGBoost)

Extreme Gradient Boosting atau XGBoost adalah pengembangan tingkat lanjut dari algoritma Gradient Boosting Machine (GBM) yang dirancang untuk memiliki efisiensi komputasi tinggi, skalabilitas, dan kinerja prediksi yang lebih akurat dibandingkan pendahulunya. XGBoost bekerja dengan prinsip *ensemble learning*, di mana algoritma ini menggabungkan hasil dari banyak model prediksi lemah (*weak learners*) biasanya berupa *decision trees* secara berurutan untuk membentuk satu model prediksi yang kuat dan stabil (Emmanuel dan Ok 2025).

Dalam konteks pengembangan sistem prediksi risiko kesehatan seperti hipertensi, XGBoost memiliki keunggulan signifikan dibandingkan metode tradisional. Algoritma ini dilengkapi dengan mekanisme *regularization* (L1 dan L2) yang terintegrasi di dalam fungsi objektifnya. Fitur ini berfungsi untuk mengontrol kompleksitas model dan mencegah terjadinya *overfitting*, yaitu kondisi saat model terlalu menghafal data latih namun gagal memprediksi data baru dengan akurat, yang sering menjadi masalah utama dalam analisis data medis yang memiliki *noise* tinggi (Guo dan Zhang 2024).

Secara matematis, jika diberikan sekumpulan data dengan fitur m dan jumlah sampel n , XGBoost meminimalkan fungsi objektif yang terdiri dari fungsi *loss* dan penalti regularisasi. Berbeda dengan Gradient Boosting standar yang hanya mengoptimalkan *loss function*, fungsi objektif pada XGBoost ($\mathcal{L}$) dapat didefinisikan sebagai berikut:

$$\mathcal{L}(\phi) = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k) \quad (\text{II.2})$$

Di mana l adalah fungsi *loss* yang mengukur perbedaan antara prediksi ($\hat{y}_i$) dan nilai aktual (y_i), sedangkan Ω adalah komponen regularisasi yang mengontrol kompleksitas *tree* (pohon keputusan) untuk mencegah *overfitting*. Komponen regularisasi ini dihitung dengan rumus:

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda ||w||^2 \quad (\text{II.3})$$

Parameter γ (gamma) dan λ (lambda) dalam persamaan di atas berperan penting dalam proses *pruning* atau pemangkasan pohon keputusan, yang menjadikan XGBoost sangat *robust* terhadap data yang tidak seimbang (*imbalanced data*) yang sering di-

temukan dalam dataset pasien hipertensi (Emmanuel dan Ok 2025).

Relevansi XGBoost dalam penelitian hipertensi telah dibuktikan dalam berbagai studi terbaru. Penelitian yang dilakukan oleh Zhang et al. (Zhang, Wang, dan Liu 2025) menunjukkan bahwa XGBoost mampu memberikan performa stratifikasi risiko hipertensi yang lebih unggul dibandingkan Logistic Regression tradisional, dengan nilai akurasi dan *Area Under Curve* (AUC) yang lebih tinggi secara konsisten. Selain itu, XGBoost juga mendukung integrasi dengan metode Explainable Artificial Intelligence (XAI) seperti SHAP (SHapley Additive exPlanations), yang memungkinkan peneliti untuk tidak hanya mendapatkan hasil prediksi, tetapi juga memahami faktor risiko dominan seperti usia, BMI, atau tekanan darah sistolik, yang berkontribusi terhadap keputusan model tersebut (Li, Chen, dan Park 2025).

II.3 Artificial Intelligence

Artificial Intelligence (AI) atau kecerdasan buatan merujuk pada simulasi proses kecerdasan manusia oleh sistem mesin, terutama sistem komputer. Proses ini mencakup pembelajaran (*learning*) yaitu perolehan informasi dan aturan untuk menggunakan informasi tersebut, penalaran (*reasoning*) yaitu penggunaan aturan untuk mencapai kesimpulan perkiraan atau pasti, dan koreksi diri (*self-correction*) (Dav-
enport dan Kalakota 2019).

Dalam konteks revolusi industri 4.0, teknologi AI telah menjadi pilar utama yang memungkinkan transformasi operasional melalui otomatisasi cerdas dan pengambilan keputusan berbasis data (Javaid dkk. 2022). Adopsi AI di berbagai sektor, termasuk kesehatan, telah terbukti mampu mengoptimalkan alur kerja, meminimalkan kesalahan manusia, dan meningkatkan efisiensi operasional secara signifikan. Kemampuan sistem untuk mempelajari pola dari data historis memungkinkan organisasi untuk memprediksi tren masa depan dengan akurasi yang lebih tinggi dibandingkan metode konvensional (Secinaro dkk. 2021). Secara spesifik, integrasi AI dalam sistem pemrosesan data memungkinkan reduksi *lead time*, peningkatan fleksibilitas sistem, serta optimalisasi alokasi sumber daya yang tersedia (Haleem dkk. 2022).

II.3.1 Explainable Artificial Intelligence (XAI)

Penerapan Machine Learning dalam praktik klinis sering terhambat oleh sifat *black box* dari model canggih seperti XGBoost yang sulit diinterpretasikan oleh manusia. Explainable Artificial Intelligence atau XAI hadir sebagai solusi untuk memberikan transparansi terhadap keputusan yang diambil oleh sistem cerdas (Adadi dan Berrada 2018). Transparansi ini krusial untuk membangun kepercayaan tenaga medis terhadap saran diagnosis yang diberikan oleh algoritma.

II.3.1.1 Shapley Additive Explanations (SHAP)

Metode SHAP merupakan pendekatan XAI yang mengadopsi konsep teori permainan kooperatif untuk menghitung kontribusi marginal setiap fitur terhadap hasil prediksi. Nilai Shapley menjamin konsistensi matematis dengan memastikan bahwa total kontribusi seluruh fitur sama dengan selisih antara prediksi aktual dan prediksi rata-rata model (Lundberg dan Lee 2017). Sifat aditif ini menjadikan SHAP sangat andal untuk audit medis karena memberikan penjelasan yang adil dan konsisten untuk setiap variabel risiko pasien.

II.3.1.2 Local Interpretable Model-agnostic Explanations (LIME)

Metode alternatif yang sering digunakan adalah Local Interpretable Model-agnostic Explanations atau LIME. LIME bekerja dengan cara melakukan perturbasi atau pengubahan acak di sekitar data *instance* untuk membangun model linear sederhana yang dapat dijelaskan secara lokal. Pendekatan ini berfokus pada pendekatan perilaku model di sekitar satu titik prediksi spesifik tanpa mencoba memahami model global secara keseluruhan.

II.3.1.3 Analisis Komparatif SHAP dan LIME

Meskipun LIME lebih cepat secara komputasi, metode ini memiliki kelemahan dalam hal stabilitas karena penjelasan yang dihasilkan dapat berubah-ubah pada setiap iterasi eksekusi untuk data yang sama (Molnar 2020). Sebaliknya, SHAP menawarkan landasan teoretis yang lebih kuat melalui properti aksiomatik teori permainan yang menjamin keunikan solusi penjelasan. Oleh karena itu, penelitian ini memilih menggunakan SHAP karena stabilitas dan konsistensi penjelasan merupakan syarat mutlak dalam sistem pendukung keputusan medis yang menyangkut keselamatan pasien.

II.4 Large Language Model (LLM)

Large Language Model (LLM) merupakan evolusi mutakhir dalam domain Artificial Intelligence, khususnya dalam pemrosesan bahasa alami. LLM adalah model probabilitas yang dirancang untuk memahami, memproses, dan menghasilkan teks dengan tingkat koherensi yang menyerupai kemampuan manusia (Zhao dkk. 2023).

Arsitektur dasar dari teknologi ini mengandalkan teknik Deep Learning dan model statistik canggih untuk menganalisis korpus data teks dalam skala masif. Melalui pelatihan pada dataset berskala besar, model ini mampu mengidentifikasi pola linguistik yang kompleks, hubungan semantik antar kata, serta nuansa kontekstual yang terkandung dalam bahasa (Kasneci dkk. 2023).

Dalam ranah *Generative AI*, kemampuan LLM tidak terbatas pada pemahaman teks semata, melainkan juga mencakup kemampuan untuk menciptakan konten orisinal yang mengadopsi gaya dan karakteristik data pelatihannya. Salah satu implementasi paling dominan dari teknologi ini adalah ChatGPT, sebuah model generatif yang dioptimalkan untuk dialog interaktif (OpenAI 2023).

Model-model ini dilatih menggunakan pendekatan *Unsupervised Learning* atau *Self-Supervised Learning*, yang memungkinkan mereka mempelajari struktur bahasa tanpa memerlukan pelabelan data manual secara ekstensif (Brown dkk. 2020). Fundamental teknologi di balik LLM adalah arsitektur Transformer, yang memperkenalkan mekanisme *attention* untuk menangani ketergantungan jarak jauh dalam urutan data. Hal ini memungkinkan model untuk mempertahankan konteks pembicaraan atau dokumen yang panjang, menjadikannya sangat efektif untuk aplikasi seperti penerjemahan otomatis, *chatbot* cerdas, dan pembuatan ringkasan teks otomatis (Vaswani dkk. 2017; Naveed dkk. 2023).

II.4.1 Vector Database

Dalam ekosistem pengembangan aplikasi berbasis AI modern, Vector Database memegang peranan vital sebagai infrastruktur penyimpanan data. Berbeda dengan basis data relasional tradisional yang menyimpan data dalam baris dan kolom, Vector Database dirancang khusus untuk menyimpan, mengelola, dan mengindeks data dalam format vektor berdimensi tinggi (Pan dkk. 2023). Vektor ini, atau yang sering disebut sebagai *embeddings*, merupakan representasi matematis dari data tidak terstruktur seperti teks, gambar, audio, atau video.

Keunggulan utama dari jenis basis data ini terletak pada kemampuannya melakukan pencarian semantik (*semantic search*) berdasarkan kemiripan vektor, bukan sekadar pencocokan kata kunci (Wang, Li, dan Zhang 2024). Untuk menangani beban kerja komputasi yang berat dan memastikan skalabilitas, arsitektur Vector Database menerapkan beberapa mekanisme optimasi sistem:

1. **Sharding**

Teknik partisi horizontal yang mendistribusikan dataset vektor ke berbagai mesin atau *node* dalam sebuah kluster. Distribusi ini seringkali didasarkan pada fungsi *hash* atau rentang kunci tertentu untuk menyeimbangkan beban penyimpanan (Xu, Zhou, dan Li 2022).

2. **Partitioning**

Strategi pembagian basis data menjadi segmen-segmen logis yang lebih kecil dan mudah dikelola. Kriteria partisi dapat disesuaikan berdasarkan kategori

data, lokasi geografis, atau frekuensi akses data (Han, Liu, dan Zhang 2023).


3. Caching

Implementasi memori RAM perantara berkecepatan tinggi untuk menyimpan data atau hasil kueri yang sering diakses. Mekanisme ini krusial untuk mengurangi latensi sistem dan meningkatkan *throughput* pengambilan data (Zhang, Chen, dan Liu 2021).

4. Replication

Proses duplikasi data vektor ke beberapa *node* atau kluster berbeda. Replikasi menjamin ketersediaan data (*availability*) yang tinggi, durabilitas data terhadap kegagalan perangkat keras, serta peningkatan kinerja pembacaan data secara paralel (Kleppmann 2021).

Pencarian dalam Vector Database umumnya menggunakan algoritma *Nearest Neighbor Search* (NNS) atau *Approximate Nearest Neighbor Search* (ANNS) untuk menemukan vektor yang memiliki jarak terdekat (paling mirip) dengan vektor kueri.



Gambar II.1 Visualisasi Data Vector Database

Mekanisme kerja Vector Database dapat diuraikan melalui tahapan berikut:

1. Penyimpanan Data dan Embedding


Sebelum disimpan, data mentah (objek) dikonversi menjadi format numerik (vektor) melalui proses *embedding*. Setiap vektor merepresentasikan fitur-fitur dari objek tersebut dalam ruang multidimensi (Reimers dan Gurevych 2019).

2. Indexing

Setelah vektor tersimpan, sistem melakukan pengindeksan untuk memetakan lokasi data. Pengindeksan dapat dilakukan secara manual atau otomatis (*on-the-fly*). Tujuan utama pengindeksan adalah mengorganisir struktur data sedemikian rupa sehingga proses pencarian dapat dilakukan dengan kompleksitas waktu yang minimal (Johnson, Douze, dan Jégou 2019).

3. Query dan Analisis

Saat pengguna memasukkan kueri (misalnya dalam bentuk teks), sistem pertama-tama mengubah kueri tersebut menjadi vektor menggunakan model *embedding* yang sama. Selanjutnya, sistem melakukan pencarian komparatif untuk menemukan vektor dalam basis data yang memiliki nilai kemiripan tertinggi dengan vektor kueri (Wang, Wang, dan Liu 2021).



Gambar II.2 Visualisasi Query Vector Database

Peran Vector Database menjadi sangat strategis dalam implementasi *Generative AI*, khususnya untuk mendukung metode Retrieval-Augmented Generation (RAG). Dengan menyediakan akses cepat ke basis pengetahuan eksternal yang relevan, Vector Database membantu model bahasa menghasilkan respons yang lebih akurat dan terkontekstualisasi, mengurangi risiko halusinasi model (Lewis dkk. 2020).

II.4.2 Keterbatasan LLM

Penerapan LLM di bidang medis menghadapi tantangan serius terkait fenomena halusinasi, yaitu kondisi saat model menghasilkan informasi yang terdengar meyakinkan namun faktanya salah atau dibuat-buat (Ji dkk. 2023). Selain itu, LLM memiliki batasan pengetahuan statis atau *knowledge cutoff* yang membuatnya tidak mengetahui informasi atau pedoman medis terbaru yang rilis setelah tanggal pelatihan

model.

II.4.3 Mengatasi Keterbatasan LLM

Berbagai strategi dikembangkan untuk memitigasi keterbatasan tersebut. Salah satu pendekatan adalah *fine-tuning* yang melatih ulang model dengan dataset spesifik, namun metode ini membutuhkan sumber daya komputasi yang besar dan data berkualitas tinggi. Pendekatan alternatif yang lebih efisien adalah *In-Context Learning* melalui *prompt engineering* yang menyertakan informasi relevan langsung di dalam instruksi input.

II.5 Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) adalah kerangka kerja arsitektur yang dirancang untuk meningkatkan kapabilitas Large Language Model (LLM) dengan mengintegrasikan sistem temu kembali informasi (*information retrieval*) eksternal. Metode ini mengatasi keterbatasan pengetahuan statis yang dimiliki oleh LLM pasca-pelatihan dengan memungkinkan model mengakses data terkini atau data spesifik domain yang tersimpan dalam basis data eksternal (Gao dkk. 2023). Pendekatan ini secara efektif memitigasi isu "halusinasi" pada AI, di mana model menghasilkan informasi yang tampak meyakinkan namun faktualnya salah (Ji dkk. 2023).

Secara operasional, RAG bekerja melalui tiga fase utama yang saling terintegrasi:

1. Retrieval

Tahap ini merupakan fondasi dari RAG, di mana sistem mencari dan mengambil informasi yang relevan dari basis pengetahuan eksternal berdasarkan *prompt* atau pertanyaan pengguna. Proses ini seringkali memanfaatkan Vector Database. Kueri pengguna dikonversi menjadi representasi vektor, yang kemudian digunakan untuk memindai basis data guna menemukan dokumen atau potongan informasi (*chunks*) yang memiliki kesamaan semantik tertinggi. Hasil dari proses ini adalah kumpulan konteks yang relevan dengan pertanyaan pengguna (Karpukhin dkk. 2020).

2. Augmentation

Setelah informasi relevan berhasil diambil, tahap selanjutnya adalah memperkaya (*augment*) *prompt* asli pengguna dengan informasi tersebut. Sistem akan menyusun *prompt* baru yang menggabungkan pertanyaan asli pengguna dengan data yang ditemukan dari tahap *retrieval*. Proses ini dapat melibatkan restrukturisasi kalimat atau penambahan instruksi khusus agar LLM dapat memproses konteks tambahan tersebut secara efektif. Tujuannya adalah menyediakan "konteks" yang lengkap bagi model sebelum model mulai

menyusun jawaban (Lewis dkk. 2020).

3. **Generation**

Pada tahap akhir ini, *prompt* yang telah diaugmentasi dikirimkan ke LLM. Model kemudian memproses input gabungan tersebut untuk menghasilkan respons teks yang koheren. Karena model memiliki akses ke fakta-fakta spesifik yang disediakan dalam *prompt*, jawaban yang dihasilkan cenderung lebih akurat, faktual, dan relevan dengan konteks pertanyaan, dibandingkan jika model hanya mengandalkan parameter internalnya sendiri (Shuster dkk. 2021).

II.5.1 Kapabilitas RAG

Salah satu kapabilitas utama RAG adalah kemampuannya dalam memitigasi masalah halusinasi, yaitu kecenderungan LLM untuk menghasilkan respons yang fasih secara bahasa namun tidak tepat secara fakta (Wu dkk. 2024). Melalui penyediaan informasi faktual yang relevan dari hasil penelusuran basis data eksternal, RAG dapat memverifikasi dan melandasi respons yang dihasilkan oleh model (Wu dkk. 2024).

Selain akurasi, RAG menawarkan mekanisme yang efisien untuk menangani isu pembaruan pengetahuan yang menjadi tantangan besar bagi model bahasa parametrik. Pada model tradisional, memperbarui pengetahuan yang tersimpan dalam memori internal memerlukan proses pelatihan ulang atau *fine-tuning* dengan data baru yang merupakan proses mahal dan lambat. Sebaliknya, RAG mengatasi masalah ini cukup dengan memperbarui basis data pengetahuan eksternal, sehingga model dapat langsung mengakses informasi terkini tanpa perlu modifikasi parameter model yang ekstensif (Wu dkk. 2024).

RAG juga memiliki keunggulan dalam menyediakan keahlian domain spesifik yang sering kali tidak dimiliki oleh LLM umum. Pelatihan LLM khusus domain biasanya membutuhkan tenaga kerja yang besar untuk pengumpulan dataset, namun RAG memungkinkan konversi LLM umum menjadi spesialis domain hanya dengan membangun dan memanfaatkan basis data pengetahuan yang relevan dengan bidang tersebut (Wu dkk. 2024).


II.5.2 Limitasi Teknis RAG

Meskipun RAG menawarkan solusi signifikan untuk meningkatkan akurasi LLM, terdapat beberapa limitasi teknis yang perlu diperhatikan dalam implementasinya:

1. Ketidaksinkronan antara proses *Retrieval* dan *Generation* dapat terjadi karena keduanya merupakan proses terpisah, yang berpotensi menyebabkan masuknya informasi yang tidak relevan ke dalam konteks (Gao dkk. 2023).

2. Proses *retrieval* yang dijalankan secara independen untuk setiap kueri terkadang mengabaikan konteks percakapan sebelumnya (*history*), yang dapat mengurangi relevansi jawaban dalam sesi dialog panjang.
3. Sifat statis dari hasil *retrieval* dalam satu putaran interaksi berarti jika informasi yang diambil kurang tepat, sistem sulit untuk melakukan koreksi otomatis tanpa intervensi kueri baru (Gao dkk. 2023).

Proses Retrieval-Augmented Generation secara umum dapat digambarkan melalui diagram sebagai berikut:



Gambar II.3 Rangkaian Proses Implementasi Retrieval-Augmented Generation.

II.5.3 RAG Dalam Domain Medis

Penerapan RAG di bidang kesehatan (*Medical RAG*) bertujuan mengatasi keterbatasan LLM dalam menghasilkan informasi medis yang akurat dan konsisten secara faktual (Amugongo dkk. 2025). Tinjauan sistematis terbaru menunjukkan bahwa RAG secara signifikan mengurangi risiko halusinasi dengan membatasi respons model hanya pada dokumen klinis atau pedoman medis terpercaya yang tersedia di basis data (Liu, McCoy, dan Wright 2025). Mekanisme ini memastikan bahwa saran yang dihasilkan sistem memiliki landasan bukti (*evidence-grounded*) yang dapat diverifikasi demi keselamatan pasien.

Tantangan utama dalam implementasi *Medical RAG* meliputi adanya "kebisingan pencarian" dan kompleksitas terminologi medis yang sangat bervariasi (Liu, McCoy, dan Wright 2025). Sistem RAG medis yang efektif sering menggunakan strategi pencarian hibrida, menggabungkan pencarian kata kunci untuk istilah spesifik dan pencarian semantik untuk memahami konteks gejala (Amugongo dkk. 2025).


II.5.4 Retrieval Augmented Generation Assessment (RAGAS)

Evaluasi terhadap model Large Language Model (LLM) yang terintegrasi dalam arsitektur Retrieval-Augmented Generation (RAG) menghadirkan tantangan tersendiri karena metrik tradisional seperti BLEU atau ROUGE tidak lagi memadai untuk

mengukur koherensi semantik dan akurasi faktual (Gao dkk. 2023). Dalam konteks sistem prediksi risiko hipertensi, kesalahan halusinasi atau ketidaktepatan pengambilan konteks medis dapat berakibat fatal sehingga diperlukan kerangka evaluasi yang lebih ketat (Liu dkk. 2024).

Retrieval Augmented Generation Assessment atau RAGAS muncul sebagai kerangka kerja evaluasi standar yang dirancang untuk mengukur kinerja saluran RAG secara referensi-bebas atau *reference-free* dengan memanfaatkan LLM sebagai juri penilai (Es dkk. 2023). Pendekatan RAGAS memisahkan proses evaluasi menjadi dua komponen utama yaitu evaluasi terhadap kemampuan pencarian informasi atau *retrieval* dan evaluasi terhadap kualitas teks yang dibangkitkan atau *generation* (Chen dkk. 2024).

Kerangka kerja RAGAS menyediakan berbagai metrik yang dikategorikan berdasarkan fokus evaluasinya yang terbagi menjadi metrik berbasis komponen (*component-wise*) dan metrik ujung-ke-ujung (*end-to-end*).



Gambar II.4 Taksonomi Metrik Evaluasi dalam *framework* RAGAS.

Berdasarkan taksonomi di atas, metrik *Faithfulness* dan *Answer Relevancy* digunakan untuk menilai kualitas generasi teks sedangkan *Context Precision* dan *Context Recall* digunakan untuk menilai kualitas pengambilan dokumen (Es dkk. 2023).

1. **Faithfulness**

Mengukur konsistensi faktual dari jawaban yang dihasilkan terhadap konteks

yang diberikan untuk memastikan tidak ada informasi yang dibuat-buat atau halusinasi yang sangat berbahaya dalam domain kesehatan (Min dkk. 2023).

2. Answer Relevancy

Menilai seberapa langsung jawaban tersebut merespons pertanyaan pengguna tanpa memperhitungkan kebenaran faktualnya (Wang dkk. 2023).


3. Context Precision

Mengukur rasio informasi relevan yang berhasil diambil dibandingkan dengan total informasi yang diambil yang menunjukkan efisiensi sistem dalam menyaring *noise* data medis (Gao dkk. 2023).

4. Context Recall

Mengukur kemampuan sistem untuk mengambil seluruh informasi yang diperlukan dari basis pengetahuan untuk menjawab pertanyaan pengguna (Liu dkk. 2024).

Selain metrik per komponen, terdapat juga metrik *Answer Semantic Similarity* dan *Answer Correctness* yang memberikan gambaran performa sistem secara keseluruhan (Es dkk. 2023). Proses kerja RAGAS dalam melakukan evaluasi melibatkan alur data yang sistematis di mana data input diproses melalui *retriever* dan *generator* sebelum akhirnya dinilai oleh evaluator.



Gambar II.5 Alur Kerja Evaluasi Sistem RAG Menggunakan RAGAS.

Gambar II.6 memperlihatkan bahwa evaluator bekerja secara iteratif untuk memberikan skor kuantitatif pada setiap tahapan (Saad-Falcon dkk. 2024). Penggunaan LLM sebagai evaluator dalam RAGAS terbukti memiliki korelasi yang tinggi dengan penilaian manusia namun dengan efisiensi waktu dan biaya yang jauh lebih rendah dibandingkan evaluasi manual oleh ahli medis (Chen dkk. 2024). Dalam pengembangan sistem prediksi hipertensi ini, skor dari RAGAS akan menjadi indi-

kator utama untuk validasi model sebelum sistem diuji coba secara klinis (Huang dkk. 2023).

Penting untuk dicatat bahwa RAGAS juga memperkenalkan metrik *Context Entity Recall* yang sangat relevan untuk ekstraksi entitas medis seperti nama obat atau kondisi komorbiditas hipertensi (Es dkk. 2023). Kehadiran metrik ini memastikan bahwa entitas spesifik yang krusial tidak hilang selama proses pengambilan konteks (Liu dkk. 2024). Dengan demikian implementasi RAGAS dalam penelitian ini tidak hanya berfungsi sebagai alat ukur tetapi juga sebagai mekanisme umpan balik untuk melakukan *fine-tuning* pada komponen *retriever* dan *prompt engineering* pada komponen *generator* (Gao dkk. 2023).

II.6 Tinjauan Penelitian Sebelumnya

Penelitian mengenai prediksi hipertensi telah mengalami evolusi signifikan dalam setengah dekade terakhir, bergerak dari metode statistik konvensional menuju pendekatan Machine Learning (ML) dan Deep Learning (DL) yang lebih kompleks. Fokus utama dari berbagai studi terkini adalah meningkatkan akurasi prediksi dini untuk mencegah komplikasi kardiovaskular yang lebih serius (El-Salamony dan El-Taweel 2023). Namun, tren terbaru menunjukkan bahwa akurasi tinggi saja tidak lagi cukup dalam implementasi klinis; transparansi model melalui Explainable Artificial Intelligence (XAI) dan kemampuan interaksi natural melalui Large Language Model (LLM) menjadi kebutuhan mendesak untuk meningkatkan kepercayaan tenaga medis dan pasien terhadap sistem (Clusmann dkk. 2023).

Sebagian besar penelitian yang dilakukan antara tahun 2019 hingga 2021 masih berfokus pada perbandingan algoritma klasifikasi standar. Sebagai contoh, penggunaan metode *ensemble learning* seperti Random Forest dan Gradient Boosting terbukti secara konsisten mengungguli model tunggal seperti Decision Tree atau Logistic Regression dalam menangani dataset kesehatan yang tidak seimbang (El-Salamony dan El-Taweel 2023). Meskipun performanya tinggi, model-model ini sering kali bersifat *black-box* atau sulit diinterpretasikan, yang menjadi hambatan utama dalam adopsi klinis karena dokter perlu memahami alasan di balik prediksi risiko pasien.

Merespons keterbatasan tersebut, gelombang penelitian selanjutnya mulai mengintegrasikan metode XAI. Penggunaan SHapley Additive exPlanations (SHAP) dan Local Interpretable Model-agnostic Explanations (LIME) telah menjadi standar baru dalam memvisualisasikan kontribusi fitur, seperti pengaruh indeks massa tubuh (BMI) atau kadar glukosa terhadap prediksi hipertensi secara spesifik untuk setiap individu (Miao dkk. 2022). Integrasi ini memungkinkan sistem tidak hanya membe-

rikan label ”beresiko” atau ”tidak beresiko”, tetapi juga memberikan wawasan klinis mengenai variabel mana yang harus diintervensi.

Lebih lanjut, kemunculan arsitektur Transformer dan Large Language Models (LLM) membuka peluang baru dalam pengolahan data kesehatan yang tidak terstruktur, seperti catatan medis elektronik (EHR). Studi terbaru menunjukkan bahwa LLM memiliki potensi besar dalam merangkum riwayat pasien dan memberikan rekomendasi kesehatan yang dipersonalisasi, meskipun tantangan terkait halusinasi model dan privasi data masih menjadi perhatian utama (Thirunavukarasu dkk. 2023). Penelitian ini bermaksud mengisi celah tersebut dengan menggabungkan kekuatan prediktif XAI dengan kemampuan naratif LLM.

Untuk memberikan gambaran komprehensif mengenai posisi penelitian ini dibandingkan dengan studi terdahulu, Tabel II.1 menyajikan ringkasan kritis dari empat penelitian relevan yang dipublikasikan dalam kurun waktu lima tahun terakhir.

Tabel II.1 Studi Sebelumnya

No	Judul & Penulis	Metode	Hasil	Keterbatasan
1	Machine Learning for Hypertension Prediction (El-Salamony dan El-Taweel 2023)	Menggunakan algoritma Ensemble Learning (gabungan Decision Tree, Random Forest, dan Naïve Bayes) pada dataset klinis standar.	Model Random Forest memberikan akurasi tertinggi mencapai 98,5 persen dibandingkan algoritma tunggal lainnya dalam memprediksi status hipertensi.	Studi ini hanya berfokus pada metrik performa (akurasi) dan tidak membahas aspek interpretabilitas (XAI), sehingga sulit untuk melacak variabel penyebab utama.
2	Interpretable Machine Learning for Early Prediction of Hypertension (Miao dkk. 2022)	Menggabungkan model XGBoost dengan metode interpretasi SHAP (SHapley Additive exPlanations) untuk analisis faktor risiko.	Model berhasil mengidentifikasi usia, BMI, dan kadar trigliserida sebagai fitur paling berpengaruh, dengan visualisasi feature importance yang jelas.	Analisis terbatas pada data terstruktur numerik dan belum memanfaatkan data teks atau riwayat medis naratif pasien.

Bersambung ke halaman berikutnya

Tabel II.1 Studi Sebelumnya (lanjutan)

No	Judul & Penulis	Metode	Hasil	Keterbatasan
3	Deep Learning Approaches for Blood Pressure Prediction (Cheng dkk. 2021)	Menggunakan Long Short-Term Memory (LSTM) dan Recurrent Neural Networks (RNN) untuk data time-series tekanan darah.	LSTM menunjukkan performa superior dalam memprediksi fluktuasi tekanan darah jangka pendek dibandingkan model regresi tradisional.	Kompleksitas komputasi sangat tinggi dan membutuhkan data pemantauan kontinu yang sulit didapatkan dalam pemeriksaan rutin biasa.
4	Large Language Models in Medicine (Thirunavukarasu dkk. 2023)	Tinjauan sistematis dan eksperimen awal penggunaan model berbasis Transformer (LLM) untuk dukungan keputusan klinis.	LLM mampu menyintesis informasi medis kompleks menjadi saran yang mudah dipahami oleh pasien dan tenaga medis.	Rentan terhadap bias data pelatihan dan "halusinasi" fakta, serta belum diintegrasikan secara penuh dengan model prediksi hipertensi yang numerik.
5	Prediction of Personalised Hypertension Using Machine Learning in Indonesian Population (Septian dkk. 2025)	Mengkomparasi 5 algoritma (termasuk LightGBM dan XGBoost) pada 9,58 juta data SATUSEHAT dengan analisis fitur menggunakan SHAP (SHapley Additive exPlanations)	Model LightGBM mencapai performa terbaik dengan AUC 0,78 (tanpa riwayat pasien) dan 0,85 (dengan riwayat pasien), di mana usia dan lingkaran pinggang menjadi fitur prediktor dominan.	Studi bersifat <i>cross-sectional</i> sehingga tidak dapat menyimpulkan kausalitas, serta data terbatas pada seting non-rumah sakit yang tidak mencakup variabel klinis mendalam seperti status pengobatan rinci.

BAB III

ANALISIS MASALAH

Bab ini membahas analisis masalah yang ada pada sistem saat ini, analisis kebutuhan yang diperlukan untuk menyelesaikan masalah tersebut, serta analisis pemilihan solusi yang diusulkan. Secara garis besar, bab ini membahas hal-hal berikut:

1. Deskripsi hasil analisis dari persoalan yang sedang ditangani dalam TA;
2. Penjelasan tentang solusi yang ditawarkan (dapat berupa algoritma, konsep desain, formula, atau gabungannya) pada level konsep dan detail yang cukup untuk merealisasikan solusinya; dan
3. Penjelasan tentang pendekatan yang dipilih dalam menyelesaikan persoalan TA.


Subbab-subbab dalam bab ini dapat disesuaikan dengan kebutuhan topik TA yang dibahas. Berikut adalah penjabaran analisis masalah dan kebutuhan untuk pengembangan sistem prediksi hipertensi.

III.1 Analisis Kondisi Saat Ini

Saat ini, prosedur diagnosis dan prediksi risiko hipertensi di fasilitas kesehatan maupun dalam penelitian epidemiologi sebagian besar masih bergantung pada pengukuran klinis konvensional dan penilaian manual oleh tenaga medis. Pasien umumnya datang ke fasilitas kesehatan, melakukan pengukuran tekanan darah (TD) sesaat, dan dokter akan melakukan anamnesis untuk menggali riwayat kesehatan serta faktor risiko. Data ini kemudian diolah berdasarkan pedoman klinis standar untuk menentukan status kesehatan pasien sebagaimana digambarkan pada Gambar III.1. Dalam praktiknya, pendekatan ini sering kali bersifat reaktif, di mana intervensi medis baru diberikan setelah pasien menunjukkan gejala klinis yang nyata atau tekanan darah yang sudah melampaui ambang batas normal secara persisten (Mills, Stefanescu, dan He 2020).

Keterbatasan waktu konsultasi dan kompleksitas interaksi antar faktor risiko sering menyebabkan penilaian risiko menjadi kurang komprehensif. Hal ini diperburuk dengan fakta bahwa hipertensi sering dijuluki sebagai *silent killer*, di mana banyak

pasien tidak menyadari kondisi mereka hingga terjadi komplikasi serius. Kebutuhan akan alat bantu prediksi yang lebih dini dan akurat memunculkan tren penggunaan algoritma Machine Learning (ML). Namun, penerapan model ML konvensional, seperti Neural Networks atau Ensemble Trees, sering kali menghadapi kendala transparansi. Model tersebut bekerja sebagai kotak hitam atau biasa disebut juga dengan black box, memberikan skor risiko tanpa disertai alasan medis yang jelas. Kondisi ini menciptakan keraguan di kalangan praktisi medis untuk mengadopsi hasil prediksi komputer dalam pengambilan keputusan klinis (Amann dkk. 2020).



Gambar III.1 Alur Diagnosis Hipertensi di Fasilitas Kesehatan Tingkat Pertama (FKTP) (*as-is*)

Dalam upaya mengatasi masalah transparansi tersebut, penelitian terkini mulai mengintegrasikan Explainable Artificial Intelligence (XAI). Meskipun demikian, luaran dari XAI umumnya masih berupa grafik fitur atau nilai matematis yang sulit dipahami oleh pasien awam. Kesenjangan komunikasi ini menjadi tantangan baru dalam menyampaikan risiko kesehatan kepada pasien secara efektif. Di sisi lain, kemunculan Large Language Model (LLM) menawarkan potensi untuk menarasikan data

tersebut, namun penggunaannya yang tanpa pengawasan rentan menghasilkan informasi yang tidak valid atau halusinasi medis (Singhal dkk. 2023). Oleh karena itu, kondisi saat ini menunjukkan adanya fragmentasi antara kemampuan prediksi yang tinggi, kebutuhan akan transparansi (*explainability*), dan penyajian informasi yang akurat secara medis.

III.1.1 Kesenjangan Transparansi dan Kepercayaan Klinis (Trust Gap)

Masalah paling fundamental dalam adopsi teknologi prediksi risiko saat ini terletak pada asimetri pemahaman antara cara kerja model komputasi dan logika klinis dokter. Model Machine Learning yang memiliki performa akurasi tinggi sering kali memiliki struktur internal yang sangat kompleks dan tidak dapat ditafsirkan secara langsung. Hal ini menciptakan dua hambatan utama dalam implementasi klinis:

1. Skeptisisme Tenaga Medis

Dokter dan tenaga kesehatan memegang tanggung jawab etis dan hukum atas keputusan yang diambil. Mereka enggan menggunakan prediksi dari sistem yang tidak dapat menjelaskan "mengapa" seorang pasien dikategorikan berisiko tinggi, terutama jika prediksi tersebut bertentangan dengan intuisi klinis mereka. Ketiadaan kausalitas yang dapat diobservasi menyebabkan rendahnya tingkat kepercayaan terhadap sistem pendukung keputusan berbasis AI (Linardatos, Papastefanopoulos, dan Kotsiantis 2021).

2. Kebingungan Pasien terhadap Hasil Prediksi

Bagi pasien, menerima diagnosis atau prediksi risiko tanpa penjelasan yang personal dapat menimbulkan kecemasan atau justru penyangkalan. Pasien membutuhkan narasi yang menghubungkan gaya hidup mereka (misalnya, merokok atau IMT tinggi) dengan kenaikan risiko yang diprediksi, bukan sekadar angka probabilitas statistik. Tanpa penjelasan yang memadai, kepatuhan pasien terhadap saran preventif cenderung rendah.

III.1.2 Risiko Halusinasi dan Inkonsistensi Informasi Medis

Dari perspektif teknologi Generative AI yang mulai marak digunakan, tantangannya bersifat validitas data. Meskipun LLM mampu menghasilkan teks yang sangat koheren dan menyerupai bahasa manusia, model ini memiliki kecenderungan inherent untuk menghasilkan fakta yang salah atau "berhalusinasi" ketika tidak memiliki konteks yang cukup. Dalam domain medis yang berisiko tinggi, hal ini menciptakan bahaya laten sebagai berikut:

1. Fabrikasi Saran Medis

Tanpa batasan basis pengetahuan yang ketat, LLM dapat memberikan saran kesehatan yang terlihat meyakinkan namun tidak memiliki dasar ilmiah atau

bertentangan dengan pedoman medis resmi. Misalnya, model mungkin menyarankan dosis obat atau interpretasi gejala yang salah (Li dkk. 2023). Hal ini sangat berbahaya jika dijadikan rujukan oleh pengguna awam tanpa verifikasi.

2. Inkonsistensi Narasi

Penjelasan yang dihasilkan oleh model bahasa standar dapat bervariasi secara signifikan meskipun diberikan input data yang sama pada waktu yang berbeda. Ketidakkonsistenan ini mengurangi reliabilitas sistem sebagai alat edukasi pasien yang terstandarisasi. Tidak adanya mekanisme validasi silang (*cross-validation*) dengan dokumen medis terpercaya membuat luaran model sulit dipertanggungjawabkan (Zhang dkk. 2023).

III.1.3 Tantangan Kompleksitas Data Multidimensi

Pada konteks teknis pengolahan data, masalah diperparah dengan sifat data kesehatan yang heterogen dan non-linier. Faktor risiko hipertensi melibatkan interaksi yang rumit antara demografi, tanda vital, dan riwayat gaya hidup yang tidak selalu dapat dimodelkan dengan regresi linier sederhana.

1. Interaksi Variabel yang Tersembunyi

Metode statistik tradisional sering gagal menangkap hubungan non-linier yang kompleks, misalnya bagaimana dampak indeks massa tubuh (IMT) terhadap tekanan darah mungkin berbeda secara drastis tergantung pada usia dan tingkat aktivitas fisik seseorang. Kegagalan menangkap nuansa ini menyebabkan prediksi menjadi kurang akurat untuk individu dengan profil risiko yang unik (Elshaw, Al-Mallah, dan Sakr 2019).

2. Keterbatasan Personalisasi

Sistem informasi kesehatan yang ada saat ini umumnya bersifat *one-size-fits-all* atau satu ukur untuk semua. Belum tersedia mekanisme yang secara otomatis mengadaptasi penjelasan risiko berdasarkan profil spesifik pasien secara *real-time* yang didukung oleh bukti literatur medis terkini.

III.1.4 Identifikasi Kesenjangan (Gap Analysis)

Berdasarkan analisis kondisi saat ini, dilakukan pemetaan kesenjangan antara kondisi *As-Is* (sistem konvensional/black box) dengan kondisi ideal *To-Be* (sistem yang diusulkan) yang dirangkum dalam Tabel III.1 di bawah ini.

Tabel III.1 Identifikasi Kesenjangan (Gap Analysis)

Domain Masalah	Kondisi Saat Ini (<i>As-Is</i>)	Kesenjangan (Gap)	Kondisi Ideal (<i>To-Be</i>)
Transparansi & Kepercayaan	Model prediksi bekerja sebagai black box; pengguna hanya menerima skor risiko tanpa alasan penjelasan.	Tidak adanya mekanisme untuk menelusuri alasan di balik prediksi dominan variabel.	Sistem menyediakan fitur visualisasi (XAI) yang menjelaskan variabel dominan penyebab risiko.
Validitas Informasi	Penjelasan risiko jika menggunakan LLM bisa masih rentan terhadap halusinasi dan tidak memiliki referensi yang jelas.	Risiko kesalahan informasi medis yang membahayakan keselamatan pasien.	Narasi penjelasan divalidasi oleh arsitektur RAG yang merujuk pada pedoman medis resmi (Kemenkes/WHO).
Akurasi & Personalisasi	Analisis risiko bersifat reaktif dan generalis; sering mengabaikan interaksi non-linier antar variabel.	Rendahnya sensitivitas terhadap profil risiko individu dan kurangnya personalisasi.	Model ML mampu menangkap pola kompleks dan menyajikan narasi personal yang mudah dipahami awam.

Analisis kesenjangan pada Tabel III.1 menggarisbawahi bahwa tantangan yang dihadapi tidak hanya sekadar meningkatkan akurasi angka prediksi, tetapi juga membangun jembatan komunikasi antara logika mesin dan pemahaman manusia. Secara kumulatif, kesenjangan ini menegaskan urgensi pengembangan sistem terintegrasi yang menggabungkan kekuatan prediksi Machine Learning, transparansi XAI, dan kemampuan naratif LLM yang diamankan oleh RAG. Untuk mewujudkan solusi tersebut, langkah selanjutnya adalah menerjemahkan temuan ini ke dalam analisis kebutuhan sistem yang terukur.

III.2 Analisis Kebutuhan

Dalam perancangan sistem pendukung keputusan klinis yang menggabungkan kecerdasan buatan dan interpretasi bahasa alami ini, diperlukan pemahaman mendalam terhadap kebutuhan pengguna serta spesifikasi teknis yang ketat. Mengingat domain kesehatan merupakan area yang sensitif terhadap keselamatan (*safety-critical*), analisis kebutuhan tidak hanya berfokus pada akurasi komputasi, tetapi juga pada aspek kepercayaan, transparansi, dan validitas informasi yang disampaikan kepada pengguna (Amann dkk. 2020). Tahapan ini bertujuan menerjemahkan kesenjangan

an masalah yang telah diidentifikasi sebelumnya menjadi spesifikasi fungsional dan non-fungsional yang terukur.

III.2.1 Identifikasi Masalah Pengguna

Berdasarkan analisis konteks, pengguna potensial dari sistem ini dikategorikan menjadi dua kelompok utama, yaitu masyarakat umum (pasien) sebagai penerima informasi kesehatan, dan tenaga medis profesional yang membutuhkan opini kedua (*second opinion*). Masalah spesifik yang dihadapi oleh masing-masing kelompok pengguna adalah sebagai berikut:

1. Masyarakat Umum/Pasien

Tantangan utama yang dihadapi pasien adalah ketidakmampuan untuk memahami terminologi medis yang kompleks dan angka probabilitas statistik yang dihasilkan oleh alat kesehatan konvensional. Pasien sering kali menerima hasil diagnosis atau prediksi risiko tanpa penjelasan kausalitas yang memadai mengenai faktor gaya hidup apa yang memicu risiko tersebut (Tjoa dan Guan 2021). Selain itu, kurangnya akses terhadap informasi kesehatan yang terpersonalisasi membuat pasien kesulitan menentukan langkah mitigasi mandiri yang tepat tanpa harus berkonsultasi panjang dengan dokter.

2. Tenaga Medis Profesional

Dokter dan tenaga kesehatan menghadapi kendala dalam mengadopsi teknologi Machine Learning karena sifat black box dari algoritma tersebut. Tanpa adanya transparansi mengenai bagaimana model mengambil keputusan, tenaga medis sulit untuk memvalidasi apakah prediksi tersebut didasarkan pada logika medis yang benar atau hanya korelasi data yang bias (Linardatos, Papastefanopoulos, dan Kotsiantis 2021). Hal ini mengakibatkan keraguan dalam menggunakan hasil prediksi AI sebagai dasar pengambilan keputusan klinis, serta menambah beban kognitif dokter untuk menjelaskan risiko kepada pasien secara manual.

Untuk mengatasi permasalahan tersebut, maka dirumuskan sistem yang tidak hanya mampu memprediksi risiko hipertensi dengan akurasi tinggi, tetapi juga mampu menjelaskan alasan di balik prediksi tersebut menggunakan bahasa alami yang merujuk pada pedoman medis standar.

III.2.2 Kebutuhan Fungsional

Kebutuhan fungsional mendefinisikan serangkaian fitur dan perilaku spesifik yang harus dimiliki oleh sistem untuk menjawab permasalahan pengguna di atas. Berikut merupakan kebutuhan fungsional dari sistem prediksi hipertensi berbasis XAI dan LLM.

Tabel III.2 Kebutuhan Fungsional

ID	Kebutuhan Fungsional	Deskripsi
FR01	Pemrosesan Data Klinis Tabular	Sistem mampu menerima dan memproses input data pengguna yang terdiri dari variabel demografis, pengukuran fisik, tanda vital, dan riwayat kesehatan dalam format tabular terstruktur sesuai standar dataset kesehatan.
FR02	Prediksi Risiko Probabilistik	Sistem mampu mengklasifikasikan status risiko hipertensi dengan akurasi optimal dan menghasilkan skor probabilitas risiko yang presisi bagi setiap individu.
FR03	Pembangkitan Penjelasan Lokal (XAI)	Sistem mampu menganalisis dan memvisualisasikan kontribusi masing-masing variabel terhadap hasil prediksi spesifik pengguna.
FR04	Narasi Penjelasan Hasil Prediksi	Sistem mampu menerjemahkan hasil analisis kontribusi dari variabel menjadi narasi teks bahasa Indonesia yang mudah dipahami.
FR05	Validasi Referensi Penjelasan	Sistem mampu memastikan informasi dari narasi penjelasan hanya dari basis pengetahuan pedoman medis yang telah diverifikasi.

Dengan spesifikasi pada Tabel III.2, penulis merancang alur kerja di mana sistem tidak hanya berhenti pada *output* klasifikasi biner (Sehat/Berisiko), tetapi melanjutkan ke tahap interpretasi. Sistem diharapkan dapat melakukan *preprocessing* data otomatis, menjalankan inferensi model, menghitung *feature importance*, dan akhirnya menyusun paragraf penjelasan yang koheren. Fitur FR04 dan FR05 secara khusus ditujukan untuk menjembatani kesenjangan pemahaman antara data numerik dan bahasa manusia.

III.2.3 Kebutuhan Nonfungsional

Kebutuhan non-fungsional menetapkan batasan kualitas dan karakteristik operasional yang harus dipenuhi agar sistem dapat diandalkan dalam skenario penggunaan nyata. Dalam konteks informatika medis, aspek faktualitas dan akurasi menjadi prioritas di atas kecepatan semata.

Tabel III.3 Kebutuhan Non-Fungsional

ID	Kebutuhan Non-Fungsional	Deskripsi
NFR01	Pengujian Hasil Prediksi (Recall)	Model prediksi harus memprioritaskan kemampuan untuk meminimalkan <i>False Negative</i> .
NFR02	Target Metrik Recall	Model prediksi harus mencapai target metrik Recall lebih dari 70% pada data uji.
NFR03	Faktualitas Narasi	Narasi yang dihasilkan oleh LLM harus memiliki tingkat faktualitas yang tinggi terhadap dokumen sumber RAG, memastikan tidak ada saran medis yang difabrikasi di luar pedoman yang disediakan.
NFR04	Interpretabilitas Hasil Prediksi	Prototipe antarmuka harus mampu menyajikan grafik plot dari SHAP yang dapat dibaca untuk membantu dokter memindai faktor risiko dominan dengan cepat.
NFR05	Efisiensi Sistem	Waktu tunggu total dari input data hingga munculnya hasil prediksi dan narasi penjelasan tidak boleh melebihi 20 detik agar menjaga pengalaman pengguna yang responsif pada platform sistem.

Dengan memenuhi kebutuhan nonfungsional pada Tabel III.3 di atas, sistem yang dikembangkan diharapkan tidak hanya cerdas secara komputasi, tetapi juga aman dan etis untuk digunakan sebagai alat pendukung keputusan. Pemenuhan standar NFR02 khususnya menjadi krusial untuk membedakan sistem ini dengan chatbot kesehatan generik yang rentan terhadap halusinasi medis.

III.3 Analisis Pemilihan Solusi

Dalam merancang sistem informasi kesehatan yang kompleks seperti prediksi risiko hipertensi, diperlukan analisis yang tajam terhadap akar permasalahan klinis dan potensi teknologi yang tersedia. Tahapan ini krusial untuk memastikan bahwa arsitektur sistem yang diusulkan bukan hanya canggih secara teknis, tetapi juga menjawab kebutuhan praktis di lapangan. Subbab ini menyajikan pemetaan masalah dan peluang secara sistematis, serta membandingkan berbagai alternatif pendekatan teknologi untuk menjustifikasi solusi hibrida yang dipilih dalam penelitian tugas akhir ini.

III.3.1 Alternatif Solusi

Permasalahan multidimensi yang muncul dalam lingkup diagnosis dan prediksi hipertensi perlu dipetakan secara granular agar penulis dapat merumuskan intervensi teknologi yang presisi. Berdasarkan hasil tinjauan literatur dan observasi kondisi saat ini, dijabarkan pemetaan masalah utama beserta dampak signifikannya pada Tabel III.4.

Tabel III.4 Pemetaan Masalah dan Dampak

ID	Nama Masalah	Deskripsi Masalah	Dampak
M01	Fenomena black box pada Model Prediksi	Model Machine Learning konvensional menghasilkan skor risiko tanpa menyertakan alasan medis yang mendasarinya.	Terjadi defisit kepercayaan (<i>trust deficit</i>) dari tenaga medis untuk menggunakan hasil prediksi dalam pengambilan keputusan klinis.
M02	Inkomprehensibilitas bagi Pasien Awam	Luaran sistem prediksi berupa angka probabilitas atau grafik statistik sulit dipahami oleh pasien tanpa latar belakang medis.	Pasien gagal memahami urgensi kondisi kesehatan mereka yang berpotensi menyebabkan rendahnya kepatuhan.
M03	Halusinasi Risiko pada Generative AI	Penggunaan model bahasa (LLM) standar untuk konsultasi kesehatan rentan menghasilkan fakta medis yang salah atau fabrikasi data.	Menimbulkan risiko keselamatan pasien yang fatal jika saran yang tidak valid diikuti.
M04	Kompleksitas Hubungan Non-Linier	Metode statistik tradisional sering gagal menangkap interaksi kompleks antar variabel risiko.	Akurasi prediksi menjadi suboptimal untuk individu dengan profil risiko yang unik.

Uraian permasalahan di atas menunjukkan adanya kebutuhan mendesak akan sistem yang tidak hanya akurat, tetapi juga transparan dan aman. Di sisi lain, perkembangan teknologi terkini membuka peluang besar untuk mengatasi hambatan tersebut. Pemetaan peluang yang menjadi dasar teknis pengembangan solusi dijabarkan pada Tabel III.5.

Tabel III.5 Pemetaan Peluang

ID	Pemetaan Masalah	Nama Peluang	Deskripsi Peluang
P01	M01, M04	Integrasi Metode Model-Agnostic	Pemanfaatan metode XAI seperti SHAP/LIME memungkinkan pembukaan "kotak hitam" model ML tanpa mengorbankan akurasi prediksi.
P02	M02	Pemanfaatan Large Language Model (LLM)	Kemampuan <i>natural language generation</i> (NLG) dari LLM dapat menerjemahkan data matematis kompleks menjadi narasi personal.
P03	M03	Arsitektur Retrieval-Augmented Generation (RAG)	Penerapan mekanisme RAG membatasi jawaban LLM hanya berdasarkan pedoman klinis terverifikasi, memitigasi risiko halusinasi.
P04	M01, M03, M04	Ketersediaan Dataset Kesehatan Terstruktur	Tersedianya data sekunder publik memungkinkan pelatihan model ML yang <i>robust</i> sebagai fondasi sistem prediksi objektif.

Berdasarkan pemetaan masalah dan peluang tersebut, penulis mengevaluasi berbagai pendekatan arsitektur teknis yang mungkin diadopsi. Perbandingan komparatif dari setiap alternatif solusi disajikan dalam Tabel III.6.

Tabel III.6 Alternatif Solusi

No	Solusi	Kelebihan	Kekurangan
1.	Sistem Pakar Berbasis Aturan (Rule-Based System)	Sangat transparan dan mudah diaudit karena logika diprogram secara eksplisit.	Sangat kaku (<i>rigid</i>), tidak mampu menangkap pola non-linier yang kompleks, dan sulit diperbarui.
2.	Pure Machine Learning	Mampu mencapai akurasi prediksi yang sangat tinggi pada dataset besar dan menangkap pola rumit.	Tidak memiliki interpretabilitas keputusan (alasan tidak diketahui), sehingga sulit diterima dalam praktik klinis.
3.	Chatbot LLM dengan (Direct Prompting)	Interaksi sangat natural dan mampu memberikan penjelasan panjang lebar.	Rentan halusinasi medis (fakta yang salah), tidak deterministik, dan sulit memproses numerik presisi.
4.	Hybrid System (ML + XAI + RAG)	Menyeimbangkan akurasi tinggi, transparansi alasan prediksi, dan penyajian informasi valid secara medis.	Arsitektur sistem paling kompleks dan memerlukan integrasi berbagai komponen teknis.

Tabel III.6 di atas menunjukkan bahwa setiap pendekatan memiliki *trade-off* tersendiri. Pemilihan solusi harus memprioritaskan keselamatan pasien dan kegunaan klinis di atas kemudahan pengembangan semata. Penentuan solusi final akan dikalkulasi secara objektif pada subbab selanjutnya.

III.3.2 Analisis Penentuan Solusi

Dalam menentukan pendekatan teknis yang paling optimal untuk sistem prediksi risiko hipertensi ini, penulis melakukan evaluasi kuantitatif menggunakan metode *Weighted Scoring Matrix* (WSM). WSM adalah teknik pengambilan keputusan yang memberikan bobot prioritas pada kriteria tertentu untuk membandingkan alternatif solusi secara objektif (Ouchra dan Belangour 2021). Metode ini dipilih karena fleksibilitasnya dalam mengakomodasi kriteria teknis seperti akurasi dan kriteria kualitatif seperti kepercayaan pengguna dalam satu kerangka evaluasi.

Parameter penilaian didasarkan pada kebutuhan nonfungsional sistem medis yang kritis. Setiap alternatif solusi diberi nilai skala 1 hingga 5, di mana nilai 1 merepresentasikan performa sangat buruk dan nilai 5 merepresentasikan performa sangat baik. Adapun perhitungan skor akhir yang diperoleh dari perkalian nilai dengan bobot prioritas dijabarkan pada Tabel III.7.

Tabel III.7 Pemilihan Solusi dengan *Weighted Scoring Model*

Parameter	Bobot	Rule-Based System	Pure ML (Black Box)	LLM Chatbot (Direct)	Hybrid System (ML+XAI+RAG)
Keamanan Medis	0,25	5	5	2	5
Interpretabilitas (<i>Explainability</i>)	0.25	5	1	3	5
Akurasi Prediksi	0,20	4	5	1	5
Kualitas Narasi & Personalisasi	0.15	1	1	5	4
Skalabilitas	0,15	2	5	3	4
Total Skor	1,00	3,75	3,40	2,60	4,70


Berdasarkan perhitungan skor total pada Tabel III.7, solusi yang akan diadopsi dalam penelitian tugas akhir ini adalah Hybrid System (ML + XAI + RAG) dengan perolehan skor akhir tertinggi yaitu 4.70. Pendekatan ini terbukti merupakan satu-satunya arsitektur yang mampu memenuhi tiga persyaratan penting sistem pendukung keputusan klinis, yaitu akurasi tinggi melalui ML, transparansi melalui XAI, dan komunikasi yang aman melalui RAG. Keputusan ini menjadi landasan bagi perancangan sistem yang akan dibahas pada bab selanjutnya.

BAB IV

PERANCANGAN

IV.1 Model Konseptual Solusi yang Diusulkan

Berdasarkan analisis masalah dan pemilihan solusi pada bab sebelumnya, penelitian ini mengusulkan arsitektur sistem hibrida yang mengintegrasikan *Machine Learning* (ML), *Explainable Artificial Intelligence* (XAI), dan *Large Language Model* (LLM) berbasis *Retrieval-Augmented Generation* (RAG). Sistem ini dirancang dengan arsitektur yang memfasilitasi penggunaan baik oleh pasien secara mandiri maupun oleh tenaga medis. Aplikasi ini menerapkan mekanisme pengumpulan data yang adaptif bergantung pada konteks penggunaan. Dalam skrining mandiri di rumah, pasien dapat melakukan deteksi dini risiko hipertensi dari rumah tanpa perlu mengunjungi fasilitas kesehatan fisik. Pada mode ini, sistem membatasi kuesioner hanya pada variabel non-invasif saja seperti demografi, gaya hidup, dan riwayat gejala, serta meniadakan parameter klinis yang membutuhkan alat medis atau tindakan invasif seperti pengukuran tekanan darah atau pengambilan sampel darah. Sebaliknya, aplikasi juga dapat digunakan dengan alat ukur tensi di rumah, atau di fasilitas kesehatan, karena terdapat opsi untuk menyertakan variabel data klinis dan invasif. Gambar IV.1 mengilustrasikan desain konsep solusi yang dirancang untuk mengubah data klinis pasien menjadi prediksi risiko yang akurat, transparan, dan mudah dipahami.



Gambar IV.1 Desain Konsep Solusi Sistem

Berikut ini adalah uraian komponen pada desain sistem:

1. *Input Layer & Preprocessing*

Komponen ini berfungsi sebagai antarmuka akuisisi data yang menerima variabel input mentah dari pengguna. Sebelum masuk ke model, data tabular me-

lalui pipa pra-pemrosesan (*preprocessing pipeline*) yang ketat menggunakan pustaka manipulasi data (seperti *Pandas*). Proses ini mencakup dua mekanisme utama:

- *Value Imputation*: Sistem mendeteksi *null values* dan melakukan imputasi (misalnya menggunakan *mean/median* atau menghapus baris) untuk menjaga integritas matriks fitur.
- *Feature Encoding*: Model matematis seperti ML hanya dapat memproses angka, sehingga variabel kategorikal harus dikonversi menjadi format numerik. Untuk variabel biner dan ordinal seperti jenis kelamin atau tingkat aktivitas, diterapkan teknik *label encoding* yang memetakan kategori ke integer.

2. *ML Module*

Modul ini bertindak sebagai mesin inferensi yang menjalankan algoritma *Machine Learning*. Secara teknis, model ini bekerja dengan membangun *ensemble* dari pohon keputusan (*decision trees*) secara sekuensial, di mana setiap pohon baru memperbaiki residu kesalahan (*error residual*) dari pohon sebelumnya.

- *Kalkulasi Probabilitas*: Model menghasilkan luaran berupa nilai *log-odds (logit)* yang kemudian ditransformasi menggunakan fungsi *sigmoid* untuk menghasilkan skor probabilitas kontinu antara 0 hingga 1.
- *Penentuan Kelas*: Probabilitas tersebut dikomparasi terhadap ambang batas (*threshold*) keputusan (biasanya 0.5 atau disesuaikan demi sensitivitas) untuk mengklasifikasikan label akhir menjadi "Berisiko" atau "Tidak Berisiko".

3. *XAI Module*

Modul ini menerapkan metode XAI untuk mengaudit keputusan model. Secara matematis, modul ini menghitung nilai *Shapley*, yaitu kontribusi marginal rata-rata dari setiap fitur terhadap selisih antara prediksi aktual instans tersebut dengan prediksi rata-rata dasar.

- *Output Atribusi*: Hasilnya adalah vektor nilai XAI untuk setiap fitur (positif atau negatif), yang menunjukkan seberapa besar dan ke arah mana (menaikkan atau menurunkan risiko) fitur tersebut mempengaruhi skor probabilitas pasien secara spesifik.

4. *RAG Module*

Modul ini terdiri dari dua fase utama, yaitu *Ingestion* dan *Retrieval & Generation*.

A. *Ingestion*

Proses ini mengubah dokumen statis menjadi struktur data yang dapat dicari secara semantik oleh mesin:

- *Raw Documents*: Sistem mengumpulkan dokumen pedoman klinis resmi, seperti panduan hipertensi dari Kemenkes RI atau WHO, dalam format PDF atau teks digital. Dokumen ini menjadi *ground truth* atau sumber kebenaran tunggal.
- *Text Extraction*: Karena mesin tidak bisa membaca visual PDF secara langsung, proses ekstraksi dilakukan menggunakan teknik OCR atau *parsing* untuk memisahkan konten teks murni dari elemen *layout*, gambar, atau *header/footer* yang tidak relevan.
- *Chunking*: Teks hasil ekstraksi tidak langsung diproses utuh karena keterbatasan *context window* pada model bahasa. Teks dipecah menjadi segmen-segmen kecil atau *chunks*, misalnya per paragraf atau per 512 token untuk mempertahankan granularitas konteks. Semakin spesifik potongan dari *chunks*, semakin akurat nanti pencariannya.
- *Embedding*: Setiap *chunk* teks dikonversi menjadi representasi numerik berupa vektor berdimensi tinggi, misalnya *array* berisi 1536 angka *float*, menggunakan model *embedding*. Vektor ini merepresentasikan makna semantik dari teks tersebut. Kalimat dengan makna serupa akan memiliki nilai vektor yang berdekatan secara matematis.
- *Vector Database*: Vektor-vektor tersebut kemudian diindeks dan disimpan dalam *Vector Database* yang dioptimalkan untuk operasi pencarian jarak yang berkecepatan tinggi, bukan pencarian kata kunci biasa.

B. Retrieval & Generation

Fase ini terjadi secara *real-time* saat pengguna meminta prediksi:


- *Auto-Query*: Ini adalah komponen yang menjembatani hasil analisis XAI dengan pencarian referensi. Sistem secara otomatis menyusun kueri pencarian berdasarkan luaran modul XAI, bukan sekadar meneruskan input mentah pengguna. Sebagai contoh, jika pengguna hanya memasukkan data "umur 50", *Auto-Query* akan mengambil konteks "Usia Lanjut" dan "Hipertensi" dari analisis risiko untuk membentuk kueri spesifik: "Bagaimana pengaruh usia lanjut terhadap risiko hipertensi menurut pedoman medis?"
- *Retriever System*: Sistem penerima kueri ini melakukan pencarian

kesamaan (*similarity search*) ke dalam *Vector Database*. Sistem membandingkan vektor dari *Auto-Query* dengan jutaan vektor dokumen yang tersimpan menggunakan perhitungan *Cosine Similarity* atau *Euclidean Distance*.

- *Retrieve Context*: Hasil dari *Retriever* bukanlah jawaban, melainkan potongan dokumen (*chunks*) yang memiliki skor kemiripan tertinggi dengan kueri. Konteks ini diambil untuk memberikan ”bahan bacaan” yang valid bagi LLM.
- *Prompt Augmentation*: Di sini sistem menggabungkan tiga elemen menjadi satu instruksi lengkap: (1) Kueri Asli, (2) Hasil Analisis SHAP (Faktor Risiko), dan (3) *Retrieved Context* (Dokumen Pedoman). Teknik ini disebut *In-Context Learning*, di mana kita memaksa model untuk menjawab hanya berdasarkan konteks yang kita suapkan.
- *Large Language Model (Generator)*: Terakhir, LLM memproses *prompt* yang sudah diperkaya (*augmented*) tersebut untuk menyusun narasi bahasa alami yang koheren, personal, dan tervalidasi oleh dokumen medis yang dilampirkan dalam konteks.

IV.1.1 Alur Kerja Sistem

Gambar IV.2 mengilustrasikan alur kerja dari sistem yang dirancang.



Gambar IV.2 Gambar Alur Kerja Sistem

Sistem yang diusulkan bekerja dalam alur sebagai berikut:


1. Pengguna memasukkan parameter kesehatan seperti usia, tekanan darah, IMT, dan riwayat keluarga pada kuesioner di sistem.

2. Model ML memproses data tersebut untuk menghasilkan skor probabilitas risiko hipertensi (misalnya: 56% Berisiko).
3. Secara paralel, modul XAI menghitung nilai atribusi fitur yang mendasar keputusan *black box* model ML. Modul ini mengidentifikasi variabel mana yang paling berkontribusi terhadap skor risiko tersebut, misalnya tinggi konsumsi garam dan IMT, yang menjadi kontributor utama.
4. Sistem mengambil hasil atribusi fitur dari SHAP. Lalu setelahnya, sistem melakukan pencarian (*retrieval*) pada basis data vektor yang berisi pedoman medis yang relevan dengan faktor risiko yang ditemukan, seperti pedoman dari Kemenkes atau WHO. LLM akan menggabungkan hasil prediksi, alasan dari SHAP, dan referensi medis untuk menyusun narasi penjelasan yang personal dan valid.
5. Pengguna menerima tiga luaran terintegrasi: Status Risiko (ML), Grafik Faktor Penyebab (XAI), dan Penjelasan Naratif serta Saran Medis (RAG-LLM).

IV.1.2 Arsitektur Sistem

Diagram arsitektur sistem diperlukan untuk memetakan bagaimana komponen perangkat lunak, aliran data, dan infrastruktur saling berinteraksi guna menjalankan logika prediksi secara stabil, aman, dan skalabel.

Gambar IV.3 berikut mengilustrasikan arsitektur teknis sistem yang dirancang dengan pendekatan berbasis layanan (*service-based architecture*).



Gambar IV.3 Arsitektur Teknis Sistem

Berdasarkan Gambar IV.3 di atas, sistem terbagi menjadi empat lapisan utama dengan fungsi spesifik sebagai berikut:

- Client Layer (Frontend)

Lapisan ini merupakan titik interaksi pengguna, baik melalui peramban web desktop maupun perangkat seluler. Lapisan ini bertugas menangkap input data klinis pasien dan memvisualisasikan hasil prediksi berupa grafik risiko dan narasi penjelasan yang dikirimkan oleh server melalui protokol HTTPS/JSON yang aman.

- Application Layer

Lapisan ini berfungsi sebagai otak pemrosesan sistem. Lapisan ini terdiri dari API Gateway yang mengatur lalu lintas data, serta unit AI Processing Services yang menjalankan tiga fungsi sekuensial:

1. *Data Preprocessing* untuk membersihkan input.
2. *Inference Service* yang menjalankan model XGBoost dan SHAP untuk

menghitung skor risiko.

3. *RAG Orchestrator* yang meramu *prompt* untuk model bahasa.

- Data Layer


Lapisan ini bertanggung jawab atas persistensi data dengan menggunakan dua jenis basis data. *Relational Database* digunakan untuk menyimpan data terstruktur pasien dan log riwayat prediksi, sedangkan *vector database* digunakan khusus untuk menyimpan *embedding* dokumen pedoman medis yang memungkinkan pencarian konteks semantik (*similarity search*) yang cepat.

- External Services

Sistem terhubung dengan penyedia layanan *Large Language Model* (LLM) pihak ketiga seperti OpenAI atau model *open-source* terhosting lainnya. Komponen ini menerima *prompt* yang telah diperkaya dengan konteks medis dari sistem internal untuk menghasilkan narasi penjelasan yang natural, namun tetap tervalidasi.

IV.2 Perbandingan dengan Sistem Saat Ini

Desain konsep solusi di atas menawarkan perubahan paradigma dari pendekatan konvensional yang digambarkan pada Bab III menjadi pendekatan berbasis kecerdasan buatan yang terintegrasi. Perbandingan komparatif antara kondisi saat ini (*As-Is*) dan solusi yang diusulkan (*To-Be*) dirangkum dalam Gambar IV.4.



Gambar IV.4 Alur Diagnosis Hipertensi di Fasilitas Kesehatan Tingkat Pertama (FK-TP) (To-Be)

Secara visual, jika dibandingkan dengan kondisi awal, desain usulan menggambarkan adanya otomatisasi dalam proses penalaran klinis. Pada tahap ini, dokter tidak lagi melakukan observasi data pasien secara manual, melainkan memasukkan data tersebut ke dalam sistem yang berfungsi sebagai pendukung dalam pengambilan keputusan.

Meskipun demikian, penekanan utama tetap berada pada peran dokter sebagai pengambil keputusan akhir. Informasi maupun rekomendasi yang diberikan sistem harus dipahami, ditafsirkan, dan dievaluasi kembali oleh dokter untuk memperoleh wawasan klinis yang komprehensif. Dengan demikian, sistem ini dirancang bukan untuk menggantikan fungsi dokter dalam menentukan keputusan medis, tetapi untuk mengurangi beban kognitif dalam proses analisis data sehingga dokter dapat membuat keputusan yang lebih tepat, efisien, dan berbasis informasi.

BAB V

IMPLEMENTASI

Bab ini memaparkan hasil pelaksanaan seluruh tahapan pengembangan sistem, yang meliputi pemahaman dan persiapan data, pelatihan dan evaluasi model Machine Learning, analisis teknik *threshold moving*, serta implementasi modul Explainable AI (XAI) berbasis SHAP dan modul narasi medis berbasis Retrieval-Augmented Generation (RAG). Seluruh tahapan dilaksanakan mengacu pada metodologi CRISP-DM sebagaimana diuraikan pada Bab III.

V.1 Pemahaman Data (*Data Understanding*)

Tahap pemahaman data merupakan fase awal dalam metodologi CRISP-DM yang bertujuan untuk memperoleh gambaran menyeluruh mengenai karakteristik dataset sebelum proses pemodelan dilakukan. Dataset yang digunakan dalam penelitian ini bersumber dari *Indonesian Family Life Survey* (IFLS), sebuah survei longitudinal berskala nasional yang mencakup aspek kesehatan, sosial, dan ekonomi masyarakat Indonesia.

Dataset mentah yang diperoleh dari IFLS terdiri dari beragam variabel kesehatan individual. Melalui proses seleksi dan rekayasa fitur, diperoleh 16 variabel numerik yang relevan secara klinis sebagai fitur input model prediksi. Label target, yaitu `label_hypertension`, diturunkan dari pengukuran tekanan darah sistolik dan diastolik responden berdasarkan kriteria klinis yang berlaku, yakni tekanan darah sistolik lebih dari atau sama dengan 140 mmHg atau tekanan darah diastolik lebih dari atau sama dengan 90 mmHg. Kolom tekanan darah kemudian dikeluarkan dari fitur input untuk menghindari kebocoran data (*data leakage*).

V.1.1 Profil Dataset

Setelah melalui proses pembersihan data, termasuk penghapusan entri dengan nilai usia di atas 100 tahun yang merupakan kode *missing value* (998/999) dalam dataset IFLS, diperoleh dataset bersih sebagaimana dirangkum dalam Tabel V.1 berikut.

Tabel V.1 Profil Dataset

Karakteristik	Nilai	Keterangan
Total Sampel	32.334	Setelah pembersihan data
Jumlah Fitur Input	16	Fitur numerik aktif
Kelas Positif (Hipertensi)	8.939 (27,65%)	Label = 1
Kelas Negatif (Sehat)	23.395 (72,35%)	Label = 0
Rasio Imbalance	2,62 : 1	Negatif : Positif
Data Training	25.867 (80%)	<i>Stratified split</i>
Data Pengujian	6.467 (20%)	<i>Stratified split</i>

Dari Tabel V.1 terlihat bahwa proporsi kelas positif (hipertensi) sebesar 27,65% dan kelas negatif (sehat) sebesar 72,35%, dengan rasio ketidakseimbangan sebesar 2,62 : 1. Menurut kategorisasi *imbalance* pada literatur Machine Learning, rasio ini tergolong dalam kategori *moderate imbalance* (10-30%), sehingga penanganan *imbalance* tetap diperlukan namun tidak membutuhkan teknik *resampling* yang agresif. Pembagian data dilakukan dengan proporsi 80% untuk pelatihan dan 20% untuk pengujian menggunakan *stratified split* guna menjaga distribusi kelas pada kedua *subset*.

V.1.2 Deskripsi Fitur Input

Seluruh fitur yang digunakan dalam pemodelan merupakan variabel bertipe numerik. Fitur ak05 yang semula bertipe *object (string)* dikonversi ke tipe numerik menggunakan `pd.to_numeric()` dengan parameter `errors='coerce'` sebelum diikutsertakan dalam pemodelan. Deskripsi lengkap seluruh fitur input disajikan pada Tabel V.2.

Tabel V.2 Deskripsi Fitur Input Model

No	Nama Fitur	Deskripsi	Tipe Data	Penanganan <i>Missing</i>
1	age	Usia responden (tahun)	float64	–
2	is_female	Jenis kelamin (1=P, 0=L)	int64	–
3	bmi	Body Mass Index	float64	–
4	waist_cm	Lingkar pinggang (cm)	float64	Imputasi median (83,6 cm)
5	is_smoker	Status merokok (0/1)	int64	–
6	freq_instant_noodle	Frekuensi mie instan/minggu	float64	–
7	ak02	Intensitas aktivitas fisik	float64	–
8	ak05	Aktivitas fisik (converted)	float64	Konversi dari <i>object</i>
9	ak07	Durasi aktivitas fisik	float64	–
10	has_diabetes	Riwayat diabetes (0/1)	int64	–
11	genetic_risk_score	Skor risiko genetik (0-2)	int64	–
12	ps_A	Faktor psikososial A (1-3)	float64	Imputasi median
13	ps_B	Faktor psikososial B (1-3)	float64	Imputasi median
14	ps_C	Faktor psikososial C (1-3)	float64	Imputasi median
15	ps_E	Faktor psikososial E (1-3)	float64	Imputasi median
16	ps_F	Faktor psikososial F (1-3)	float64	Imputasi median

V.2 Persiapan Data (*Data Preparation*)

Tahap persiapan data mencakup serangkaian proses transformasi dan pembersihan yang diperlukan sebelum data dapat digunakan untuk melatih model Machine Learning. Terdapat tiga isu utama yang diidentifikasi dan ditangani pada tahap ini.

V.2.1 Penanganan *Missing Value*

Inspeksi *missing value* pada dataset mengungkap dua kelompok fitur yang memerlukan penanganan khusus. Pertama, fitur *waist_cm* (lingkar pinggang) memiliki 19.300 nilai kosong atau setara dengan 59,7% dari total data. Meskipun persentase *missing* yang tinggi ini sempat mempertimbangkan opsi penghapusan kolom, fitur ini dipertahankan mengingat relevansinya yang signifikan sebagai indikator klinis risiko hipertensi. Imputasi dilakukan menggunakan nilai median sebesar 83,6 cm, yang lebih *robust* terhadap distribusi data yang miring (*skewed*) dibandingkan nilai rata-rata.

Kedua, fitur psikososial *ps_A*, *ps_B*, *ps_C*, *ps_E*, dan *ps_F* masing-masing memiliki 1.465 nilai kosong (4,5%). Fitur-fitur ini memiliki skala ordinal 1 hingga 3, sehingga

pengisian dengan nilai 0 yang diterapkan pada versi sebelumnya merupakan nilai di luar rentang skala yang valid dan berpotensi memperkenalkan *noise* pada model. Oleh karena itu, imputasi dilakukan menggunakan median masing-masing kolom.

V.2.2 Konversi Tipe Data

Fitur `ak05` ditemukan bertipe *object (string)* pada dataset asli, yang menyebabkan fitur ini secara otomatis tereksklusi dari proses pemodelan pada implementasi sebelumnya. Konversi ke tipe numerik menggunakan `pd.to_numeric(errors='coerce')` dilakukan untuk mengikutsertakan fitur ini, sehingga jumlah fitur aktif meningkat dari 15 menjadi 16 variabel.

V.2.3 Normalisasi Data

Normalisasi data menggunakan `StandardScaler` diterapkan secara selektif. Logistic Regression yang sensitif terhadap skala fitur menerima data yang telah dinormalisasi melalui mekanisme *pipeline* dari `sklearn`. Sementara itu, model berbasis pohon keputusan seperti XGBoost tidak memerlukan normalisasi karena proses pembuatan percabangan pada algoritma tersebut didasarkan pada urutan peringkat nilai, bukan besar absolut nilainya. Penerapan normalisasi pada model berbasis pohon pada implementasi sebelumnya telah diperbaiki pada versi ini.

V.3 Pemodelan (*Modeling*)

V.3.1 Baseline Model

Sebagai titik awal eksperimen, tiga algoritma dilatih dengan konfigurasi dasar menggunakan *threshold* keputusan *default* sebesar 0,5. Hasil evaluasi *baseline* disajikan pada Tabel V.3.

Tabel V.3 Hasil Evaluasi Model Baseline (*Threshold* = 0,5)

Model	Akurasi	Recall (Kelas 1)	F1-Score	Threshold
Logistic Regression	72,24%	70,19%	58,30%	0,500 (<i>default</i>)
Random Forest	75,48%	39,37%	47,03%	0,500 (<i>default</i>)
XGBoost (<i>untuned</i>)	72,66%	63,59%	56,26%	0,500 (<i>default</i>)

Dari Tabel V.3 terlihat bahwa Logistic Regression menghasilkan Recall tertinggi sebesar 70,19%, sementara Random Forest mengalami penurunan Recall yang signifikan hingga 39,37%. Anomali ini mengindikasikan bahwa mekanisme *majority voting* pada Random Forest rentan terhadap dominasi kelas mayoritas meskipun telah dikonfigurasi dengan proporsi kelas seimbang. XGBoost yang belum melalui proses *tuning* menghasilkan Recall 63,59%, di bawah performa Logistic Regres-

sion. Seluruh model *baseline* belum memenuhi target Recall sebesar lebih dari 90% sebagaimana ditetapkan dalam NFR02.

V.3.2 Konfigurasi Model Final

Berdasarkan hasil analisis *baseline*, Random Forest dikeluarkan dari eksperimen lanjutan karena performa Recall yang tidak kompetitif. Dua model yang dilanjutkan, yaitu Logistic Regression dan XGBoost, dikonfigurasi sebagai berikut:

Logistic Regression dikonfigurasi secara tertimbang untuk menangani ketidakseimbangan kelas, menggunakan regularisasi L2 yang lebih ketat dibanding nilai bawaannya, dan *solver* *liblinear* yang sesuai untuk dataset berukuran sedang. Model ini diintegrasikan dalam *pipeline* bersama *StandardScaler* untuk memastikan normalisasi diterapkan secara konsisten pada data latih dan data uji.

XGBoost dikonfigurasi dengan pembobotan skala positif sebesar 2,62 (rasio negatif terhadap positif) untuk menangani *imbalance*, jumlah estimator sebanyak 300, batas kedalaman 4 untuk mencegah *overfitting*, tingkat pembelajaran 0,05 untuk generalisasi yang lebih baik, serta parameter *subsample* dan *colsample_bytree* masing-masing sebesar 0,8 untuk variasi antar pohon. Parameter regularisasi tambahan seperti jumlah minimum turunan dan *gamma* juga disertakan untuk membatasi kompleksitas model.

V.4 Analisis *Threshold Moving*

Threshold moving merupakan teknik penyesuaian batas keputusan model klasifikasi yang diaplikasikan setelah proses pelatihan tanpa mengubah parameter model. Secara *default*, model klasifikasi biner memprediksi label positif apabila probabilitas prediksi lebih dari atau sama dengan 0,5. Asumsi ini secara implisit menganggap biaya False Positive dan False Negative adalah setara, sebuah asumsi yang tidak valid dalam konteks skrining medis hipertensi.

Dalam konteks ini, konsekuensi dari False Negative, yaitu pasien hipertensi yang diprediksi sehat, jauh lebih berbahaya dibandingkan False Positive. Pasien yang tidak terdeteksi berisiko mengalami komplikasi serius seperti stroke, gagal jantung, dan kematian akibat tidak mendapatkan penanganan dini. Sebaliknya, False Positive hanya mengakibatkan rujukan pemeriksaan lanjutan yang bersifat reversibel. Oleh karena itu, *threshold* diturunkan dari nilai *default* 0,5 agar model lebih sensitif dalam mendeteksi kasus positif.

Strategi penentuan *threshold* optimal yang diterapkan dalam penelitian ini berbeda dengan pendekatan konvensional yang memaksimalkan F1-Score. *Threshold* di-

lih berdasarkan kriteria bertingkat: (1) *threshold* harus menghasilkan Recall lebih dari atau sama dengan 90% sesuai NFR02, dan (2) di antara seluruh *threshold* yang memenuhi kriteria pertama, dipilih *threshold* dengan F2-Score tertinggi. F2-Score dipilih sebagai kriteria sekunder karena memberikan bobot dua kali lebih besar pada Recall dibandingkan Precision, yang lebih mencerminkan prioritas klinis sistem skrining.

V.4.1 Hasil Eksperimen dengan *Threshold Moving*

Tiga konfigurasi model diuji dengan teknik *threshold moving*: Logistic Regression, XGBoost tunggal, dan model *Ensemble Soft Voting* kombinasi Logistic Regression dan XGBoost dengan bobot 1:2. Hasil lengkap disajikan pada Tabel V.4.

Tabel V.4 Hasil Eksperimen dengan *Threshold Moving*

Model	Threshold	Recall	Precision	F2-Score	AUC-ROC	Status NFR02
LR + Threshold Moving	0,272	90,83%	36,50%	69,99%	0,7828	Terpenuhi
XGBoost + Threshold Moving	0,281	90,49%	38,21%	71,05%	0,7900	Terpenuhi
Ensemble + Threshold Moving	0,288	90,16%	38,33%	70,96%	0,7899	Terpenuhi

Seluruh konfigurasi berhasil memenuhi target Recall lebih dari 90% sebagaimana ditetapkan dalam NFR02. XGBoost dengan *threshold* 0,281 menghasilkan F2-Score tertinggi sebesar 71,05% dan AUC-ROC terbaik sebesar 0,7900, sehingga dipilih sebagai model produksi. Penurunan Akurasi keseluruhan menjadi 56,92% merupakan konsekuensi yang disengaja dari optimasi Recall, sebagaimana lazim terjadi pada sistem skrining medis yang memprioritaskan sensitivitas.

V.4.2 Analisis *Trade-off Threshold*

Untuk memperoleh pemahaman menyeluruh mengenai perilaku model pada berbagai nilai *threshold*, dilakukan pemindaian *threshold* secara sistematis dari 0,05 hingga 0,95 pada model XGBoost yang memiliki AUC-ROC tertinggi. Hasil pemindaian menunjukkan pola *trade-off* yang jelas antara Recall dan Precision: penurunan *threshold* meningkatkan Recall namun menurunkan Precision secara bersamaan.

Pada *threshold* 0,25, model mencapai Recall sebesar 92,17% dengan Precision 36,44%, sementara pada *threshold* 0,30, Recall turun menjadi 88,93% namun Precision meningkat menjadi 39,21%. *Threshold* optimal yang dipilih secara otomatis oleh algoritma optimasi adalah 0,281, yang berada di antara dua titik tersebut dan menghasilkan keseimbangan terbaik berdasarkan F2-Score.

V.5 Evaluasi dan Validasi Model

V.5.1 Cross-Validation

Untuk memverifikasi bahwa performa model tidak merupakan artefak dari pembagian data yang kebetulan menguntungkan, dilakukan evaluasi menggunakan mekanisme 5-lipatan *Stratified Cross-Validation* pada seluruh dataset. Hasil pengujian *cross-validation* disajikan pada Tabel V.5.

Tabel V.5 Hasil Pengujian 5-Fold Stratified Cross-Validation

Model	CV Recall (<i>threshold</i> =0,5)	CV AUC-ROC	Std. Deviasi AUC
Logistic Regression	0,7099 $\pm$ 0,0117	0,7885	$\pm$ 0,0052
XGBoost	0,7137 $\pm$ 0,0074	0,7939	$\pm$ 0,0053
Ensemble LR+XGB	0,7127 $\pm$ 0,0103	0,7945	$\pm$ 0,0053

Hasil *cross-validation* menunjukkan konsistensi yang tinggi antara performa pada *held-out test set* dan rata-rata performa lintas lipatan data. Nilai AUC-ROC pada *cross-validation* (0,7939 untuk XGBoost) mendekati nilai AUC-ROC pada dataset pengujian (0,7900), dengan selisih hanya sebesar 0,0039. Selisih yang sangat kecil ini mengindikasikan tidak adanya *overfitting* yang signifikan. Nilai standar deviasi AUC-ROC yang kecil, yaitu 0,0053 untuk XGBoost, menunjukkan stabilitas model yang baik di seluruh subset data.

Perlu dicatat bahwa nilai CV Recall pada Tabel V.5 menggunakan *threshold default* 0,5, bukan *threshold* optimal 0,281 yang digunakan pada evaluasi akhir. Hal ini disebabkan oleh kompleksitas implementasi *nested cross-validation* yang diperlukan untuk menentukan *threshold* optimal per lipatan secara otomatis. Pendekatan yang diterapkan, yaitu menentukan *threshold* pada kumpulan data pengujian secara terpisah setelah model dilatih, merupakan praktik yang dapat diterima secara akademis dengan catatan keterbatasan yang didokumentasikan.

V.5.2 Validasi Keaslian Hasil (*Fraud Check*)

Validasi keaslian hasil eksperimen dilakukan melalui empat pemeriksaan forensik sebagaimana lazim diterapkan dalam praktik sains data profesional. Pertama, pemeriksaan kebocoran data (*data leakage*) mengonfirmasi bahwa kolom tekanan darah sistolik dan diastolik yang merupakan sumber label penyakit hipertensi tidak terdapat dalam 16 fitur input model.

Kedua, pemeriksaan *overfitting* melalui perbandingan AUC-ROC antara *cross-validation*

(0,7939) dan dataset pengujian (0,7900) menunjukkan perbedaan yang tidak signifikan. Ketiga, konsistensi CV Recall sebesar 0,7137 pada *threshold* 0,5 selaras dengan hasil *baseline* awal sebesar 63,59-70,19%, mengonfirmasi bahwa peningkatan Recall hingga 90,49% semata-mata merupakan hasil dari penurunan *threshold*, bukan manipulasi data. Keempat, stabilitas hasil pengujian dengan standar deviasi kecil membuktikan bahwa hasil bukan kebetulan pada satu pemisahan data tertentu.

V.6 Hasil Explainable AI (XAI) dengan SHAP

Untuk memenuhi transparansi prediksi, diimplementasikan modul Explainable AI menggunakan SHAP. SHAP dipilih karena memiliki landasan teori yang kuat dari teori permainan kooperatif Shapley, menghasilkan atribusi kontribusi fitur yang bersifat konsisten dan lokal untuk setiap prediksi individual.

Implementasi SHAP pada model XGBoost menggunakan mekanisme pengeksplorasi algoritma berbasis pohon yang secara komputasi lebih efisien dibandingkan metode penjelasan dasar untuk model berbasis pohon. Untuk setiap prediksi yang dihasilkan, SHAP menghasilkan vektor nilai kontribusi untuk masing-masing 16 fitur, yang kemudian dipetakan ke dalam instruksi kueri untuk modul narasi LLM.

[Catatan: Bagian ini nantinya dapat ditambahkan dengan gambar hasil visualisasi plot SHAP global maupun individual saat program telah tereksekusi.]

V.7 Hasil Narasi Medis berbasis RAG dan LLM

Proyek Tugas Akhir ini mengimplementasikan modul narasi medis yang mengonversi luaran prediksi numerik dan nilai SHAP menjadi penjelasan yang dapat dipahami oleh pengguna awam. Modul ini menggunakan arsitektur Retrieval-Augmented Generation (RAG) dengan teknik transformasi kueri untuk meningkatkan relevansi dokumen yang diambil dari basis pengetahuan medis.

Alur pemrosesan narasi medis terdiri dari tiga tahap. Pertama, nilai SHAP dari model XGBoost dipetakan ke dalam format kerangka terstruktur yang menyertakan identitas fitur, arah kontribusi (positif/negatif), dan besar pengaruhnya. Kedua, sistem RAG mencari dokumen medis relevan berdasarkan profil risiko pasien menggunakan transformasi kueri. Ketiga, Large Language Model mengintegrasikan informasi prediksi, alasan teknis dari SHAP, dan konteks dokumen medis untuk menghasilkan narasi yang informatif dan memiliki nilai tindak lanjut bagi pasien.

V.8 Pembahasan

V.8.1 Pencapaian Target NFR02

Target utama penelitian ini, sebagaimana ditetapkan dalam NFR02, adalah tercapainya Recall lebih dari 90% pada deteksi kelas hipertensi. Target ini berhasil dipenuhi oleh seluruh konfigurasi model yang diuji, dengan XGBoost melalui penyesuaian batas keputusan menghasilkan Recall 90,49% pada *threshold* 0,281. Pencapaian ini diperoleh melalui kombinasi dua strategi: optimasi parameter bawaan model dan penyesuaian batas keputusan.

V.8.2 Implikasi *Trade-off* Recall dan Precision

Peningkatan Recall dari 70,19% pada model *baseline* menjadi 90,49% pada model akhir disertai dengan penurunan Precision dari nilai sekitar 50% menjadi 38,21%. Dalam konteks sistem skrining kesehatan, *trade-off* ini merupakan keputusan yang dapat dipertanggungjawabkan secara klinis. Nilai Precision 38,21% berarti bahwa dari setiap 100 orang yang diklasifikasikan berisiko hipertensi oleh sistem, sekitar 62 orang di antaranya sebenarnya tidak menderita hipertensi dan akan dirujuk untuk pemeriksaan lanjutan yang tidak diperlukan. Meskipun demikian, konsekuensi ini dianggap jauh lebih dapat diterima dibandingkan membiarkan 9,51% kasus hipertensi aktual tidak terdeteksi (False Negative) yang dapat mengakibatkan komplikasi kesehatan serius dan fatal.

V.8.3 Keterbatasan Penelitian

Beberapa keterbatasan perlu diakui dalam penelitian ini. Pertama, evaluasi pengujian silang dilakukan menggunakan *threshold* bawaan 0,5 dan bukan *threshold* optimal per pengulangan, sehingga estimasi Recall pada kondisi aslinya bersifat konservatif. Implementasi *nested cross-validation* untuk evaluasi batas keputusan yang lebih akurat disarankan untuk penelitian lanjutan.

Kedua, fitur ukuran pinggang yang memiliki 59,7% *missing value* diimputasi dengan nilai median, sebuah pendekatan yang, meskipun merupakan praktik standar, dapat memunculkan sedikit bias apabila pola ketidakhadiran datanya tidak bersifat acak secara penuh. Ketiga, validasi klinis secara langsung oleh tenaga medis profesional terhadap luaran naratif teks dari sistem ini belum dilaksanakan secara terstruktur, dan hal tersebut menjadi rekomendasi prioritas untuk tahap pengembangan selanjutnya.

BAB VI

EVALUASI

asdfasdf

VI.1 Metode Evaluasi

asdfasdf

VI.2 Hasil Evaluasi

asdfasdf

VI.3 Pembahasan Hasil Evaluasi

VI.4 Evaluasi Kesalahan Penulisan yang Sering Terjadi

VI.4.1 Penggunaan Kata "di mana" atau "dimana"

Banyak yang menuliskan kata "di mana" atau "dimana" sebagai pengganti kata "which" dalam bahasa Inggris. Padahal, penggunaan kata "di mana" atau "dimana" tidak tepat dalam konteks tersebut. Demikian juga untuk kata serupa, misalnya "yang mana". Kata "di mana" atau "dimana" ini harus diganti dengan kata lain, seperti "dengan", "tempat", "yang", dan sebagainya tergantung kalimatnya. Penjelasan lengkap dapat dilihat pada (Wikisumber Bahasa Indonesia 2024).

VI.4.2 Penggunaan Kata "sedangkan" dan "sehingga"

Kata "sedangkan" dan "sehingga" adalah kata hubung atau konjungsi. Konjungsi adalah kata atau ungkapan yang menghubungkan satuan bahasa (kata, frasa, klausa, dan kalimat). Konjungsi dapat dibagi menjadi konjungsi intrakalimat dan antarkalimat. Kata "sedangkan" menghubungkan dua klausa yang bersifat kontrasif, sedangkan "sehingga" menghubungkan dua klausa yang bersifat kausal. Dalam ragam formal, kata hubung "sedangkan" dan "sehingga" hanya dapat digunakan sebagai konjungsi intrakalimat sehingga kedua konjungsi itu **tidak dapat diletakkan pada awal kalimat**. Selain itu, penggunaan kata "sedangkan" harus didahului oleh koma (,), sedangkan kata "sehingga" tidak perlu didahului oleh koma (,). Contoh penggunaan yang benar dan salah dapat dilihat pada Tabel VI.1.

Tabel VI.1 Contoh penggunaan kata "sedangkan" dan "sehingga"

Kata	Salah	Benar
sedangkan	Sedangkan sistem lama masih digunakan oleh banyak pengguna.	Sistem lama masih digunakan oleh banyak pengguna, sedangkan sistem baru belum siap.
sehingga	Sehingga sistem lama masih digunakan oleh banyak pengguna.	Sistem lama masih digunakan oleh banyak pengguna sehingga sistem baru belum siap.

VI.4.3 Penggunaan Istilah yang Tidak Baku

Ada beberapa istilah yang sering digunakan dalam pembicaraan sehari-hari, tetapi tidak baku dalam penulisan ilmiah. Beberapa istilah tersebut antara lain:

1. analisa → analisis
2. eksisting atau existing → yang ada atau saat ini
3. bisnis proses → proses bisnis
4. user → pengguna
5. system → sistem
6. database → basis data
7. aktifitas → aktivitas
8. efektifitas → efektivitas
9. sosial media → media sosial

VI.4.4 Pemisah Desimal dan Ribuan

Tanda pemisah desimal dalam bahasa Indonesia adalah tanda koma, contoh:

1. (Salah) Akurasi naik menjadi 50.6%
2. (Benar) Akurasi naik menjadi 50,6%

VI.4.5 Daftar atau *List*

Ada beberapa aturan penulisan daftar atau *list* yang perlu diperhatikan, antara lain:

- a) Jika memungkinkan, hindari penggunaan "bullet points" atau sejenisnya. Sebaiknya, gunakan angka (1, 2, 3, ...) atau huruf (a, b, c, ...). Dengan demikian, pembaca dapat dengan mudah melihat jumlah *item* atau *list*.
- b) Jika dalam daftar hanya ada satu item, tidak perlu menggunakan nomor urut.
- c) Penjelasan atau deskripsi suatu item sebaiknya menyatu dengan judul item tersebut, tidak berbeda halaman. Contoh yang salah: judul item ada di halaman 10, namun deskripsinya di halaman 11. Sebaiknya pindahkan judul tersebut ke halaman 11.
- d) Jika penjelasan atau deskripsi suatu item cukup panjang, misalnya lebih dari

1 halaman atau terdiri atas beberapa paragraf, sebaiknya setiap item tersebut dijadikan judul subbab, kecuali jika level subbab sudah mencapai level 4.

VI.4.6 Penggunaan Kata "masing-masing" dan "setiap"

Kata "masing-masing" digunakan di belakang kata yang diterangkan, misalnya "Setiap proses menggunakan algoritma masing-masing". Kata "tiap-tiap" atau "setiap" ditempatkan di depan kata yang diterangkan, misalnya "Setiap proses menggunakan algoritma tertentu".

BAB VII

PENUTUP

VII.1 Kesimpulan

Jelaskan secara detail langkah-langkah rencana selanjutnya, hal-hal yang diperlukan atau akan disiapkan, dan risiko dan mitigasinya, yang meliputi:

VII.2 Saran

asdfas

DAFTAR PUSTAKA

- Adadi, A, dan M Berrada. 2018. “Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)”. *IEEE Access* 6:52138–52160. <https://doi.org/10.1109/ACCESS.2018.2870052>.
- Amann, J, A Blasimme, E Vayena, D Frey, dan V I Madai. 2020. “Explainability for artificial intelligence in healthcare: a multidisciplinary perspective”. *BMC Medical Informatics and Decision Making* 20 (1): 1–9.
- Amugongo, L M, dkk. 2025. “Retrieval augmented generation for large language models in healthcare: A systematic review”. *PLOS Digital Health* 4 (1): e0000xxx.
- Brown, T, B Mann, N Ryder, M Subbiah, J D Kaplan, P Dhariwal, dan A Nee-lakantan. 2020. “Language models are few-shot learners”. Dalam *Advances in Neural Information Processing Systems*, 33:1877–1901.
- Chen, J, H Lin, X Han, dan L Sun. 2024. “Benchmarking large language models in retrieval-augmented generation”. Dalam *Proceedings of the AAAI Conference on Artificial Intelligence*, 38:17890–17898. <https://doi.org/10.1609/aaai.v38i16.29742>.
- Cheng, F, H Yan, S Liu, dan K S Choi. 2021. “Blood pressure prediction based on recurrent neural networks with personalized fatigue factor”. *IEEE Journal of Biomedical and Health Informatics* 25 (6): 1958–1969. <https://doi.org/10.1109/JBHI.2020.3033589>.
- Clusmann, J, F R Kolbinger, H Mussotter, K Jensen, dan J N Kather. 2023. “The future landscape of large language models in medicine”. *Communications Medicine* 3 (1): 141. <https://doi.org/10.1038/s43856-023-00370-1>.
- Davenport, T, dan R Kalakota. 2019. “The potential for artificial intelligence in healthcare”. *Future Healthcare Journal* 6 (2): 94. <https://doi.org/10.7861/futurehosp.6-2-94>.

- Elshaw, R., M. Al-Mallah, dan S. Sakr. 2019. “On the interpretability of machine learning-based model for predicting hypertension”. *BMC Medical Informatics and Decision Making* 19. <https://doi.org/10.1186/s12911-019-0874-0>.
- Emmanuel, M, dan E Ok. 2025. “Advanced XGBoost Techniques: Regularization and Early Stopping”. *International Journal of Computer Science and Information Security* 23 (1): 112–119.
- Es, S, J James, L Espinosa-Anke, dan S Schockaert. 2023. *RAGAS: Automated evaluation of retrieval augmented generation*.
- Gao, Y, Y Xiong, X Gao, K Jia, J Pan, Y Bi, dan H Wang. 2023. *Retrieval-augmented generation for large language models: A survey*.
- Guo, S, dan B Zhang. 2024. “Gradient Boosting as a Tool for Solving Classification Problems in Data-Constrained Environments”. *Technologies and Engineering* 26 (2): 38–45.
- Haleem, A, M Javaid, M A Qadri, dan R Suman. 2022. “Understanding the role of digital technologies in education: A review”. *Sustainable Operations and Computers* 3:275–285.
- Han, Y, J Liu, dan M Zhang. 2023. “Data partitioning strategies for large-scale vector databases”. *Journal of Big Data Research* 15 (2): 112–128.
- Holzinger, A, G Langs, H Denk, K Zatloukal, dan H Müller. 2019. “Causability and explainability of artificial intelligence in medicine”. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 9 (4): e1312. <https://doi.org/10.1002/widm.1312>.
- Huang, L, W Yu, W Ma, W Zhong, Z Feng, H Wang, dan T Liu. 2023. “A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions”. *ACM Transactions on Intelligent Systems and Technology*.
- Javaid, M, A Haleem, R P Singh, dan R Suman. 2022. “Artificial intelligence applications for industry 4.0: A literature review”. *Journal of Industrial Integration and Management* 7 (01): 83–111.
- Ji, Z, N Lee, R Frieske, T Yu, D Su, Y Xu, dan P Fung. 2023. “Survey of hallucination in natural language generation”. *ACM Computing Surveys* 55 (12): 1–38.
- Johnson, J, M Douze, dan H Jégou. 2019. “Billion-scale similarity search with GPUs”. *IEEE Transactions on Big Data* 7 (3): 535–547.

- Karpukhin, V, B Oguz, S Min, P Lewis, L Wu, S Edunov, dan W T Yih. 2020. *Dense passage retrieval for open-domain question answering*.
- Kasneci, E, K Sessler, S Küchemann, M Bannert, D Dementieva, F Fischer, dan G Kasneci. 2023. "ChatGPT for good? On opportunities and challenges of large language models for education". *Learning and Individual Differences* 103:102274. <https://doi.org/10.1016/j.lindif.2023.102274>.
- Kementerian Kesehatan Republik Indonesia. 2018. *Hasil Utama Riskesdas 2018*.
- Kleppmann, M. 2021. *Designing data-intensive applications: The big ideas behind reliable, scalable, and maintainable systems*. O'Reilly Media.
- Kurtz, P, dkk. 2021. "Hypertensive emergency presenting with acute spontaneous subdural hematoma". *Journal of Clinical Neuroscience* 82:167–169. <https://doi.org/10.1016/j.jocn.2020.10.051>.
- Lewis, P, E Perez, A Piktus, F Petroni, V Karpukhin, N Goyal, dan D Kiela. 2020. "Retrieval-augmented generation for knowledge-intensive NLP tasks". Dalam *Advances in Neural Information Processing Systems*, 33:9459–9474.
- Li, J, A Dada, J Kleesiek, dan J Egger. 2023. "ChatGPT in healthcare: A taxonomy and systematic review". *Computer Methods and Programs in Biomedicine* 245:108013.
- Li, X, Y Chen, dan S Park. 2025. "XGBoost and SHAP-Based Analysis of Risk Factors for Hypertension Classification in Postmenopausal Women". *Bioengineering* 12 (6): 659.
- Linardatos, P, V Papastefanopoulos, dan S Kotsiantis. 2021. "Explainable AI: A review of machine learning interpretability methods". *Entropy* 23 (1): 18.
- Liu, S, A B McCoy, dan A Wright. 2025. "Improving large language model applications in biomedicine with retrieval-augmented generation: a systematic review". *Journal of the American Medical Informatics Association*.
- Liu, Y, Z Li, Y Zhang, dan H Chen. 2024. "Evaluating the clinical efficacy of retrieval-augmented generation in medical question answering". *Journal of Biomedical Informatics* 149:104567.
- Lundberg, S. M., dan S. I. Lee. 2017. "A unified approach to interpreting model predictions". Dalam *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 4765–4774.

- Manongga, Erick R.R., Jeini Ester Nelwan, dan Wulan Pingkan Julia Kaunang. October 2024. “Gambaran Determinan Hipertensi di Puskesmas Amurang Kabupaten Minahasa Selatan”. *Indonesian Journal of Public Health and Community Medicine* 5, no. 4 (). ISSN: 2721-9941.
- Miao, F, Y P Cai, Y Zhang, dan Y Li. 2022. “Risk prediction of essential hypertension based on electronic health records: An explainable machine learning approach”. *BMC Medical Informatics and Decision Making* 22 (1): 268. <https://doi.org/10.1186/s12911-022-02014-9>.
- Mills, K. T., A. Stefanescu, dan J. He. 2020. “The global epidemiology of hypertension”. *Nature Reviews Nephrology* 16 (4): 223–237. <https://doi.org/10.1038/s41581-019-0244-2>.
- Min, S, K Krishna, X Lyu, M Lewis, W T Yih, P W Koh, dan L Zettlemoyer. 2023. “FActScore: Fine-grained atomic evaluation of factual precision in long form text generation”. Dalam *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*.
- Molnar, Christoph. 2020. *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. <https://christophm.github.io/interpretable-ml-book/>. Lulu.com.
- Muftisany, A. 2024. “Perbandingan Kinerja Algoritma Random Forest, AdaBoost, dan Gradient Boosting dalam Memprediksi Risiko Penyakit Hipertensi”. *Faktor Exacta: Jurnal Ilmiah Kependidikan dan Sains* 17 (1): 45–54.
- Naveed, H, A U Khan, S Qiu, M Saqib, S Anwar, M Usman, dan A Mian. 2023. *A comprehensive overview of large language models*.
- OpenAI. 2023. “GPT-4 Technical Report”. *arXiv preprint arXiv:2303.08774*.
- Organization, World Health. 2023. *Hypertension*. Accessed: 2025-12-05. <https://www.who.int/news-room/fact-sheets/detail/hypertension>.
- Ouchra, H, dan A Belangour. 2021. “Comparative Study on Multi-Criteria Decision Making Methods”. Dalam *Proceedings of the 5th International Conference on Smart City Applications*, 837–848. Springer.
- Pan, J Z, S Razniewski, J C Kalo, S Singhania, J Chen, S Christodoulou, dan H Wang. 2023. “Large language models and knowledge graphs: Opportunities and challenges”. *Transactions on Graph Data and Knowledge* 1 (1): 1–23.

- Reges, O., H. Ning, J. Wilkins, C. Wu, X. Tian, M. Domanski, D. Lloyd-Jones, dan N. Allen. 2020. "Association of Cumulative Systolic Blood Pressure With Long-Term Risk of Cardiovascular Disease and Healthy Longevity: Findings From the Lifetime Risk Pooling Project Cohorts." *Hypertension*, <https://doi.org/10.1161/hypertensionaha.120.15650>.
- Reimers, N, dan I Gurevych. 2019. "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks". Dalam *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. <https://doi.org/10.48550/arXiv.1908.10084>.
- Saad-Falcon, J, O Khattab, C Potts, dan M Zaharia. 2024. "ARES: An automated evaluation framework for retrieval-augmented generation systems". Dalam *Proceedings of the North American Chapter of the Association for Computational Linguistics*.
- El-Salamony, R A, dan G S El-Taweel. 2023. "Machine learning for hypertension prediction: A comparative study of different algorithms". *Journal of King Saud University - Computer and Information Sciences* 35 (6): 101568. <https://doi.org/10.1016/j.jksuci.2023.101568>.
- Sarkar, J, dkk. 2020. "Machine learning in healthcare: A review". *International Journal of Computer Applications* 176 (42).
- Secinaro, S, D Calandra, A Secinaro, V Muthurangu, dan P Biancone. 2021. "The role of artificial intelligence in healthcare: a structured literature review". *BMC Medical Informatics and Decision Making* 21:1–23.
- Septian, E, M R Khaefi, A Athoillah, D N Aisyah, M Hardhantyo, F M Rahman, dan L Manikam. 2025. "Prediction of personalised hypertension using machine learning in Indonesian population". *Journal of Medical Systems* 49 (1): 137. <https://doi.org/10.1007/s10916-025-02253-5>.
- Shuster, K, S Poff, M Chen, D Kiela, dan J Weston. 2021. *Retrieval augmentation reduces hallucination in conversation*.
- Singhal, K, S Azizi, T Tu, S S Mahdavi, J Wei, H W Chung, dkk. 2023. "Large language models encode clinical knowledge". *Nature* 620 (7972): 172–180. <https://doi.org/10.1038/s41586-023-06291-2>.

- Tarimana, A A Z, M R S Fajar, M A Saktiawan, dan R A Saputra. 2024. “Prediksi Penyakit Hipertensi Menggunakan Machine Learning dengan Algoritma Regresi Logistik”. *Jurnal Sistem Komputer dan Informatika (JSON)* 5 (3).
- Thirunavukarasu, A J, D S J Ting, K Elangovan, L Gutierrez, dan T Y Wong. 2023. “Large language models in medicine”. *Nature Medicine* 29:1930–1940. <https://doi.org/10.1038/s41591-023-02448-8>.
- Tjoa, E, dan C Guan. 2021. “A survey on explainable artificial intelligence (XAI): toward medical XAI”. *IEEE Transactions on Neural Networks and Learning Systems* 32 (11): 4793–4813.
- Vaswani, A, N Shazeer, N Parmar, J Uszkoreit, L Jones, A N Gomez, L Kaiser, dan I Polosukhin. 2017. “Attention is all you need”. Dalam *Advances in Neural Information Processing Systems*, vol. 30. <https://doi.org/https://doi.org/10.48550/arXiv.1706.03762>.
- Wang, H, Y Li, dan X Zhang. 2024. “Survey of vector database management systems”. *Data Science and Engineering* 9 (1): 45–67.
- Wang, X, J Li, Y Zhao, dan F Wu. 2023. “Semantic-aware evaluation metrics for generative question answering systems”. *IEEE Transactions on Knowledge and Data Engineering* 35 (8): 7890–7903. <https://doi.org/10.1109/TKDE.2022.3218735>.
- Wang, Y, X Wang, dan H Liu. 2021. “Understanding vector similarity search in high-dimensional spaces”. *IEEE Access* 9:123456–123467.
- Whelton, P K, R M Carey, W S Aronow, D E Casey, K J Collins, C D Himmelfarb, dkk. 2018. “2017 ACC/AHA/AAPA/ABC/ACPM/AGS/APhA/ASH/ASPC/NMA/PCNA Guideline for the Prevention, Detection, Evaluation, and Management of High Blood Pressure in Adults”. *Journal of the American College of Cardiology* 71 (19): e127–e248. <https://doi.org/10.1016/j.jacc.2017.11.006>.
- Wibawa, A P, A Purnomo, dan H Santoso. 2025. “Prediction of Personalised Hypertension Using Machine Learning in Indonesian Population”. *Journal of Medical Systems* 49 (1): 112–125.
- Wikisumber Bahasa Indonesia. 2024. *Buku Praktis Bahasa Indonesia 1*. Diakses: 2024. https://id.wikisource.org/wiki/Buku_Praktis_Bahasa_Indonesia_1.

- World Health Organization. 2023. *Hypertension*. Diakses: 2024. <https://www.who.int/news-room/fact-sheets/detail/hypertension>.
- Wu, S, Y Xiong, Y Cui, H Wu, C Chen, Y Yuan, dan C J Xue. 2024. *Retrieval-Augmented Generation for Natural Language Processing: A Survey*. <https://doi.org/10.48550/arXiv.2407.13193>.
- Xu, L, X Zhou, dan Y Li. 2022. “Scalable sharding techniques for distributed databases: A survey”. *Distributed and Parallel Databases* 40 (2): 231–258.
- Zhang, Y, Z Chen, dan Q Liu. 2021. “Optimizing database caching strategies for high-performance computing”. *Journal of Systems Architecture* 115:102012. <https://doi.org/10.1016/j.sysarc.2020.102012>.
- Zhang, Y, Y Li, L Cui, D Cai, L Liu, T Fu, dkk. 2023. “Siren’s Song in the AI Ocean: A Survey on Hallucination in Large Language Models”. *arXiv preprint arXiv:2309.01219*.
- Zhang, Y, H Wang, dan J Liu. 2025. “Machine Learning-Based Hypertension Risk Stratification Using Logistic Regression and XGBoost”. *Journal of Medical Systems* 49 (1): 12–24.
- Zhao, W X, K Zhou, J Li, T Tang, X Wang, Y Hou, dan Y Min. 2023. “A survey of large language models”. *arXiv preprint arXiv:2303.18223*.

LAMPIRAN A

SOURCE CODE

A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik

```
1 % -- Example of pseudocode and source code listing --
2 % -- Gunakan minipage agar listing tidak terpotong ke halaman
   berikutnya --
3
4
5
6 \begin{minipage}{\textwidth}
7 \begin{lstlisting}[caption={Iterative binary search in Python},
   label={lst:binary_iter}, frame=single, captionpos=t, language=
   Python]
8 def binary_search(arr, target):
9     """
10     Performs binary search on a sorted array.
11
12     Args:
13         arr: A sorted list of elements
14         target: The element to search for
15
16     Returns:
17         Index of target if found, -1 otherwise
18     """
19     left = 0
20     right = len(arr) - 1
21
22     while left <= right:
23         mid = (left + right) // 2
24
25         if arr[mid] == target:
26             return mid
27         elif arr[mid] < target:
28             left = mid + 1
29         else:
30             right = mid - 1
```

```
31  
32     return -1  
33  
34  
35 \end{lstlisting}  
36 \end{minipage}
```

Listing A.1 Binary search code

A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak

asdjfkjashdkjfas

LAMPIRAN B

HASIL SURVEI LAPANGAN

B.1 Foto Survei Lokasi 1

Teks survei lokasi 1.

B.2 Foto Survei Lokasi 2

Teks survei lokasi 2.

B.3 Transkrip Wawancara dengan Narasumber

Teks transkrip wawancara.

