

SISTEM INFORMASI BERBASIS MACHINE LEARNING DAN EXPLAINABLE ARTIFICIAL INTELLIGENCE UNTUK ESTIMASI RISIKO HIPERTENSI

Laporan Tugas Akhir

Oleh

**Samuel Franciscus Togar Hasurungan
18222131**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
Juli 2026**

LEMBAR PENGESAHAN

**Sistem Informasi Berbasis Machine Learning dan Explainable
Artificial Intelligence untuk Estimasi Risiko Hipertensi**

Laporan Tugas Akhir

Oleh

**Samuel Franciscus Togar Hasurungan
18222131**

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Laporan Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 16 Juli 2026

Pembimbing

Prof. Dr. Ir. Suhono Harso Supangkat, M.Eng.

NIP. 19621203198811101

LEMBAR PERNYATAAN

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenar-benarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan tugas akhir ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan laporan tugas akhir.
3. Isi laporan ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 16 Juli 2026

Samuel Franciscus Togar Hasurungan

NIM: 18222131

ABSTRAK

Sistem Informasi Berbasis Machine Learning dan Explainable Artificial Intelligence untuk Estimasi Risiko Hipertensi

oleh

Samuel Franciscus Togar Hasurungan

18222131

Hipertensi adalah salah satu faktor risiko utama yang berkontribusi terhadap terjadinya penyakit kardiovaskular dengan prevalensi yang terus meningkat, namun penanganannya masih cenderung reaktif sehingga banyak kasus baru terdeteksi setelah timbul komplikasi. Pendekatan *machine learning* berpotensi mengestimasi risiko hipertensi lebih dini, tetapi sifat *black box* model menghambat kepercayaan klinis, sementara luaran *Explainable Artificial Intelligence* (XAI) yang berupa nilai numerik sulit dipahami masyarakat awam dan penggunaan *Large Language Model* (LLM) generik rentan terhadap halusinasi medis. Penelitian ini bertujuan merancang dan mengimplementasikan sistem estimasi risiko hipertensi yang mengintegrasikan *machine learning*, XAI, dan LLM agar prediksi tidak hanya akurat, tetapi juga transparan dan komunikatif. Metode yang digunakan mengikuti kerangka CRISP-DM dengan data sekunder *Indonesian Family Life Survey* gelombang kelima (IFLS-5), yang menghasilkan 30.251 responden dewasa dengan delapan fitur non-invasif. Empat algoritma, yaitu *Logistic Regression*, *Random Forest*, *XGBoost*, dan *CatBoost*, dibandingkan, dan *XGBoost* dipilih sebagai model akhir dengan ROC-AUC 0,78 serta *recall* 0,71 pada titik operasi *Youden Index*, sehingga memenuhi kriteria keberhasilan berupa ROC-AUC minimal 0,75 dan *recall* minimal 0,70. Interpretasi model dilakukan menggunakan SHAP (*SHapley Additive exPlanations*), sedangkan narasi penjelasan dibangun melalui arsitektur dua lapisan: seluruh angka, arah pengaruh, dan fakta ditetapkan secara deterministik dari nilai SHAP, sedangkan LLM (*llama-3.1-8b-instant*) hanya bertugas menghaluskan bahasa tanpa mekanisme temu-kembali eksternal (RAG), sehingga risiko halusinasi dapat ditekan. Seluruh komponen diintegrasikan ke dalam purwarupa berbasis web. Hasil validasi oleh seorang dokter umum atas tujuh kasus menunjukkan komponen SHAP memperoleh rerata 3,60 dan komponen narasi LLM 3,93 pada skala Likert 1–5, yang keduanya tergolong valid. Dengan demikian, sistem terbukti mampu menyajikan estimasi risiko hipertensi yang akurat, transparan, dan mudah dipahami, serta layak digunakan sebagai alat bantu skrining awal dan edukasi, bukan sebagai pengganti diagnosis tenaga kesehatan.

Kata kunci: Hipertensi, Machine Learning, Explainable AI, SHAP, Large Language Model.

KATA PENGANTAR

Puji dan syukur senantiasa penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat, kelancaran, serta karunia-Nya, sehingga penyusunan Laporan Tugas Akhir yang berjudul “Sistem Informasi Berbasis *Machine Learning* dan *Explainable Artificial Intelligence* untuk Estimasi Risiko Hipertensi” ini dapat diselesaikan dengan baik. Penyusunan laporan ini merupakan salah satu persyaratan akademik guna meraih gelar Sarjana pada Program Studi Sistem dan Teknologi Informasi, Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung.

Penelitian dan pengembangan sistem dalam Tugas Akhir ini diharapkan mampu memberikan sumbangsih nyata pada bidang teknologi kesehatan. Secara khusus, sistem ini dirancang untuk menghadirkan pendekatan edukasi naratif yang transparan terkait risiko hipertensi menggunakan *Explainable AI*, memberikan alternatif penyampaian informasi yang lebih terstruktur dibandingkan sistem konvensional. Penulis menyadari bahwa perjalanan dalam merancang dan menyusun penelitian ini penuh dengan dinamika serta proses pembelajaran yang sangat berharga.

Tentu saja, penyelesaian tugas akhir ini tidak lepas dari doa, bimbingan, serta dukungan moral maupun material dari orang-orang di sekitar penulis. Oleh karenanya, penulis ingin menghaturkan rasa terima kasih yang mendalam kepada:

1. Keluarga tercinta, khususnya kedua orang tua dan saudara penulis, yang terus memberikan kasih sayang, doa restu, serta motivasi tak terhingga di setiap langkah perjalanan akademik penulis.
2. Keluarga besar di Medan dan Lubuk Pakam, yang mungkin tanpa penulis sadari juga memberikan dukungan dan doa pada penulis.
3. Kakak, yang telah menjadi dukungan mental utama penulis selama keberjalanan pengerjaan tugas akhir ini, yang selalu menghibur penulis dengan guyonan abstrak (tidak jelas tapi lucu), selalu mendorong penulis untuk menyelesaikan tugas akhir ini, dan selalu bersedia membantu di saat penulis membutuhkan bantuan teknis.
4. Mama sebagai partisipan yang telah bersedia meluangkan waktunya untuk meninjau maupun menguji coba sistem yang dikembangkan, atas masukan dan evaluasi yang sangat konstruktif.
5. Bapak sebagai kepala rumah tangga yang selalu dapat diandalkan dan dengan penuh kesediaan membantu penulis dalam mengurus berbagai keperluan ru-

mah tangga, sehingga penulis dapat lebih memfokuskan waktu dan perhatian pada proses penyelesaian tugas akhir.

6. Bapak Prof. Dr. Suhono Harso Supangkat, M.Eng. dan Ir. Devi Willieam Anggara, S.T., M.Phil., Ph.D., IPP, selaku Dosen Pembimbing yang telah meluangkan waktu dan tenaganya untuk membimbing penulis dari awal hingga pengerjaan tugas akhir ini dituntaskan.
7. Seluruh jajaran dosen maupun staf pengajar di lingkungan Program Studi Sistem dan Teknologi Informasi ITB yang telah membekali penulis dengan fondasi ilmu pengetahuan selama masa perkuliahan.
8. Teman-teman penulis di Purwakarta, yang telah memberikan candaan dan kebersamaan pada penulis selama masa pengerjaan TA.
9. Playlist Coffee, cafe yang menjadi tempat penulis untuk beristirahat sejenak dan bersosialisasi dengan teman-teman penulis di Purwakarta.
10. Rekan-rekan seperjuangan dan kolega penulis, atas segala kolaborasi, dukungan, diskusi produktif, serta bantuan teknis yang sangat berarti selama pengerjaan proyek dan masa studi.
11. Kendrick Lamar dan Kanye West, atas karya-karya musiknya yang telah menemani dan menjadi sumber inspirasi bagi penulis pada saat mengalami ke-buntuan ide maupun kekusutan pikiran selama proses pengerjaan tugas akhir.

Penulis sangat menyadari bahwa laporan serta sistem yang dibangun ini masih memiliki ruang untuk penyempurnaan dan jauh dari kata sempurna. Maka dari itu, setiap kritik maupun saran yang membangun akan sangat penulis hargai demi perbaikan dan pengembangan penelitian serupa di masa yang akan datang.

Akhir kata, penulis berharap semoga Tugas Akhir ini dapat memberikan manfaat, inspirasi, dan wawasan baru bagi para pembaca, dunia akademik, serta masyarakat luas.

Bandung, 16 Juli 2026

Penulis,

Samuel Franciscus Togar Hasurungan

DAFTAR ISI

LEMBAR PENGESAHAN	iii
LEMBAR PERNYATAAN	v
ABSTRAK	vii
KATA PENGANTAR	ix
DAFTAR ISI	xi
DAFTAR GAMBAR	xv
DAFTAR TABEL	xvii
DAFTAR ALGORITMA	xix
DAFTAR SINGKATAN	xxi
DAFTAR SIMBOL	xxiii
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	3
I.3 Tujuan	3
I.4 Batasan Masalah	4
I.5 Metodologi	5
I.6 Sistematika Penulisan	7
II STUDI LITERATUR	9
II.1 Hipertensi	9
II.1.1 Faktor Risiko	10
II.1.1.1 Faktor Risiko Tidak Dapat Dimodifikasi	10
II.1.1.2 Faktor Risiko Dapat Dimodifikasi	11
II.2 Machine Learning	14
II.2.1 Algoritma Machine Learning	14
II.2.1.1 Logistic Regression	15
II.2.1.2 Random Forest	15
II.2.1.3 Extreme Gradient Boosting (XGBoost)	15
II.2.1.4 Categorical Boosting (CatBoost)	16
II.2.2 Class Weighting	16
II.2.3 Z-score Normalization	16
II.2.4 Hyperparameter Tuning	17
II.2.5 Optimasi Threshold	17
II.2.6 Metrik Evaluasi	18
II.2.6.1 ROC-AUC	19
II.2.6.2 PR-AUC	20
II.2.6.3 Specificity	20
II.2.6.4 Recall (Sensitivity)	20
II.2.6.5 F1-Score	20
II.2.6.6 Accuracy	21
II.3 Explainable Artificial Intelligence (XAI)	21
II.3.1 Shapley Additive Explanations (SHAP)	21
II.4 Large Language Model (LLM)	23

II.4.1	Keterbatasan LLM	23
II.4.2	Mengatasi Keterbatasan LLM	24
II.5	Prompt Engineering	24
II.5.1	Teknik Perancangan Prompt	24
II.5.2	Prompt Engineering sebagai Mitigasi Halusinasi	25
II.6	Tinjauan Penelitian Sebelumnya	26
III	ANALISIS MASALAH	31
III.1	Analisis Kondisi Saat Ini	31
III.1.1	Skrining Mandiri Berbasis Aplikasi: Skrining Riwayat Kesehatan pada Mobile JKN	31
III.1.2	Prosedur Skrining Hipertensi di Fasilitas Kesehatan Tingkat Pertama	33
III.1.3	Pemanfaatan Teknologi Prediksi Berbasis AI dan Keterbatasannya	34
III.1.4	Kesenjangan Transparansi dan Kepercayaan Klinis	35
III.1.5	Risiko Halusinasi dan Inkonsistensi Informasi Medis	35
III.1.6	Tantangan Kompleksitas Data Multidimensi	36
III.1.7	Identifikasi Kesenjangan (Gap Analysis)	36
III.2	Analisis Kebutuhan	38
III.2.1	Identifikasi Masalah Pengguna	38
III.2.2	Kebutuhan Fungsional	39
III.2.3	Kebutuhan Nonfungsional	40
III.3	Analisis Pemilihan Solusi	41
III.3.1	Alternatif Solusi	41
III.3.2	Analisis Penentuan Solusi	43
IV	PERANCANGAN	45
IV.1	Arsitektur Sistem yang Diusulkan	45
IV.2	Tahapan Perancangan	48
IV.2.1	Perancangan Akuisisi dan Pra-pemrosesan Data	48
IV.2.2	Perancangan Modul Prediksi Risiko	49
IV.2.3	Perancangan Modul Interpretasi (XAI)	51
IV.2.4	Perancangan Modul Narasi	51
IV.3	Rancangan Antarmuka Pengguna	53
IV.4	Diagram Tahapan Keseluruhan Penelitian	56
V	IMPLEMENTASI	59
V.1	Data Understanding	59
V.1.1	Akuisisi Data	59
V.1.1.1	Sumber Data	59
V.1.1.2	Ekstraksi Kolom	60
V.1.2	Eksplorasi Data	67
V.1.2.1	Struktur dan Dimensi Dataset	68
V.1.2.2	Penentuan dan Karakteristik Variabel Target	68
V.1.2.3	Kelengkapan Data dan Statistik Deskriptif	71
V.1.2.4	Analisis Bivariat antara Fitur dan Hipertensi	74

	V.1.2.5 Karakteristik yang Memengaruhi Pemodelan	77
	V.1.2.6 Identifikasi Anomali dan Permasalahan Data	77
V.2	Data Preparation	78
	V.2.1 Profil Dataset Final	84
	V.2.2 Deskripsi Fitur Input	85
V.3	Modelling	86
	V.3.1 Implementasi Machine Learning	86
	V.3.1.1 Pembagian Dataset	86
	V.3.1.2 Strategi Pelatihan Model	87
	V.3.1.3 Evaluasi Baseline	88
	V.3.1.4 Pengaruh StandardScaler	88
	V.3.1.5 Hyperparameter Tuning	89
	V.3.1.6 Hasil Setelah Tuning	90
	V.3.1.7 Optimasi Threshold	91
	V.3.1.8 Confusion Matrix	93
	V.3.1.9 ROC Curve	93
	V.3.1.10Pemilihan Model Terbaik	94
	V.3.2 Implementasi XAI	95
	V.3.2.1 Penetapan Explainer TreeSHAP	96
	V.3.2.2 Analisis Global	96
	V.3.2.3 Ambang Netral dan Kategori Risiko Terendah	102
	V.3.2.4 Analisis Lokal	103
	V.3.2.5 Evaluasi dan Keterbatasan	103
	V.3.3 Implementasi Narasi Medis berbasis Kaidah Deterministik dan LLM	104
	V.3.3.1 Arsitektur Narasi	104
	V.3.3.2 Lapisan Deterministik: Arah, Besaran, dan Barometer	105
	V.3.3.3 Klasifikasi Keandalan Fitur	107
	V.3.3.4 Pembuatan Saran Gaya Hidup	108
	V.3.3.5 Contoh Keluaran	109
	V.3.3.6 Evaluasi dan Keterbatasan	110
V.4	Hasil Implementasi Purwarupa	110
	V.4.1 Lingkungan dan Teknologi Implementasi	111
	V.4.2 Antarmuka dan Alur Penggunaan	111
	V.4.3 Keluaran Sistem	114
VI	EVALUASI	117
VI.1	Evaluasi Kuantitatif (ML)	117
VI.2	Evaluasi Kualitatif (XAI + LLM)	118
	VI.2.1 Metode Evaluasi	118
	VI.2.1.1Strategi Evaluasi	118
	VI.2.1.2Dasar Pemilihan Instrumen	119
	VI.2.1.3Objek dan Prosedur Validasi	119
	VI.2.1.4Metode Analisis Hasil Evaluasi	122
	VI.2.2 Hasil Evaluasi	122
	VI.2.3 Pembahasan Hasil Evaluasi	124

VI.2.3.1	Interpretasi Kualitas Komponen SHAP	124
VI.2.3.2	Interpretasi Kualitas Narasi LLM	125
VI.2.3.3	Keterkaitan Antarkomponen dan Implikasi Sistem .	125
VI.2.3.4	Keterbatasan	126
VI.2.3.5	Rekomendasi Perbaikan Sistem	126
VII	PENUTUP	127
VII.1	Kesimpulan	127
VII.2	Saran	128
Lampiran A	TAUTAN <i>SOURCE CODE</i>	141
A.1	Repositori <i>Frontend</i>	141
A.2	Repositori <i>Backend</i> dan Implementasi Tugas Akhir	141
Lampiran B	<i>EVALUASI KUALITATIF SISTEM</i>	143
B.1	Evaluasi XAI dan LLM pada Sistem Estimasi Risiko Hipertensi . .	143
B.2	Dokumentasi Evaluasi	155
Lampiran C	TAUTAN <i>DIAGRAM</i>	157
C.1	Tahapan Data Understanding	157
C.2	Tahapan Implementasi ML	158

DAFTAR GAMBAR

III.1 Alur mekanisme Skrining Riwayat Kesehatan (SRK) pada aplikasi Mobile JKN	32
III.2 Alur skrining hipertensi di Fasilitas Kesehatan Tingkat Pertama (FK-TP)	34
IV.1 Arsitektur sistem yang diusulkan	46
IV.2 Alur kerja sistem yang diusulkan	48
IV.3 Tahapan pra-pemrosesan data masukan	49
IV.4 Tahapan perancangan modul prediksi risiko	50
IV.5 Tahapan perancangan modul interpretasi (XAI)	51
IV.6 Rancangan arsitektur modul narasi	53
IV.7 Rancangan antarmuka formulir masukan tahap 1	54
IV.8 Rancangan antarmuka formulir masukan tahap 2	54
IV.9 Rancangan antarmuka formulir masukan tahap 3	55
IV.10 Rancangan antarmuka formulir masukan tahap 3	56
IV.11 Diagram Tahapan Keseluruhan Penelitian	57
V.1 Komposisi Kelas Target Hipertensi	69
V.2 Distribusi Tekanan Darah Sistolik	69
V.3 Distribusi Tekanan Darah Diastolik	70
V.4 Sistolik vs Diastolik menurut Status Hipertensi	70
V.5 Persentase Missing Value per Fitur	72
V.6 Korelasi antar Variabel Numerik	73
V.7 Tingkat Hipertensi per Kelompok Umur	75
V.8 Tingkat Hipertensi per Kategori BMI	75
V.9 Tingkat Hipertensi menurut Faktor Biner	76
V.10 Tingkat Hipertensi per Skor Kualitas Tidur	77
V.11 Alur Proses Data Preparation	79
V.12 Confusion matrix model setelah tuning pada ambang Youden	93
V.13 Kurva ROC dan titik Youden tiap model pada data uji	94
V.14 Tingkat Kepentingan Fitur Berdasarkan Rata-rata Nilai Absolut SHAP	96

V.15 Sebaran Nilai SHAP Seluruh Fitur (<i>beeswarm</i>)	97
V.16 Nilai SHAP terhadap Usia	98
V.17 Nilai SHAP terhadap IMT	98
V.18 Nilai SHAP terhadap Jenis Kelamin	99
V.19 Nilai SHAP terhadap Gangguan Tidur	100
V.20 Nilai SHAP terhadap Kualitas Tidur	100
V.21 Nilai SHAP terhadap Status Merokok	101
V.22 Nilai SHAP terhadap Riwayat Diabetes	101
V.23 Nilai SHAP terhadap Riwayat Kolesterol Tinggi	101
V.24 Contoh Analisis Lokal SHAP untuk Satu Individu (Satuan Probabilitas)	104
V.25 Antarmuka pengisian data faktor risiko non-invasif (Langkah 1) . .	112
V.26 Antarmuka pengisian data faktor risiko non-invasif (Langkah 2) . .	113
V.27 Antarmuka pengisian data faktor risiko non-invasif (Langkah 3) . .	113
V.28 Halaman hasil: status risiko, grafik SHAP, dan narasi penjelasan . .	115
 B.1 Dokumentasi Evaluasi 1	 155
B.2 Dokumentasi Evaluasi 2	155
 C.1 Tahapan data understanding Penelitian	 157
C.2 Tahapan pengembangan model Machine Learning Penelitian	158

DAFTAR TABEL

II.1	Studi Sebelumnya	27
III.1	Identifikasi Kesenjangan (Gap Analysis)	37
III.2	Kebutuhan Fungsional	39
III.3	Kebutuhan Non-Fungsional	40
III.4	Pemetaan Masalah dan Dampak	41
III.5	Pemetaan Peluang	42
III.6	Alternatif Solusi	43
III.7	Pemilihan Solusi dengan <i>Weighted Scoring Model</i>	44
IV.1	Alternatif rancangan modul narasi	52
V.1	Berkas Data IFLS yang Digunakan dalam Penelitian	61
V.2	Deskripsi Variabel	64
V.3	Pengelompokan Variabel Berdasarkan Tingkat Nilai Hilang	71
V.4	Statistik Deskriptif Variabel Numerik	73
V.5	Korelasi Point-Biserial Fitur Numerik dengan Hipertensi	74
V.6	Daftar Fitur Terpilih untuk Pemodelan	83
V.7	Profil Dataset Final	84
V.8	Deskripsi Fitur Input Model	85
V.9	Ukuran data latih dan data uji	87
V.10	Proporsi kelas pada data latih dan data uji	87
V.11	Kinerja model baseline pada data uji	88
V.12	Pengaruh StandardScaler pada Logistic Regression	89
V.13	Ruang parameter yang diuji	89
V.14	Kombinasi hyperparameter terbaik	90
V.15	Kinerja model setelah tuning pada data uji	90
V.16	Perubahan ROC-AUC dari baseline ke hasil tuning	90
V.17	Ambang optimal berdasarkan Youden Index	91
V.18	Perbandingan kinerja pada ambang 0,5 dan ambang Youden	92
V.19	Ambang Netral dan Kategori Risiko Terendah Tiap Fitur	102
V.20	Pembagian Tugas Dua Lapisan Penyusun Narasi	105

V.21 Kategori Besaran Pengaruh Berdasarkan Kontribusi Lokal	107
V.22 Tingkat Keandalan Fitur dan Penanganan Teks Fakta	108
V.23 Teknologi yang Digunakan pada Purwarupa	112
VI.1 Rekapitulasi kinerja model terbaik (XGBoost) pada data uji	118
VI.2 Penelusuran aspek instrumen SHAP ke Salih dkk. (2024)	120
VI.3 Penelusuran aspek instrumen LLM ke kerangka QUEST, Tam dkk. (2024)	120
VI.4 Profil tujuh kasus yang divalidasi	121
VI.5 Skala interpretasi rerata skor Likert	122
VI.6 Skor validasi komponen SHAP per kasus	122
VI.7 Skor validasi komponen LLM per kasus	123
VI.8 Hasil validasi komponen SHAP	123
VI.9 Hasil validasi komponen LLM	123

DAFTAR ALGORITMA

V.1	Prapemrosesan dan Persiapan Data Hipertensi	80
V.2	Penyusunan Narasi Penjelasan Berbasis Kaidah Deterministik dan LLM	106

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
AI	<i>Artificial Intelligence</i>	3
ANN	<i>Artificial Neural Network</i>	24
API	<i>Application Programming Interface</i>	4
AUC	<i>Area Under the Curve</i>	6
BMI	<i>Body Mass Index</i>	55
CRISP-DM	<i>Cross-Industry Standard Process for Data Mining</i>	5
FN	<i>False Negative</i>	16
FP	<i>False Positive</i>	16
FR	<i>Functional Requirement</i>	41
HPA	<i>Hypothalamic-Pituitary-Adrenal</i>	12
IFLS	<i>Indonesia Family Life Survey</i>	51
IMT	Indeks Massa Tubuh	11
IPAQ	<i>International Physical Activity Questionnaire</i>	53
ISH	<i>International Society of Hypertension</i>	10
JNC	<i>Joint National Committee</i>	59
JSON	<i>JavaScript Object Notation</i>	41
LIME	<i>Local Interpretable Model-agnostic Explanations</i>	19
LLM	<i>Large Language Model</i>	2
MCC	<i>Matthews Correlation Coefficient</i>	24
ML	<i>Machine Learning</i>	1
NFR	<i>Non-Functional Requirement</i>	41
NLG	<i>Natural Language Generation</i>	37
PR-AUC	<i>Precision-Recall Area Under the Curve</i>	6
RAAS	<i>Renin-Angiotensin-Aldosterone System</i>	9
RAG	<i>Retrieval-Augmented Generation</i>	4
REST	<i>Representational State Transfer</i>	41
ROC	<i>Receiver Operating Characteristic</i>	6
ROC-AUC	<i>Receiver Operating Characteristic – Area Under the Curve</i>	6
SHAP	<i>Shapley Additive Explanations</i>	4

SVM	<i>Support Vector Machine</i>	24
TDD	Tekanan Darah Diastolik	9
TDS	Tekanan Darah Sistolik	9
TN	<i>True Negative</i>	16
TOD	<i>Target Organ Damage</i>	9
TP	<i>True Positive</i>	16
WHO	<i>World Health Organization</i>	59
WSM	<i>Weighted Scoring Matrix</i>	38
XAI	<i>Explainable Artificial Intelligence</i>	2
XGBoost	<i>Extreme Gradient Boosting</i>	13

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
α	Koefisien bobot untuk <i>loss function</i> , tingkat signifikansi statistik	75
β	Koefisien bobot untuk <i>Binary Cross-Entropy loss</i>	75
λ	Koefisien bobot untuk CTC <i>loss</i> , parameter regularisasi	75
θ	Parameter model <i>neural network</i>	75
σ	Deviasi standar	75
μ	Rata-rata (<i>mean</i>)	75
ϵ	<i>Token blank</i> /kosong dalam CTC, konstanta kecil untuk stabilitas numerik	75
Δ	Delta (selisih/perubahan nilai)	75
π	<i>Alignment path</i> dalam CTC	75
π_t	<i>Token</i> pada <i>timestep</i> t dalam <i>alignment path</i>	76
∇ atau ∂	Operator gradien atau turunan parsial	75
$\sum$	Operator penjumlahan	75
$\prod$	Operator perkalian	75
$\int$	Operator integral	75
argmax	Argumen yang memaksimalkan fungsi	76
$\sim$	Terdistribusi menurut	75
$\rightarrow$	Menuju atau konvergen ke	75
$\mathcal{L}$	Fungsi <i>loss</i> (kerugian)	75
$\mathcal{L}_{total}$	Total <i>loss function</i>	75
$\mathcal{L}_{adversarial}$ atau $\mathcal{L}_{adv}$	<i>Adversarial loss</i>	75
$\mathcal{L}_{reconstruction}$	<i>Reconstruction loss</i>	75
$\mathcal{L}_{L1}$	L1 <i>loss</i> (<i>Mean Absolute Error</i>)	75
$\mathcal{L}_{L2}$	L2 <i>loss</i> (<i>Mean Squared Error</i>)	75
$\mathcal{L}_{CTC}$	CTC (<i>Connectionist Temporal Classification</i>) <i>loss</i>	75
$\mathcal{L}_{perceptual}$	<i>Perceptual loss</i>	75

$\mathcal{L}_{pixel}$	<i>Pixel-wise loss</i>	75
$\mathcal{L}_{BCE}$	<i>Binary Cross-Entropy loss</i>	75
$\mathcal{L}_{GAN}$	<i>GAN loss</i>	75
$\mathcal{L}_{cycle}$	<i>Cycle consistency loss</i>	75
G	<i>Generator dalam GAN</i>	75
D	<i>Discriminator dalam GAN</i>	75
$G(z)$	<i>Output dari generator dengan input z</i>	75
$D(x)$	<i>Output dari discriminator dengan input x</i>	75
$G_{A \rightarrow B}$	<i>Generator dari domain A ke B</i>	75
$G_{B \rightarrow A}$	<i>Generator dari domain B ke A</i>	75
$V(D, G)$	<i>Fungsi nilai (value function) dalam GAN</i>	75
x	<i>Sampel data asli, input citra</i>	75
y	<i>Label atau ground truth, kondisi dalam conditional GAN</i>	75
z	<i>Noise vector atau representasi laten</i>	
$\mathbb{E}$	<i>Ekspektasi atau nilai harapan</i>	75
p_{data}	<i>Distribusi data asli</i>	75
p_z	<i>Distribusi prior (noise)</i>	75
$p(y x)$	<i>Probabilitas bersyarat output y given input x</i>	75
$p_t(\pi_t x)$	<i>Probabilitas token pada timestep t</i>	
$\mathcal{B}$	<i>Fungsi penciutan (collapse function) dalam CTC</i>	75
$\mathcal{B}^{-1}$	<i>Fungsi invers penciutan dalam CTC</i>	75
T	<i>Jumlah timestep atau panjang sequence</i>	
$ x - G(y) _1$	<i>L1 distance antara ground truth dan generated image</i>	75
$ x - G(y) _2$	<i>L2 distance antara ground truth dan generated image</i>	75
$N \times N$	<i>Ukuran patch dalam PatchGAN</i>	
d	<i>Cohen's d (effect size)</i>	75
n	<i>Jumlah sampel</i>	75
p	<i>p-value (nilai probabilitas statistik)</i>	75

r	Koefisien korelasi	75
R^2	Koefisien determinasi	
$O(n)$	Notasi Big-O untuk kompleksitas linear	75
$O(n^2)$	Notasi Big-O untuk kompleksitas kuadratik	75

BAB I

PENDAHULUAN

I.1 Latar Belakang

Hipertensi merupakan masalah kesehatan global yang menjadi faktor risiko utama untuk berbagai kondisi kardiovaskular, termasuk stroke dan gagal jantung (Mills, Stefanescu, dan He 2020). Selain itu, berdasarkan estimasi dari Organisasi Kesehatan Dunia, penderita hipertensi di seluruh dunia telah mencapai angka 1,28 miliar orang pada kelompok usia dewasa (World Health Organization 2023). Kementerian Kesehatan Republik Indonesia (2018) juga mencatat bahwa angka kejadian hipertensi di dalam negeri telah menunjukkan prevalensi yang tinggi dan meningkat secara signifikan dari waktu ke waktu. Oleh karena itu, hipertensi menjadi salah satu permasalahan kesehatan masyarakat yang memiliki tingkat urgensi tinggi karena prevalensinya yang terus meningkat serta berpotensi menimbulkan berbagai komplikasi serius apabila tidak dideteksi dan ditangani secara tepat.

Meskipun penanganan hipertensi saat ini telah menjadi prioritas, praktik yang sering dilakukan saat ini masih cenderung bersifat reaktif, yaitu baru dilakukan setelah masalah atau komplikasi muncul (Whelton dkk. 2018). Hal tersebut selaras dengan kutipan oleh Haddadin, Estrella, dan Herzog (2018) yang menyampaikan bahwa intervensi medis biasanya baru berjalan setelah kondisi pasien memburuk secara klinis atau tekanan darahnya terdeteksi sangat tinggi. Pola penanganan yang reaktif ini berisiko besar menyeret pasien ke dalam kondisi darurat seperti krisis hipertensi dan komplikasi lainnya.

Oleh karena itu, pendekatan berbasis *machine learning* kini menjadi salah satu opsi yang sangat potensial dalam melakukan estimasi terhadap risiko hipertensi. Algoritma ML modern terbukti sangat andal dalam memetakan interaksi non-linier yang rumit di antara beragam variabel risiko yang ada (Tarimana dkk. 2024). Namun, implementasi praktis model tersebut di lingkungan klinis masih terkendala oleh sifat black box, dengan sistem masih mungkin untuk mengeluarkan hasil prediksi tanpa disertai dasar penalaran yang logis bagi penggunaanya. Menurut Julia Amann

dkk. (2022), istilah *black box* merujuk pada algoritma kecerdasan buatan, khususnya jaringan saraf tiruan, yang mekanisme kerja internalnya tidak transparan bagi pengguna.

Oleh karena itu, untuk mengatasi hambatan ini, pendekatan Explainable Artificial Intelligence (XAI) dihadirkan untuk mengungkap cara kerja di dalam model agar proses penarikan kesimpulan dapat dirunut kembali secara ilmiah (Adadi dan Berrada 2018). Aspek keterbukaan tersebut juga seharusnya menjadi pilar yang sangat krusial dalam domain informatika medis demi menjaga akuntabilitas tindakan sekaligus untuk memprioritaskan keselamatan pasien di atas apapun (Holzinger dkk. 2019). Meskipun metode XAI mampu memberikan transparansi teknis, hasil yang dikeluarkan biasanya masih berupa data numerik yang tergolong sulit dipahami oleh masyarakat awam (Liao dan Varshney 2021). Berdasarkan analisis sosiologis dari Miller (2019), kesulitan komprehensi ini muncul karena representasi matematis murni dari XAI tidak sejalan dengan cara manusia memproses suatu informasi, sehingga pengguna awam tetap membutuhkan narasi kausal yang lebih intuitif.

Untuk mengatasi masalah ini, studi ini mengintegrasikan teknologi *Large Language Model* (LLM) yang berfungsi mentransformasi hasil interpretasi dari sistem ke dalam bentuk komunikasi bahasa sederhana yang lebih komunikatif dan personal (Thirunavukarasu dkk. 2023). Namun, persoalan dalam penerapan model bahasa generik pada bidang yang krusial seperti kesehatan adalah risiko bias informasi atau fenomena halusinasi data. Secara konseptual, fenomena halusinasi ini merujuk pada anomali komputasional yang memicu algoritma untuk memproduksi keluaran teks dengan struktur bahasa yang koheren, meskipun substansi informasinya merupakan hasil fabrikasi yang keliru secara faktual dan sama sekali tidak memiliki pijakan empiris pada sumber pengetahuan aslinya (Z. Ji dkk. 2023). Oleh karena itu, penelitian ini membatasi peran LLM secara ketat melalui teknik *prompt engineering*, yaitu perancangan instruksi yang menempatkan model semata-mata sebagai penerjemah atas hasil atribusi XAI yang bersifat deterministik, bukan sebagai sumber pengetahuan medis yang berdiri sendiri. Dengan pendekatan ini, keluaran model dikunci pada fakta yang telah dihasilkan sistem serta dilarang mengarang angka maupun klaim medis spesifik, sementara aspek edukasi dibatasi pada anjuran gaya hidup umum yang telah lazim diterima. Melalui strategi tersebut, risiko halusinasi dapat ditekan tanpa memerlukan komponen pencarian pengetahuan eksternal, sekaligus menjaga kesederhanaan dan efisiensi arsitektur sistem.

Berdasarkan latar belakang tersebut, penelitian ini mengusung sebuah metode alter-

natif dan efektif lewat penggabungan model prediksi *machine learning*, interpretasi *Explainable AI*, dan *Large Language Model* ke dalam sistem estimasi risiko hipertensi. Pada sistem ini, LLM akan berfungsi untuk menerjemahkan luaran yang matematis dari XAI menjadi narasi bahasa alami yang personal dan mudah dipahami, sekaligus menyampaikan edukasi gaya hidup umum yang relevan bagi pengguna. Untuk menjaga akuntabilitasnya, peran LLM dikendalikan melalui teknik *prompt engineering* yang mengunci keluaran model pada hasil atribusi XAI sehingga model tidak mengarang klaim medis di luar fakta yang dihasilkan sistem. Dengan demikian, sistem yang diusulkan diharapkan mampu menyajikan estimasi risiko hipertensi yang tidak hanya memiliki tingkat akurasi prediksi yang baik, tetapi juga transparan, mudah dipahami oleh pengguna, serta tetap akuntabel dalam penyampaian informasi medis.

I.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah:

1. Bagaimana membangun model klasifikasi risiko hipertensi berbasis *machine learning* yang mampu membedakan dua kategori risiko dengan kinerja terbaik pada dataset tabular dengan variabel yang beragam?
2. Bagaimana menerapkan metode Explainable Artificial Intelligence (XAI) untuk menghasilkan gambaran fitur yang mempengaruhi prediksi model secara transparan?
3. Bagaimana menerapkan teknik *prompt engineering* dengan LLM untuk mentransformasi luaran teknis XAI menjadi penjelasan naratif yang personal dan mudah dipahami masyarakat awam, sekaligus mengendalikan risiko halusinasi agar model tidak mengarang klaim medis di luar hasil analisis sistem?

I.3 Tujuan

Tujuan utama pelaksanaan Tugas Akhir ini adalah:

1. Menghasilkan sebuah model klasifikasi risiko hipertensi berbasis *machine learning* yang mampu membedakan dua kategori risiko dengan kinerja terbaik berdasarkan dataset tabular dengan variabel fitur yang beragam.
2. Menerapkan metode Explainable Artificial Intelligence (XAI) untuk menghasilkan atribusi fitur yang dapat dipahami oleh pengguna.
3. Mengembangkan modul narasi berbasis LLM melalui teknik *prompt engineering* yang memanfaatkan hasil XAI untuk menjelaskan atribusi fitur terhadap hasil prediksi, menghasilkan penjelasan personal yang mudah dipahami, serta memberikan edukasi gaya hidup umum dengan pengendalian halusinasi me-

lalui rancangan prompt.

I.4 Batasan Masalah

Penelitian ini menetapkan batasan-batasan spesifik untuk menjaga fokus pembahasan dan kelayakan pengerjaan dalam kerangka waktu yang tersedia. Batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian ini menggunakan data sekunder dalam bentuk tabular yang diperoleh dari repositori publik terverifikasi yang sifatnya anonim.
2. Variabel yang digunakan dibatasi pada faktor-faktor risiko hipertensi yang diidentifikasi melalui kajian literatur dan divalidasi melalui konsultasi dengan profesional di bidang medis
3. Model prediksi dikembangkan menggunakan pendekatan Supervised Machine Learning dengan fokus pada kasus klasifikasi biner, yaitu membedakan antara kelas risiko hipertensi dan non-hipertensi.
4. Implementasi XAI dibatasi pada metode *post-hoc* berbasis Shapley Additive Explanations (SHAP), yaitu algoritma TreeSHAP yang sesuai untuk model prediksi berbasis pohon (*tree ensemble*), untuk menghasilkan nilai atribusi fitur. Metode ini dipilih untuk menjelaskan kontribusi setiap variabel terhadap prediksi akhir model tanpa mengubah struktur internal model prediksi itu sendiri.
5. Penelitian ini memanfaatkan LLM yang telah dilatih sebelumnya melalui antarmuka pemrograman aplikasi (API) atau model lokal yang sudah terkuantisasi. Penelitian tidak mencakup proses fine-tuning atau pelatihan ulang model bahasa secara keseluruhan, melainkan berfokus pada teknik prompt engineering untuk mengarahkan dan membatasi keluaran model.
6. Modul penjelasan berbasis LLM dibatasi pada penerjemahan hasil atribusi XAI menjadi narasi bahasa alami dan edukasi gaya hidup umum. Penelitian ini tidak menggunakan basis pengetahuan eksternal maupun mekanisme retrieval (RAG). Pengendalian akurasi dilakukan sepenuhnya melalui perancangan prompt yang melarang model mengarang angka atau klaim medis spesifik di luar fakta yang telah dihasilkan sistem.
7. Hasil akhir penelitian ini adalah purwarupa perangkat lunak berbasis web yang berfungsi sebagai alat skrining awal dan edukasi bagi masyarakat awam. Luaran dari sistem ini tidak diperuntukkan sebagai diagnosis medis yang mutlak, melainkan hanya sebagai informasi pendukung awal, sehingga tidak dapat menggantikan diagnosis resmi dari dokter atau tenaga kesehatan profesional.
8. Identifikasi faktor risiko hipertensi pada penelitian ini dibatasi pada pedoman WHO dan Kementerian Kesehatan Republik Indonesia (Kemenkes RI) kare-

na keduanya merupakan pedoman resmi yang disusun berdasarkan sintesis berbagai bukti ilmiah dan evaluasi para ahli, sehingga lebih representatif dibandingkan mengacu pada satu atau beberapa penelitian individual.

9. Penelitian ini hanya mengakuisisi sebagian kuesioner pada dataset IFLS-5 yang memuat variabel terkait faktor risiko hipertensi. Pemilihan modul dan variabel didasarkan pada hasil studi literatur terhadap faktor risiko hipertensi di pedoman klinis terverifikasi, yaitu WHO dan Kementerian Kesehatan Republik Indonesia, sehingga kuesioner yang tidak relevan dengan faktor tersebut tidak diikutsertakan dalam penelitian.

I.5 Metodologi

Penelitian ini mengadopsi kerangka kerja CRISP-DM (*Cross-Industry Standard Process for Data Mining*) yang terdiri atas enam tahap utama sebagai berikut:

1. Business Understanding

Tahap ini merupakan tahap fondasi yang bertujuan untuk mendefinisikan masalah penelitian secara presisi serta membangun landasan teoretis yang kuat. Pertama-tama, investigasi awal dilakukan secara mendalam untuk mengumpulkan fakta empiris yang mendasari latar belakang masalah. Kegiatan ini mencakup penelusuran data statistik kesehatan global dari World Health Organization dan data nasional dari Kementerian Kesehatan Republik Indonesia guna memvalidasi urgensi hipertensi sebagai komorbiditas utama. Selain itu, dilakukan analisis kesenjangan teknologi untuk mengidentifikasi hambatan adopsi kecerdasan artifisial di ranah klinis, khususnya terkait isu transparansi model, yang kemudian menjadi dasar perumusan solusi. Untuk memperkuat dasar penelitian, dilakukan studi literatur pada basis data bereputasi seperti IEEE Xplore, PubMed, dan ScienceDirect. Pencarian informasi difokuskan pada pengumpulan teori dan metode state-of-the-art dengan menggunakan kata kunci spesifik pada komponen-komponen utama penelitian, yaitu hipertensi, ML, XAI, dan LLM. Hasil kajian tersebut kemudian menjadi dasar teori dalam penelitian ini, yang dituliskan dalam Bab II Studi Literatur.

2. Data Understanding

Setelah tujuan penelitian ditetapkan, langkah berikutnya adalah memahami data yang akan digunakan. Pada tahap ini, peneliti terlebih dahulu mengidentifikasi faktor-faktor risiko hipertensi melalui kajian literatur dan konsultasi dengan dokter umum sebagai dasar dalam menentukan variabel penelitian. Selanjutnya, dataset sekunder yang diperoleh dari sumber publik terverifikasi dianalisis untuk memastikan ketersediaan variabel-variabel tersebut. Proses pemahaman data meliputi peninjauan karakteristik dataset, jenis dan definisi

setiap variabel, distribusi data, serta identifikasi potensi permasalahan seperti nilai yang hilang, inkonsistensi data, dan ketidakseimbangan distribusi kelas. Selain itu, dilakukan evaluasi terhadap kesesuaian variabel yang tersedia dengan kebutuhan penelitian sehingga hanya faktor-faktor risiko yang relevan yang digunakan pada tahap pemodelan. Pemahaman yang menyeluruh terhadap karakteristik data menjadi landasan dalam menentukan strategi prapemrosesan yang tepat, sehingga proses pengembangan model dapat dilakukan secara lebih andal dan menghasilkan performa yang optimal.

3. Data Preparation

Pada tahap ini, data dipersiapkan agar bisa digunakan oleh algoritma *machine learning*. Proses yang dilakukan meliputi pembersihan data untuk menangani nilai yang hilang atau *outliers*, dan mengubah data kategorikal menjadi bentuk numerik. Setelah semua proses selesai, *dataset* kemudian dipartisi ke dalam data pelatihan dan data pengujian. Data pelatihan digunakan sebagai dasar pembentukan model, sementara data pengujian dimanfaatkan untuk mengukur kemampuan generalisasi model terhadap data baru yang tidak digunakan selama tahap pelatihan.

4. Modelling

Tahap pemodelan merupakan inti dari proses pengembangan sistem pada penelitian ini. Pada tahap ini, beberapa algoritma *machine learning* dilatih menggunakan data yang telah dipersiapkan pada tahap sebelumnya. Kinerja setiap model kemudian dievaluasi menggunakan beberapa metrik evaluasi, yaitu ROC-AUC, PR-AUC, Recall (Sensitivity), Specificity, Accuracy, dan F1-Score. Model dengan performa terbaik selanjutnya diinterpretasikan menggunakan metode Explainable Artificial Intelligence (XAI), yaitu SHAP (*SHapley Additive exPlanations*), untuk mengidentifikasi kontribusi setiap fitur terhadap hasil prediksi yang dihasilkan model. Dengan demikian, hasil prediksi tidak hanya berupa keluaran klasifikasi, tetapi juga disertai penjelasan mengenai faktor-faktor yang memengaruhi keputusan model.

Selanjutnya, hasil interpretasi dari metode XAI dimanfaatkan sebagai masukan bagi *Large Language Model* (LLM) yang dikendalikan melalui teknik *prompt engineering*. Prompt dirancang untuk mengarahkan LLM dalam mengubah hasil atribusi fitur menjadi narasi bahasa alami yang personal, mudah dipahami, serta dilengkapi edukasi gaya hidup umum yang relevan. Selain itu, prompt juga menerapkan berbagai batasan untuk mengurangi risiko halusinasi, seperti mencegah model menghasilkan nilai numerik, interpretasi, maupun klaim medis yang tidak didukung oleh informasi yang diberikan sis-

tem. Melalui pendekatan ini, sistem diharapkan mampu menghasilkan penjelasan yang lebih mudah dipahami tanpa mengurangi ketepatan dan konsistensi informasi yang disampaikan.

5. Evaluation

Tahap evaluasi dilakukan secara bertahap terhadap setiap komponen sistem. Evaluasi diawali dengan pengukuran performa model klasifikasi menggunakan metrik evaluasi yang sudah disebutkan. Selanjutnya, hasil analisis kontribusi fitur yang dihasilkan oleh SHAP divalidasi oleh profesional di bidang medis (dokter) untuk menilai kesesuaiannya dengan pengetahuan medis. Terakhir, kualitas narasi yang dihasilkan LLM dievaluasi oleh profesional di bidang medis berdasarkan aspek faktualitas medis, konsistensi terhadap hasil atribusi SHAP, koherensi bahasa, serta potensi halusinasi dengan mengacu pada pedoman klinis dan informasi yang tersedia pada sistem.

6. Deployment

Tahap terakhir dalam penelitian ini adalah pengembangan purwarupa aplikasi berbasis web. Model yang sudah dilatih dan dievaluasi diintegrasikan ke dalam aplikasi agar dapat digunakan oleh pengguna secara langsung.

I.6 Sistematika Penulisan

Sistematika penulisan laporan tugas akhir ini memberikan panduan bagi pembaca tentang struktur dan alur pembahasan. Berikut adalah sistematika penulisannya:

1. Bab I Pendahuluan: Berisi latar belakang, rumusan masalah, tujuan, batasan masalah, metodologi, dan sistematika penulisan laporan tugas akhir.
2. Bab II Studi Literatur: Berisi kajian pustaka yang relevan dengan topik tugas akhir, termasuk teori-teori, konsep-konsep, dan hasil-hasil penelitian sebelumnya yang mendukung pelaksanaan tugas akhir.
3. Bab III Analisis: Berisi penjelasan tentang analisis masalah dan kebutuhan pengguna serta berbagai alternatif solusinya.
4. Bab IV Perancangan: Berisi penjelasan tentang perancangan solusi yang diusulkan, misalnya arsitektur sistem, desain basis data, antarmuka pengguna, dan sebagainya.
5. Bab V Implementasi: Berisi penjelasan tentang proses implementasi solusi yang diusulkan, termasuk langkah-langkah yang diambil, teknologi yang digunakan, dan hasil yang diperoleh.
6. Bab VI Evaluasi: Berisi analisis dan evaluasi terhadap solusi yang diimplementasikan, termasuk metode pengujian, hal-hal yang disiapkan sebelum pengujian, hasil pengujian, dan penilaian kinerja.
7. Bab VII Kesimpulan dan Saran: Berisi kesimpulan dari hasil pelaksanaan

tugas akhir dan saran untuk pengembangan lebih lanjut.

8. Daftar Pustaka: Berisi daftar referensi yang digunakan dalam penyusunan laporan tugas akhir.
9. Lampiran: Berisi dokumen-dokumen pendukung seperti kode program, data lengkap hasil pengujian, rekaman wawancara, dan lain-lain.

BAB II

STUDI LITERATUR

II.1 Hipertensi

Hipertensi secara global didefinisikan sebagai suatu kondisi hemodinamik kronis yang ditandai dengan meningkatnya tekanan darah di arteri secara persisten. Menurut konsensus medis internasional terbaru, hipertensi bukan sekadar angka tekanan darah yang tinggi, melainkan sindrom kardiovaskular progresif yang memicu perubahan struktural dan fungsional pada pembuluh darah serta organ vital (Reges dkk. 2020). Dalam konteks fisiologis, kondisi ini terjadi apabila tekanan darah sistolik mencapai sedikitnya 140 mmHg maupun tekanan darah diastolik sedikitnya 90 mmHg, setelah dilakukan pengukuran berulang di klinik (Reges dkk. 2020). International Society of Hypertension (ISH) juga mendukung klaim tersebut, menyatakan bahwa hipertensi pada orang dewasa yaitu diatas 18 tahun, umumnya ditegakkan apabila tekanan darah sistolik mencapai ≥ 140 mmHg dan/atau tekanan darah diastolik mencapai ≥ 90 mmHg. (Unger dkk. 2020). Tekanan darah sistolik menunjukkan tekanan yang dihasilkan ketika jantung berkontraksi untuk memompa darah ke seluruh tubuh, sedangkan tekanan darah diastolik mencerminkan tekanan ketika jantung berada pada fase relaksasi di antara dua denyut. (Whelton dkk. 2018)

Penyakit ini sering dikenal sebagai *the silent killer* karena sebagian besar penderita tidak menunjukkan gejala klinis yang spesifik hingga terjadi kerusakan organ target atau *Target Organ Damage* (TOD) seperti hipertrofi ventrikel kiri, gagal ginjal kronis, atau retinopati (Mills, Stefanescu, dan He 2020). Prevalensi hipertensi terus meningkat secara global, didorong oleh penuaan populasi dan pergeseran gaya hidup, dengan data terbaru menunjukkan bahwa lebih dari 1,28 miliar orang dewasa berusia 30–79 tahun di seluruh dunia hidup dengan hipertensi, dengan dua pertiga di antaranya tinggal di negara berpenghasilan rendah dan menengah (World Health Organization 2023).

Di Indonesia, hipertensi masih menjadi tantangan kesehatan utama dengan tingkat pengendalian yang rendah. Studi epidemiologi terbaru menunjukkan bahwa preva-

lensi hipertensi di Indonesia tidak hanya didominasi oleh lansia, tetapi mulai merambah ke populasi usia produktif akibat transisi nutrisi dan penurunan aktivitas fisik (Manongga, Nelwan, dan Kaunang October 2024). Patofisiologi hipertensi melibatkan interaksi kompleks antara curah jantung dan resistensi vaskular perifer, yang diatur oleh sistem saraf simpatis, sistem renin-angiotensin-aldosteron (RAAS), dan keseimbangan cairan tubuh. Ketidakseimbangan pada salah satu mekanisme ini dapat memicu vasokonstriksi berkepanjangan yang berujung pada elevasi tekanan darah sistemik.

Hipertensi adalah salah satu faktor risiko utama penyakit kardiovaskular dan berkontribusi terhadap tingginya angka morbiditas maupun mortalitas di seluruh dunia (World Health Organization 2023). Apabila tidak dikendalikan dengan baik, hipertensi dapat menyebabkan berbagai komplikasi serius, seperti penyakit jantung koroner, gagal jantung, stroke, penyakit ginjal kronis, retinopati, serta meningkatkan risiko kematian dini (World Health Organization 2023). Oleh karena itu, deteksi dini, pengendalian faktor risiko, dan pengelolaan hipertensi secara berkelanjutan menjadi langkah penting untuk mencegah terjadinya komplikasi dan meningkatkan kualitas hidup penderita.

II.1.1 Faktor Risiko

Menurut Black dan Hawks (2014), faktor risiko hipertensi terklasifikasi menjadi dua, yaitu faktor risiko yang tidak dapat dimodifikasi dan faktor risiko yang dapat dimodifikasi. Pembagian serupa juga digunakan dalam konsensus klinis nasional yang mengelompokkan faktor risiko kardiovaskular pada pasien hipertensi (Perhimpunan Dokter Hipertensi Indonesia 2021). Identifikasi faktor-faktor ini krusial karena interaksi antar variabel tersebutlah yang akan dianalisis oleh model komputasi untuk menghasilkan prediksi yang akurat.

II.1.1.1 Faktor Risiko Tidak Dapat Dimodifikasi

1. Usia

Bertambahnya usia merupakan salah satu faktor risiko hipertensi yang tidak dapat dimodifikasi. (Mills, Stefanescu, dan He 2020) Seiring proses penuaan, pembuluh darah mengalami perubahan struktural dan fungsional, seperti berkurangnya elastisitas arteri, peningkatan kekakuan pembuluh darah, serta penurunan kemampuan endotel dalam mempertahankan homeostasis vaskular. (Benetos, Petrovic, dan Strandberg 2019) Perubahan tersebut menyebabkan resistensi vaskular perifer meningkat sehingga jantung memerlukan tekanan yang lebih besar untuk mengalirkan darah ke seluruh tubuh. (Benetos,

Petrovic, dan Strandberg 2019) Selain itu, berbagai studi epidemiologi menunjukkan bahwa prevalensi hipertensi meningkat secara progresif seiring bertambahnya usia, terutama setelah memasuki usia paruh baya.(Mills, Stefanescu, dan He 2020) Oleh karena itu, individu berusia lanjut umumnya memiliki risiko lebih tinggi mengalami hipertensi dibandingkan kelompok usia yang lebih muda.

2. Jenis Kelamin

Perbedaan jenis kelamin diketahui memengaruhi risiko seseorang mengalami hipertensi (Reckelhoff 2018). Pada usia dewasa muda, wanita umumnya memiliki tekanan darah yang lebih rendah dibandingkan pria karena hormon estrogen berperan dalam mempertahankan fungsi endotel, meningkatkan vasodilatasi, serta memberikan efek protektif terhadap sistem kardiovaskular (Reckelhoff 2018). Namun, setelah memasuki masa menopause, kadar estrogen menurun sehingga efek perlindungan tersebut berkurang dan risiko hipertensi pada wanita meningkat (H. Ji dkk. 2020). Oleh karena itu, jenis kelamin perlu dipertimbangkan sebagai faktor yang berkontribusi terhadap risiko hipertensi.

3. Genetik dan Riwayat Keluarga

Faktor genetik merupakan salah satu faktor risiko hipertensi yang tidak dapat dimodifikasi (Padmanabhan, Caulfield, dan Dominiczak 2015). Individu yang memiliki riwayat hipertensi pada orang tua atau saudara kandung cenderung memiliki risiko lebih tinggi untuk mengalami hipertensi dibandingkan individu tanpa riwayat keluarga (Mills, Stefanescu, dan He 2020). Kondisi tersebut berkaitan dengan adanya pewarisan variasi gen yang memengaruhi regulasi tekanan darah, fungsi ginjal, keseimbangan natrium, serta sistem renin–angiotensin–aldosteron (Padmanabhan, Caulfield, dan Dominiczak 2015). Kombinasi perubahan pada mekanisme tersebut dapat meningkatkan kecenderungan terjadinya peningkatan tekanan darah (Padmanabhan, Caulfield, dan Dominiczak 2015).

II.1.1.2 Faktor Risiko Dapat Dimodifikasi

1. Obesitas dan Indeks Massa Tubuh (IMT)

Terdapat korelasi linier yang kuat antara peningkatan indeks massa tubuh dan tekanan darah, dan obesitas diperkirakan berkontribusi terhadap sebagian besar kasus hipertensi primer (Parvanova dkk. 2024). Jaringan adiposa yang berlebih, terutama lemak visceral dan perirenal, memicu hipertensi melalui aktivasi berlebih sistem saraf simpatis dan sistem renin–angiotensin–aldosteron, kompresi fisik pada ginjal, serta peningkatan reabsorpsi natrium yang beru-

jung pada ekspansi volume cairan (Parvanova dkk. 2024). Organisasi Kesehatan Dunia juga menempatkan kelebihan berat badan dan obesitas sebagai salah satu faktor risiko metabolik utama hipertensi yang dapat dimodifikasi (World Health Organization 2023).

2. Asupan Garam (Natrium)

Konsumsi natrium yang berlebihan merupakan salah satu determinan utama peningkatan tekanan darah melalui peningkatan volume cairan ekstraseluler dan disfungsi endotel. Tinjauan sistematis dan meta-analisis terhadap uji acak terkontrol menunjukkan bahwa pengurangan asupan natrium menurunkan tekanan darah secara bergantung dosis, baik pada individu hipertensi maupun normotensi (Huang dkk. 2020). Oleh karena itu, pembatasan asupan garam harian menjadi salah satu intervensi gaya hidup paling hemat biaya untuk pengendalian hipertensi (World Health Organization 2023).

3. Kurangnya Aktivitas Fisik

Gaya hidup sedentari berkaitan dengan penurunan kebugaran kardiorespirasi dan peningkatan resistensi insulin yang meningkatkan risiko hipertensi (Hayes dkk. 2022). Sebaliknya, aktivitas fisik teratur terbukti menurunkan tekanan darah melalui perbaikan fungsi endotel, penurunan resistensi vaskular sistemik, dan penurunan aktivitas simpatis (Hayes dkk. 2022). Aktivitas fisik yang tidak memadai juga termasuk faktor risiko hipertensi yang direkomendasikan untuk dikendalikan oleh Organisasi Kesehatan Dunia (World Health Organization 2023).

4. Merokok

Zat kimia dalam rokok, terutama nikotin, memicu pelepasan katekolamin yang menyebabkan vasokonstriksi akut dan peningkatan denyut jantung, sementara paparan kronis menimbulkan inflamasi sistemik tingkat rendah dan kekakuan arteri (Gao dkk. 2023). Studi berbasis populasi menunjukkan bahwa merokok berkaitan dengan peningkatan risiko hipertensi, dengan risiko yang lebih besar pada perokok berat (Gao dkk. 2023).

5. Faktor Psikososial dan Stres

Stres merupakan respons fisiologis tubuh terhadap tuntutan atau ancaman yang, pada kondisi akut, bersifat adaptif melalui aktivasi sumbu *Hypothalamic–Pituitary–Adrenal* (HPA) dan sistem saraf simpatis untuk mempertahankan homeostasis (Russell dan Lightman 2019). Aktivasi ini memicu pelepasan hormon kortisol serta katekolamin, terutama norepinefrin dan epinefrin, yang secara sementara meningkatkan denyut jantung, curah jantung, dan resistensi vaskular perifer sehingga tekanan darah naik. Pada stres akut, kenaikan

tekanan darah tersebut bersifat sementara dan umumnya kembali normal setelah stresor mereda. Namun, ketika paparan stres berlangsung terus-menerus atau kronis, aktivasi kedua sistem tersebut menjadi berkepanjangan dan berpotensi menimbulkan perubahan yang menetap pada regulasi tekanan darah (Spruill 2010).

Paparan stres kronis menyebabkan peningkatan kadar kortisol dan katekolamin secara persisten yang memicu vasokonstriksi berkelanjutan, aktivasi sistem *Renin–Angiotensin–Aldosterone System* (RAAS), retensi natrium, serta *vascular remodeling* (Scalco dkk. 2005). Rangkaian perubahan fisiologis ini meningkatkan resistensi vaskular perifer dan volume cairan tubuh sehingga tekanan darah cenderung menetap pada level yang lebih tinggi. Selain melalui jalur fisiologis langsung, stres kronis juga berkontribusi secara tidak langsung dengan mendorong perilaku tidak sehat seperti pola makan buruk, konsumsi alkohol, merokok, dan gangguan tidur yang turut meningkatkan risiko hipertensi (Spruill 2010). Kombinasi kedua jalur tersebut menjadikan stres psikososial sebagai salah satu faktor risiko hipertensi yang dapat dimodifikasi.

Bukti epidemiologis mengenai hubungan stres dan hipertensi terus berkembang meskipun belum sepenuhnya konsisten. Tinjauan sistematis oleh Sparrenberger dkk. (2009) menyimpulkan bahwa stres akut hanya menimbulkan kenaikan tekanan darah sementara, tetapi sejumlah studi kohort menunjukkan bahwa stres psikososial kronis serta faktor psikososial lain seperti kecemasan berkaitan dengan peningkatan kejadian hipertensi. Temuan tersebut diperkuat oleh meta-analisis Gasperin dkk. (2009) terhadap studi kohort yang menemukan bahwa individu dengan tingkat stres psikologis tinggi memiliki risiko peningkatan tekanan darah yang lebih besar, meskipun besar efeknya tergolong moderat. Dengan demikian, stres dan faktor psikososial merupakan aspek penting yang perlu dipertimbangkan dalam penilaian risiko hipertensi.

6. Diabetes Melitus

Diabetes melitus dan hipertensi kerap muncul secara bersamaan karena berbagai mekanisme patofisiologis yang sama, meliputi resistensi insulin, disfungsi endotel, dan aktivasi sistem renin–angiotensin–aldosteron (Petrie, Guzik, dan Touyz 2018). Hipertensi dilaporkan sekitar dua kali lebih sering ditemukan pada penderita diabetes dibandingkan individu tanpa diabetes, dan koeksistensi kedua kondisi tersebut secara substansial meningkatkan risiko komplikasi kardiovaskular (Petrie, Guzik, dan Touyz 2018). Oleh karena itu, status diabetes merupakan faktor risiko penting yang perlu diperhitungkan dalam penilaian risiko hipertensi.

7. Kolesterol Tinggi (Dislipidemia)

Dislipidemia, khususnya kadar *Low-Density Lipoprotein* (LDL) yang tinggi, memicu disfungsi endotel yang menjadi tahap awal aterosklerosis serta gangguan kemampuan pembuluh darah untuk berdilatasi (Higashi 2023). Gangguan fungsi endotel ini dapat berkontribusi terhadap peningkatan tekanan darah, antara lain melalui aktivasi sistem renin–angiotensin–aldosteron, vaso-konstriksi, dan retensi natrium (Higashi 2023). Dengan demikian, kadar kolesterol yang tinggi kerap menyertai dan memperberat kondisi hipertensi.

8. Kualitas Tidur

Kualitas dan durasi tidur yang buruk berkaitan dengan peningkatan risiko hipertensi. Meta-analisis menunjukkan bahwa kualitas tidur subjektif yang buruk berhubungan dengan peningkatan kemungkinan terjadinya hipertensi (Lo dkk. 2018). Mekanisme yang mendasari mencakup peningkatan tonus simpatik yang menetap serta terganggunya penurunan tekanan darah pada malam hari (*nocturnal dipping*), yang dalam jangka panjang dapat memicu hipertensi (Lo dkk. 2018). Oleh karena itu, kualitas tidur menjadi faktor gaya hidup yang layak untuk dipertimbangkan dalam penilaian risiko hipertensi.

II.2 Machine Learning

Machine learning merupakan salah satu bidang dalam kecerdasan buatan yang berfokus pada pengembangan model komputasi agar mampu mengenali pola dari data dan menghasilkan prediksi tanpa bergantung pada aturan yang ditentukan secara eksplisit (Sarker 2021). Dalam konteks prediksi risiko hipertensi, permasalahan yang dihadapi tergolong klasifikasi biner terawasi (*supervised binary classification*), yaitu memetakan sekumpulan fitur faktor risiko pasien ke dalam salah satu dari dua kelas: berisiko atau tidak berisiko (Sarker 2021). Data yang digunakan pada penelitian ini bersifat tabular dengan kombinasi fitur numerik dan kategorikal, sehingga pemilihan algoritma difokuskan pada metode yang secara empiris menunjukkan kinerja kuat pada karakteristik data tersebut. Bagian ini membahas algoritma klasifikasi yang digunakan, teknik penanganan ketidakseimbangan kelas, normalisasi fitur, penyetelan hiperparameter, serta metrik yang dipakai untuk mengevaluasi kinerja model.

II.2.1 Algoritma Machine Learning

Bagian ini menguraikan empat algoritma klasifikasi yang dievaluasi dalam penelitian ini, yaitu Logistic Regression sebagai model linear *baseline*, serta tiga model berbasis *ensemble* pohon keputusan: Random Forest, XGBoost, dan CatBoost. Keempatnya dipilih karena secara konsisten dilaporkan berkinerja baik pada masalah

klasifikasi data tabular di ranah kesehatan (Septian dkk. 2025). Logistic Regression diikuti sebagai pembanding karena sifatnya yang sederhana dan mudah diinterpretasi, sedangkan ketiga model *ensemble* dipertimbangkan karena kemampuannya menangkap hubungan non-linear antar faktor risiko. Perbandingan keempat algoritma bertujuan menemukan model dengan keseimbangan terbaik antara akurasi prediksi dan kestabilan kinerja pada data yang tidak seimbang.

II.2.1.1 Logistic Regression

Logistic Regression adalah metode klasifikasi statistik yang memodelkan probabilitas suatu kejadian biner sebagai fungsi logistik dari kombinasi linear fitur masukan (Hosmer, Lemeshow, dan Sturdivant 2013). Model ini mengestimasi koefisien untuk setiap fitur sehingga besar maupun arah pengaruh masing-masing faktor risiko terhadap peluang hipertensi dapat dibaca secara langsung, misalnya melalui nilai *odds ratio*. Keunggulan utamanya terletak pada kesederhanaan komputasi dan interpretabilitas yang tinggi, sehingga algoritma ini kerap dijadikan *baseline* dalam studi prediksi penyakit (Zhang, Wang, dan Liu 2025). Namun, karena mengasumsikan hubungan linear antara fitur dan *log-odds*, model ini cenderung kurang optimal dalam menangkap interaksi kompleks dan pola non-linear yang umum ditemukan pada data klinis (Tarimana dkk. 2024).

II.2.1.2 Random Forest

Random Forest merupakan algoritma *ensemble* yang menggabungkan banyak pohon keputusan (*decision trees*) untuk menghasilkan prediksi yang lebih akurat dan stabil dibandingkan pohon tunggal (Breiman 2001). Setiap pohon dilatih pada subset data yang dibentuk melalui *bootstrap* (*bagging*) dengan pemilihan fitur acak pada tiap percabangan, sehingga antarpohon memiliki korelasi rendah dan kesalahan individual saling menetralkan. Prediksi akhir diperoleh melalui pemungutan suara mayoritas untuk klasifikasi, yang membuat model relatif tahan terhadap *overfitting* dan *noise*. Mekanisme keacakan ganda ini menjadikan Random Forest andal pada data tabular kesehatan, meskipun kinerjanya pada dataset berskala besar dapat tertinggal dibandingkan metode *boosting* modern (S dkk. 2024).

II.2.1.3 Extreme Gradient Boosting (XGBoost)

Extreme Gradient Boosting (XGBoost) adalah implementasi *gradient boosting* yang membangun pohon keputusan secara berurutan, dengan setiap pohon baru difokuskan untuk memperbaiki kesalahan residual dari gabungan pohon sebelumnya (Chen dan Guestrin 2016). Berbeda dengan *gradient boosting* standar, XGBoost menyisipkan regularisasi (*L1* dan *L2*) pada fungsi objektifnya untuk mengendalikan kom-

pleksitas model dan menekan risiko *overfitting* (Chen dan Guestrin 2016). Algoritma ini juga dirancang untuk efisiensi komputasi melalui pemrosesan paralel dan penanganan nilai hilang secara internal, sehingga mampu mengolah data dalam jumlah besar dengan cepat. Karakteristik tersebut menjadikan XGBoost salah satu algoritma paling banyak digunakan dan berkinerja tinggi dalam prediksi risiko penyakit berbasis data tabular (Li, Chen, dan Park 2025).

II.2.1.4 Categorical Boosting (CatBoost)

CatBoost adalah algoritma *gradient boosting* yang dikembangkan dengan penekanan khusus pada penanganan fitur kategorikal secara efisien (Prokhorenkova dkk. 2018). Untuk menghindari kebocoran informasi target (*target leakage*) yang lazim terjadi pada teknik *target encoding* konvensional, CatBoost menerapkan *ordered target statistics* yang menghitung nilai encode hanya dari data yang muncul sebelumnya dalam suatu urutan acak. Selain itu, algoritma ini menggunakan *ordered boosting* untuk mengurangi bias pada estimasi gradien sehingga model yang dihasilkan lebih stabil dan tahan terhadap *overfitting*. Keunggulan tersebut membuat CatBoost sering menunjukkan performa kompetitif pada data tabular, termasuk pada studi prediksi penyakit di populasi Indonesia (Septian dkk. 2025).

II.2.2 Class Weighting

Ketidakseimbangan kelas (*class imbalance*) terjadi ketika jumlah sampel pada suatu kelas jauh lebih sedikit dibandingkan kelas lainnya, kondisi yang umum ditemukan pada data medis karena penderita suatu penyakit biasanya lebih sedikit daripada individu sehat (He dan Garcia 2009). Ketimpangan ini menyebabkan model cenderung bias terhadap kelas mayoritas dan gagal mengenali kelas minoritas yang justru menjadi fokus utama deteksi dini. *Class weighting* merupakan pendekatan pada tingkat algoritma yang mengatasi masalah tersebut dengan memberikan bobot lebih besar pada kesalahan klasifikasi kelas minoritas di dalam fungsi kerugian (*loss function*). Berbeda dengan metode *resampling* yang mengubah distribusi data, teknik ini mempertahankan data asli sehingga tidak berisiko menghilangkan informasi maupun menghasilkan sampel sintetik yang menyesatkan (Krawczyk 2016).

II.2.3 Z-score Normalization

Z-score normalization adalah teknik penskalaan fitur numerik yang mentransformasikan setiap nilai menjadi skor standar berdasarkan rata-rata dan simpangan baku distribusinya (Patro dan Sahu 2015). Hasil transformasi menghasilkan fitur dengan rata-rata nol dan simpangan baku satu, sehingga fitur-fitur dengan rentang nilai yang sangat berbeda, misalnya usia dan indeks massa tubuh, berada pada skala yang se-

tara. Penyeragaman skala ini penting agar tidak ada fitur yang mendominasi proses pelatihan semata-mata karena rentang nilainya lebih besar. Teknik ini khususnya bermanfaat bagi algoritma yang sensitif terhadap skala fitur seperti Logistic Regression, sementara pada model berbasis pohon pengaruhnya cenderung minimal namun tetap menjaga konsistensi tahap praproses (Patro dan Sahu 2015).

II.2.4 Hyperparameter Tuning

Hyperparameter adalah parameter konfigurasi model yang nilainya ditetapkan sebelum proses pelatihan dan tidak dipelajari langsung dari data, seperti *learning rate*, jumlah pohon, dan kedalaman maksimum pohon (Bergstra dan Bengio 2012). Hyperparameter tuning merupakan proses pencarian kombinasi nilai hyperparameter yang menghasilkan kinerja model terbaik pada data validasi. Untuk menilai setiap kombinasi secara andal, kinerja umumnya diukur menggunakan validasi silang k-lipatan (*k-fold cross-validation*), yaitu membagi data latih menjadi k bagian dan menggilir salah satunya sebagai data validasi agar estimasi kinerja tidak bergantung pada satu pembagian data tertentu. Pencarian kombinasi tersebut dapat dilakukan dengan beberapa strategi, di antaranya *grid search* yang menelusuri seluruh kombinasi secara sistematis dan *random search* yang mengambil sampel kombinasi secara acak. Bergstra dan Bengio (2012) menunjukkan bahwa *random search* sering kali lebih efisien daripada *grid search* karena mampu menemukan konfigurasi yang baik dengan jumlah percobaan yang lebih sedikit, terutama ketika hanya sebagian hyperparameter yang berpengaruh signifikan terhadap kinerja.

II.2.5 Optimasi Threshold

Model klasifikasi biner umumnya menghasilkan probabilitas atau skor risiko yang perlu diubah menjadi keputusan kelas melalui suatu nilai ambang (*threshold*). Ambang bawaan sebesar 0,5 tidak selalu merupakan titik operasi terbaik, terutama pada data tidak seimbang atau ketika kesalahan pada salah satu kelas lebih merugikan daripada kelas lainnya. Optimasi threshold bertujuan mencari nilai ambang yang paling sesuai dengan prioritas permasalahan, misalnya menyeimbangkan sensitivity dan specificity atau memaksimalkan penangkapan kasus positif. Salah satu metode yang umum digunakan adalah Youden Index (J), yang dihitung sebagai selisih antara *true positive rate* dan *false positive rate* ($J = TPR - FPR$); ambang dengan nilai J tertinggi dipilih karena merepresentasikan titik operasi yang paling menjauh dari garis tebakan acak pada kurva ROC (Habibzadeh, Habibzadeh, dan Yadollahie 2016).

Dalam konteks tugas akhir ini, titik operasi Youden dipilih karena paling sesuai de-

ngan karakteristik permasalahan yang dihadapi, yaitu deteksi dini risiko hipertensi pada data yang tidak seimbang. Secara geometris, nilai J setara dengan jarak vertikal antara suatu titik pada kurva ROC dan garis diagonal tebakan acak, sehingga ambang dengan J tertinggi merupakan titik yang memaksimalkan selisih antara proporsi kasus positif yang berhasil dideteksi (*sensitivity*) dan proporsi kasus negatif yang keliru ditandai sebagai positif ($1 - \text{specificity}$) (Habibzadeh, Habibzadeh, dan Yadollahie 2016). Titik tersebut merepresentasikan keseimbangan terbaik antara kemampuan menangkap individu berisiko dan kemampuan menghindari alarm palsu. Kriteria Youden juga tidak bergantung pada proporsi kelas dalam data sehingga tetap stabil pada kondisi kelas minoritas yang jarang dan tidak tertarik ke arah kelas mayoritas sebagaimana ambang yang dioptimalkan semata-mata berdasarkan *accuracy* (Perkins dan Schisterman 2006). Perlu ditegaskan bahwa kriteria Youden bukan mekanisme utama untuk memprioritaskan kelas positif, melainkan diterapkan di atas model yang sebelumnya telah dibuat sensitif terhadap kelas hipertensi melalui pembobotan kelas (*class weighting*) pada tahap pelatihan. Prioritas untuk menekan kasus terlewat (*false negative*) ditegaskan terutama pada tahap pemodelan, yaitu melalui metrik yang berorientasi pada *recall* serta ambang *recall* minimum yang ditetapkan sejak awal sebagai syarat kelayakan model. Pada sistem skrining hipertensi, kesalahan melewatkan individu berisiko (*false negative*) memang dinilai lebih merugikan karena menunda upaya pencegahan, tetapi alarm palsu (*false positive*) tetap membebani alur rujukan pemeriksaan lanjutan sehingga tidak dapat diabaikan. Oleh karena itu, di antara berbagai titik operasi yang mungkin, ambang Youden dipilih karena memberikan keseimbangan yang reproduktibel dan tidak bergantung pada proporsi kelas; apabila di kemudian hari dikehendaki postur yang lebih agresif dalam menekan *false negative*, ambang keputusan dapat diturunkan untuk memenuhi target *recall* tertentu tanpa melatih ulang model karena keluaran probabilitas tetap dipertahankan.

II.2.6 Metrik Evaluasi

Evaluasi kinerja model klasifikasi memerlukan metrik yang sesuai dengan karakteristik data, terutama pada kasus ketidakseimbangan kelas yang membuat sebagian metrik menjadi kurang representatif. Sebagian besar metrik diturunkan dari *confusion matrix* yang memuat jumlah *true positive* (TP), *true negative* (TN), *false positive* (FP), dan *false negative* (FN). Bagian ini menguraikan metrik-metrik yang digunakan untuk menilai kualitas prediksi model dalam penelitian ini. Penggunaan beberapa metrik secara bersamaan bertujuan memberikan gambaran kinerja yang lebih menyeluruh sekaligus menghindari kesimpulan yang menyesatkan.

Keempat komponen *confusion matrix* tersebut didefinisikan berdasarkan kesesuaian antara kelas hasil prediksi dan kelas sebenarnya, dengan kelas positif pada penelitian ini merepresentasikan individu yang berisiko hipertensi (Fawcett 2006). *True positive* (TP) adalah jumlah individu berisiko hipertensi yang diprediksi dengan benar sebagai berisiko, sedangkan *true negative* (TN) adalah jumlah individu yang tidak berisiko dan diprediksi dengan benar sebagai tidak berisiko. Kedua komponen ini merepresentasikan prediksi yang tepat, sehingga semakin besar nilainya menandakan kinerja model yang semakin baik dalam mengenali kedua kelas secara benar.

Sebaliknya, *false positive* (FP) menyatakan individu yang sebenarnya tidak berisiko tetapi diprediksi berisiko, sementara *false negative* (FN) menyatakan individu yang sebenarnya berisiko tetapi diprediksi tidak berisiko (Sokolova dan Lapalme 2009). Dalam konteks deteksi dini hipertensi, kedua jenis kesalahan ini memiliki konsekuensi yang berbeda: FN berpotensi lebih berbahaya karena individu yang benar-benar berisiko tidak terdeteksi sehingga kehilangan kesempatan untuk memperoleh intervensi dini, sedangkan FP menimbulkan kekhawatiran dan pemeriksaan lanjutan yang sebenarnya tidak diperlukan. Perbedaan konsekuensi ini tidak diatasi dengan membiarkan titik operasi model, melainkan melalui pemilihan metrik yang berorientasi pada *recall* serta penetapan ambang *recall* minimum sebagai syarat kelayakan model pada tahap pemodelan, sehingga kepekaan terhadap kasus positif tetap diutamakan tanpa mengabaikan beban *false positive*. Karena hampir seluruh metrik evaluasi, seperti *recall*, *specificity*, *precision*, dan F1-Score, diturunkan dari keempat komponen tersebut, pemahaman terhadap TP, TN, FP, dan FN menjadi dasar penting dalam menilai kualitas prediksi model (Sokolova dan Lapalme 2009).

II.2.6.1 ROC-AUC

ROC-AUC (*Area Under the Receiver Operating Characteristic Curve*) mengukur kemampuan model dalam membedakan mana kelas positif dan yang negatif di seluruh nilai ambang (*threshold*) klasifikasi (Fawcett 2006). Kurva ROC dibentuk dengan memplot *true positive rate* terhadap *false positive rate*, dan luas area di bawahnya merepresentasikan probabilitas model memberikan skor lebih tinggi pada sampel positif acak dibandingkan sampel negatif acak. Nilai ROC-AUC berkisar dari 0,5 yang setara dengan tebakan acak hingga 1,0 yang menandakan pemisahan sempurna antar kelas. Karena tidak bergantung pada satu ambang tertentu, metrik ini kerap digunakan sebagai ukuran kinerja umum pada klasifikasi biner (Fawcett 2006).

II.2.6.2 PR-AUC

PR-AUC (*Area Under the Precision-Recall Curve*) mengukur luas area di bawah kurva yang memplot *precision* terhadap *recall* pada berbagai nilai ambang (Saito dan Rehmsmeier 2015). Metrik ini berfokus pada kinerja model terhadap kelas positif sehingga lebih informatif dibandingkan ROC-AUC ketika kelas positif jauh lebih sedikit daripada kelas negatif. Pada kondisi tersebut, ROC-AUC dapat memberikan kesan optimistis yang menyesatkan, sementara PR-AUC lebih realistis menggambarkan *trade-off* antara ketepatan dan kelengkapan deteksi kasus positif (Saito dan Rehmsmeier 2015). Nilai dasar (*baseline*) PR-AUC bergantung pada proporsi kelas positif dalam data, sehingga interpretasinya harus mempertimbangkan tingkat ketidakseimbangan dataset (Saito dan Rehmsmeier 2015).

II.2.6.3 Specificity

Specificity mengukur proporsi kasus negatif yang berhasil diklasifikasikan dengan benar oleh model, yaitu rasio *true negative* terhadap seluruh kasus yang sebenarnya negatif (Sokolova dan Lapalme 2009). Metrik ini mencerminkan kemampuan model dalam menghindari *false positive*, yakni menghindari pelabelan individu sehat sebagai berisiko. Dalam konteks skrining hipertensi, specificity yang rendah dapat menimbulkan kekhawatiran berlebih serta pemeriksaan lanjutan yang sebenarnya tidak diperlukan. Oleh karena itu, specificity umumnya dianalisis berdampingan dengan sensitivity untuk menilai keseimbangan kinerja model pada kedua kelas (Sokolova dan Lapalme 2009).

II.2.6.4 Recall (Sensitivity)

Recall, yang juga dikenal sebagai sensitivity, mengukur proporsi kasus positif yang berhasil dikenali dengan benar oleh model, yaitu rasio *true positive* terhadap seluruh kasus yang sebenarnya positif (Sokolova dan Lapalme 2009). Metrik ini sangat penting pada aplikasi medis karena kegagalan mendeteksi individu yang benar-benar berisiko (*false negative*) dapat berakibat fatal akibat tertundanya penanganan. Nilai recall yang tinggi memastikan sebagian besar penderita terdeteksi, meskipun konsekuensinya dapat berupa peningkatan jumlah *false positive*. Dalam sistem deteksi dini hipertensi, recall kerap dijadikan salah satu metrik prioritas karena biaya melewati kasus positif jauh lebih besar daripada biaya alarm palsu (Sokolova dan Lapalme 2009).

II.2.6.5 F1-Score

F1-Score adalah rata-rata harmonik (*harmonic mean*) dari precision dan recall yang merangkum keduanya ke dalam satu nilai tunggal (Sokolova dan Lapalme 2009).

Penggunaan rata-rata harmonik membuat metrik ini hanya bernilai tinggi apabila precision dan recall sama-sama tinggi, sehingga model tidak dapat memperoleh skor baik dengan mengorbankan salah satunya. Karakteristik tersebut menjadikan F1-Score lebih representatif dibandingkan accuracy pada data yang tidak seimbang, terutama ketika baik *false positive* maupun *false negative* sama-sama memiliki konsekuensi penting. F1-Score banyak digunakan pada domain medis ketika ketepatan dan kelengkapan deteksi sama-sama diperhitungkan (Sokolova dan Lapalme 2009).

II.2.6.6 Accuracy

Accuracy mengukur proporsi prediksi yang benar terhadap keseluruhan prediksi yang dibuat oleh model (Sokolova dan Lapalme 2009). Metrik ini populer karena mudah dipahami dan dihitung, namun dapat menyesatkan pada kasus klasifikasi dengan distribusi kelas yang timpang. Sebagai contoh, pada dataset dengan mayoritas kelas negatif, model yang selalu memprediksi kelas mayoritas tetap memperoleh accuracy tinggi meskipun gagal mengenali satu pun kasus positif. Oleh karena itu, accuracy sebaiknya tidak digunakan sendirian, melainkan dilengkapi metrik lain seperti F1-Score, ROC-AUC, atau PR-AUC agar penilaian kinerja lebih holistik (Sokolova dan Lapalme 2009).

II.3 Explainable Artificial Intelligence (XAI)

Penerapan Machine Learning dalam praktik klinis sering terhambat oleh sifat *black box* dari model berkinerja tinggi seperti XGBoost, yang proses pengambilan keputusannya sulit ditelusuri oleh manusia. Explainable Artificial Intelligence (XAI) hadir sebagai solusi untuk memberikan transparansi terhadap keputusan yang dihasilkan oleh sistem cerdas sehingga alasan di balik setiap prediksi dapat dipahami (Adadi dan Berrada 2018). Transparansi ini krusial di ranah kesehatan karena tenaga medis perlu memahami dasar suatu prediksi sebelum menggunakannya dalam pengambilan keputusan yang menyangkut keselamatan pasien. Di antara berbagai metode XAI yang tersedia, penelitian ini menggunakan Shapley Additive Explanations (SHAP) karena landasan teoretisnya yang kuat serta konsistensi penjelasannya, dibandingkan metode alternatif seperti Local Interpretable Model-agnostic Explanations (LIME) yang penjelasannya cenderung kurang stabil pada eksekusi berulang (Molnar 2025).

II.3.1 Shapley Additive Explanations (SHAP)

Metode SHAP merupakan pendekatan XAI yang mengadopsi konsep teori permainan kooperatif untuk menghitung kontribusi marginal (*Shapley value*) setiap fitur terhadap hasil prediksi model (Lundberg dan Lee 2017). Lundberg dan Lee (2017)

memperkenalkan SHAP sebagai kerangka terpadu (*unified framework*) yang menyatukan berbagai metode atribusi fitur ke dalam satu kelas metode aditif, dan membuktikan bahwa nilai Shapley merupakan satu-satunya solusi yang secara simultan memenuhi tiga aksioma yang diinginkan, yaitu *local accuracy* (jumlah kontribusi seluruh fitur setara dengan selisih antara prediksi aktual dan prediksi rata-rata model), *missingness*, dan *consistency*. Sifat aditif dan berbasis aksioma inilah yang menjadikan SHAP lebih unggul dibandingkan metode berbasis perturbasi lokal seperti LIME, yang penjelasannya dapat berubah-ubah untuk data yang sama pada setiap iterasi eksekusi (Molnar 2025). Karena stabilitas dan konsistensi penjelasan merupakan syarat penting dalam sistem pendukung keputusan medis, SHAP dipilih sebagai metode interpretasi utama dalam penelitian ini untuk mengidentifikasi kontribusi tiap faktor risiko terhadap prediksi hipertensi.

Tantangan utama dalam penerapan nilai Shapley terletak pada beban komputasinya. Perhitungan nilai Shapley secara eksak pada kasus umum menuntut evaluasi seluruh kemungkinan koalisi fitur sehingga kompleksitasnya tumbuh secara eksponensial terhadap jumlah fitur. Oleh karena itu, pendekatan SHAP yang bersifat *model-agnostic* umumnya hanya mengestimasi nilai Shapley melalui penarikan sampel, sehingga hasilnya bersifat aproksimatif dan tetap berbeban komputasi tinggi (Lundberg dan Lee 2017). Untuk mengatasi keterbatasan tersebut pada model berbasis pohon, Lundberg dkk. (2020) mengembangkan TreeSHAP, yaitu algoritma yang dirancang khusus (*model-specific*) untuk model berbasis pohon. Dengan memanfaatkan struktur pohon keputusan, TreeSHAP mampu menghitung nilai Shapley secara eksak (*exact Shapley values*) dalam waktu polinomial, yaitu $O(TLD^2)$ dengan T menyatakan jumlah pohon, L jumlah daun maksimum pada suatu pohon, dan D kedalaman maksimum pohon, alih-alih waktu eksponensial pada perhitungan langsung. Selain menghasilkan atribusi lokal yang eksak, Lundberg dkk. (2020) juga menunjukkan bahwa nilai TreeSHAP dapat diagregasikan untuk memperoleh pemahaman global mengenai perilaku model, sehingga satu metode yang sama dapat menjelaskan prediksi baik pada tingkat individu maupun populasi.

Model yang digunakan pada penelitiann ini mayoritas merupakan model *tree ensemble*. Berdasarkan landasan teori tersebut, metode interpretasi yang dipilih adalah TreeSHAP karena secara khusus dikembangkan untuk model berbasis pohon dan mampu menghitung nilai Shapley secara eksak sekaligus efisien (Lundberg dkk. 2020). Pemilihan TreeSHAP memastikan bahwa atribusi fitur yang dihasilkan merupakan kontribusi yang tepat sesuai perilaku model, bukan hasil aproksimasi, sebuah syarat penting bagi sistem pendukung keputusan medis yang menuntut penjelasan yang

akurat dan dapat dipertanggungjawabkan. Landasan teori pemilihan TreeSHAP ini menjadi acuan pada tahap perancangan dan implementasi modul interpretasi yang dibahas pada Bab IV dan Bab V.

II.4 Large Language Model (LLM)

Large Language Model (LLM) merupakan evolusi mutakhir dalam domain Artificial Intelligence, khususnya dalam pemrosesan bahasa alami. LLM adalah model probabilitas yang dirancang untuk memahami, memproses, dan menghasilkan teks dengan tingkat koherensi yang menyerupai kemampuan manusia (Naveed dkk. 2023).

Arsitektur dasar dari teknologi ini mengandalkan teknik Deep Learning dan model statistik canggih untuk menganalisis korpus data teks dalam skala masif. Melalui pelatihan pada dataset berskala besar, model ini mampu mengidentifikasi pola linguistik yang kompleks, hubungan semantik antar kata, serta nuansa kontekstual yang terkandung dalam bahasa (Kasneci dkk. 2023).

Dalam ranah *Generative AI*, kemampuan LLM tidak terbatas pada pemahaman teks semata, melainkan juga mencakup kemampuan untuk menciptakan konten orisinal yang mengadopsi gaya dan karakteristik data pelatihannya. Salah satu implementasi paling dominan dari teknologi ini adalah ChatGPT, sebuah model generatif yang dioptimalkan untuk dialog interaktif (OpenAI 2023).

Model-model ini dilatih menggunakan pendekatan *Unsupervised Learning* atau *Self-Supervised Learning*, yang memungkinkan mereka mempelajari struktur bahasa tanpa memerlukan pelabelan data manual secara ekstensif (Brown dkk. 2020). Fundamental teknologi di balik LLM adalah arsitektur Transformer, yang memperkenalkan mekanisme *attention* untuk menangani ketergantungan jarak jauh dalam urutan data. Hal ini memungkinkan model untuk mempertahankan konteks pembicaraan atau dokumen yang panjang, menjadikannya sangat efektif untuk aplikasi seperti penerjemahan otomatis, *chatbot* cerdas, dan pembuatan ringkasan teks otomatis (Vaswani dkk. 2017; Naveed dkk. 2023).

II.4.1 Keterbatasan LLM

Penerapan LLM di bidang medis menghadapi tantangan serius terkait fenomena halusinasi, yaitu kondisi saat model menghasilkan informasi yang terdengar meyakinkan namun faktanya salah atau dibuat-buat (Z. Ji dkk. 2023). Selain itu, LLM memiliki batasan pengetahuan statis atau *knowledge cutoff* yang membuatnya tidak mengetahui informasi atau pedoman medis terbaru yang rilis setelah tanggal pelatihan model.

II.4.2 Mengatasi Keterbatasan LLM

Berbagai strategi dikembangkan untuk memitigasi keterbatasan tersebut. Salah satu pendekatan adalah *fine-tuning* yang melatih ulang model dengan dataset spesifik, namun metode ini membutuhkan sumber daya komputasi yang besar dan data berlabel berkualitas tinggi. Pendekatan alternatif yang lebih efisien adalah *In-Context Learning* melalui *prompt engineering*, yaitu menyertakan informasi relevan secara langsung di dalam instruksi masukan tanpa mengubah bobot model. Kemampuan model bahasa berskala besar untuk mempelajari pola tugas hanya dari contoh dan konteks yang disertakan dalam *prompt*, tanpa pembaruan parameter, pertama kali ditunjukkan secara empiris pada model GPT-3 (Brown dkk. 2020). Karena tidak memerlukan pelatihan ulang, pendekatan ini menghindari kebutuhan akan sumber daya komputasi besar maupun dataset berlabel spesifik-tugas yang menjadi prasyarat *fine-tuning*, sehingga lebih ringan, murah, dan fleksibel untuk diterapkan pada domain spesifik (Liu dkk. 2023). Keunggulan efisiensi inilah yang menjadikan *in-context learning* melalui *prompt engineering* sebagai strategi yang dipilih dalam penelitian ini untuk mengarahkan keluaran LLM tanpa beban pelatihan ulang model.

II.5 Prompt Engineering

Prompt engineering merupakan disiplin perancangan instruksi masukan (*prompt*) yang bertujuan mengarahkan perilaku Large Language Model (LLM) agar menghasilkan keluaran sesuai kebutuhan tugas tanpa mengubah parameter internal model (Brown dkk. 2020). Berbeda dengan *fine-tuning* yang menuntut pelatihan ulang dan sumber daya komputasi besar, prompt engineering memanfaatkan kemampuan *in-context learning* model, yaitu kemampuan LLM untuk menyesuaikan respons hanya berdasarkan konteks dan contoh yang disertakan di dalam prompt (Brown dkk. 2020). Pendekatan ini menjadikan prompt engineering sebagai metode yang ringan, murah, dan fleksibel untuk mengendalikan LLM pada aplikasi spesifik domain tanpa modifikasi bobot model.

II.5.1 Teknik Perancangan Prompt

Terdapat beberapa teknik dasar yang umum digunakan dalam perancangan prompt (Naveed dkk. 2023):

1. **Zero-shot prompting**

Model diberikan instruksi tugas secara langsung tanpa menyertakan contoh. Teknik ini mengandalkan pengetahuan yang telah dipelajari model selama pelatihan dan sesuai untuk tugas yang relatif umum.

2. **Few-shot prompting**

Prompt dilengkapi sejumlah kecil contoh pasangan masukan–keluaran seba-

gai demonstrasi pola yang diharapkan. Contoh tersebut membantu model menyelaraskan format dan gaya jawaban dengan ekspektasi tugas (Brown dkk. 2020).

3. **Role prompting**

Model diberi peran atau persona tertentu (misalnya "Anda adalah dokter yang empatik") untuk mengarahkan gaya bahasa, sudut pandang, dan tingkat formalitas keluaran agar sesuai dengan konteks komunikasi kepada pasien.

4. **Constraint atau guardrail prompting**

Prompt menyertakan aturan eksplisit yang membatasi ruang keluaran model, seperti larangan mengarang angka, kewajiban hanya menggunakan fakta yang disediakan, serta batasan panjang dan format (Hakim dkk. 2025). *Guardrail* dalam konteks ini dipahami sebagai serangkaian batasan yang diterapkan pada masukan, proses, maupun keluaran LLM agar model tetap patuh pada kriteria yang telah ditetapkan (Hakim dkk. 2025). Teknik ini krusial pada domain berisiko tinggi seperti kesehatan untuk menekan keluaran yang tidak diinginkan. Hakim dkk. (2025) menunjukkan penerapannya pada setelan medis kritis-keselamatan (*pharmacovigilance*), yaitu dengan merancang serangkaian *guardrail* yang melarang model mengarang istilah obat maupun kejadian tidak diinginkan dan mewajibkan pengungkapan ketidakpastian, sehingga keluaran naratif LLM terkendali dan risiko halusinasi yang membahayakan pasien dapat ditekan.

II.5.2 Prompt Engineering sebagai Mitigasi Halusinasi

Pada domain medis, tantangan utama penerapan LLM adalah fenomena halusinasi, yaitu keluaran yang koheren secara bahasa namun keliru secara fakta (Z. Ji dkk. 2023). Salah satu strategi mitigasi yang efektif tanpa memerlukan basis pengetahuan eksternal adalah membatasi peran LLM melalui prompt yang *grounded*, yakni mengunci keluaran model pada fakta terstruktur yang telah dihasilkan oleh komponen lain dari sistem (Z. Ji dkk. 2023). Dalam konteks penelitian ini, fakta terstruktur tersebut berupa hasil atribusi fitur dari analisis SHAP. Dengan menyisipkan nilai kontribusi tiap faktor risiko secara eksplisit di dalam prompt serta melarang model menambahkan klaim di luar fakta tersebut, peran LLM dipersempit menjadi penerjemah dan penyampai edukasi gaya hidup umum, bukan sumber pengetahuan medis yang otonom. Strategi ini memungkinkan sistem memperoleh manfaat naratif LLM sekaligus menjaga akuntabilitas faktual, tanpa kompleksitas dan beban komputasi mekanisme temu-kembali (*retrieval*).

II.6 Tinjauan Penelitian Sebelumnya

Penelitian mengenai prediksi risiko hipertensi telah berkembang pesat dalam beberapa tahun terakhir, bergeser dari metode statistik konvensional menuju pendekatan Machine Learning (ML) yang lebih mampu menangani data tabular dengan variabel yang beragam. Fokus utama berbagai studi adalah meningkatkan akurasi deteksi dini agar intervensi dapat dilakukan sebelum komplikasi kardiovaskular terjadi (Silva dkk. 2022). Metode berbasis *ensemble* seperti Random Forest dan varian *gradient boosting* secara konsisten dilaporkan mengungguli model tunggal pada dataset kesehatan yang tidak seimbang. Dalam konteks Indonesia, sejumlah studi bahkan telah memanfaatkan data berskala besar untuk membangun model skrining hipertensi berbasis faktor risiko non-laboratorium (Estiko dkk. 2025; Septian dkk. 2025).

Meskipun akurasinya tinggi, model ML yang kompleks umumnya bersifat *black box* sehingga alasan di balik setiap prediksinya sulit dipahami. Untuk mengatasi keterbatasan ini, gelombang penelitian berikutnya mengintegrasikan metode Explainable Artificial Intelligence (XAI) seperti SHAP dan LIME guna mengungkap kontribusi tiap fitur terhadap hasil prediksi (Adadi dan Berrada 2018). Melalui atribusi fitur tersebut, sistem tidak hanya memberikan label risiko, tetapi juga menunjukkan variabel mana, misalnya usia, lingkaran pinggang, atau riwayat keluarga, yang paling memengaruhi keputusan model. Namun, keluaran XAI umumnya masih berupa nilai numerik atau grafik yang sulit dicerna oleh masyarakat awam.

Di sisi lain, kemunculan Large Language Model (LLM) membuka peluang baru untuk menjembatani kesenjangan komunikasi tersebut. LLM memiliki potensi besar dalam merangkum informasi medis yang kompleks menjadi penjelasan bahasa alami yang personal dan mudah dipahami (Thirunavukarasu dkk. 2023). Meskipun demikian, penerapan LLM di ranah medis masih dibayangi risiko halusinasi, yaitu keluaran yang terdengar meyakinkan namun keliru secara fakta, sehingga penggunaannya perlu dikendalikan secara ketat (Clusmann dkk. 2023). Belakangan mulai bermunculan studi yang memadukan atribusi XAI dengan LLM untuk menghasilkan narasi penjelasan, misalnya kerangka *prompt* yang menerjemahkan nilai SHAP menjadi penjelasan naratif (Lee, Cho, Lee, dkk. 2025). Meskipun demikian, upaya integrasi semacam ini masih terbatas pada domain klinis lain seperti perawatan intensif dan penyakit kardiovaskular, serta umumnya ditujukan bagi tenaga medis, bukan masyarakat awam.

Berdasarkan tinjauan tersebut, terdapat celah penelitian yang dapat diisi. Pada ranah hipertensi, mayoritas studi berhenti pada tahap prediksi ML dan interpretasi XAI

yang keluarannya masih bersifat teknis, sedangkan integrasi lanjutan dengan LLM untuk menerjemahkan hasil tersebut menjadi narasi yang dapat dipahami masyarakat awam belum ditemukan, khususnya pada konteks populasi Indonesia dengan fitur non-invasif. Meskipun pendekatan serupa mulai berkembang di domain klinis lain, penelitian ini menerapkannya secara spesifik untuk estimasi risiko hipertensi dengan memadukan model prediksi ML, interpretasi SHAP, dan LLM yang dikendalikan melalui *prompt engineering*, disertai pengendalian halusinasi tanpa basis pengetahuan eksternal, guna menghasilkan estimasi yang akurat, transparan, sekaligus komunikatif bagi pengguna awam. Untuk memberikan gambaran posisi penelitian ini dibandingkan studi terdahulu, Tabel II.1 merangkum lima penelitian relevan beserta metode, hasil, dan keterbatasannya.

Tabel II.1 Studi Sebelumnya

No	Judul & Penulis	Metode	Hasil	Keterbatasan
1	Screening Hypertension Using Non-Laboratory Risk Factors With Machine Learning: A Retrospective Cross-Sectional Study in Indonesia (Estiko dkk. 2025)	Membandingkan Random Forest, Gradient Boosting, dan XGBoost dengan Logistic Regression sebagai <i>baseline</i> untuk menyaring hipertensi menggunakan sebelas faktor risiko non-laboratorium pada ratusan ribu peserta Posbindu di Indonesia, dengan validasi internal (<i>10-fold cross-validation</i>) dan eksternal.	Model berbasis <i>boosting</i> (XGBoost) berkinerja terbaik dan mengungguli <i>baseline</i> Logistic Regression pada validasi internal maupun eksternal. Riwayat keluarga hipertensi, usia, lingkar pinggang, dan IMT menjadi faktor prediktor paling berpengaruh.	Bersifat <i>cross-sectional</i> sehingga tidak dapat menyimpulkan kausalitas atau insidensi, hanya menganalisis faktor non-laboratorium, dan hasil prediksinya belum diterjemahkan menjadi penjelasan naratif bagi pengguna awam.

Bersambung ke halaman berikutnya

No	Judul & Penulis	Metode	Hasil	Keterbatasan
2	Prediction of Personalised Hypertension Using Machine Learning in Indonesian Population (Septian dkk. 2025)	Mengomparasi lima algoritma, yaitu XGBoost, LightGBM, CatBoost, Logistic Regression, dan Random Forest, pada 9,58 juta data SATU-SEHAT dengan analisis kontribusi fitur menggunakan SHAP (<i>SHapley Additive exPlanations</i>).	Model LightGBM mencapai performa terbaik dengan AUC 0,78 tanpa riwayat pasien dan 0,85 dengan riwayat pasien. Analisis SHAP menunjukkan usia, riwayat keluarga, berat badan, dan lingkaran pinggang sebagai prediktor dominan.	Studi bersifat <i>cross-sectional</i> sehingga tidak dapat menyimpulkan kausalitas, terbatas pada setting non-rumah sakit tanpa variabel klinis mendalam, serta hasil interpretasinya belum disajikan sebagai narasi untuk awam.
3	XGBoost and SHAP-Based Analysis of Risk Factors for Hypertension Classification in Korean Postmenopausal Women (Li, Chen, dan Park 2025)	Menggunakan XGBoost, Support Vector Machine (SVM), dan Artificial Neural Network (ANN) untuk klasifikasi hipertensi, dengan interpretabilitas model melalui SHAP guna mengidentifikasi faktor risiko paling berpengaruh.	Model XGBoost memberikan performa terbaik dengan AUC 92,12%, akurasi 84,73%, dan MCC 0,71. SHAP mengidentifikasi usia dan lingkaran pinggang sebagai faktor paling dominan.	Terbatas pada populasi wanita pascamenopause di Korea Selatan sehingga sulit digeneralisasi, serta faktor gaya hidup seperti konsumsi garam, aktivitas fisik, dan tingkat stres tidak disertakan karena keterbatasan data.

Bersambung ke halaman berikutnya

No	Judul & Penulis	Metode	Hasil	Keterbatasan
4	Explainable AI in Action: A Comparative Analysis of Hypertension Risk Factors Using SHAP and LIME (Donmez, Kutlu, Mansour, dkk. 2025)	Menerapkan model XGBoost untuk memprediksi hipertensi pada 623 pasien dengan 13 biomarker, lalu membandingkan dua metode XAI, yaitu SHAP dan LIME, untuk menjelaskan kontribusi fitur terhadap prediksi.	Model XGBoost mencapai akurasi 99,4%, presisi 100%, recall 97,30%, dan F1-score 98,6%. SHAP dan LIME berhasil mengungkap faktor risiko utama di balik prediksi model.	Dataset relatif kecil (623 pasien) dengan metrik nyaris sempurna yang berpotensi <i>overfitting</i> , bergantung pada biomarker laboratorium sehingga tidak non-invasif, dan penjelasannya belum disajikan dalam bentuk narasi bahasa alami.
5	Large Language Models in Medicine (Thirunavukarasu dkk. 2023)	Tinjauan mengenai penerapan Large Language Model (LLM) berbasis arsitektur Transformer untuk beragam tugas klinis, termasuk komunikasi dan edukasi kepada pasien.	LLM berpotensi menyintesis informasi medis kompleks menjadi penjelasan yang mudah dipahami oleh pasien maupun tenaga medis.	Rentan terhadap halusinasi fakta dan bias data pelatihan, serta belum diintegrasikan dengan model prediksi risiko numerik seperti keluaran ML dan XAI.

BAB III


ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Sistem deteksi dini hipertensi di Indonesia saat ini secara umum berjalan melalui dua jalur utama, yaitu skrining mandiri berbasis aplikasi dan pemeriksaan fisik berkala di fasilitas kesehatan. Keduanya dirancang untuk mendeteksi risiko penyakit sejak dini, sebelum kondisi berkembang menjadi komplikasi yang serius. Jalur pertama yaitu menggunakan fitur "Skrining Riwayat Kesehatan" pada aplikasi Mobile JKN yang dikelola oleh BPJS Kesehatan, sehingga peserta dapat menilai tingkat risikonya secara mandiri berdasarkan riwayat dan gaya hidup tanpa harus lebih dahulu datang ke fasilitas kesehatan. Jalur kedua berupa pengukuran dan pemeriksaan langsung oleh tenaga medis di Fasilitas Kesehatan Tingkat Pertama (FKTP). Subbab ini menganalisis kedua jalur tersebut sebagai kondisi awal (*as-is*) untuk memahami keterbatasan proses yang berjalan saat ini, sekaligus menjadi dasar perumusan solusi yang diusulkan pada penelitian ini.

III.1.1 Skrining Mandiri Berbasis Aplikasi: Skrining Riwayat Kesehatan pada Mobile JKN

Jalur pertama deteksi dini merupakan skrining mandiri berbasis aplikasi melalui fitur Skrining Riwayat Kesehatan (SRK) pada aplikasi Mobile JKN yang dikelola oleh BPJS Kesehatan (Juwita dan Santoso 2022). Fitur ini dirancang untuk mendeteksi potensi risiko penyakit tidak menular (PTM) sejak dini pada peserta Jaminan Kesehatan Nasional, dengan menyoroti empat penyakit dengan beban tertinggi di Indonesia, yaitu diabetes melitus, hipertensi, penyakit ginjal kronis, dan penyakit jantung koroner (Juwita dan Santoso 2022).



Gambar III.1 Alur mekanisme Skrining Riwayat Kesehatan (SRK) pada aplikasi Mobile JKN

Alur mekanisme kerja fitur Skrining Riwayat Kesehatan (SRK) pada aplikasi Mobile JKN ditunjukkan pada Gambar III.1. Peserta masuk ke aplikasi Mobile JKN menggunakan Nomor Induk Kependudukan (NIK), kemudian memilih menu Skrining Riwayat Kesehatan dan menjawab sejumlah pertanyaan terstruktur mengenai gaya hidup harian serta riwayat penyakit pada diri sendiri maupun keluarga, seperti kebiasaan merokok, aktivitas fisik, pola makan, serta riwayat keluarga terhadap keempat penyakit tersebut. Berdasarkan jawaban tersebut, sistem menghitung dan mengeluarkan hasil berupa kategori tingkat risiko, yaitu risiko rendah, sedang, atau risiko tinggi, terhadap masing-masing penyakit. Hasil skrining ini kemudian tersimpan pada sistem dan menjadi panduan bagi dokter di FKTP tempat peserta terdaftar, peserta dengan hasil berisiko tinggi diarahkan untuk tindak lanjut melalui pemeriksaan lebih lanjut di fasilitas kesehatan (Juwita dan Santoso 2022).

Karakteristik penting dari jalur ini adalah penilaian risiko yang sepenuhnya bertumpu pada faktor risiko riwayat dan gaya hidup yang dilaporkan sendiri oleh peserta, bukan pada pengukuran tekanan darah langsung. Pendekatan berbasis faktor risiko non-laboratorium inilah yang menjadi konteks utama penelitian ini, karena memungkinkan estimasi risiko dilakukan lebih awal sebelum tekanan darah tinggi benar-benar terukur. Meskipun demikian, keluaran SRK saat ini berupa kategori tingkat risiko (rendah, sedang, atau tinggi) yang disertai anjuran umum, seperti menjaga pola hidup sehat atau berkonsultasi ke FKTP, tetapi belum menjelaskan secara personal faktor mana yang paling berkontribusi terhadap risiko masing-masing peserta. Dengan kata lain, hasil skrining menunjukkan seberapa besar risiko seseorang,

tetapi belum menjelaskan mengapa risiko tersebut muncul, sehingga masih terdapat ruang untuk meningkatkan sifat personal dan nilai edukatif dari hasil skrining tersebut.

III.1.2 Prosedur Skrining Hipertensi di Fasilitas Kesehatan Tingkat Pertama


Jalur kedua deteksi dini berupa skrining dan pemeriksaan hipertensi di Fasilitas Kesehatan Tingkat Pertama (FKTP), yang saat ini masih bergantung pada pengukuran klinis konvensional dan penilaian manual oleh tenaga medis. Pasien yang datang ke FKTP menjalani proses registrasi terlebih dahulu, kemudian perawat melakukan anamnesis serta pengukuran antropometri dan tekanan darah (TD), meliputi tinggi badan, berat badan, lingkar perut, dan tensi. Apabila tekanan darah melampaui ambang 140/90 mmHg, dokter melanjutkan dengan analisis hasil dan menilai faktor risiko pasien, seperti usia, status merokok, dan kadar gula darah, untuk menentukan status kesehatan serta tata laksana sebagaimana digambarkan pada Gambar III.2.

Jalur ini efektif untuk menegakkan diagnosis secara akurat, tetapi mensyaratkan kehadiran fisik pasien di fasilitas kesehatan. Ketergantungan pada kehadiran fisik inilah yang menjadi salah satu penyebab cakupan deteksi dini hipertensi belum optimal, baik secara global (Mills, Stefanescu, dan He 2020) maupun di Indonesia, dengan sebagian besar penderita belum terdiagnosis dan baru menyadari kondisinya setelah timbul komplikasi (Kementerian Kesehatan Republik Indonesia 2018). Hambatan akses turut memperberat kondisi ini, salah satunya beban antrean dan waktu tunggu yang panjang di Puskesmas; sebuah studi di layanan rawat jalan Puskesmas mencatat 93,5% pasien mengalami waktu tunggu lebih dari 60 menit (Manyering dkk. 2023), kondisi yang dapat menurunkan kenyamanan dan menjadi disinsentif bagi masyarakat untuk memeriksakan diri secara rutin.

Kondisi tersebut menunjukkan bahwa skrining yang sepenuhnya bergantung pada kehadiran fisik di FKTP belum memadai untuk mendorong deteksi dini secara luas. Diperlukan jalur skrining awal yang dapat diakses secara mandiri agar masyarakat lebih dahulu menyadari tingkat risikonya, sehingga kesadaran tersebut dapat mengarahkan mereka untuk menjalani pemeriksaan lanjutan di fasilitas kesehatan secara lebih tepat sasaran.

Selain hambatan akses tersebut, keterbatasan waktu konsultasi dan kompleksitas interaksi antar faktor risiko membuat penilaian risiko secara manual sulit dilakukan secara komprehensif untuk setiap pasien. Keterbatasan inilah yang mendorong tren pemanfaatan algoritma *machine learning* sebagai alat bantu prediksi risiko yang lebih dini dan akurat. Namun, penerapan model ML konvensional, seperti Neural Ne-

networks atau Ensemble Trees, sering kali menghadapi kendala transparansi. Model tersebut bekerja sebagai kotak hitam atau biasa disebut juga dengan *black box*, memberikan skor risiko tanpa disertai alasan medis yang jelas. Kondisi ini menciptakan keraguan di kalangan praktisi medis untuk mengadopsi hasil prediksi komputer dalam pengambilan keputusan klinis (Amann dkk. 2020).



Gambar III.2 Alur skrining hipertensi di Fasilitas Kesehatan Tingkat Pertama (FK-TP)

III.1.3 Pemanfaatan Teknologi Prediksi Berbasis AI dan Keterbatasannya

Untuk mengatasi keterbatasan tersebut, penelitian terkini mulai memanfaatkan teknologi prediksi berbasis kecerdasan artifisial. Salah satu arah utamanya adalah integrasi Explainable Artificial Intelligence (XAI) untuk membuka mekanisme model prediksi yang bersifat *black box*. Meskipun demikian, luaran dari XAI umumnya masih berupa grafik fitur atau nilai matematis yang sulit dipahami oleh pasien awam. Kesenjangan komunikasi ini menjadi tantangan baru dalam menyampaikan risiko kesehatan kepada pasien secara efektif. Di sisi lain, kemunculan Large Language Model (LLM) menawarkan potensi untuk menarasikan data tersebut, namun peng-

gunaannya yang tanpa pengawasan rentan menghasilkan informasi yang tidak valid atau halusinasi medis (Clusmann dkk. 2023). Oleh karena itu, kondisi saat ini menunjukkan adanya fragmentasi antara kemampuan prediksi yang tinggi, kebutuhan akan transparansi (*explainability*), dan penyajian informasi yang akurat secara medis.

III.1.4 Kesenjangan Transparansi dan Kepercayaan Klinis

Masalah paling fundamental dalam adopsi teknologi prediksi risiko saat ini terletak pada kesenjangan pemahaman antara cara kerja model komputasi dan logika klinis dokter. Model *machine learning* yang memiliki performa akurasi tinggi sering kali memiliki struktur internal yang sangat kompleks dan tidak dapat ditafsirkan secara langsung. Hal ini menciptakan dua hambatan utama dalam implementasi klinis:

1. Skeptisisme Tenaga Medis

Dokter dan tenaga kesehatan memegang tanggung jawab etis dan hukum atas keputusan yang diambil. Mereka enggan menggunakan prediksi dari sistem yang tidak dapat menjelaskan "mengapa" seorang pasien dikategorikan berisiko tinggi, terutama jika prediksi tersebut bertentangan dengan intuisi klinis mereka. Ketiadaan kausalitas yang dapat diobservasi menyebabkan rendahnya tingkat kepercayaan terhadap sistem pendukung keputusan berbasis AI (Linardatos, Papastefanopoulos, dan Kotsiantis 2021).

2. Kebingungan Pasien terhadap Hasil Prediksi

Bagi pasien, menerima diagnosis atau prediksi risiko tanpa penjelasan yang personal dapat menimbulkan kecemasan atau justru penyangkalan. Pasien membutuhkan narasi yang menghubungkan gaya hidup mereka (misalnya, merokok atau IMT tinggi) dengan kenaikan risiko yang diprediksi, bukan sekadar angka probabilitas statistik. Tanpa penjelasan yang memadai, kepatuhan pasien terhadap saran preventif cenderung rendah.

III.1.5 Risiko Halusinasi dan Inkonsistensi Informasi Medis

Dari perspektif teknologi Generative AI yang mulai marak digunakan, tantangannya bersifat validitas data. Meskipun LLM mampu menghasilkan teks yang sangat koheren dan menyerupai bahasa manusia, model ini memiliki kecenderungan inherent untuk menghasilkan fakta yang salah atau "berhalusinasi" ketika tidak memiliki konteks yang cukup. Dalam domain medis yang berisiko tinggi, hal ini menciptakan bahaya laten sebagai berikut:

1. Misinformasi Saran Medis

Tanpa batasan basis pengetahuan yang ketat, LLM dapat memberikan saran kesehatan yang terlihat meyakinkan namun tidak memiliki dasar ilmiah atau

bertentangan dengan pedoman medis resmi. Misalnya, model mungkin menyarankan dosis obat atau interpretasi gejala yang salah (Li dkk. 2023). Hal ini sangat berbahaya jika dijadikan rujukan oleh pengguna awam tanpa verifikasi.

2. Inkonsistensi Narasi

Penjelasan yang dihasilkan oleh model bahasa standar dapat bervariasi secara signifikan meskipun diberikan input data yang sama pada waktu yang berbeda. Ketidakkonsistenan ini mengurangi reliabilitas sistem sebagai alat edukasi pasien yang terstandarisasi. Tidak adanya mekanisme validasi silang (*cross-validation*) dengan dokumen medis terpercaya membuat luaran model sulit dipertanggungjawabkan (Z. Ji dkk. 2023).

III.1.6 Tantangan Kompleksitas Data Multidimensi

Pada konteks teknis pengolahan data, masalah diperparah dengan sifat data kesehatan yang heterogen dan non-linier. Faktor risiko hipertensi melibatkan interaksi yang rumit antara demografi, tanda vital, dan riwayat gaya hidup yang tidak selalu dapat dimodelkan dengan regresi linier sederhana.

1. Interaksi Variabel yang Tersembunyi

Metode statistik tradisional sering gagal menangkap hubungan non-linier yang kompleks, misalnya bagaimana dampak indeks massa tubuh (IMT) terhadap tekanan darah mungkin berbeda secara drastis tergantung pada usia dan tingkat aktivitas fisik seseorang. Kegagalan menangkap nuansa ini menyebabkan prediksi menjadi kurang akurat untuk individu dengan profil risiko yang unik (Elshaw, Al-Mallah, dan Sakr 2019).

2. Keterbatasan Personalisasi

Sistem informasi kesehatan yang ada saat ini umumnya bersifat *one-size-fits-all* atau satu ukur untuk semua. Belum tersedia mekanisme yang secara otomatis mengadaptasi penjelasan risiko berdasarkan profil spesifik pasien secara *real-time* yang didukung oleh bukti literatur medis terkini.

III.1.7 Identifikasi Kesenjangan (Gap Analysis)

Berdasarkan analisis kondisi saat ini, dilakukan pemetaan kesenjangan antara kondisi *As-Is* (sistem konvensional/*black box*) dengan kondisi ideal *To-Be* (sistem yang diusulkan) yang dirangkum dalam Tabel III.1 di bawah ini.

Tabel III.1 Identifikasi Kesenjangan (Gap Analysis)

Domain Masalah	Kondisi Saat Ini (<i>As-Is</i>)	Kesenjangan (Gap)	Kondisi Ideal (<i>To-Be</i>)
Transparansi & Kepercayaan	Model prediksi bekerja sebagai <i>black box</i> ; pengguna hanya menerima skor risiko tanpa alasan penjas.	Tidak adanya mekanisme untuk menelusuri alasan di balik prediksi dominan variabel.	Sistem menyediakan fitur visualisasi (XAI) yang menjelaskan variabel dominan penyebab risiko.
Validitas Informasi	Penjelasan risiko jika menggunakan LLM bisa masih rentan terhadap halusinasi dan tidak memiliki referensi yang jelas.	Risiko kesalahan informasi medis yang membahayakan keselamatan pasien.	Narasi penjelasan dikendalikan melalui kombinasi kaidah deterministik dan <i>prompt engineering</i> (<i>guardrail</i>); angka dan arah pengaruh ditetapkan secara deterministik dari kontribusi faktor risiko yang dihasilkan metode XAI sehingga LLM tidak mengarang klaim medis di luar fakta sistem.
Akurasi & Personalisasi	Analisis risiko bersifat reaktif dan generalis; sering mengabaikan interaksi non-linier antar variabel.	Rendahnya sensitivitas terhadap profil risiko individu dan kurangnya personalisasi.	Model ML mampu menangkap pola kompleks dan menyajikan narasi personal yang mudah dipahami awam.

Analisis kesenjangan pada Tabel III.1 menggarisbawahi bahwa tantangan yang dihadapi tidak hanya sekadar meningkatkan akurasi angka prediksi, tetapi juga membangun jembatan komunikasi antara logika mesin dan pemahaman manusia. Secara kumulatif, kesenjangan ini menegaskan urgensi pengembangan sistem terintegrasi yang menggabungkan kekuatan prediksi *machine learning*, transparansi XAI, dan kemampuan naratif LLM yang dikendalikan melalui *prompt engineering*. Untuk mewujudkan solusi tersebut, langkah selanjutnya adalah menerjemahkan temuan ini ke dalam analisis kebutuhan sistem yang terukur.

III.2 Analisis Kebutuhan

Dalam perancangan sistem pendukung keputusan klinis yang menggabungkan kecerdasan buatan dan interpretasi bahasa alami ini, diperlukan pemahaman mendalam terhadap kebutuhan pengguna serta spesifikasi teknis yang ketat. Mengingat domain kesehatan merupakan area yang sensitif terhadap keselamatan (*safety-critical*), analisis kebutuhan tidak cuma bergantung pada akurasi komputasi, namun juga pada aspek kepercayaan, transparansi, dan validitas informasi yang disampaikan kepada pengguna (Amann dkk. 2020). Tahapan ini bertujuan menerjemahkan kesenjangan masalah yang telah diidentifikasi sebelumnya menjadi spesifikasi fungsional dan non-fungsional yang terukur.

III.2.1 Identifikasi Masalah Pengguna

Pengguna utama sistem ini adalah masyarakat umum sebagai penerima informasi hasil skrining dan edukasi kesehatan. Di samping itu, tenaga medis profesional diposisikan sebagai pihak yang meninjau dan memvalidasi kelayakan keluaran sistem (*validator*), sehingga kebutuhan akan transparansi dari sudut pandang medis tetap menjadi pertimbangan penting dalam perancangan. Masalah spesifik yang mendasari kebutuhan sistem dari kedua sudut pandang tersebut adalah sebagai berikut:

1. Masyarakat Umum/Pasien

Tantangan utama yang dihadapi pasien adalah ketidakmampuan untuk memahami terminologi medis yang kompleks dan angka probabilitas statistik yang dihasilkan oleh alat kesehatan konvensional. Pasien sering kali menerima hasil diagnosis atau prediksi risiko tanpa penjelasan kausalitas yang memadai mengenai faktor gaya hidup apa yang memicu risiko tersebut (Adadi dan Berrada 2018). Selain itu, kurangnya akses terhadap informasi kesehatan yang terpersonalisasi membuat pasien kesulitan menentukan langkah mitigasi mandiri yang tepat tanpa harus berkonsultasi panjang dengan dokter.

2. Tenaga Medis Profesional (Validator)

Dalam perannya meninjau kelayakan sistem, tenaga medis menghadapi kendala pada sifat *black box* dari algoritma *machine learning*. Tanpa adanya transparansi mengenai bagaimana model mengambil keputusan, tenaga medis sulit untuk memvalidasi apakah prediksi tersebut didasarkan pada logika medis yang benar atau hanya korelasi data yang bias (Linardatos, Papastefanopoulos, dan Kotsiantis 2021). Hal ini menegaskan perlunya sistem menyediakan penjelasan yang dapat ditelusuri agar keluaran dapat divalidasi secara klinis sebelum dipercaya untuk mendukung keputusan.

Untuk mengatasi permasalahan tersebut, maka dirumuskan sistem yang tidak ha-

nya mampu memprediksi risiko hipertensi dengan akurasi tinggi, tetapi juga mampu menjelaskan alasan di balik prediksi tersebut menggunakan bahasa alami yang mudah dipahami sekaligus terkendali agar tetap faktual.

III.2.2 Kebutuhan Fungsional

Kebutuhan fungsional berisi atas serangkaian fitur dan perilaku spesifik yang harus dipenuhi oleh sistem guna menjawab permasalahan di atas. Berikut merupakan kebutuhan fungsional dari sistem.

Tabel III.2 Kebutuhan Fungsional

ID	Kebutuhan Fungsional	Deskripsi
FR01	Pemrosesan Data Non-Invasif Tabular	Sistem mampu menerima dan memproses input data non-invasif pengguna yang terdiri atas variabel demografis, pengukuran antropometri (tinggi dan berat badan yang diturunkan menjadi indeks massa tubuh), riwayat penyakit (diabetes dan kolesterol tinggi), status merokok, serta kualitas dan gangguan tidur dalam format tabular terstruktur.
FR02	Prediksi Risiko Probabilistik	Sistem mampu mengklasifikasikan status risiko hipertensi dengan akurasi optimal dan menghasilkan skor probabilitas risiko bagi setiap individu.
FR03	Penjelasan Lokal	Sistem mampu menganalisis dan memvisualisasikan kontribusi masing-masing variabel faktor risiko terhadap hasil prediksi spesifik pengguna.
FR04	Narasi Penjelasan Hasil Prediksi	Sistem mampu menyusun narasi teks bahasa Indonesia yang mudah dipahami dari hasil analisis kontribusi variabel faktor risiko, dengan angka dan arah pengaruh yang ditetapkan secara deterministik dari nilai atribusi.
FR05	Pengendalian Faktualitas Narasi	Sistem mampu memastikan narasi penjelasan hanya menjabarkan hasil kontribusi variabel faktor risiko dan tidak menambahkan klaim medis di luar fakta tersebut.

Dengan spesifikasi pada Tabel III.2, alur kerja sistem diharapkan tidak hanya berhenti pada klasifikasi risiko hipertensi, tetapi melanjutkannya ke tahap interpretasi dari hasil klasifikasi tersebut. Sistem diharapkan dapat melakukan *preprocessing* data otomatis, menjalankan inferensi model, menghitung *feature importance*, dan

akhirnya menyusun paragraf penjelasan yang koheren serta terkendali agar tidak keluar dari hasil analisis SHAP. Fitur FR04 dan FR05 secara khusus ditujukan untuk menjembatani kesenjangan pemahaman antara data numerik dan bahasa manusia.

III.2.3 Kebutuhan Nonfungsional

Kebutuhan non-fungsional menetapkan batasan kualitas dan karakteristik operasional yang harus dipenuhi agar sistem dapat diandalkan dalam skenario penggunaan nyata. Dalam konteks informatika medis, aspek faktualitas dan akurasi menjadi prioritas di atas kecepatan semata.

Tabel III.3 Kebutuhan Non-Fungsional

ID	Kebutuhan Non-Fungsional	Deskripsi
NFR01	Performa Diskriminasi Model	Model prediksi harus memiliki kemampuan diskriminasi keseluruhan yang baik dalam membedakan antara pasien risiko hipertensi dan non-hipertensi, dengan kriteria sukses nilai ROC-AUC minimal sebesar 0,75 pada data uji.
NFR02	Target Metrik Recall	Model prediksi harus memprioritaskan kemampuan untuk meminimalkan <i>False Negative</i> guna mencegah pasien hipertensi tidak terdeteksi, dengan target recall minimal sebesar 0,70 pada data uji.
NFR03	Faktualitas Narasi	Narasi yang dihasilkan oleh LLM harus memiliki tingkat faktualitas yang tinggi terhadap hasil kontribusi faktor risiko dan konteks yang disediakan sistem, memastikan tidak ada angka atau saran medis yang difabrikasi di luar fakta tersebut.
NFR04	Interpretabilitas Hasil Prediksi	Purwarupa antarmuka harus mampu menyajikan grafik plot dari SHAP yang dapat dibaca untuk membantu pengguna memindai faktor risiko dominan dengan cepat.

Dengan memenuhi kebutuhan nonfungsional pada Tabel III.3 di atas, sistem yang dikembangkan diharapkan tidak hanya cerdas secara komputasi, tetapi juga aman dan etis untuk digunakan sebagai alat pendukung keputusan. Pemenuhan NFR02 menjadi krusial untuk menekan kasus *false negative* agar pasien berisiko tidak lolos dari deteksi pada tahap skrining, sedangkan pemenuhan NFR03 membedakan sistem ini dari chatbot kesehatan generik yang rentan terhadap halusinasi medis.

III.3 Analisis Pemilihan Solusi

Dalam merancang sistem informasi kesehatan yang kompleks seperti prediksi risiko hipertensi, diperlukan analisis yang tajam terhadap akar permasalahan klinis dan potensi teknologi yang tersedia. Tahapan ini krusial untuk memastikan bahwa arsitektur sistem yang diusulkan bukan hanya canggih secara teknis, tetapi juga menjawab kebutuhan praktis di lapangan. Subbab ini menyajikan pemetaan masalah dan peluang secara sistematis, serta membandingkan berbagai alternatif pendekatan teknologi untuk menjustifikasi solusi yang dipilih dalam penelitian tugas akhir ini.

III.3.1 Alternatif Solusi

Permasalahan multidimensi yang muncul dalam lingkup diagnosis dan prediksi hipertensi perlu dipetakan secara granular agar penulis dapat merumuskan intervensi teknologi yang presisi. Berdasarkan hasil tinjauan literatur dan observasi kondisi saat ini, dijabarkan pemetaan masalah utama beserta dampak signifikannya pada Tabel III.4.

Tabel III.4 Pemetaan Masalah dan Dampak

ID	Nama Masalah	Deskripsi Masalah	Dampak
M01	Fenomena <i>black box</i> pada Model Prediksi	Model <i>machine learning</i> konvensional menghasilkan skor risiko tanpa menyertakan alasan medis yang mendasarinya.	Terjadi defisit kepercayaan (<i>trust deficit</i>) dari tenaga medis untuk menggunakan hasil prediksi dalam pengambilan keputusan klinis.
M02	Inkomprehensibilitas bagi Pasien Awam	Luaran sistem prediksi berupa angka probabilitas atau grafik statistik sulit dipahami oleh pasien tanpa latar belakang medis.	Pasien gagal memahami urgensi kondisi kesehatan mereka yang berpotensi menyebabkan rendahnya kepatuhan.
M03	Halusinasi Risiko pada Generative AI	Penggunaan model bahasa (LLM) standar untuk konsultasi kesehatan rentan menghasilkan fakta medis yang salah atau fabrikasi data.	Menimbulkan risiko keselamatan pasien yang fatal jika saran yang tidak valid diikuti.
M04	Kompleksitas Hubungan Non-Linier	Metode statistik tradisional sering gagal menangkap interaksi kompleks antar variabel risiko.	Akurasi prediksi menjadi suboptimal untuk individu dengan profil risiko yang unik.

Uraian permasalahan di atas menunjukkan adanya kebutuhan mendesak akan sistem yang tidak hanya akurat, tetapi juga transparan dan aman. Di sisi lain, perkembangan teknologi terkini membuka peluang besar untuk mengatasi hambatan tersebut. Pemetaan peluang yang menjadi dasar teknis pengembangan solusi dijabarkan pada Tabel III.5.

Tabel III.5 Pemetaan Peluang

ID	Pemetaan Masalah	Nama Peluang	Deskripsi Peluang
P01	M01, M04	Integrasi Metode Model-Agnostic	Pemanfaatan metode XAI seperti SHAP/LIME memungkinkan pembukaan "kotak hitam" model ML tanpa mengorbankan akurasi prediksi.
P02	M02	Pemanfaatan Large Language Model (LLM)	Kemampuan <i>natural language generation</i> (NLG) dari LLM dapat menerjemahkan data matematis kompleks menjadi narasi personal.
P03	M03	Kendali Deterministik dan Prompt Engineering	Kombinasi lapisan kaidah deterministik dan prompt terbatas (<i>guardrail</i>) menetapkan angka serta arah pengaruh dari kontribusi variabel faktor risiko dan melarang fabrikasi informasi di luar konteks faktor risiko tersebut, sehingga risiko halusinasi dimitigasi tanpa basis pengetahuan eksternal.
P04	M01, M03, M04	Ketersediaan Dataset Kesehatan Terstruktur	Tersedianya data sekunder publik memungkinkan pelatihan model ML yang <i>robust</i> sebagai fondasi sistem prediksi objektif.

Berdasarkan pemetaan masalah dan peluang tersebut, penulis mengevaluasi berbagai pendekatan arsitektur teknis yang mungkin diadopsi. Perbandingan komparatif dari setiap alternatif solusi disajikan dalam Tabel III.6.

Tabel III.6 Alternatif Solusi

No	Solusi	Kelebihan	Kekurangan
1.	Sistem Pakar Berbasis Aturan (Rule-Based System)	Sangat transparan dan mudah diaudit karena logika diprogram secara eksplisit.	Sangat kaku (<i>rigid</i>), tidak mampu menangkap pola non-linier yang kompleks, dan sulit diperbarui.
2.	Pure <i>Machine Learning</i>	Mampu mencapai akurasi prediksi yang sangat tinggi pada dataset besar dan menangkap pola rumit.	Tidak memiliki interpretabilitas keputusan (alasan tidak diketahui), sehingga sulit diterima dalam praktik klinis.
3.	Narasi LLM tanpa <i>grounding</i> (<i>direct prompting</i>)	Penjelasan yang lebih mudah dipahami orang awam.	Rentan terhadap halusinasi karena keluaran tidak dikunci pada fakta.
4.	ML + XAI + LLM	Menyeimbangkan akurasi tinggi, transparansi alasan prediksi, dan narasi mudah dipahami dengan keluaran LLM yang dikendalikan kaidah deterministik dan <i>prompt engineering</i> .	Memerlukan integrasi beberapa komponen teknis serta perancangan lapisan kendali dan prompt yang cermat.

Tabel III.6 di atas menunjukkan bahwa setiap pendekatan memiliki *trade-off* tersendiri. Pemilihan solusi harus memprioritaskan keselamatan pasien dan kegunaan klinis di atas kemudahan pengembangan semata. Penentuan solusi final akan dikalkulasi secara objektif pada subbab selanjutnya.

III.3.2 Analisis Penentuan Solusi

Dalam menentukan pendekatan teknis yang paling optimal untuk sistem prediksi risiko hipertensi ini, penulis melakukan evaluasi kuantitatif menggunakan metode *Weighted Scoring Matrix* (WSM). WSM adalah teknik pengambilan keputusan yang memberikan bobot prioritas pada kriteria tertentu untuk membandingkan alternatif solusi secara objektif. Metode ini dipilih karena fleksibilitasnya dalam mengakomodasi kriteria teknis seperti akurasi dan kriteria kualitatif seperti kepercayaan pengguna dalam satu kerangka evaluasi.

Parameter penilaian diturunkan dari kebutuhan nonfungsional sistem medis yang kritis, yaitu keamanan medis, interpretabilitas, akurasi prediksi, dan kualitas narasi (selaras dengan NFR01–NFR04), sedangkan skalabilitas disertakan sebagai pertim-

bangun kemudahan penerapan. Setiap alternatif solusi diberi nilai skala 1 hingga 5, dengan nilai 1 merepresentasikan performa sangat buruk dan nilai 5 merepresentasikan performa sangat baik. Adapun perhitungan skor akhir yang diperoleh dari perkalian nilai dengan bobot prioritas dijabarkan pada Tabel III.7.

Tabel III.7 Pemilihan Solusi dengan *Weighted Scoring Model*

Parameter	Bobot	Rule-Based System	ML	Narasi LLM tanpa <i>groun- ding</i>	ML+XAI+LLM
Keamanan Medis	0,25	5	5	2	5
Interpretabilitas (<i>Explainability</i>)	0,25	5	1	3	5
Akurasi Prediksi	0,20	4	5	1	5
Kualitas Narasi & Personalisasi	0,15	1	1	5	4
Skalabilitas	0,15	2	5	3	4
Total Skor	1,00	3,75	3,40	2,65	4,70

Berdasarkan perhitungan skor total pada Tabel III.7, solusi yang akan diadopsi dalam penelitian tugas akhir ini adalah Sistem Prediksi Risiko Hipertensi dengan Pendekatan Machine Learning, Explainable AI, dan Large Language Model (LLM) dengan perolehan skor akhir tertinggi yaitu 4,70. Pendekatan ini terbukti merupakan satu-satunya arsitektur yang mampu memenuhi tiga persyaratan penting sistem pendukung keputusan klinis, yaitu akurasi tinggi melalui ML, transparansi melalui XAI, dan komunikasi yang aman melalui LLM yang dikendalikan prompt engineering. Keputusan ini menjadi landasan bagi perancangan sistem yang akan dibahas pada bab selanjutnya.

BAB IV


PERANCANGAN

Bab ini memaparkan perancangan sistem estimasi risiko hipertensi yang diusulkan. Pada bab ini, ditekankan perancangan sebagai sebuah *proses*. Setiap keputusan rancangan diturunkan secara eksplisit dari kebutuhan fungsional (FR) dan nonfungsional (NFR) yang telah dirumuskan pada Bab III. Untuk memudahkan pembaca, arsitektur akhir sistem ditampilkan lebih dahulu sebagai gambaran utuh pada Subbab IV.1, kemudian tahapan yang menurunkan tiap komponennya dari kebutuhan dijelaskan pada Subbab IV.2.

IV.1 Arsitektur Sistem yang Diusulkan

Berdasarkan analisis pemilihan solusi pada Bab III, sistem mengadopsi arsitektur yang menggabungkan *Machine Learning* (ML) untuk prediksi, *Explainable Artificial Intelligence* (XAI) untuk interpretasi, dan *Large Language Model* (LLM) untuk narasi. Faktualitas narasi tidak diserahkan sepenuhnya kepada LLM, melainkan dikendalikan melalui kombinasi lapisan kaidah deterministik dan pembatasan LLM melalui *prompt engineering*, sebagaimana ditetapkan pada kebutuhan FR05 dan NFR03.

Secara teknis, sistem dirancang dengan pendekatan berbasis layanan (*service-based architecture*) yang memisahkan antarmuka pengguna (*frontend*) dari mesin analisis (*backend*), sehingga seluruh logika prediksi terpusat di sisi server dan berkomunikasi melalui antarmuka REST berformat JSON. Gambar IV.1 menyajikan arsitektur akhir sistem secara utuh.



Gambar IV.1 Arsitektur sistem yang diusulkan

Berdasarkan Gambar IV.1, sistem tersusun atas empat bagian dengan tautan langsung ke kebutuhan pada Bab III:

1. Client Layer.

Antarmuka web yang menangkap masukan data non-invasif pengguna (mendukung FR01) dan menyajikan tiga luaran, yaitu status risiko, grafik kontribusi fitur, dan narasi penjelasan (mendukung FR02, FR03, dan FR04). Komunikasi ke server memakai REST/JSON melalui protokol aman.

2. **Application Layer (*backend*).**

Inti pemrosesan berbasis FastAPI yang mengekspos satu titik akhir utama *POST /api/v1/analyze*. Lapisan ini menjalankan empat fungsi berurutan: pra-pemrosesan masukan, inferensi model prediksi, perhitungan atribusi SHAP, dan penyusunan narasi. Keempat fungsi ini merupakan realisasi FR01–FR05 dan dirancang bertahap pada Subbab IV.2.


3. **Model dan Artefak.**

Berkas model terlatih beserta ambang keputusan dan urutan fitur disimpan sebagai satu artefak sehingga konfigurasi prediksi pada sistem identik dengan hasil eksperimen. Sistem tidak menggunakan basis data relasional maupun basis data vektor, karena purwarupa berperan sebagai bukti konsep tanpa perlu persistensi data pengguna.

4. **Layanan LLM Eksternal.**

Sistem memanggil layanan LLM pihak ketiga, yaitu Groq dengan model *llama-3.1-8b-instant*, semata untuk menghaluskan bahasa narasi. Tidak terdapat mekanisme temu-kembali (RAG) maupun basis pengetahuan eksternal; bila layanan tidak tersedia, sistem memakai materi narasi deterministik sebagai *fallback*.

Aliran kerja sistem saat digunakan (*runtime*) diilustrasikan pada Gambar IV.2. Pengguna memasukkan delapan fitur non-invasif; model menghasilkan skor probabilitas; skor dikategorikan memakai ambang keputusan; modul XAI menghitung kontribusi tiap fitur; modul narasi menyusun penjelasan; dan sistem mengembalikan tiga luaran terpadu.



Gambar IV.2 Alur kerja sistem yang diusulkan

Cara tiap komponen arsitektur ini diperoleh dari kebutuhan diuraikan pada subbab berikut.


IV.2 Tahapan Perancangan

Subbab ini memaparkan tahapan yang menurunkan arsitektur pada Subbab IV.1 dari kebutuhan Bab III. Setiap modul dirancang dengan menautkannya ke FR/NFR terkait, mempertimbangkan alternatif rancangan, lalu menetapkan keputusan yang dipilih. Rincian implementasi teknis dan bukti empiris dari tiap keputusan dibahas lebih lanjut pada Bab V.

IV.2.1 Perancangan Akuisisi dan Pra-pemrosesan Data

Berdasarkan kebutuhan fungsional FR01, sistem harus menerima dan memproses masukan data non-invasif dalam format tabular. Oleh karena itu, dirancang skema masukan yang terdiri atas delapan fitur non-invasif, yaitu usia, jenis kelamin, indeks massa tubuh (IMT), status merokok, riwayat diabetes, riwayat kolesterol tinggi, kualitas tidur, dan gangguan tidur (deskripsi lengkap pada Bab V). Pengukuran tekanan darah sengaja tidak dijadikan fitur masukan karena nilai tersebut menjadi dasar pembentukan label sehingga penyertaannya akan menimbulkan kebocoran data.

Agar masukan siap diproses model, dirancang tahapan pra-pemrosesan yang dijalankan berurutan: (1) validasi kelengkapan masukan; (2) konversi berat dan tinggi badan menjadi IMT di sisi klien sehingga *backend* menerima tepat delapan fitur; (3) imputasi nilai hilang; dan (4) pengodean variabel kategorik menjadi representasi biner. Untuk imputasi, dipertimbangkan dua alternatif, yaitu menghapus baris tidak lengkap atau mengisi nilai hilang. Penghapusan baris tidak sesuai untuk skenario penggunaan nyata karena masukan tunggal pengguna harus tetap dapat diproses; maka dipilih imputasi menggunakan nilai median untuk fitur numerik/ordinal dan modus untuk fitur biner, dengan parameter imputasi ditetapkan dari data latih agar konsisten dan bebas kebocoran. Tahapan ini diilustrasikan pada Gambar IV.3.




Gambar IV.3 Tahapan pra-pemrosesan data masukan

IV.2.2 Perancangan Modul Prediksi Risiko

Modul prediksi diturunkan dari FR02 yang menuntut klasifikasi biner risiko hipertensi beserta skor probabilitas, serta dari NFR01 dan NFR02 yang menekankan minimalisasi *false negative* dengan target recall minimal 0,70. Konsekuensi rancangannya adalah pemilihan pendekatan *supervised learning* untuk klasifikasi biner, pena-

nganan ketidakseimbangan kelas, dan optimasi ambang keputusan agar sensitivitas terhadap kelas hipertensi terjaga.

Tiga keputusan rancangan ditetapkan pada modul ini. Pertama, pemilihan keluarga algoritma: beberapa algoritma dibandingkan secara empiris, dan model *gradient boosting* XGBoost dipilih sebagai model akhir dengan pertimbangan kinerja, dukungan analisis kontribusi fitur, dan kemudahan penerapan (perbandingan lengkap pada Bab V). Kedua, penanganan ketidakseimbangan kelas: dipertimbangkan teknik *re-sampling* (mis. *oversampling*) dan pembobotan kelas (*class weighting*); karena ketidakseimbangan tergolong moderat, dipilih pembobotan kelas yang tidak mengubah struktur data dan lebih tahan terhadap *overfitting*. Ketiga, penentuan ambang keputusan: alih-alih memakai ambang bawaan 0,5, ambang ditetapkan memakai *Youden Index* demi menyeimbangkan sensitivitas dan spesifisitas sesuai NFR01/NFR02. Alur modul prediksi ditunjukkan pada Gambar IV.4.




Gambar IV.4 Tahapan perancangan modul prediksi risiko

IV.2.3 Perancangan Modul Interpretasi (XAI)

Modul interpretasi diturunkan dari FR03 yang menuntut sistem menganalisis dan memvisualisasikan kontribusi tiap fitur terhadap prediksi, serta dari NFR04 yang menuntut grafik SHAP yang terbaca untuk memindai faktor risiko dominan. Metode yang dipilih adalah SHAP (*SHapley Additive exPlanations*) karena bersifat aditif, berlandaskan aksioma nilai Shapley, dan dapat menjelaskan prediksi baik pada tingkat global maupun individu.

Keputusan rancangan pada modul ini adalah penetapan *explainer*. Mengacu pada landasan teori yang telah diuraikan pada Subbab II.3.1, dipilih TreeSHAP (*TreeExplainer*) karena model akhir yang digunakan berbasis pohon, yaitu XGBoost (*tree ensemble*). TreeSHAP dikembangkan secara khusus untuk model berbasis pohon sehingga menghitung nilai Shapley secara eksak dan efisien, sesuai dengan karakteristik model yang digunakan (Lundberg dkk. 2020). Rancangan penyajian juga ditetapkan, yaitu analisis global dalam satuan *log-odds* dan analisis lokal dalam satuan probabilitas agar lebih mudah dipahami pengguna. Alur modul interpretasi ditunjukkan pada Gambar IV.5.



Gambar IV.5 Tahapan perancangan modul interpretasi (XAI)

IV.2.4 Perancangan Modul Narasi


Modul narasi diturunkan dari FR04 yang menuntut narasi bahasa Indonesia yang mudah dipahami, serta dari FR05 dan NFR03 yang menuntut faktualitas tinggi dan pengendalian halusinasi. Karena keluaran menyentuh ranah kesehatan, prioritas rancangannya adalah menekan misinformasi. Untuk itu, dipertimbangkan empat alter-

natif rancangan sebagaimana dirangkum pada Tabel IV.1.

Tabel IV.1 Alternatif rancangan modul narasi

Alternatif	Kelebihan	Kekurangan	Pilihan
LLM murni (<i>direct prompting</i>)	Narasi luwes dan mudah dipahami.	Rawan halusinasi; angka dan arah tidak terkendali.	—
RAG/ <i>grounding</i> ke dokumen medis	Berbasis rujukan eksternal.	Kompleks, memerlukan basis pengetahuan dan biaya tambahan, tetap rawan salah rujuk.	—
Deterministik penuh (<i>template</i>)	Sangat faktual dan dapat ditelusuri.	Kaku, kurang personal dan luwes.	—
Deterministik + LLM (penghalus bahasa)	Angka/arah/fakta terkunci deterministik, bahasa tetap luwes; dilengkapi <i>fallback</i> .	Memerlukan perancangan dua lapisan yang cermat.	✓

Berdasarkan Tabel IV.1, dipilih arsitektur deterministik + LLM. Pendekatan RAG yang sempat dipertimbangkan pada tahap proposal tidak dilanjutkan karena menambah kompleksitas dan biaya tanpa menjamin bebas kesalahan, sementara kebutuhan faktualitas dapat dipenuhi secara lebih ringkas melalui kaidah deterministik. Dalam rancangan ini, seluruh angka, arah pengaruh, pemilihan fakta, dan materi saran ditetapkan secara deterministik dari nilai SHAP dan kondisi klinis pasien, sedangkan LLM (Groq *llama-3.1-8b-instant*) hanya bertugas merangkai ulang materi saran menjadi bahasa yang lebih luwes dan empatik. Penyusunan *prompt* menerapkan *guardrail* berupa penetapan persona, penyisipan fakta terstruktur, dan larangan memfabrikasi angka maupun klaim medis. Apabila layanan LLM tidak tersedia, sistem memakai materi deterministik sebagai *fallback* sehingga keluaran tetap valid. Rancangan dua lapisan ini diilustrasikan pada Gambar IV.6.



Gambar IV.6 Rancangan arsitektur modul narasi

IV.3 Rancangan Antarmuka Pengguna

Antarmuka dirancang untuk mendukung akuisisi masukan (FR01) dan penyajian tiga luaran, yaitu status risiko (FR02), grafik kontribusi fitur (FR03), dan narasi penjelasan (FR04). Pengguna utama antarmuka ini adalah masyarakat awam yang melakukan skrining mandiri, sedangkan tenaga medis berperan sebagai validator keluaran; karena itu, tampilan diutamakan sederhana dan komunikatif.

Formulir masukan dirancang bertahap dalam tiga langkah agar tidak membebani pengguna, yaitu: (1) demografi dan fisik (usia, jenis kelamin, berat badan, tinggi badan); (2) riwayat medis dan gaya hidup (status merokok, riwayat diabetes, dan riwayat kolesterol tinggi berdasarkan diagnosis tenaga kesehatan); dan (3) kualitas tidur (skor kualitas dan gangguan tidur). Rancangan formulir ditunjukkan pada Gambar IV.7, IV.8, dan IV.9.

← Beranda
Langkah 1 dari 3
Reset

Demografi & Fisik

Data dasar diri Anda.

Berapa usia Anda?

21
tahun

Apa jenis kelamin Anda?

Laki-laki

Berapa berat badan Anda?

70
kg

Berapa tinggi badan Anda?

180
cm

Lanjutkan

Gambar IV.7 Rancangan antarmuka formulir masukan tahap 1

← Beranda
Langkah 2 dari 3
Reset

Riwayat Medis & Gaya Hidup

Kondisi kesehatan dan kebiasaan yang memengaruhi tekanan darah.

Apakah Anda pernah atau sedang aktif mengonsumsi tembakau (merokok, melinting, pipa, atau mengunyah)?

Tidak

Apakah Dokter/Paramedis/Perawat/Bidan pernah mengatakan bahwa Anda memiliki penyakit diabetes?

Tidak

Apakah Dokter/Paramedis/Perawat/Bidan pernah mengatakan bahwa Anda memiliki kolesterol tinggi?

Tidak

Kembali

Lanjutkan

Gambar IV.8 Rancangan antarmuka formulir masukan tahap 2

← Beranda
Langkah 3 dari 3
Reset

Kualitas Tidur

Pola tidur Anda dalam sebulan terakhir.

Dalam 1 minggu terakhir, bagaimana Anda menilai kualitas tidur Anda?

3 — Cukup

Dalam satu minggu terakhir, seberapa sering Anda mengalami gangguan tidur (sulit tidur atau sering terbangun)?


1 — Tidak pernah

Kembali

Kirim & Analisis

Gambar IV.9 Rancangan antarmuka formulir masukan tahap 3

Halaman hasil dirancang menyajikan tiga luaran secara terpadu: status risiko sebagai label “Risiko Rendah”/“Risiko Tinggi” beserta pengukur (*meter*) probabilitas berwarna; grafik kontribusi faktor berupa diagram batang horizontal (merah menaikkan, hijau menurunkan risiko); dan narasi penjelasan yang ditutup pernyataan bahwa hasil merupakan informasi pendukung awal dan bukan pengganti diagnosis tenaga kesehatan. Rancangan halaman hasil ditunjukkan pada Gambar IV.11.




Gambar IV.10 Rancangan antarmuka formulir masukan tahap 3

Meskipun sistem mengotomatiskan sebagian proses penalaran risiko, keputusan klinis akhir tetap berada pada tenaga kesehatan. Luaran sistem diposisikan sebagai alat bantu skrining awal dan edukasi bagi masyarakat awam, bukan sebagai pengganti diagnosis medis. Dengan demikian, rancangan ini menekankan deteksi dini dan pemahaman risiko yang transparan, sekaligus tetap menjaga peran tenaga kesehatan sebagai penentu tindakan medis lanjutan.

IV.4 Diagram Tahapan Keseluruhan Penelitian

Berikut ini merupakan diagram dari tahapan keseluruhan penelitian.



Gambar IV.11 Diagram Tahapan Keseluruhan Penelitian

BAB V

IMPLEMENTASI

Bab ini memaparkan hasil pelaksanaan seluruh tahapan pengembangan sistem, yang meliputi pemahaman dan persiapan data, pelatihan dan evaluasi model *machine learning*, implementasi metode Explainable AI berbasis SHAP, dan narasi medis berbasis *Large Language Model* dengan teknik *prompt engineering*. Seluruh tahapan dilaksanakan mengacu pada metodologi CRISP-DM sebagaimana diuraikan pada Bab I.

V.1 Data Understanding

Tahap pemahaman data merupakan awal dari metode CRISP-DM. Tahap ini bertujuan untuk melihat gambaran umum dataset sebelum pemodelan.

V.1.1 Akuisisi Data

V.1.1.1 Sumber Data

Penelitian ini menggunakan data *Indonesian Family Life Survey* gelombang kelima di tahun 2014. Survei nasional ini mencakup data kesehatan, sosial, dan ekonomi lebih dari 36.000 responden di seluruh Indonesia. IFLS tahun 2014 merupakan gelombang kelima atau IFLS-5. Data ini menjadi gelombang terbaru yang terbit hingga saat ini (Strauss, Witoelar, dan Sikoki 2016).

Peneliti memilih IFLS-5 karena memiliki data observasi yang sangat beragam. Penulis belum menemukan survei nasional terbuka dan gratis lain di Indonesia yang menandingi keberagaman dari IFLS. Data tahun 2014 tersebut tetap relevan untuk kondisi kesehatan masyarakat saat ini. Karakteristik klinis dan penyebaran penyakit hipertensi tidak banyak mengalami perubahan. Riset Kesehatan Dasar (Riskesdas) tahun 2018 memperkuat fakta tersebut. Laporan Kementerian Kesehatan RI (Kementerian Kesehatan Republik Indonesia 2018) menunjukkan pola hipertensi orang dewasa tetap sama sejak 2014. Jadi, data IFLS-5 tetap sah untuk melatih model *machine learning*.

Peneliti mengunduh data tersebut dari portal resmi *RAND Corporation*. Berkas da-

ta yang sudah diunduh kemudian didistribusikan dalam format .dta yaitu Stata yang terkompresi dalam arsip .zip. Setelah mengunduh dan mengekstrak berkas-berkas tersebut, direktori data diorganisasi dalam struktur hierarkis di dalam repositori penulis. Setiap subfolder merepresentasikan satu berkas survei, dan berkas yang digunakan dalam penelitian ini dirangkum pada Tabel V.1.

V.1.1.2 Ekstraksi Kolom

Mengingat setiap berkas .dta IFLS dapat mengandung ratusan hingga ribuan kolom variabel yang sebagian besar tidak relevan dengan penelitian ini, penulis mengambil variabel yang diperlukan dari keseluruhan isi berkas ke dalam memori. Pustaka bernama *pyreadstat* digunakan untuk membaca berkas .dta karena mendukung pembacaan parsial melalui parameter *usecols*, sehingga hanya kolom yang telah didefinisikan sebelumnya yang dimuat ke dalam memori.

Proses ekstraksi dilakukan secara bertahap untuk setiap berkas secara terpisah. Karena IFLS menyimpan informasi responden dalam berbagai modul survei yang terpisah, diperlukan identifikasi *dataset* yang relevan dengan faktor risiko hipertensi berdasarkan *guideline* yang ada di situs web RAND Corporation. Proses eksplorasi dilakukan terhadap modul demografi, gaya hidup, penyakit kronis, frekuensi makan, pengukuran fisik, serta kualitas tidur. Seluruh modul yang terpilih kemudian dianalisis struktur atribut, ketersediaan variabel, serta mekanisme penghubung data-nya. Integrasi data dilakukan menggunakan variabel identitas unik responden, yaitu *PIDLINK*, yang tersedia secara konsisten pada seluruh modul yang digunakan.

Proses pembentukan populasi penelitian diawali dengan menggabungkan data pelacakan responden, yaitu *ptrack*, dan data demografi, yaitu *b3a_cov*, menggunakan metode *right join* berdasarkan *PIDLINK*. Penggunaan *right join* dilakukan karena *b3a_cov* berisikan data responden pada IFLS gelombang 5, sedangkan *ptrack* berisikan data responden dari kuesioner gelombang 1 sampai 5. Karena fokus penelitian ini pada IFLS gelombang 5, maka integritas data dari *b3a_cov* diprioritaskan. Hasil proses ini menghasilkan *dataset* dengan 36.391 responden yang kemudian ditetapkan sebagai *dataset* rujukan utama atau *dataset master*.

Setelah *dataset master* terbentuk, proses integrasi dilanjutkan pada modul gaya hidup yang terdiri atas data merokok dan aktivitas fisik. Sebelumnya, informasi aktivitas fisik direncanakan diambil dari modul *b3b_ak1* dan *b3b_ak2*. Namun, hasil penelusuran lebih mendalam menunjukkan bahwa modul AK sebenarnya merupakan representasi dari modul Asuransi Kesehatan, bukan aktivitas fisik. Oleh karena itu, untuk menjaga validitas metodologis, sumber data aktivitas fisik dialihkan ke modul

Tabel V.1 Berkas Data IFLS yang Digunakan dalam Penelitian

Nama Berkas	Buku	Variabel Utama	Keterangan
<i>ptrack & b3a_cov</i>	Tracking & Book 3A	<i>pidlink, sex, age</i>	Identitas unik (<i>pidlink</i>) sebagai kunci penggabungan serta demografi dasar berupa usia dan jenis kelamin; menjadi dasar <i>dataset master</i>
<i>b3b_km & b3b_kk2</i>	Book 3B	<i>km01a, kk020</i>	Status merokok serta frekuensi aktivitas fisik berbasis IPAQ (aktivitas berat, sedang, dan jalan kaki)
<i>B3B_CD3</i>	Book 3B	<i>cd05</i>	Riwayat penyakit kronis; kode 'B' untuk diabetes dan kode 'M' untuk kolesterol tinggi
<i>B3B_FM2</i>	Book 3B	<i>fm03</i>	Frekuensi konsumsi makanan; kode 'L' untuk <i>fast food</i> , 'M' untuk minuman bersoda, dan 'O' untuk gorengan
<i>BUS_US</i>	Book US	<i>us04, us06, us06a, us07a1, us07a2</i>	Pengukuran fisik berupa tinggi badan, berat badan, dan lingkar pinggang, serta tekanan darah sistolik dan diastolik yang menjadi dasar pembentukan label
<i>B3B_TDR</i>	Book 3B	<i>tdr01</i>	Kualitas tidur dan gangguan tidur dengan skala ordinal 1–5

yang tepat, yaitu modul *b3b_kk2* (Kesehatan Kronis). Ekstraksi dilakukan pada variabel *kk020* yang mencakup komponen pertanyaan berbasis *International Physical Activity Questionnaire* (IPAQ), yang kemudian di-*pivot* menjadi tiga fitur frekuensi aktivitas, yaitu *freq_hard_act*, *freq_moderate_act*, dan *freq_walking*. Sementara itu, untuk informasi merokok, pemrosesan disederhanakan dengan hanya mengekstraksi variabel *km01a* dari modul *b3b_km* untuk membentuk atribut *is_smoking*. Langkah ini dipilih karena variabel *km01a* secara langsung dan komprehensif sudah dapat merepresentasikan status kepemilikan kebiasaan merokok responden. Data dari kedua modul tersebut kemudian dihubungkan ke *dataset master* menggunakan metode *left join*.

Eksplorasi berikutnya dilakukan pada modul penyakit kronis yang tersimpan dalam modul *B3B_CD3*. *Dataset* ini memiliki struktur *one-to-many* karena setiap responden dapat memiliki lebih dari satu catatan penyakit kronis dengan kode penyakit yang berbeda. Oleh karena itu dilakukan identifikasi variabel tipe penyakit terlebih dahulu untuk menyeleksi entri yang merepresentasikan diabetes mellitus menggunakan kode penyakit yang sesuai dalam dokumentasi IFLS. Setelah pencarian, ditemukan kode penyakit diabetes adalah 'B' pada variabel *cd05*. Melalui mekanisme filter yang sama, ekstraksi juga dilakukan untuk mengidentifikasi riwayat kolesterol tinggi responden menggunakan kode penyakit 'M' pada variabel *cd05* untuk membentuk fitur *is_high_cholesterol*. Hasil akuisisi data diabetes dan kolesterol ini kemudian direduksi dan ditransformasikan menjadi atribut biner tingkat individu menggunakan *PIDLINK* sebagai penghubung.

Eksplorasi juga dilakukan pada modul frekuensi makan yang tersimpan pada modul *B3B_FM2* untuk mengidentifikasi frekuensi konsumsi makanan. Berdasarkan dokumentasi IFLS, kode makanan tertentu digunakan untuk merepresentasikan konsumsi berbagai jenis makanan yang beragam, seperti ubi, ikan, mie instan, dan lain-lain. Frekuensi makanan yang ingin penulis dapatkan adalah frekuensi *fast-food* atau makanan cepat saji. Setelah dilakukan proses penelusuran terhadap atribut jenis makanan dan frekuensi konsumsi, ditemukan bahwa informasi frekuensi konsumsi tersedia pada variabel *fm03* yang merekam jumlah hari konsumsi dalam periode pengamatan, dan kode 'L' sebagai kode dari frekuensi *fast food*. Selanjutnya, untuk memperkaya variasi faktor risiko dari pola makan, dilakukan ekstraksi tambahan pada variabel *fm03* menggunakan kode 'M' untuk konsumsi minuman bersoda (*freq_soda*) dan kode 'O' untuk konsumsi makanan digoreng (*freq_fried_food*). Variabel tersebut dipilih sebagai indikator pola konsumsi makanan yang berpotensi berhubungan dengan asupan natrium dan risiko hipertensi.

Selanjutnya dilakukan eksplorasi terhadap modul pengukuran fisik yang tersimpan pada modul *BUS_US*. Pada proses ini, penulis sengaja ingin melakukan pergantian nama dari data untuk memperjelas dan mempermudah pemrosesan atribut di tahap berikutnya. Hasil audit berhasil mengidentifikasi variabel *us06* yang diganti menjadi berat badan, *us04* yang diganti menjadi tinggi badan, *us06a* yang diganti menjadi lingkaran pinggang, *us07a1* yang diganti menjadi tekanan darah sistolik, dan *us07a2* yang diganti menjadi tekanan darah diastolik. Ketersediaan data berat dan tinggi badan di *dataset* juga memungkinkan untuk fitur turunan berupa indeks massa tubuh atau *Body Mass Index* (BMI) terealisasi di tahap berikutnya.

Selain pengukuran antropometri, kualitas dan gangguan tidur juga dieksplorasi melalui modul *B3B_TDR* (atau modul terkait kuesioner tidur). Fitur bernama *sleep_quality* diekstraksi dari variabel *tdr01* untuk melihat kualitas tidur umum. Untuk menangkap aspek gangguan istirahat secara lebih spesifik, variabel *tdr01* dengan jenis pertanyaannya gangguan tidur (*tdrtype* = 1) juga diekstraksi menjadi fitur *sleep_disturbance*. Kedua fitur ini mengukur persepsi responden menggunakan skala ordinal 1 sampai 5.

Seluruh variabel dari berbagai modul kemudian diintegrasikan dengan *dataset master* menggunakan metode *left join* berdasarkan *PIDLINK*. Penggunaan *left join* dipilih untuk mempertahankan jumlah responden pada populasi dasar dan menghindari kehilangan observasi akibat ketidaklengkapan data pada modul tertentu. Dengan pendekatan ini, responden yang tidak memiliki informasi pada suatu variabel tetap dipertahankan dalam *dataset* dan nilai yang tidak tersedia direpresentasikan sebagai *missing value*. Strategi tersebut memungkinkan proses penanganan data hilang dilakukan secara sistematis pada tahap *Data Preparation* tanpa mengurangi ukuran populasi penelitian secara signifikan.

Hasil akhir tahap *Data Understanding* berupa *dataset* terintegrasi yang terdiri atas 36.391 responden dan 19 variabel. Variabel tersebut mencakup karakteristik usia, jenis kelamin, status merokok, aktivitas fisik, status diabetes, frekuensi konsumsi *fast food*, pengukuran antropometri, dan tekanan darah. *Dataset* yang dihasilkan telah memberikan gambaran mengenai cakupan informasi yang tersedia sekaligus menunjukkan keterhubungan antar modul IFLS melalui *PIDLINK*. Hasil pemahaman ini kemudian menjadi dasar dalam proses pembersihan data, transformasi fitur, penanganan nilai hilang, dan pengembangan model pada tahap *Data Preparation*. Berikut ini merupakan deskripsi variabel dari data yang sudah diekstraksi, sebagaimana disajikan pada Tabel V.2.

Tabel V.2 Deskripsi Variabel

Variabel	Nama IFLS	Pertanyaan / Keterangan	Jenis Data
ID Individu	<i>pidlink</i>	Nomor identifikasi unik yang bersifat permanen dan digunakan untuk mengidentifikasi setiap responden pada satu atau lebih gelombang survei IFLS. Penelitian ini hanya memanfaatkan <i>pidlink</i> dari gelombang IFLS 2014.	Numerik
Jenis kelamin	<i>sex</i>	Apa jenis kelamin anda? (Laki-laki/perempuan)	Kategorikal
Usia	<i>age</i>	Berapa usia anda?	Numerik
Merokok	<i>km01a</i>	Apakah anda pernah mempunyai kebiasaan menghisap rokok/cerutu? (ya/tidak)	Kategorikal

Variabel	Nama IFLS	Pertanyaan / Keterangan	Jenis Data
Aktivitas fisik	<i>kk020_A</i> , <i>kk020_B</i> , <i>kk020_C</i>	1. Selama 7 hari terakhir, berapa hari anda melakukan Kegiatan fisik berat [A] paling tidak selama 10 menit berturut-turut? 2. Selama 7 hari terakhir, berapa hari anda melakukan Kegiatan fisik sedang [B] paling tidak selama 10 menit berturut-turut? 3. Selama 7 hari terakhir, berapa hari anda berjalan kaki [C] paling tidak selama 10 menit berturut-turut? A. Kegiatan fisik berat yaitu kegiatan yang membuat anda bernapas jauh lebih berat dari biasanya, seperti mengangkat barang berat, menggali, mencangkul, bersepeda sambil membawa beban berat, dan sebagainya. B. Kegiatan fisik sedang, yaitu kegiatan yang membuat anda bernapas agak lebih berat dari biasanya, seperti mengangkat barang yang tidak terlalu	Numerik

Variabel	Nama IFLS	Pertanyaan / Keterangan	Jenis Data
Diabetes	<i>cd05</i> (dengan <i>cdtype='B'</i>)	Apakah Dokter/Paramedis/Perawat/Bidan pernah mengatakan bahwa anda memiliki penyakit diabetes? (ya/tidak)	Kategorikal
Kolesterol Tinggi	<i>cd05</i> (dengan <i>cdtype='M'</i>)	Apakah Dokter/Paramedis/Perawat/Bidan pernah mengatakan bahwa anda memiliki penyakit kolesterol tinggi? (ya/tidak)	Kategorikal
Fast food	<i>fm03</i>	Dalam seminggu terakhir, berapa hari anda mengonsumsi makanan cepat saji? (KFC, Burger, dll)	Numerik
Minuman Bersoda	<i>fm03</i>	Dalam seminggu terakhir, berapa hari anda mengonsumsi minuman bersoda?	Numerik
Gorengan	<i>fm03</i>	Dalam seminggu terakhir, berapa hari anda mengonsumsi makanan yang digoreng?	Numerik
Berat badan	<i>us06</i>	Berapa berat badan anda?	Numerik
Tinggi badan	<i>us04</i>	Berapa tinggi badan anda?	Numerik
Lingkar pinggang	<i>us06a</i>	Berapa panjang lingkar pinggang anda?	Numerik

Variabel	Nama IFLS	Pertanyaan / Keterangan	Jenis Data
Sistolik	<i>us07a1</i>	Tekanan darah sistolik responden, dipakai sebagai label.	Numerik
Diastolik	<i>us07a2</i>	Tekanan darah diastolik responden, dipakai sebagai label.	Numerik
Tidur	<i>tdr01</i>	Dalam 1 minggu terakhir, bagaimana Anda menilai kualitas tidur Anda? 1. Sangat baik 2. Baik 3. Cukup 4. Buruk 5. Sangat buruk	Ordinal
Gangguan tidur	<i>tdr01</i> (dengan <i>tdr-type=1</i>)	Dalam satu minggu terakhir, seberapa sering Anda mengalami gangguan tidur (sulit tidur atau sering terbangun)? 1. Tidak pernah 2. Jarang 3. Kadang-kadang Sering Selalu	Ordinal

V.1.2 Eksplorasi Data

Eksplorasi data awal merupakan tahap untuk memahami struktur, distribusi nilai, serta karakteristik dataset sebelum data diolah lebih lanjut. Tujuan utamanya adalah menemukan pola, anomali, dan permasalahan kualitas data yang akan memengaruhi tahap persiapan data dan pemodelan. Pada penelitian ini eksplorasi dilakukan terhadap berkas hasil akuisisi data IFLS, dengan hipertensi sebagai variabel targetnya. Proses eksplorasi mencakup pengecekan isi data, perhitungan statistik deskriptif, serta visualisasi data yang disertai interpretasinya.

V.1.2.1 Struktur dan Dimensi Dataset


Pengecekan awal dilakukan untuk memastikan kerangka data berada dalam keadaan utuh. Dataset memuat 36.391 baris dan 19 kolom, dengan *pidlink* sebagai pengidentifikasi tiap individu. Seluruh nilai *pidlink* bersifat unik dan tidak ditemukan baris yang terduplikasi, sehingga setiap baris mewakili satu individu yang berbeda. Dengan demikian, penanganan duplikasi tidak diperlukan pada tahap pembersihan data.

Sebagian besar kolom kategorik terbaca sebagai angka desimal, dan beberapa diantaranya mengandung nilai berkode khusus yang perlu pengecekan lebih lanjut. Nilai tersebut mencakup 998 pada variabel *age*, kode 8 dan 9 pada variabel *is_diabetes* dan *is_high_cholesterol*, serta kode 9 pada variabel *sleep_quality* dan *sleep_disturbance*. Kolom *is_smoking* juga perlu diperiksa karena isinya masih berupa kode IFLS 1 dan 3. Seluruh nilai berkode khusus tersebut diubah menjadi nilai kosong terlebih dahulu sebelum analisis dilanjutkan.

V.1.2.2 Penentuan dan Karakteristik Variabel Target


Variabel target hipertensi tidak tersedia secara langsung dalam dataset, sehingga harus dibentuk dari hasil pengukuran tekanan darah. Berdasarkan panduan klinis JNC 7 dan WHO, seseorang dikategorikan hipertensi apabila tekanan sistoliknya mencapai 140 mmHg atau lebih, atau tekanan diastoliknya mencapai 90 mmHg atau lebih. Karena ambang 140/90 mmHg berlaku spesifik untuk orang dewasa, eksplorasi target dan analisis bivariat pada subbab ini difokuskan pada responden berusia 18 tahun ke atas agar konsisten dengan populasi yang digunakan pada tahap pemodelan; perincian pembatasan usia dibahas pada tahap Data Preparation. Selain itu, karena label dibentuk langsung dari nilai tekanan darah, tekanan darah yang tidak wajar juga dibersihkan terlebih dahulu agar label yang dihasilkan akurat. Setelah responden di bawah 18 tahun dikeluarkan, tiga baris bernilai mustahil disisihkan, dan baris tanpa pengukuran dibuang, diperoleh 30.251 responden dewasa dengan tekanan darah valid.

Gambar V.1 menyajikan komposisi kelas pada variabel target setelah proses pelabelan dilakukan. Dari 30.251 responden dewasa, sebanyak 8.851 orang atau 29,26% tergolong hipertensi, sedangkan 21.400 orang atau 70,74% tidak hipertensi. Rasio antara kedua kelas sekitar satu berbanding dua koma empat, yang tergolong relatif seimbang dan jauh lebih baik dibandingkan apabila diabetes dijadikan target dengan kasus positif kurang dari satu persen. Oleh karena itu, pemodelan dapat dilakukan tanpa teknik penyeimbangan kelas yang agresif, meskipun metrik recall dan



Gambar V.1 Komposisi Kelas Target Hipertensi


F1-score tetap perlu dipantau di samping akurasi.




Gambar V.2 Distribusi Tekanan Darah Sistolik

Gambar V.2 memperlihatkan sebaran tekanan darah sistolik beserta garis ambang 140 mmHg. Distribusi memuncak pada kisaran 110 sampai 130 mmHg dan cenderung menjulur ke kanan hingga melewati 200 mmHg. Sebagian responden berada di sebelah kanan garis ambang, dan kelompok inilah yang tergolong hipertensi dari sisi sistolik. Kemiringan distribusi ke kanan menandakan adanya sejumlah nilai pencilan pada sisi tinggi yang perlu ditangani dengan hati-hati pada tahap berikutnya.

Gambar V.3 menampilkan sebaran tekanan darah diastolik beserta garis ambang 90 mmHg. Distribusi diastolik terlihat lebih simetris dibandingkan sistolik, dengan puncak pada kisaran 70 sampai 85 mmHg. Seorang responden dapat tergolong hipertensi melalui kriteria diastolik meskipun nilai sistolik masih di bawah 140 mmHg, karena pelabelan cukup memenuhi salah satu dari kedua kriteria tersebut. Dengan demikian, kedua komponen tekanan darah sama-sama berperan dalam pembentukan label.



Gambar V.3 Distribusi Tekanan Darah Diastolik



Gambar V.4 Sistolik vs Diastolik menurut Status Hipertensi

Gambar V.4 menggabungkan tekanan sistolik pada sumbu horizontal dan diastolik pada sumbu vertikal, dengan warna merah menandai responden hipertensi. Titik berwarna merah mengelompok di sebelah kanan garis 140 dan di atas garis 90, sedangkan titik berwarna biru terkonsentrasi pada pojok kiri bawah. Pemisahan yang tampak jelas ini terjadi karena label memang dihitung langsung dari kedua nilai tekanan darah. Hal ini menjadi peringatan penting, sebab memasukkan tekanan darah sebagai fitur akan menimbulkan kebocoran data, sehingga kedua variabel tersebut wajib dikeluarkan dari daftar prediktor.

V.1.2.3 Kelengkapan Data dan Statistik Deskriptif


Permasalahan kualitas data yang paling menonjol adalah tingginya proporsi nilai hilang yang tersebar tidak merata antarvariabel. Sebagian kolom hampir kosong, sementara sebagian lain hampir lengkap. Tabel V.3 mengelompokkan variabel menurut tingkat kekosongannya agar strategi penanganannya dapat ditentukan secara proporsional. Pengelompokan ini penting karena kolom dengan kekosongan parah memerlukan perlakuan yang berbeda dari kolom dengan kekosongan ringan.

Tabel V.3 Pengelompokan Variabel Berdasarkan Tingkat Nilai Hilang

Kategori	Rentang lang	Hi-	Variabel
Sangat parah	50% ke atas		<i>freq_fast_food</i> 90,4%, <i>freq_soda</i> 83,2%, <i>freq_hard_act</i> 81,0%, <i>waist_cm</i> 63,7%, <i>freq_moderate_act</i> 51,7%
Sedang	10% sampai 50%		<i>freq_fried_food</i> 43,8%, <i>freq_walking</i> 39,7%, <i>sleep_disturbance</i> 13,6%, <i>sleep_quality</i> 13,6%, <i>bp_systolic</i> dan <i>bp_diastolic</i> 10,6%, <i>weight_kg</i> 10,4%, <i>height_cm</i> 10,3%
Ringan	di bawah 10%		<i>is_diabetes</i> 5,9%, <i>is_high_cholesterol</i> 5,9%, <i>is_smoking</i> 5,8%, <i>age</i> 0,03%, <i>sex</i> 0,02%
Lengkap	sekitar 0%		<i>pidlink</i>

Untuk memperjelas sebaran kekosongan tersebut, proporsi nilai hilang setiap kolom divisualisasikan pada Gambar V.5. Grafik tersebut memperlihatkan bahwa kelompok variabel gaya hidup, yaitu frekuensi konsumsi makanan dan aktivitas fisik, mendominasi sisi kiri dengan kekosongan tertinggi. Sebaliknya, variabel identitas dan demografi seperti *pidlink*, *sex*, dan *age* berada pada sisi kanan dengan kekosongan

mendekati nol. Visualisasi ini mempertegas bahwa keputusan seleksi fitur nantinya perlu mempertimbangkan tingkat kelengkapan tiap variabel.



Gambar V.5 Persentase Missing Value per Fitur

Pola nilai hilang ini bersifat tidak acak dan tampak mengikuti desain survei. Variabel aktivitas fisik dan pola makan kosong pada sebagian besar responden bukan karena kesalahan pencatatan, melainkan karena pertanyaannya hanya diajukan kepada sebagian peserta. Kekosongan dengan pola seperti ini berisiko menimbulkan bias apabila ditambah secara sembarangan. Oleh karena itu, penanganannya tidak dapat diseragamkan, dan sebagian kolom mungkin lebih baik dibuang daripada dipaksakan untuk dipertahankan.


Statistik deskriptif digunakan untuk memahami rentang nilai dan kecenderungan tiap variabel numerik. Karena kolom *bmi* tidak tersedia pada dataset, nilainya dihitung terlebih dahulu dari berat dan tinggi badan sebelum diringkaskan. Tabel V.4 menyajikan tujuh variabel numerik utama beserta ukuran pemusatan dan penyebarannya. Pemeriksaan terhadap nilai ekstrem juga dilakukan untuk mendeteksi kemungkinan kesalahan pencatatan.

Beberapa nilai pada tabel tersebut layak dicermati lebih lanjut. Nilai rata-rata yang konsisten lebih tinggi daripada median pada berat badan, bmi, dan tekanan darah menunjukkan distribusi yang condong ke kanan, yang merupakan ciri umum data antropometri. Nilai maksimum bmi sebesar 68,76 dan sistolik sebesar 246 mengindikasikan keberadaan pencilan pada sisi tinggi. Sementara itu, usia kini berhenti pada angka wajar 110 tahun setelah nilai berkode khusus 998 dibersihkan.

Gambar V.6 menyajikan matriks korelasi antarvariabel numerik untuk mengidentifikasi keterkaitan dan redundansi. Korelasi tertinggi ditemukan antara bmi dengan

Tabel V.4 Statistik Deskriptif Variabel Numerik

Variabel	N	Mean	Std	Min	Median	Maks
<i>age</i>	30.251	39,95	15,21	18	37	110
<i>weight_kg</i>	30.083	57,27	11,87	22,0	56,0	133,1
<i>height_cm</i>	30.109	156,35	8,50	94,3	156,0	198,0
<i>waist_cm</i>	13.097	83,93	11,77	32,0	83,6	150,0
<i>bmi</i>	30.055	23,42	4,45	10,85	22,82	68,76
<i>bp_systolic</i>	30.251	130,12	22,37	64	126	246
<i>bp_diastolic</i>	30.251	79,82	12,37	35	78	187



Gambar V.6 Korelasi antar Variabel Numerik

berat badan sebesar 0,85 dan dengan lingkar pinggang sebesar 0,83, yang wajar karena ketiganya mengukur dimensi tubuh yang serupa. Tekanan sistolik dan diastolik juga menunjukkan korelasi yang kuat sebesar 0,73. Tingginya korelasi antarvariabel ini menandakan adanya multikolinearitas, sehingga cukup dipilih salah satu variabel sebagai wakil agar model tidak menjadi tidak stabil.

V.1.2.4 Analisis Bivariat antara Fitur dan Hipertensi


Analisis bivariat dilakukan untuk mengidentifikasi faktor yang paling berhubungan dengan kejadian hipertensi. Secara kuantitatif, analisis menggunakan koefisien korelasi point-biserial untuk mengukur kedekatan hubungan variabel numerik, serta analisis komparatif untuk menghitung tingkat kejadian pada setiap subkelompok. Secara visual, hubungan tersebut direpresentasikan melalui grafik batang dan grafik batang berkelompok untuk mengidentifikasi pola serta perbedaan distribusi persentase hipertensi. Hasil korelasi disajikan pada Tabel V.5, yang menunjukkan bahwa hanya sebagian kecil faktor yang berhubungan kuat, sedangkan sebagian besar lainnya berhubungan lemah.

Tabel V.5 Korelasi Point-Biserial Fitur Numerik dengan Hipertensi


Fitur	Korelasi dengan Hipertensi
<i>age</i>	+0,410
<i>bmi</i>	+0,186
<i>waist_cm</i>	+0,186
<i>sleep_quality</i>	+0,060
<i>freq_fried_food</i>	+0,025
<i>freq_moderate_act</i>	+0,017
<i>freq_walking</i>	+0,011
<i>freq_hard_act</i>	+0,009
<i>freq_fast_food</i>	-0,006
<i>freq_soda</i>	-0,009
<i>sleep_disturbance</i>	-0,032

Gambar V.7 menggambarkan tingkat hipertensi pada setiap kelompok umur. Tingkat hipertensi meningkat secara konsisten, mulai dari sekitar 12% pada kelompok di bawah 30 tahun, lalu 36% pada rentang 40 sampai 49 tahun, hingga mencapai 72% pada kelompok 70 tahun ke atas. Tidak terdapat satu pun kelompok yang membalik kecenderungan kenaikan tersebut. Dengan korelasi tertinggi di antara seluruh kandidat sebesar 0,410, usia menjadi faktor risiko paling dominan dan kemungkinan besar menjadi prediktor utama dalam pemodelan.

Gambar V.8 memperlihatkan tingkat hipertensi menurut kategori indeks massa tu-




Gambar V.7 Tingkat Hipertensi per Kelompok Umur



Gambar V.8 Tingkat Hipertensi per Kategori BMI

buh berdasarkan klasifikasi WHO. Tingkat hipertensi meningkat seiring naiknya kategori, yaitu 21% pada kelompok *underweight*, 25% pada kelompok normal, 37% pada kelompok *overweight*, dan 47% pada kelompok obesitas. Selisih lebih dari dua kali lipat antara kelompok *underweight* dan obesitas menunjukkan hubungan positif yang kuat antara kelebihan berat badan dan hipertensi. Karena *bmi* dihitung sendiri dari berat dan tinggi badan, variabel ini menjadi ringkasan yang menggantikan kedua variabel asalnya sekaligus.


Faktor gaya hidup lain menunjukkan hubungan yang lemah dengan hipertensi. Frekuensi aktivitas fisik dan pola makan, yaitu aktivitas berat, sedang, jalan kaki, *fast food*, soda, dan gorengan, seluruhnya hanya memiliki korelasi yang sangat kecil, di bawah nol koma nol tiga, sebagian bahkan bernilai negatif. Nilai korelasi yang sangat kecil tersebut diperberat oleh kekosongan data yang tinggi, yaitu 91% pada *fast food*, 84% pada soda, dan 81% pada aktivitas berat. Dengan kondisi tersebut, variabel-variabel gaya hidup ini menjadi kandidat paling lemah dan berpotensi diabaikan pada tahap seleksi fitur.



Gambar V.9 Tingkat Hipertensi menurut Faktor Biner

Gambar V.9 membandingkan tingkat hipertensi antara kelompok yang memiliki dan tidak memiliki suatu karakteristik pada empat faktor biner. Dua faktor menonjol tajam, yaitu status diabetes dengan tingkat hipertensi 56,6% berbanding 28,6%, serta status kolesterol tinggi dengan tingkat 52,1% berbanding 28,2%. Sebaliknya, kebiasaan merokok hanya menghasilkan selisih sekitar 0,3% dan jenis kelamin nyaris tidak menunjukkan perbedaan. Perlu dicatat bahwa sebagian hubungan diabetes dan kolesterol dengan hipertensi dapat dipengaruhi oleh faktor usia, karena ketiga kondisi tersebut cenderung meningkat pada kelompok yang lebih tua.

Gambar V.10 menampilkan tingkat hipertensi menurut skor kualitas tidur. Terdapat kecenderungan kenaikan yang landai, dari sekitar 24% pada skor terbaik hingga



Gambar V.10 Tingkat Hipertensi per Skor Kualitas Tidur

sekitar 32% pada saat kualitas tidur memburuk. Korelasinya tergolong kecil, yaitu 0,06, sehingga fitur ini bukan merupakan faktor utama. Meskipun demikian, arah hubungannya masuk akal secara klinis dan datanya cukup lengkap, sehingga fitur ini masih layak dipertahankan sebagai faktor pendukung.

V.1.2.5 Karakteristik yang Memengaruhi Pemodelan

Beberapa hasil eksplorasi berdampak langsung pada perancangan model. Yang pertama dan paling penting, tekanan darah harus dikeluarkan dari daftar fitur, karena label hipertensi dibentuk langsung dari sistolik dan diastolik sehingga penyertaannya akan menimbulkan kebocoran data. Yang kedua, komposisi target yang relatif seimbang pada 29,26% memungkinkan penggunaan pendekatan standar tanpa penyeimbangan kelas yang agresif, meskipun metrik recall dan F1-score tetap perlu dipantau. Yang ketiga, analisis bivariat menunjukkan bahwa usia, bmi, status diabetes, dan status kolesterol tinggi merupakan kandidat fitur terkuat, sedangkan aktivitas fisik, pola makan, dan lingkaran pinggang yang sarat kekosongan layak dipertimbangkan untuk dibuang, dengan kualitas tidur sebagai faktor pendukung yang lemah namun masih dapat dipertahankan.

V.1.2.6 Identifikasi Anomali dan Permasalahan Data

Pemeriksaan terhadap nilai ekstrem dan kualitas data mengungkap beberapa permasalahan yang harus ditangani pada tahap persiapan data, yaitu sebagai berikut.

1. Nilai berkode khusus pada variabel *age*
 Nilai 998 muncul pada empat baris dan teridentifikasi sebagai kode nilai hilang, sebab usia valid tertinggi berikutnya adalah 110 tahun. Apabila tidak dikonversi menjadi nilai hilang, kode ini akan mendistorsi seluruh statistik dan korelasi terkait usia.
2. Nilai tekanan darah yang mustahil secara fisiologis

Ditemukan tiga baris dengan nilai diastolik lebih besar atau sama dengan sistolik serta nilai di luar rentang wajar yang mengindikasikan kesalahan pencatatan.

3. Ketidaksesuaian tipe data

Variabel kategorik berkode terbaca sebagai numerik dan perlu dikonversi serta dipetakan ulang dari kode 1/3 menjadi representasi biner 1/0 agar interpretasi model lebih jelas.

4. Nilai hilang


Sejumlah kolom gaya hidup memiliki proporsi nilai hilang yang sangat tinggi, mencapai 90% pada fast food, sehingga tidak dapat diimputasi secara wajar dan menjadi kandidat untuk dibuang pada tahap seleksi fitur.

Dataset ini masih menyimpan sejumlah permasalahan kualitas data pada isinya. Permasalahan tersebut meliputi nilai berkode khusus, nilai tekanan darah yang mustahil, serta nilai hilang yang tidak acak dengan proporsi tinggi pada variabel gaya hidup. Analisis menunjukkan sinyal yang cukup jelas, yaitu hipertensi paling kuat berhubungan dengan usia dan berat badan, dengan status diabetes dan kolesterol tinggi sebagai faktor penegas. Seluruh temuan ini menjadi dasar dalam merancang tahap persiapan data pada subbab berikutnya.

V.2 Data Preparation

Tahap data preparation bertujuan mengubah data mentah menjadi dataset yang bersih, konsisten, dan siap digunakan untuk pemodelan. Seluruh keputusan pada tahap ini dirancang berdasarkan temuan yang diperoleh pada tahap eksplorasi data awal, sehingga setiap permasalahan kualitas data yang teridentifikasi memiliki penanganan yang spesifik. Tahapan ini dilaksanakan menurut urutan yang ketat, sebab setiap langkah memengaruhi langkah berikutnya, terutama yang berkaitan dengan pembentukan label target dan pencegahan kebocoran data. Gambaran umum keseluruhan alur proses data preparation yang diterapkan disajikan pada Gambar V.11.

Gambar V.11 memperlihatkan gambaran umum alur data preparation, mulai dari dataset mentah (36.391 responden, 19 fitur), melewati serangkaian proses pembersihan dan transformasi, hingga terbentuk dataset bersih tanpa pencilan (30.251 responden, 8 fitur) yang kemudian dibagi secara *stratified* menjadi data latih dan data uji sebelum diimputasi. Rincian proses tersebut dijabarkan ke dalam delapan langkah berurutan (A–H) pada uraian berikut. Penyesuaian utama meliputi penempatan pembersihan kode tersamar di posisi paling awal, penambahan filter usia dewasa, serta penghapusan tekanan darah dari himpunan fitur untuk mencegah kebocoran data. Berbeda dengan rancangan sebelumnya, pembagian data dan imputasi kini



Gambar V.11 Alur Proses Data Preparation

dilaksanakan langsung pada tahap ini, dengan imputasi yang hanya dipelajari dari data latih agar tidak terjadi kebocoran informasi. Keseluruhan langkah persiapan data tersebut diringkas dalam bentuk pseudocode pada Algoritma V.1.

A. Pembersihan Nilai Khusus IFLS

Langkah pertama adalah mengonversi seluruh nilai yang memiliki makna khusus dalam IFLS menjadi nilai kosong. Saat mengisi kuesioner IFLS, terdapat sejumlah kasus ketika responden tidak memberikan jawaban yang valid, baik karena responden tidak mengetahui jawabannya maupun karena pewawancara terlewat menanyakannya. Kedua kondisi tersebut diwakili oleh angka 8 untuk jawaban tidak tahu dan angka 9 untuk pertanyaan yang terlewat, yang dapat membesar menjadi 98 atau 99 dan 998 atau 999 mengikuti jumlah digit kolomnya. Pada dataset ini, kode khusus tersebut ditemukan pada 16 baris *is_diabetes*, 17 baris *is_high_cholesterol*, serta masing-masing satu baris pada *sleep_quality* dan *sleep_disturbance*, sementara kode 998 pada variabel *age* turut diperiksa dan dikonversi apabila ditemukan. Langkah ini sengaja diletakkan paling awal agar nilai khusus tidak ikut terhitung sebagai data nyata pada saat imputasi maupun perhitungan statistik di tahap berikutnya.

B. Pembatasan Responden pada Usia Dewasa

Langkah kedua adalah membatasi populasi hanya pada responden berusia 18 tahun ke atas. Pembatasan ini diperlukan karena angka 140/90 mmHg sebagai ambang batas diagnosis hipertensi berlaku spesifik untuk orang dewasa berusia 18 tahun ke atas. Berdasarkan pedoman klinis terbaru dari Kementerian Kesehatan Republik Indonesia (Kemenkes) (Kementerian Kesehatan Republik Indonesia 2018), *World Health*

Organization (WHO) (World Health Organization 2023), dan *International Society of Hypertension* (ISH) (Unger dkk. 2020), seseorang berusia ≥ 18 tahun dinyatakan mengalami Hipertensi Derajat 1 apabila tekanan darah sistolik mencapai 140–159 mmHg dan/atau diastolik 90–99 mmHg saat diukur di klinik. Ambang tersebut dirumuskan khusus untuk populasi dewasa dan tidak berlaku sama untuk anak-anak maupun remaja, yang memiliki kriteria berbasis persentil menurut usia, jenis kelamin, dan tinggi badan. Apabila responden di bawah 18 tahun tetap disertakan, label hipertensi yang terbentuk berpotensi keliru dan komposisi kelas menjadi tidak representatif. Dari 36.391 responden awal, sebanyak 2.486 responden berusia di bawah 18 tahun dikeluarkan sehingga tersisa 33.905 responden yang diproses pada langkah berikutnya.

C. Koreksi Nilai Mustahil Tekanan Darah

Langkah ketiga adalah mengoreksi nilai tekanan darah yang mustahil secara fisiologis dengan mengubahnya menjadi nilai kosong. Nilai yang dianggap tidak wajar mencakup kondisi diastolik lebih besar atau sama dengan sistolik serta nilai yang berada di luar rentang yang masuk akal. Berdasarkan pemeriksaan, ditemukan tiga baris dengan nilai tekanan darah mustahil yang kemudian disisihkan bersama baris lain yang memang tidak memiliki pengukuran tekanan darah. Setelah seluruh baris tanpa tekanan darah valid dikeluarkan, tersisa 30.251 responden yang digunakan untuk membentuk label.

D. Pembentukan Label Target Hipertensi

Setelah tekanan darah dibersihkan, label target hipertensi dibentuk berdasarkan kriteria JNC 7 dan WHO, yaitu tekanan sistolik 140 mmHg atau lebih, atau tekanan diastolik 90 mmHg atau lebih. Dari 30.251 responden dewasa dengan tekanan darah valid, diperoleh komposisi 29,26% responden hipertensi dan 70,74% tidak hipertensi, konsisten dengan komposisi pada tahap eksplorasi data yang juga difokuskan pada populasi dewasa berusia 18 tahun ke atas. Komposisi tersebut masih tergolong relatif seimbang sehingga pemodelan dapat dilakukan tanpa teknik penyeimbangan kelas yang agresif.

E. Penghapusan Variabel Penyebab Kebocoran Data

Langkah kelima adalah mengeluarkan variabel *bp_systolic* dan *bp_diastolic* dari himpunan fitur prediktor. Penghapusan ini bersifat wajib karena label target merupakan fungsi deterministik dari kedua variabel tersebut. Apabila keduanya tetap disertakan sebagai fitur, model akan memperoleh jawaban secara langsung sehingga menimbulkan kebocoran data yang membuat performa tampak sempurna namun

tidak aman. Dengan mengeluarkan kedua variabel ini, model dipaksa mempelajari hubungan dari faktor risiko yang sesungguhnya, bukan dari komponen pembentuk labelnya.

F. Pengodean Variabel Kategorik

Variabel kategorik berkode dikonversi menjadi representasi biner 1 dan 0 agar interpretasi model menjadi jelas dan konsisten. Variabel *sex* diubah menjadi *is_female*, *is_smoking* menjadi *is_smoker*, *is_diabetes* menjadi *has_diabetes*, dan *is_high_cholesterol* menjadi *has_high_cholesterol*. Pada proses ini nilai kosong sengaja dipertahankan dan tidak diisi terlebih dahulu agar dapat diimputasi secara benar setelah pembagian data. Pemetaan ulang ini menghindarkan model dari kesalahan menafsirkan kode 3 sebagai nilai yang secara kuantitatif lebih besar daripada kode 1.

G. Penghitungan BMI dan Seleksi Fitur

Karena variabel *bmi* tidak tersedia secara langsung pada dataset, nilainya dihitung terlebih dahulu dari berat dan tinggi badan menggunakan rumus berat dibagi kuadrat tinggi dalam meter. Selanjutnya dilakukan seleksi fitur untuk membuang variabel yang redundan, berkekosongan tinggi, atau berhubungan lemah dengan target.

Sebagai kriteria utama penguguran fitur akibat ketidaklengkapan data, penulis menetapkan ambang batas nilai hilang sebesar 40%, sehingga fitur dengan proporsi nilai hilang di atas 40% digugurkan dari himpunan prediktor, sedangkan fitur di bawah ambang tersebut dipertahankan dan nilai hilangnya diimputasi. Penetapan ambang ini sejalan dengan prinsip umum penanganan data hilang bahwa fitur dengan proporsi nilai hilang yang tinggi tidak dapat diimputasi secara andal dan berisiko memasukkan bias ke dalam model apabila tetap dipertahankan (Kang 2013). Bahkan, sebagian literatur menyarankan bahwa data dengan proporsi nilai hilang yang sangat besar, yaitu di atas kisaran 40%, sebaiknya tidak diimputasi karena hasilnya cenderung hanya bersifat pembangkit hipotesis (Jakobsen dkk. 2017); dengan demikian, ambang 40% yang diterapkan pada penelitian ini.

Berdasarkan ambang tersebut, tujuh fitur digugurkan karena proporsi nilai hilangnya melebihi 40%, yaitu *freq_fast_food* (90%), *freq_soda* (83%), *freq_hard_act* (81%), *waist_cm* (64%), *freq_moderate_act* (52%), *freq_fried_food* (44%), dan *freq_walking* (40%). Di luar kriteria nilai hilang, variabel *weight_kg* dan *height_cm* turut dibuang bukan karena ketidaklengkapan data, melainkan karena informasinya telah sepenuhnya diwakili oleh fitur turunan *bmi*.

Sebaliknya, fitur *sleep_disturbance* tetap dipertahankan meskipun korelasi bivari-

atnya tergolong paling lemah, yaitu $-0,032$, karena proporsi nilai hilangnya masih berada di bawah ambang 30%, yaitu 13,6%, dan keputusan eliminasi pada tahap ini tidak didasarkan semata-mata pada korelasi linear. Korelasi point-biserial yang rendah hanya mengukur hubungan linear dan tidak menangkap kemungkinan efek non-linear, dan pada tahap interpretasi model efek fitur ini terkonfirmasi bermakna melalui analisis SHAP (lihat Gambar V.19).

Dengan diterapkannya seluruh kriteria di atas, jumlah variabel menyusut dari 19 variabel pada dataset terintegrasi menjadi delapan fitur prediktor terpilih ditambah satu variabel target, sebagaimana dirinci pada Tabel V.6.

Tabel V.6 Daftar Fitur Terpilih untuk Pemodelan

Fitur	Jenis	Keterangan
<i>age</i>	Numerik	Usia responden, faktor risiko terkuat dengan korelasi 0,42
<i>is_female</i>	Biner	Jenis kelamin, bernilai 1 untuk perempuan, diturunkan dari sex
<i>bmi</i>	Numerik	Indeks massa tubuh, dihitung dari berat dan tinggi badan
<i>is_smoker</i>	Biner	Status merokok, diturunkan dari is_smoking
<i>has_diabetes</i>	Biner	Status diabetes, diturunkan dari is_diabetes
<i>has_high_cholesterol</i>	Biner	Status kolesterol tinggi, diturunkan dari is_high_cholesterol
<i>sleep_quality</i>	Ordinal	Skor kualitas tidur dengan skala 1 sampai 5
<i>sleep_disturbance</i>	Ordinal	Skor gangguan tidur dengan skala 1 sampai 5
<i>label_hypertension</i>	Target	Bernilai 1 untuk hipertensi dan 0 untuk tidak hipertensi

Sumber: Hasil pengolahan data, 2026

H. Pembagian Data dan Imputasi Nilai Hilang

Pembagian data dilakukan dengan proporsi 80% untuk data latih (*training set*) dan 20% untuk data uji (*testing set*) menggunakan metode pemisahan bertingkat (*stratified split*) guna menjaga distribusi kelas pada kedua subsampel. Penggunaan *stratified split* bertujuan agar proporsi kelas hipertensi dan non-hipertensi pada data latih maupun data uji tetap merepresentasikan distribusi data asli, sehingga hasil evaluasi model menjadi lebih reliabel. Proporsi 80:20 dipilih karena dapat menyediakan jumlah data yang memadai untuk proses pembelajaran model, sekaligus mempertahankan ukuran sampel pengujian yang representatif untuk mengukur kemampuan generalisasi model secara objektif.

Setelah pembagian, diperoleh 24.200 data latih dan 6.051 data uji dengan proporsi hipertensi yang seragam pada kisaran 29,26% di kedua himpunan. Imputasi dilakukan menggunakan nilai median untuk variabel numerik dan ordinal, yaitu *age*, *bmi*, serta skor kualitas dan gangguan tidur, dan nilai modus untuk variabel biner, yaitu *is_female*, status merokok, diabetes, dan kolesterol; nilai hilang pada *age* dan *is_female* praktis nihil sehingga imputasi keduanya nyaris tidak berpengaruh. Parameter imputasi hanya dipelajari dari data latih lalu diterapkan pada data uji, sehingga tidak terjadi kebocoran informasi dari data uji ke data latih. Setelah imputasi, kedua himpunan tidak lagi memuat nilai kosong dan disimpan sebagai berkas *train_hipertensi.csv* dan *test_hipertensi.csv* untuk digunakan pada tahap pemodelan.

Secara keseluruhan, tahap persiapan data menghasilkan dataset bersih yang terdiri atas 30.251 responden dewasa dengan delapan fitur prediktor dan satu variabel target. Seluruh permasalahan yang teridentifikasi pada eksplorasi data telah ditangani, meliputi nilai berkode khusus, pembatasan usia, nilai tekanan darah yang mustahil, ketidaksesuaian penyandian, redundansi antarfitur, serta risiko kebocoran data. Data telah terbagi menjadi 24.200 data latih dan 6.051 data uji yang seluruhnya tidak lagi mengandung nilai kosong setelah imputasi. Dengan demikian, dataset hasil tahap ini telah memenuhi syarat untuk digunakan pada tahap pemodelan berikutnya.

V.2.1 Profil Dataset Final

Setelah melalui proses pembersihan data, diperoleh dataset sebagaimana dirangkum dalam Tabel V.7 berikut.

Tabel V.7 Profil Dataset Final

Karakteristik	Nilai
Total Sampel	30.251
Jumlah Fitur Input	8
Kelas Positif (Hipertensi)	8.851 (29,26%)
Kelas Negatif (Non-hipertensi)	21.400 (70,74%)
Rasio Imbalance	2,42 : 1
Data Training	24.200 (80%)
Data Pengujian	6.051 (20%)

Berdasarkan Tabel V.7, proporsi kelas positif (hipertensi) tercatat sebesar 29,26%, sedangkan kelas negatif (non-hipertensi) mendominasi dengan proporsi 70,74%, sehingga menghasilkan rasio ketidakseimbangan sekitar 2,42:1. Merujuk pada literatur terkait pembelajaran pada data tidak seimbang, rasio ini tergolong dalam kategori

ketidakseimbangan moderat (*moderate imbalance*), karena proporsi kelas minoritas berada pada rentang 10–30% dari total observasi (Krawczyk 2016). Meskipun tidak dikategorikan sebagai ketidakseimbangan ekstrem, dominasi kelas negatif ini tetap berpotensi menggeser kecenderungan model untuk memprediksi kelas mayoritas, yang pada gilirannya dapat menurunkan sensitivitas deteksi kasus hipertensi. Oleh karena itu, penanganan untuk menyeimbangkan performa tetap diperlukan. Namun, mengingat tingkat ketidakseimbangan yang masih moderat, pendekatan algoritmik seperti pembobotan kelas (*class weighting*) atau penyesuaian ambang batas (*threshold adjustment*) dinilai lebih rasional. Pendekatan tersebut secara empiris lebih direkomendasikan dibandingkan dengan teknik *resampling* yang agresif, seperti *oversampling* atau *undersampling*, yang rentan memicu terjadinya *overfitting* maupun hilangnya informasi krusial dari struktur asli dataset (He dan Garcia 2009).

V.2.2 Deskripsi Fitur Input

Model final menggunakan delapan fitur input hasil seleksi pada tahap *Data Preparation*, yang terdiri atas fitur numerik, biner, dan ordinal. Deskripsi lengkap kedelapan fitur beserta tipe datanya disajikan pada Tabel V.8.

Tabel V.8 Deskripsi Fitur Input Model

No	Nama Fitur	Deskripsi	Tipe Data	Keterangan
1	<i>age</i>	Usia responden (tahun)	Numerik	Faktor risiko terkuat
2	<i>is_female</i>	Jenis kelamin	Biner	1 = Perempuan, 0 = Laki-laki
3	<i>bmi</i>	<i>Body Mass Index</i>	Numerik	Satuan: kg/m^2 ; dihitung dari berat dan tinggi badan
4	<i>is_smoker</i>	Status merokok	Biner	1 = Ya, 0 = Tidak
5	<i>has_diabetes</i>	Riwayat diabetes	Biner	1 = Ya, 0 = Tidak
6	<i>has_high_cholesterol</i>	Riwayat kolesterol tinggi	Biner	1 = Ya, 0 = Tidak
7	<i>sleep_quality</i>	Skor kualitas tidur	Ordinal	Skala 1–5
8	<i>sleep_disturbance</i>	Skor gangguan tidur	Ordinal	Skala 1–5

Kedelapan fitur tersebut merupakan hasil seleksi pada tahap *Data Preparation* yang mempertahankan variabel demografi, antropometri, riwayat penyakit, dan kualitas tidur yang paling relevan dengan hipertensi, sekaligus membuang variabel dengan kekosongan data tinggi maupun korelasi lemah terhadap target. Himpunan fitur inilah yang digunakan secara konsisten pada seluruh tahap pemodelan dan interpretasi berikutnya.

Perlu dicatat bahwa dua faktor risiko yang ditekankan pada kajian literatur (Bab II), yaitu asupan garam (natrium) dan riwayat hipertensi keluarga, tidak dapat disertakan sebagai fitur model karena keterbatasan ketersediaan data. Variabel pola makan yang menjadi proksi asupan natrium, yaitu frekuensi konsumsi *fast food*, minuman bersoda, dan gorengan, memiliki kekosongan data yang ekstrem, yaitu berkisar 81%–91%, sehingga tidak dapat diimputasi secara wajar dan dibuang pada tahap seleksi fitur; sementara itu, variabel riwayat hipertensi keluarga tidak tersedia secara memadai pada modul IFLS-5 yang digunakan. Ketidaktersediaan kedua faktor ini merupakan salah satu keterbatasan penelitian sekaligus membuka peluang perbaikan pada penelitian lanjutan dengan sumber data yang lebih lengkap.

V.3 Modelling

Bagian ini menjelaskan cara model klasifikasi hipertensi dibangun dan dianalisis, mulai dari tujuan pemodelan, pembagian data, strategi pelatihan, evaluasi awal, penyetelan hyperparameter, optimasi ambang keputusan, pemilihan model akhir, sampai analisis transparansi keputusan dari model lewat metode XAI.

V.3.1 Implementasi Machine Learning

Tahap implementasi Machine Learning bertujuan membangun model pembelajaran mesin untuk mengestimasi risiko hipertensi berdasarkan faktor individu yang diperoleh dari IFLS-5. Empat algoritma diuji, yaitu Logistic Regression, Random Forest, XGBoost, dan CatBoost. Keempatnya dipilih untuk membandingkan tiga pendekatan yang berbeda cara kerjanya. Logistic Regression mewakili model linear yang mudah ditafsirkan dan menjadi tolok ukur dasar. Random Forest mewakili metode *bagging* yang menggabungkan banyak pohon keputusan secara paralel. XGBoost dan CatBoost mewakili metode *gradient boosting* yang membangun pohon secara bertahap dan umumnya kuat pada data tabular. Dengan membandingkan ketiga pendekatan ini, laporan dapat menunjukkan pendekatan mana yang paling sesuai untuk data yang digunakan. Sebagai kriteria keberhasilan yang ditetapkan di awal, sebuah model dinilai memadai untuk digunakan sebagai alat skrining apabila mencapai ROC-AUC minimal 0,75 dan recall minimal 0,70 pada data uji. Kriteria ini menjadi acuan kelayakan model, bukan sekadar perbandingan relatif antaralgoritma.

V.3.1.1 Pembagian Dataset

Dataset dibagi menjadi data latih sebanyak 80 persen dan data uji sebanyak 20 persen. Pembagian dilakukan secara *stratified*, artinya proporsi kelas normal dan hipertensi dijaga tetap sama antara data latih dan data uji. Langkah ini penting karena data tidak seimbang, sehingga tanpa stratifikasi ada risiko salah satu subset kekurangan

sampel kelas hipertensi. Nilai *random_state* ditetapkan agar hasil pembagian dapat diulang dan seluruh eksperimen bersifat reproducible.

Penelitian ini tidak memakai data validasi terpisah. Sebagai gantinya, penyetelan hyperparameter dilakukan dengan validasi silang tiga lipatan di dalam data latih. Skema ini memanfaatkan data latih lebih hemat karena setiap sampel bergiliran menjadi data validasi, sekaligus menjaga data uji tetap murni dan hanya dipakai satu kali pada evaluasi akhir. Ringkasan ukuran dan komposisi kelas ditampilkan pada Tabel V.9 dan Tabel V.10.

Tabel V.9 Ukuran data latih dan data uji

Dataset	Jumlah
Train	24.200
Test	6.051

Tabel V.10 Proporsi kelas pada data latih dan data uji

Dataset	Normal	Hipertensi
Train	70,74%	29,26%
Test	70,75%	29,25%

Kelas hipertensi hanya sekitar 29 persen dari seluruh data. Ketidakseimbangan ini menjadi dasar pemilihan strategi pelatihan dan metrik evaluasi pada bagian selanjutnya.

V.3.1.2 Strategi Pelatihan Model

Sebelum pelatihan, fitur numerik distandarisasi memakai *StandardScaler* khusus untuk Logistic Regression. Standarisasi mengubah setiap fitur agar memiliki rata-rata nol dan simpangan baku satu. Langkah ini membantu solver Logistic Regression mencapai konvergensi dan membuat penalti regularisasi bekerja adil antar fitur. Model berbasis pohon, yaitu Random Forest, XGBoost, dan CatBoost, tidak distandarisasi karena algoritma tersebut memecah data berdasarkan nilai ambang tiap fitur sehingga skala tidak berpengaruh. Parameter *StandardScaler* dihitung hanya dari data latih, kemudian diterapkan ke data uji, agar tidak terjadi kebocoran informasi dari data uji ke proses pelatihan.

Ketidakseimbangan kelas ditangani secara bawaan pada masing-masing algoritma. Logistic Regression dan Random Forest memakai *class_weight* bernilai *balanced*,

XGBoost memakai *scale_pos_weight* yang dihitung dari rasio jumlah kelas negatif terhadap kelas positif, dan CatBoost memakai *auto_class_weights* bernilai *Balanced*. Ketiga mekanisme ini memberi bobot lebih besar pada kelas hipertensi ketika model belajar, sehingga model tidak hanya mengejar akurasi dengan cara memihak kelas mayoritas.

Penyetelan hyperparameter dilakukan dengan *GridSearchCV* yang menguji seluruh kombinasi nilai pada ruang parameter, dievaluasi memakai validasi silang tiga lipatan. Fungsi objektif penyetelan adalah ROC-AUC. Metrik ini dipilih karena mengukur kemampuan model memeringkat pasien berisiko di atas pasien tidak berisiko pada seluruh rentang ambang, sehingga tidak bergantung pada satu ambang tertentu dan tahan terhadap ketidakseimbangan kelas.

V.3.1.3 Evaluasi Baseline

Evaluasi awal dilakukan memakai konfigurasi bawaan tiap algoritma tanpa penyetelan, dengan ambang keputusan bawaan 0,5. Hasilnya ditampilkan pada Tabel V.11.

Tabel V.11 Kinerja model baseline pada data uji

Model	ROC-AUC	Recall	Specificity	PR-AUC	F1	Akurasi
Logistic Regression	0,7735	0,4085	0,9073	0,5772	0,5003	0,7614
Random Forest	0,7285	0,4475	0,8327	0,4961	0,4832	0,7200
XGBoost	0,7639	0,4158	0,8883	0,5517	0,4933	0,7501
CatBoost	0,7756	0,4198	0,8984	0,5683	0,5041	0,7584

Berdasarkan Tabel V.11, CatBoost memperoleh ROC-AUC tertinggi sebesar 0,7756, sedangkan Random Forest memperoleh ROC-AUC terendah sebesar 0,7285. Hasil ini menunjukkan bahwa algoritma boosting memiliki kemampuan membedakan kelas yang lebih baik daripada Random Forest pada konfigurasi bawaan. Perlu dicatat bahwa nilai recall seluruh model masih rendah, berkisar 0,41 sampai 0,45. Nilai recall yang rendah berarti banyak pasien hipertensi yang belum terdeteksi. Kondisi ini menjadi alasan penanganan ketidakseimbangan kelas diterapkan pada tahap penyetelan.

V.3.1.4 Pengaruh StandardScaler

Untuk menguji dampak standarisasi, Logistic Regression dijalankan dua kali dengan konfigurasi identik, yaitu satu kali tanpa *StandardScaler* dan satu kali dengan *StandardScaler*. Perbandingannya ditampilkan pada Tabel V.12.

Tabel V.12 Pengaruh StandardScaler pada Logistic Regression

Metrik	Tanpa Scaling	Dengan Scaling	Selisih
ROC-AUC	0,7735	0,7735	0,0000
Recall	0,4085	0,4085	0,0000
Specificity	0,9070	0,9073	0,0003
PR-AUC	0,5772	0,5772	0,0000
F1	0,5002	0,5003	0,0001
Akurasi	0,7612	0,7614	0,0002

Selisih seluruh metrik mendekati nol, dengan perubahan terbesar hanya 0,0003 pada specificity. Standarisasi tidak memberikan perubahan kinerja yang berarti pada data ini karena solver Logistic Regression sudah mencapai konvergensi meskipun fitur tidak distandarisasi. Temuan ini tetap dilaporkan sebagai bukti empiris bahwa standarisasi pada kasus ini berperan menjaga kestabilan proses optimasi, bukan meningkatkan kemampuan model membedakan kelas. Standarisasi tetap dipertahankan pada Logistic Regression sebagai praktik yang baik agar penalti regularisasi bekerja adil antar fitur.

V.3.1.5 Hyperparameter Tuning

Penyetelan hyperparameter memakai *GridSearchCV* dengan objektif ROC-AUC dan validasi silang tiga lipatan. Ruang parameter yang diuji untuk tiap model dirangkum pada Tabel V.13, sedangkan kombinasi terbaik hasil pencarian ditampilkan pada Tabel V.14.

Tabel V.13 Ruang parameter yang diuji

Model	Hyperparameter
Logistic Regression	C: 0,01; 0,1; 1; 10
Random Forest	max_depth: 5; 10; tanpa batas n_estimators: 100; 200
XGBoost	max_depth: 3; 5; 7 learning_rate: 0,01; 0,1 n_estimators: 100; 200
CatBoost	depth: 4; 6 learning_rate: 0,01; 0,1 iterations: 100; 200

Tabel V.14 Kombinasi hyperparameter terbaik

Model	Parameter Terbaik
Logistic Regression	$C = 1$
Random Forest	$\text{max_depth} = 5$; $\text{n_estimators} = 200$
XGBoost	$\text{learning_rate} = 0,1$; $\text{max_depth} = 3$; $\text{n_estimators} = 100$
CatBoost	$\text{depth} = 4$; $\text{iterations} = 100$; $\text{learning_rate} = 0,1$

Kombinasi terbaik cenderung memilih model yang tidak terlalu dalam. XGBoost terbaik pada *max_depth* bernilai 3 dan CatBoost terbaik pada *depth* bernilai 4. Pohon yang dangkal menekan risiko *overfitting* pada data ini.

V.3.1.6 Hasil Setelah Tuning

Kinerja model setelah penyetelan, tetap pada ambang bawaan 0,5, ditampilkan pada Tabel V.15.

Tabel V.15 Kinerja model setelah tuning pada data uji

Model	ROC-AUC	Recall	Specificity	PR-AUC	F1	Akurasi
Logistic Regression	0,7737	0,7107	0,7115	0,5764	0,5902	0,7113
Random Forest	0,7735	0,7045	0,7110	0,5678	0,5863	0,7091
XGBoost	0,7795	0,7186	0,7036	0,5795	0,5901	0,7080
CatBoost	0,7804	0,7153	0,7085	0,5841	0,5910	0,7105

Perubahan ROC-AUC dari baseline ke hasil tuning ditampilkan pada Tabel V.16 agar peningkatannya terlihat langsung.

Tabel V.16 Perubahan ROC-AUC dari baseline ke hasil tuning

Model	Baseline	Tuned	Selisih
Logistic Regression	0,7735	0,7737	+0,0002
Random Forest	0,7285	0,7735	+0,0450
XGBoost	0,7639	0,7795	+0,0156
CatBoost	0,7756	0,7804	+0,0048

Peningkatan ROC-AUC paling besar terjadi pada Random Forest, yaitu 0,0450, karena pembatasan kedalaman pohon mengurangi *overfitting* pada konfigurasi bawaan. Pada model lain peningkatan ROC-AUC kecil.

Perubahan yang paling menonjol justru terlihat pada recall dan specificity, bukan pada ROC-AUC. Recall naik tajam dari kisaran 0,41 pada baseline menjadi kisaran 0,71 setelah tuning, sementara specificity turun dari kisaran 0,89 menjadi kisaran 0,71. Perubahan ini bukan hasil pencarian hyperparameter, melainkan hasil pembobotan kelas yang diterapkan pada tahap tuning, yaitu *class_weight*, *scale_pos_weight*, dan *auto_class_weights*. Pembobotan menggeser batas keputusan ke arah yang lebih mudah mengenali kelas hipertensi. Nilai ROC-AUC yang hampir tidak berubah menegaskan bahwa kemampuan model memeringkat pasien pada dasarnya sama, sedangkan yang berubah adalah titik operasi pada ambang 0,5. Pergeseran ini menguntungkan untuk skrining hipertensi karena mengurangi jumlah pasien berisiko yang tidak terdeteksi.

V.3.1.7 Optimasi Threshold

Ambang bawaan 0,5 belum tentu merupakan titik operasi terbaik. Ambang ini memberi bobot yang sama pada kesalahan di kedua kelas, padahal pada skrining hipertensi kesalahan melewatkan pasien berisiko lebih merugikan daripada kesalahan menandai orang sehat untuk pemeriksaan ulang. Karena itu ambang keputusan dicari secara eksplisit.

Titik ambang ditentukan memakai Youden Index yang dinotasikan sebagai J . Nilai J dihitung sebagai selisih antara *true positive rate* dan *false positive rate*, yaitu $J = TPR - FPR$. Secara geometris, J mewakili jarak vertikal terjauh antara kurva ROC dan garis diagonal tebakan acak. Ambang dengan nilai J tertinggi adalah titik yang paling menyeimbangkan tingkat positif palsu dan tingkat negatif palsu. Ambang optimal tiap model ditampilkan pada Tabel V.17.

Tabel V.17 Ambang optimal berdasarkan Youden Index

Model	Ambang Optimal	Nilai J
Logistic Regression	0,5220	0,4230
Random Forest	0,5174	0,4209
XGBoost	0,5160	0,4254
CatBoost	0,5398	0,4306

Perbandingan kinerja pada ambang bawaan 0,5 dan pada ambang Youden ditampilkan pada Tabel V.18. Nilai ROC-AUC dan PR-AUC tidak dicantumkan ulang pada perbandingan ini karena keduanya dihitung dari probabilitas dan tidak berubah oleh pemilihan ambang.

Tabel V.18 Perbandingan kinerja pada ambang 0,5 dan ambang Youden

Model	Ambang	Recall	Specificity	F1	Akurasi
Logistic Regression	0,5	0,7107	0,7115	0,5902	0,7113
	Youden	0,6853	0,7377	0,5908	0,7224
Random Forest	0,5	0,7045	0,7110	0,5863	0,7091
	Youden	0,6842	0,7367	0,5896	0,7214
XGBoost	0,5	0,7186	0,7036	0,5901	0,7080
	Youden	0,7062	0,7192	0,5921	0,7154
CatBoost	0,5	0,7153	0,7085	0,5910	0,7105
	Youden	0,6836	0,7470	0,5956	0,7285

Seluruh ambang Youden berada sedikit di atas 0,5, yaitu antara 0,5160 dan 0,5398. Nilai yang dekat dengan 0,5 ini merupakan konsekuensi dari pembobotan kelas pada tahap tuning, yang sudah membuat model relatif seimbang sejak awal. Akibatnya, pergeseran ambang ke atas 0,5 sedikit menurunkan recall dan sedikit menaikkan specificity, F1, dan akurasi. Sebagai contoh, XGBoost mengalami penurunan recall dari 0,7186 menjadi 0,7062 dan kenaikan specificity dari 0,7036 menjadi 0,7192.


Pemilihan ambang Youden sebagai titik operasi final merupakan keputusan yang disengaja dengan tiga pertimbangan. Pertama, pembobotan kelas pada tahap pelatihan telah menggeser model agar sensitif terhadap kelas hipertensi, sehingga bahkan pada ambang di sekitar 0,5 model sudah mempertahankan recall yang relatif tinggi, yaitu sekitar 0,71. Kedua, karena ambang Youden hanya bergeser tipis dari 0,5, penurunan recall yang ditimbulkannya sangat kecil, yaitu hanya 0,0124 pada XGBoost, sementara specificity, F1, dan akurasi justru meningkat, sehingga Youden memberikan titik operasi yang seimbang dan reproduktibel tanpa mengorbankan sensitivitas secara berarti. Ketiga, memaksimalkan recall secara agresif akan menekan precision dan membanjiri alur rujukan pemeriksaan lanjutan dengan positif palsu, yang justru kontraproduktif bagi sistem skrining berskala. Dengan demikian, meskipun kesalahan melewati pasien (*false negative*) dinilai lebih merugikan, ambang Youden dipandang sebagai kompromi yang paling dapat dipertanggungjawabkan karena mempertahankan recall yang tinggi sekaligus mengendalikan beban positif palsu.

Perlu ditegaskan bahwa titik operasi ini tidak bersifat kaku. Karena keluaran model berupa probabilitas tetap dipertahankan, ambang keputusan dapat disetel ulang tanpa melatih ulang model: apabila di kemudian hari dikehendaki postur skrining yang

lebih agresif dalam menekan *false negative*, ambang dapat diturunkan untuk memenuhi target recall tertentu. Nilai ambang Youden inilah yang disimpan bersama model sebagai titik operasi bawaan sistem, menggantikan ambang 0,5.

V.3.1.8 Confusion Matrix

Gambar V.12 menampilkan *confusion matrix* keempat model pada data uji, dievaluasi memakai ambang Youden.




Gambar V.12 Confusion matrix model setelah tuning pada ambang Youden

Setiap *confusion matrix* memuat empat komponen. *True positive* adalah pasien hipertensi yang diprediksi hipertensi. *True negative* adalah orang normal yang diprediksi normal. *False positive* adalah orang normal yang diprediksi hipertensi. *False negative* adalah pasien hipertensi yang diprediksi normal.

Pada konteks hipertensi, *false negative* adalah komponen yang paling perlu diperhatikan karena mewakili pasien berisiko yang lolos dari deteksi dan berpotensi tidak mendapat penanganan dini. Data uji memuat sekitar 1.770 pasien hipertensi dan sekitar 4.281 orang normal. Untuk XGBoost pada ambang Youden dengan recall 0,7062, jumlah *false negative* berada di kisaran 520 pasien, sedangkan jumlah *true positive* berada di kisaran 1.250 pasien. Angka *false negative* yang masih cukup besar ini menunjukkan bahwa model belum menangkap seluruh pasien berisiko, sehingga hasilnya lebih tepat digunakan sebagai alat bantu skrining awal, bukan sebagai pengganti diagnosis klinis.

V.3.1.9 ROC Curve

Gambar V.13 menampilkan kurva ROC keempat model beserta titik ambang Youden masing-masing.



Gambar V.13 Kurva ROC dan titik Youden tiap model pada data uji

Kurva ROC menggambarkan hubungan antara *true positive rate* dan *false positive rate* pada seluruh rentang ambang. Semakin dekat kurva ke sudut kiri atas, semakin baik kemampuan model membedakan kelas. Berdasarkan Gambar V.13, kurva CatBoost dan XGBoost berada paling dekat dengan sudut kiri atas, sejalan dengan nilai ROC-AUC keduanya yang tertinggi, yaitu 0,7804 untuk CatBoost dan 0,7795 untuk XGBoost. Kurva Logistic Regression dan Random Forest berada sedikit di bawahnya dengan ROC-AUC di kisaran 0,7735. Perbedaan antar model tergolong kecil, yang menunjukkan bahwa keempat model memiliki kemampuan membedakan kelas yang setara pada data ini.

V.3.1.10 Pemilihan Model Terbaik

Pemilihan model akhir tidak hanya didasarkan pada satu metrik, melainkan pada beberapa pertimbangan sekaligus, yaitu kemampuan membedakan kelas, kemampuan menangkap pasien berisiko, kemudahan penafsiran, dukungan analisis kontribusi fitur, serta kemudahan penerapan pada sistem.

Dari sisi ROC-AUC, CatBoost dan XGBoost hampir setara, dengan selisih hanya 0,0009. Selisih sekecil ini tidak cukup untuk menyatakan salah satu unggul secara meyakinkan. Dari sisi recall pada ambang bawaan 0,5, XGBoost memperoleh nilai tertinggi sebesar 0,7186, yang berarti paling banyak menangkap pasien hipertensi. Karena tujuan utama sistem adalah skrining risiko, kemampuan menangkap pasien

berisiko diberi bobot penting.

XGBoost juga memiliki dukungan yang matang untuk analisis kontribusi fitur berbasis SHAP, sehingga hasil prediksi dapat dijelaskan per fitur maupun per pasien. Kemampuan menjelaskan ini penting pada konteks kesehatan agar keputusan model dapat dipahami. Dari sisi penerapan, XGBoost tersedia luas, ringan saat prediksi, dan mudah disimpan lalu dimuat kembali pada sistem, sehingga cocok untuk diintegrasikan pada layanan skrining.

Berdasarkan gabungan pertimbangan tersebut, yaitu kemampuan membedakan kelas yang setara dengan model terbaik, recall tertinggi, dukungan penjelasan berbasis SHAP, serta kemudahan penerapan, XGBoost dipilih sebagai model akhir. Dengan ROC-AUC 0,7795 serta recall 0,7186 pada ambang 0,5 dan 0,7062 pada ambang Youden, XGBoost memenuhi kriteria keberhasilan yang ditetapkan di awal, yaitu ROC-AUC minimal 0,75 dan recall minimal 0,70. Model XGBoost terbaik disimpan bersama nilai ambang Youden dan urutan nama fitur, agar proses prediksi pada sistem memakai konfigurasi yang sama persis dengan hasil eksperimen.

V.3.2 Implementasi XAI

Setelah XGBoost terpilih sebagai model akhir, dilakukan interpretasi model menggunakan *Explainable AI* berbasis SHAP (*SHapley Additive exPlanations*) untuk menjelaskan dasar setiap prediksi. SHAP mengukur kontribusi tiap fitur terhadap keluaran model berdasarkan teori nilai Shapley, yaitu dengan menimbang dampak rata-rata sebuah fitur ketika diperhitungkan pada berbagai kombinasi fitur lain. Sifatnya aditif, sehingga penjumlahan nilai dasar (*base value*) dengan seluruh kontribusi fitur akan menghasilkan kembali keluaran model untuk satu individu. Dengan demikian, setiap penjelasan dapat dipertanggungjawabkan secara matematis, baik pada tingkat populasi maupun individu.


Penyajian nilai SHAP menggunakan pendekatan gabungan, yaitu analisis global dalam satuan *log-odds* yang merupakan keluaran mentah model, dan analisis lokal dalam satuan probabilitas agar lebih mudah dipahami pengguna. Perlu dicatat bahwa model XGBoost dilatih dengan pembobotan kelas positif untuk menangani ketidakseimbangan data, sehingga rata-rata keluaran probabilistik model berada di sekitar 0,45, lebih tinggi dibandingkan prevalensi hipertensi pada data pemodelan yang sebesar 29,26%.

V.3.2.1 Penetapan Explainer TreeSHAP

Sesuai landasan teori yang telah diuraikan pada Subbab II.3.1, metode interpretasi yang digunakan pada penelitian ini adalah TreeSHAP (*TreeExplainer*). Penetapan ini mengikuti karakteristik model prediksi akhir, yaitu XGBoost yang tergolong *tree ensemble*. Sebagaimana dikembangkan oleh Lundberg dkk. (2020), TreeSHAP dirancang khusus untuk model berbasis pohon sehingga mampu menghitung nilai Shapley secara eksak (*exact Shapley values*) dalam waktu polinomial dengan memanfaatkan struktur pohon keputusan, alih-alih melalui aproksimasi berbeban komputasi tinggi seperti pada pendekatan SHAP yang bersifat *model-agnostic*. Dengan demikian, atribusi fitur yang dihasilkan bersifat tepat dan konsisten dengan aksioma nilai Shapley (Lundberg dan Lee 2017), sekaligus efisien untuk dijalankan pada sistem. Implementasi TreeSHAP pada penelitian ini dilakukan melalui pustaka shap dengan memanggil *TreeExplainer* atas objek model XGBoost terlatih, sehingga terdapat keterkaitan yang konsisten antara landasan teori, perancangan, dan implementasi modul interpretasi.


V.3.2.2 Analisis Global

Analisis global merangkum kontribusi fitur di seluruh data untuk mengetahui fitur yang paling menentukan estimasi model. Gambar V.14 menyajikan tingkat kepentingan fitur berdasarkan rata-rata nilai absolut SHAP. Usia merupakan fitur paling dominan, diikuti indeks massa tubuh (IMT) dan jenis kelamin, sedangkan fitur lain seperti kualitas tidur, gangguan tidur, status merokok, kolesterol tinggi, dan diabetes memberikan kontribusi yang jauh lebih kecil. Pola ini mengindikasikan bahwa model bertumpu terutama pada faktor demografis dan komposisi tubuh dalam mengestimasi risiko hipertensi.



Gambar V.14 Tingkat Kepentingan Fitur Berdasarkan Rata-rata Nilai Absolut SHAP

Gambar V.15 menampilkan sebaran kontribusi setiap fitur, dengan warna menyatakan nilai fitur (biru untuk rendah, merah untuk tinggi) dan posisi horizontal menyatakan arah serta besar dampaknya. Pada usia dan IMT, nilai tinggi berada di sisi positif sehingga menaikkan estimasi risiko, sedangkan nilai rendah menurunkannya. Pada jenis kelamin, laki-laki cenderung menaikkan estimasi risiko dibandingkan perempuan. Lebar sebaran titik pada setiap baris menggambarkan besarnya variasi pengaruh fitur di antara seluruh sampel.




Gambar V.15 Sebaran Nilai SHAP Seluruh Fitur (*beeswarm*)


Untuk memahami hubungan tiap fitur secara lebih rinci, distribusi nilai SHAP ditinjau melalui *dependence plot*. Gambar V.16 memperlihatkan kontribusi fitur *age* yang mengikuti pola non-linier, yaitu bernilai negatif pada usia muda di bawah sekitar 30 tahun, meningkat hampir linier mulai sekitar 30 hingga 70 tahun, lalu melandai pada usia lanjut. Pola ini konsisten dengan pengetahuan medis bahwa risiko hipertensi meningkat seiring bertambahnya usia.

Gambar V.17 menampilkan kontribusi fitur *bmi* yang bernilai negatif pada IMT rendah, meningkat tajam pada rentang sekitar 20 hingga 37, lalu cenderung mendatar setelahnya. Hal ini sejalan dengan pemahaman klinis bahwa kelebihan berat badan dan obesitas merupakan faktor risiko hipertensi. Pola tersebut sekaligus menjadikan IMT sebagai fitur berpengaruh terbesar kedua setelah usia.

Gambar V.18 memperlihatkan kontribusi fitur *is_female*. Individu laki-laki cenderung memiliki nilai SHAP positif, sedangkan perempuan cenderung negatif. Dengan kata lain, model mengaitkan jenis kelamin laki-laki dengan peningkatan estimasi risiko hipertensi. Arah ini selaras dengan temuan epidemiologis yang menunjukkan prevalensi hipertensi yang lebih tinggi pada laki-laki, khususnya pada usia dewasa hingga paruh baya. Sebaran nilai pada masing-masing kategori juga




Gambar V.16 Nilai SHAP terhadap Usia



Gambar V.17 Nilai SHAP terhadap IMT

mengindikasikan adanya interaksi dengan fitur lain seperti usia dan IMT.




Gambar V.18 Nilai SHAP terhadap Jenis Kelamin

Gambar V.19 menampilkan kontribusi fitur *sleep_disturbance*. Secara umum, semakin tinggi tingkat gangguan tidur, nilai SHAP cenderung semakin positif, sehingga model menangkap kecenderungan bahwa frekuensi gangguan tidur yang lebih tinggi berkaitan dengan estimasi risiko yang lebih besar, sejalan dengan literatur mengenai hubungan antara kualitas istirahat dan tekanan darah. Meskipun demikian, arah global yang positif ini disertai sebaran nilai SHAP yang cukup lebar pada setiap tingkatan, sehingga pada sebagian individu kontribusi fitur ini masih dapat bernilai negatif atau menurunkan estimasi risiko meskipun tren keseluruhannya menaikkan risiko. Variasi pada tingkat individu tersebut timbul karena adanya interaksi dengan fitur lain dan karena besar pengaruh fitur ini tergolong kecil dibandingkan usia dan IMT, sehingga interpretasi lokalnya perlu dilakukan secara hati-hati dan tidak selalu searah dengan tren global.


Gambar V.20 menampilkan kontribusi fitur *sleep_quality*. Mengikuti skala IFLS yang dipakai model, yaitu nilai 1 untuk kualitas tidur terbaik hingga 5 untuk terburuk, kualitas tidur yang makin buruk (nilai makin tinggi) memberikan kontribusi SHAP positif yang menaikkan estimasi risiko, sedangkan kualitas tidur yang baik (nilai rendah) menurunkannya. Arah ini konsisten dengan literatur yang menghubungkan kualitas tidur buruk dengan peningkatan risiko hipertensi, meskipun besar pengaruhnya tergolong kecil.

Sebaliknya, satu fitur menunjukkan pola yang berlawanan dengan dugaan umum. Pada Gambar V.21, fitur *is_smoker* memberikan kontribusi yang sedikit negatif dibandingkan individu yang tidak merokok. Pola ini berpengaruh kecil dan didu-




Gambar V.19 Nilai SHAP terhadap Gangguan Tidur

ga dipengaruhi oleh faktor perancu (*confounding*) pada data survei, sehingga perlu ditinjau lebih lanjut bersama tenaga medis dan tidak dimaknai sebagai hubungan sebab-akibat.




Gambar V.20 Nilai SHAP terhadap Kualitas Tidur


Gambar V.22 dan Gambar V.23 menampilkan kontribusi fitur *has_diabetes* dan *has_high_cholesterol*. Individu dengan riwayat kedua kondisi tersebut memiliki nilai SHAP positif yang menaikkan estimasi risiko. Arah ini sesuai dengan pemahaman medis mengenai keterkaitan kedua kondisi tersebut dengan tekanan darah. Akan tetapi, sebaran nilainya cukup lebar dan kontribusinya kecil secara keseluruhan. Hal ini disebabkan oleh proporsi data positif yang sangat sedikit untuk kedua fitur, sehingga model kurang memiliki cukup contoh untuk mempelajari polanya secara stabil, dan keterbatasan ini perlu dicatat dalam interpretasi.



Gambar V.21 Nilai SHAP terhadap Status Merokok



Gambar V.22 Nilai SHAP terhadap Riwayat Diabetes



Gambar V.23 Nilai SHAP terhadap Riwayat Kolesterol Tinggi

V.3.2.3 Ambang Netral dan Kategori Risiko Terendah

Selain meninjau arah dan besar kontribusi, nilai SHAP dapat dimanfaatkan untuk memperkirakan ambang nilai yang netral bagi tiap fitur. Untuk fitur kontinu, ambang netral didefinisikan sebagai nilai fitur ketika kontribusi SHAP-nya mendekati nol, yaitu titik saat fitur tidak menaikkan maupun menurunkan estimasi risiko. Untuk fitur biner atau ordinal, ditinjau kategori dengan rata-rata nilai SHAP terendah, yaitu kategori yang paling menurunkan estimasi risiko. Ringkasan hasilnya disajikan pada Tabel V.19.

Tabel V.19 Ambang Netral dan Kategori Risiko Terendah Tiap Fitur

Fitur	Tipe	Ambang / kategori terendah	Keterangan
Usia	Kontinu	≈ 43 tahun (40–45)	Arah positif; nilai di bawah ambang menurunkan risiko
IMT	Kontinu	≈ 24 (22–25)	Arah positif; IMT normal menurunkan risiko
Jenis kelamin	Biner	Perempuan	Laki-laki cenderung menaikkan risiko
Diabetes	Biner	Tidak diabetes	Sesuai pemahaman medis
Kolesterol tinggi	Biner	Tidak kolesterol tinggi	Sesuai pemahaman medis
Gangguan tidur	Ordinal	Tingkat terendah	Gangguan lebih tinggi menaikkan risiko
Status merokok	Biner	Tidak ditafsirkan	Pola berlawanan dengan medis; perlu evaluasi
Kualitas tidur	Ordinal	Kualitas terbaik	Kualitas tidur lebih buruk menaikkan risiko

Pada fitur kontinu, usia memiliki ambang netral sekitar 43 tahun dan IMT sekitar 24, keduanya dengan arah positif, sehingga nilai di bawah ambang cenderung menurunkan estimasi risiko dan di atasnya menaikannya. Ambang IMT sekitar 24 menarik karena berdekatan dengan batas atas kategori IMT normal menurut standar kesehatan, sehingga model secara implisit menempatkan rentang IMT normal sebagai kondisi yang relatif netral. Pada fitur biner dan ordinal, kategori dengan risiko terendah umumnya sejalan dengan pemahaman medis, yaitu tidak memiliki diabetes maupun kolesterol tinggi, serta tingkat gangguan tidur yang paling rendah dan kualitas tidur yang paling baik. Untuk jenis kelamin, kategori perempuan menunjukkan kontribusi yang lebih menurunkan risiko, meskipun jenis kelamin merupakan karakteristik bawaan dan bukan pilihan yang dapat diubah.

Perlu ditekankan bahwa pendekatan ini tidak dapat diterapkan pada seluruh fitur

secara langsung. Pada status merokok, kategori dengan nilai SHAP terendah justru bertentangan dengan pengetahuan medis, sehingga tidak layak dimaknai sebagai kondisi ideal. Hal ini sejalan dengan temuan sebelumnya bahwa fitur tersebut memiliki pola yang berlawanan dengan dugaan umum dan diduga dipengaruhi oleh faktor perancu pada data. Dengan demikian, penentuan nilai ideal berbasis SHAP harus selalu divalidasi terhadap pengetahuan domain sebelum digunakan sebagai dasar rekomendasi.


V.3.2.4 Analisis Lokal

Selain analisis global, SHAP juga dapat menjelaskan estimasi untuk satu individu secara terpisah. Pada analisis lokal yang disajikan dalam satuan probabilitas, estimasi dimulai dari nilai dasar sekitar 0,45 atau 45%, yaitu rata-rata keluaran model atas data. Nilai dasar yang relatif tinggi ini merupakan akibat penerapan pembobotan kelas saat pelatihan, dan bukan prevalensi hipertensi pada data pemodelan yang sebesar 29,26%. Dari titik awal tersebut, setiap fitur menambah atau mengurangi nilai estimasi sesuai kontribusinya hingga diperoleh keluaran akhir model untuk individu bersangkutan.

Gambar V.24 menunjukkan contoh analisis lokal untuk seorang individu berusia 59 tahun, berjenis kelamin laki-laki, dengan IMT 24,1, kualitas tidur baik, serta tanpa riwayat diabetes maupun kolesterol tinggi. Estimasi akhir model untuk individu ini adalah sekitar 0,76 atau 76,2%, sehingga tergolong berisiko tinggi. Kontribusi positif terbesar berasal dari usia (sekitar 0,27), diikuti oleh jenis kelamin laki-laki dan IMT yang besarnya sebanding (sekitar 0,04 dan 0,03), sementara kualitas tidur dan status merokok memberikan kontribusi negatif yang kecil. Dengan demikian, peningkatan estimasi risiko pada individu ini didorong terutama oleh faktor usia.

V.3.2.5 Evaluasi dan Keterbatasan

Hasil interpretasi SHAP dievaluasi untuk memastikan kelayakannya secara klinis. Sebagian besar pola yang dihasilkan model selaras dengan pemahaman medis, yaitu usia, IMT, jenis kelamin laki-laki, kualitas tidur, gangguan tidur, diabetes, dan kolesterol tinggi yang berkontribusi menaikkan estimasi risiko hipertensi. Sebaliknya, terdapat satu pola yang berlawanan dengan dugaan umum, yaitu pada status merokok, yang berpengaruh kecil dan diduga dipengaruhi oleh faktor perancu pada data survei. Selain itu, fitur diabetes dan kolesterol tinggi memiliki keterbatasan berupa jumlah data positif yang sangat sedikit sehingga interpretasinya kurang stabil, sehingga pola yang tidak intuitif maupun fitur dengan data terbatas tersebut direkomendasikan untuk dikonfirmasi lebih lanjut melalui evaluasi oleh tenaga medis atau



Gambar V.24 Contoh Analisis Lokal SHAP untuk Satu Individu (Satuan Probabilitas)

domain expert sebelum digunakan dalam pengambilan keputusan.

V.3.3 Implementasi Narasi Medis berbasis Kaidah Deterministik dan LLM

Interpretasi SHAP pada subbab V.3.2 menghasilkan kontribusi tiap fitur, baik secara global maupun untuk satu individu, dalam bentuk nilai numerik. Bentuk numerik ini tepat secara matematis namun sulit dipahami oleh pengguna awam. Oleh karena itu, dibangun sebuah lapisan narasi yang menerjemahkan nilai SHAP menjadi penjelasan berbahasa Indonesia yang mudah dicerna pasien, mengikuti gagasan pemanfaatan LLM untuk meningkatkan keterbacaan nilai SHAP (Zeng 2024), mencakup faktor risiko yang paling berpengaruh beserta arahnya, serta saran perbaikan gaya hidup. Karena keluaran ini menyentuh ranah kesehatan, prioritas utama perancangannya adalah menekan halusinasi dan misinformasi, sehingga penggunaan *Large Language Model* (LLM) dibatasi secara ketat.

Kebutuhan pembatasan ini diperkuat oleh temuan pada subbab V.3.2. Sebagaimana dirangkum pada Tabel V.19, satu fitur, yaitu status merokok, memiliki arah kontribusi yang berlawanan dengan pengetahuan medis dan ditandai “tidak ditafsirkan”. Apabila arah SHAP fitur tersebut diterjemahkan mentah-mentah menjadi kalimat untuk pasien, sistem berpotensi menyatakan bahwa merokok menurunkan risiko hipertensi, yang merupakan misinformasi berbahaya. Lapisan narasi ini dirancang untuk mengoperasionalkan peringatan tersebut secara otomatis.

V.3.3.1 Arsitektur Narasi

Narasi dibangun melalui dua lapisan dengan pembagian tugas yang tegas, sebagaimana dirangkum pada Tabel V.20. Prinsip utamanya adalah seluruh *angka* dan *arah*

ditentukan secara deterministik oleh kode, sedangkan LLM hanya bertugas merangkai kalimat saran. Dengan demikian, LLM tidak pernah menghitung persentase, menentukan arah pengaruh, maupun menciptakan anjuran medis baru, sehingga sumber kesalahan faktual dari model generatif dapat dihilangkan pada bagian yang paling kritis.

Tabel V.20 Pembagian Tugas Dua Lapisan Penyusun Narasi

Lapisan	Peran	Sifat
Deterministik	Menentukan arah, besaran, barometer, pemilihan teks fakta, dan penyusunan materi saran dari nilai SHAP serta kondisi klinis	Berbasis aturan
LLM	Merangkai ulang materi saran menjadi bahasa yang fleksibel dan empatik	Generatif terkendali

Setiap prediksi menghasilkan tiga komponen keluaran, yaitu ringkasan tingkat risiko, interpretasi tiga faktor teratas (masing-masing berupa penjelasan objektif dan alasan berbasis fakta), serta satu paragraf saran gaya hidup. Keseluruhan alur penyusunan narasi tersebut diringkas sebagai pseudocode pada Algoritma V.2.

V.3.3.2 Lapisan Deterministik: Arah, Besaran, dan Barometer

Arah pengaruh setiap fitur ditentukan langsung dari *tanda* nilai SHAP individu, bukan dari korelasi fitur maupun asumsi. Nilai SHAP positif dimaknai menaikkan estimasi risiko dan nilai negatif menurunkannya. Pilihan ini penting karena pada tahap awal ditemukan bahwa penanda arah berbasis korelasi dapat terbalik terhadap keluaran model sebenarnya, sehingga tanda SHAP per individu dipakai sebagai satu-satunya sumber arah.

Besaran pengaruh dinyatakan sebagai persentase kontribusi lokal, yaitu nilai absolut SHAP sebuah fitur dibagi jumlah nilai absolut SHAP seluruh fitur pada individu tersebut, sebagaimana Persamaan (V.1). Perhitungan dilakukan pada satuan *log-odds* yang merupakan ruang aditif SHAP, agar konsisten dengan analisis global.

$$\text{kontribusi}_i = \frac{|\phi_i|}{\sum_{j=1}^n |\phi_j|} \times 100\% \quad (\text{V.1})$$

dengan ϕ_i menyatakan nilai SHAP fitur ke- i dan n jumlah fitur. Persentase ini kemudian dikategorikan menjadi lima tingkat sebagaimana Tabel V.21. Ambang tersebut sekaligus berfungsi sebagai pengaman: faktor dengan kontribusi di bawah 3% dinyatakan dapat diabaikan, sehingga sistem tidak membuat klaim tegas atas faktor

Algoritma V.2 Penyusunan Narasi Penjelasan Berbasis Kaidah Deterministik dan LLM

Require: Nilai SHAP individu $\{\phi_i\}$, data klinis pasien, probabilitas risiko p

Ensure: Narasi penjelasan berbahasa Indonesia

```
1: Tetapkan tingkat risiko dari  $p$  memakai ambang Youden (tinggi atau rendah)
2: for all fitur  $i$  do
3:    $arah_i \leftarrow \text{tanda}(\phi_i)$   $\triangleright$  positif menaikkan, negatif menurunkan risiko
4:    $kontribusi_i \leftarrow |\phi_i| / \sum_j |\phi_j| \times 100\%$ 
5:    $kategori_i \leftarrow \text{kategorikan besaran } kontribusi_i$ 
6: end for
7: Pilih tiga fitur dengan kontribusi terbesar
8: for all fitur terpilih  $i$  do
9:   if  $i$  tergolong Tingkat C (mis. status merokok) then
10:    Tolak arah yang keliru; tampilkan fakta medis yang benar  $\triangleright$  override
11:   else if  $kontribusi_i < 3\%$  then
12:    Sampaikan fakta secara hedged tanpa klaim sebab-akibat
13:   else
14:    Susun teks fakta penuh sesuai arah SHAP
15:   end if
16: end for
17: Bentuk materi saran deterministik dari faktor klinis yang dapat diubah
18:  $materi \leftarrow \text{ringkasan risiko} + \text{interpretasi tiga faktor} + \text{saran}$ 
19: if layanan LLM tersedia then
20:    $narasi \leftarrow \text{LLM.haluskan}(materi)$   $\triangleright$  guardrail: angka/arah/klaim tidak boleh diubah
21: else
22:    $narasi \leftarrow materi$   $\triangleright$  fallback deterministik
23: end if
24: return  $narasi$ 
```

yang pengaruhnya tidak berarti.

Tabel V.21 Kategori Besaran Pengaruh Berdasarkan Kontribusi Lokal

Kategori	Rentang Kontribusi
Dominan	$\geq 50\%$
Kuat	25%–49,9%
Moderat	10%–24,9%
Kecil	3%–9,9%
Sangat kecil	$< 3\%$

Agar penjelasan objektif terasa membumi, nilai indeks massa tubuh dibandingkan terhadap sebuah barometer, yaitu klasifikasi baku WHO: kurang dari 18,5 sebagai kurus, 18,5 sampai 24,9 sebagai normal, 25 sampai 29,9 sebagai berlebih, dan 30 ke atas sebagai obesitas. Klasifikasi WHO ini selaras dengan ambang netral IMT model yang berada di sekitar 24, yaitu batas atas kategori normal, sebagaimana dibahas pada Tabel V.19. Untuk usia, nilai ditampilkan apa adanya tanpa label tahap kehidupan, mengingat tidak terdapat satu standar klasifikasi usia baku yang konsisten sehingga penambahan label berpotensi menyesatkan; arah dan besaran pengaruh usia tetap ditentukan dari nilai SHAP-nya.

V.3.3.3 Klasifikasi Keandalan Fitur

Tidak semua fitur layak diberi penjelasan berbasis fakta yang tegas. Berdasarkan kesesuaian arah model dengan bukti medis pada subbab V.3.2, kedelapan fitur dikelompokkan ke dalam tiga tingkat keandalan sebagaimana Tabel V.22. Tingkat A memuat fitur yang arahnya searah dan konsisten dengan bukti medis sehingga memperoleh penjelasan fakta penuh sesuai tanda SHAP. Tingkat B memuat fitur yang pengaruhnya kecil atau arahnya spesifik pada model sehingga penjelasannya disampaikan secara berhati-hati tanpa klaim sebab-akibat. Tingkat C memuat status merokok, satu-satunya fitur yang arah modelnya bertentangan dengan bukti medis.

Penanganan khusus tingkat C bekerja sebagai berikut. Teks objektif untuk status merokok tidak pernah menyatakan arah “menurunkan risiko”, melainkan hanya menyebut besaran pengaruhnya yang pada praktiknya selalu tergolong sangat kecil. Sementara itu, teks faktanya selalu menyatakan kebenaran medis, yaitu bahwa kebiasaan merokok cenderung meningkatkan risiko hipertensi. Dengan mekanisme ini, artefak model tidak diteruskan menjadi misinformasi, namun informasi yang benar tetap sampai kepada pasien.

Tabel V.22 Tingkat Keandalan Fitur dan Penanganan Teks Fakta

Tingkat	Fitur	Penanganan teks fakta
A	Usia, IMT, diabetes, kolesterol tinggi	Fakta penuh, arah mengikuti tanda SHAP
B	Jenis kelamin, kualitas tidur, gangguan tidur	Fakta di- <i>hedge</i> ; tunduk pada pengaman 3%
C	Status merokok	Di- <i>override</i> : fakta medis yang benar selalu ditampilkan, arah “protektif” yang keliru ditolak

V.3.3.4 Pembuatan Saran Gaya Hidup

Saran gaya hidup disusun secara deterministik, bukan dibangkitkan bebas oleh LLM, agar seluruh anjuran dapat dipertanggungjawabkan. Setiap faktor risiko yang dapat diubah memiliki satu potongan anjuran baku yang disusun mengacu pada pengetahuan medis umum dan pedoman hipertensi. Potongan-potongan inilah yang dirangkai menjadi materi saran, sehingga isi anjuran tidak pernah bergantung pada pengetahuan bebas model generatif.

Perbedaan mendasar dari rancangan awal terletak pada pemicu saran. Saran tidak dipicu oleh tanda SHAP, melainkan oleh kondisi klinis nyata pasien, dan hanya menyasar faktor yang dapat diubah. Faktor usia dan jenis kelamin dikecualikan karena tidak dapat dimodifikasi. Sebuah faktor memicu saran apabila indeks massa tubuh mencapai 25 atau lebih, pasien berstatus perokok, memiliki riwayat diabetes atau kolesterol tinggi, atau memiliki gangguan tidur tingkat tinggi maupun kualitas tidur yang rendah. Pemisahan ini memberi manfaat ganda: saran berhenti merokok tetap muncul untuk pasien perokok meskipun SHAP model menandainya “protektif”, sedangkan pasien dengan IMT normal tidak akan menerima saran penurunan berat badan yang tidak relevan.

Faktor pemicu yang terpilih kemudian disusun menjadi materi saran deterministik yang selalu diawali kalimat “Berdasarkan faktor tersebut, disarankan pasien untuk...” dan diakhiri anjuran berkonsultasi dengan tenaga kesehatan. Materi inilah yang diserahkan kepada LLM. Model *llama-3.1-8b-instant* yang diakses melalui layanan Groq hanya diminta menuliskan ulang materi tersebut agar lebih fleksibel, dengan larangan menambah atau mengubah anjuran maupun angka, larangan menyuruh mengubah faktor yang tidak dapat diubah, serta aturan akurasi medis, misalnya kata natrium hanya boleh dirangkai dengan “membatasi” atau “mengurangi”.

Apabila layanan LLM tidak tersedia, sistem secara otomatis memakai materi saran deterministik apa adanya sehingga keluaran tetap valid.

V.3.3.5 Contoh Keluaran

Untuk menggambarkan hasil akhir, digunakan kembali individu yang sama dengan contoh analisis lokal pada Gambar V.24, yaitu seorang laki-laki berusia 59 tahun dengan IMT 24,1, berstatus perokok, kualitas tidur baik, serta tanpa riwayat diabetes maupun kolesterol tinggi, dengan estimasi risiko 76,2%. Narasi yang dihasilkan sistem ditampilkan pada kutipan berikut.

Hasil analisis menunjukkan risiko hipertensi Anda sebesar 76,2%, yang termasuk kategori tinggi.

Usia Anda yakni 59 tahun, memiliki pengaruh dominan dalam meningkatkan risiko ini, dengan kontribusi 72,7% dari keseluruhan faktor. Bertambahnya usia meningkatkan risiko hipertensi karena elastisitas dinding arteri menurun dan kekakuan pembuluh darah meningkat seiring waktu.

Indeks massa tubuh (IMT) Anda sebesar 24,1 yang tergolong normal, memiliki pengaruh moderat dalam meningkatkan risiko ini, dengan kontribusi 11,3% dari keseluruhan faktor. Indeks massa tubuh yang lebih tinggi meningkatkan risiko hipertensi karena menambah beban kerja jantung dan resistensi pembuluh darah.

Kualitas tidur Anda tergolong baik (skor 2 dari 5) dan memiliki pengaruh kecil dalam menurunkan risiko ini, dengan kontribusi 6,6% dari keseluruhan faktor. Kualitas tidur yang baik berkaitan dengan risiko hipertensi yang lebih rendah, dan karena pengaruhnya tergolong kecil, keterkaitan ini tidak dijadikan klaim sebab-akibat.

Berdasarkan faktor tersebut, disarankan pasien untuk berhenti merokok karena memberi manfaat langsung bagi kesehatan pembuluh darah dan tekanan darah, dan memperbaiki kualitas tidur dengan jadwal tidur yang teratur serta membatasi kafein dan paparan layar sebelum tidur, serta berkonsultasi dengan tenaga kesehatan untuk pemeriksaan dan penanganan lebih lanjut.

Contoh ini memperlihatkan dua mekanisme pengaman bekerja sekaligus. Pertama, kualitas tidur muncul sebagai faktor ketiga dengan arah menurunkan risiko yang kini konsisten dengan literatur karena kualitas tidur pasien tergolong baik; karena pengaruhnya kecil, teks faktanya tetap di-*hedge* sehingga tidak menjadi klaim sebab-akibat. Kedua, status merokok tidak tampil pada tiga faktor teratas karena kontribusi

SHAP-nya sangat kecil dan berarah keliru, tetapi saran berhenti merokok tetap muncul karena dipicu oleh kondisi klinis pasien yang memang seorang perokok. Dengan demikian, keterbatasan model yang diidentifikasi pada subbab V.3.2 tidak berubah menjadi misinformasi pada keluaran akhir.

V.3.3.6 Evaluasi dan Keterbatasan

Keandalan faktual narasi bertumpu pada pemisahan tugas: seluruh angka, arah, kategori, dan pemilihan fakta bersifat deterministik dan dapat ditelusuri kembali ke nilai SHAP, sementara peran generatif LLM dibatasi pada penghalusan bahasa saran yang isinya telah ditetapkan secara deterministik. Rancangan ini menekan ruang munculnya halusinasi pada bagian yang paling berisiko.

Meskipun demikian, terdapat sejumlah keterbatasan. Cakupan saran bergantung pada kelengkapan potongan anjuran baku yang disusun, sehingga faktor risiko di luar daftar tersebut belum tertangani. Penggunaan LLM berukuran relatif kecil juga menuntut instruksi yang ketat agar keluaran tetap patuh, dan variasi antar pemanggilan tetap mungkin terjadi. Selain itu, template fakta dan saran medis disusun berdasarkan pengetahuan umum dan pedoman, sehingga tetap memerlukan penelaahan oleh tenaga medis sebelum digunakan pada konteks pelayanan sebenarnya. Sejalan dengan simpulan pada subbab sebelumnya, seluruh keluaran narasi diposisikan sebagai alat bantu edukasi dan skrining awal, bukan pengganti diagnosis maupun nasihat klinis.

V.4 Hasil Implementasi Purwarupa

Bagian ini memaparkan hasil implementasi purwarupa sistem berbasis web yang mengintegrasikan ketiga modul, yaitu model klasifikasi XGBoost, interpretasi SHAP, dan modul narasi berbasis LLM, ke dalam satu alur kerja *end-to-end*. Purwarupa ini berfungsi sebagai bukti konsep (*proof of concept*) yang mendemonstrasikan bahwa ketiga komponen dapat bekerja secara terpadu, mulai dari masukan data faktor risiko non-invasif hingga keluaran berupa status risiko, grafik faktor penyebab, dan narasi penjelasan.

Purwarupa diwujudkan dengan arsitektur berbasis layanan (*service-based*) yang memisahkan antarmuka pengguna (*frontend*) dari mesin analisis (*backend*). Kedua sisi berkomunikasi melalui antarmuka REST berbasis JSON, sehingga seluruh logika prediksi terpusat di backend sementara frontend berfokus pada pengumpulan masukan dan penyajian hasil.

V.4.1 Lingkungan dan Teknologi Implementasi

Antarmuka pengguna dibangun menggunakan kerangka kerja Next.js 14 berbasis React 18 dengan bahasa TypeScript dan penataan gaya Tailwind CSS. Komunikasi ke backend memanfaatkan *fetch* bawaan peramban dalam format JSON, sedangkan visualisasi kontribusi fitur dirender secara mandiri tanpa pustaka grafik pihak ketiga agar tampilan tetap ringan dan terkendali.

Backend dikembangkan dengan kerangka kerja FastAPI (Python) dan mengekspos satu titik akhir utama, yaitu *POST /api/v1/analyze*, yang menerima delapan fitur non-invasif serta mengembalikan hasil prediksi, atribusi SHAP, dan narasi dalam satu respons JSON. Model XGBoost terlatih dimuat dari satu artefak *joblib* yang menyimpan tiga komponen sekaligus, yaitu objek model, ambang keputusan, dan urutan nama fitur, sehingga konfigurasi prediksi pada sistem identik dengan hasil eksperimen. Ambang Youden sebesar 0,516 yang tersimpan pada artefak inilah yang dipakai untuk mengklasifikasikan keluaran menjadi kategori risiko tinggi (*high risk*) atau risiko rendah (*low risk*), menggantikan ambang bawaan 0,5. Nilai fitur yang tidak lengkap ditangani melalui berkas nilai imputasi cadangan, meskipun dalam pemakaian normal kedelapan fitur selalu terkirim dari formulir. Model tidak memerlukan penskalaan karena berbasis pohon keputusan.

Interpretasi dihitung dengan *TreeExplainer* dari pustaka SHAP atas model XGBoost, yang menghasilkan kontribusi bertanda untuk tiap fitur dan kemudian diurutkan berdasarkan besarnya. Modul narasi memanfaatkan layanan LLM Groq dengan model *llama-3.1-8b-instant*. Sesuai rancangan pada Subbab V.3.3, seluruh angka, arah, dan materi saran ditentukan secara deterministik oleh kode, sedangkan LLM hanya bertugas menghaluskan bahasa. Sistem tidak menggunakan basis pengetahuan eksternal maupun mekanisme temu-kembali (RAG) pada saat inferensi. Apabila layanan LLM tidak tersedia, sistem secara otomatis memakai materi narasi deterministik sehingga keluaran tetap valid. Ringkasan teknologi yang digunakan disajikan pada Tabel V.23.

V.4.2 Antarmuka dan Alur Penggunaan

Antarmuka terdiri atas tiga halaman, yaitu halaman beranda sebagai pengantar, halaman formulir untuk pengisian data, dan halaman hasil untuk menampilkan luaran. Halaman formulir dirancang sebagai kuesioner bertahap tiga langkah, yaitu:

1. **Demografi dan Fisik:** usia, jenis kelamin, berat badan, dan tinggi badan.
2. **Riwayat Medis dan Gaya Hidup:** status merokok, riwayat diabetes, dan riwayat kolesterol tinggi berdasarkan diagnosis tenaga kesehatan.

Tabel V.23 Teknologi yang Digunakan pada Purwarupa

Komponen	Teknologi	Keterangan
Antarmuka (<i>frontend</i>)	Next.js 14, React 18, TypeScript, Tailwind CSS	Aplikasi web; komunikasi <i>fetch</i> JSON; grafik SHAP dirender mandiri tanpa pustaka grafik
Layanan (<i>backend</i>)	FastAPI (Python)	Titik akhir tunggal <i>POST /api-/v1/analyze</i>
Model prediksi	XGBoost (<i>XGBClassifier</i>)	Dimuat dari artefak <i>joblib</i> berisi model, ambang Youden 0,516, dan urutan fitur; tanpa penskalaan
Interpretasi (XAI)	SHAP (<i>TreeExplainer</i>)	Menghasilkan kontribusi bertanda tiap fitur
Narasi (LLM)	Groq <i>llama-3.1-8b-instant</i>	Hanya menghaluskan bahasa; tanpa RAG; dilengkapi <i>fallback</i> deterministik

3. Kualitas Tidur: skor kualitas tidur dan skor gangguan tidur.

← Beranda Langkah 1 dari 3 Reset

Demografi & Fisik
Data dasar diri Anda.

Berapa usia Anda?

21 tahun

Apa jenis kelamin Anda?

Laki-laki ▼

Berapa berat badan Anda?

70 kg

Berapa tinggi badan Anda?

180 cm

Lanjutkan

Gambar V.25 Antarmuka pengisian data faktor risiko non-invasif (Langkah 1)

← Beranda Langkah 2 dari 3 Reset

Riwayat Medis & Gaya Hidup

Kondisi kesehatan dan kebiasaan yang memengaruhi tekanan darah.

Apakah Anda pernah atau sedang aktif mengonsumsi tembakau (merokok, melinting, pipa, atau mengunyah)?

Tidak

Apakah Dokter/Paramedis/Perawat/Bidan pernah mengatakan bahwa Anda memiliki penyakit diabetes?

Tidak

Apakah Dokter/Paramedis/Perawat/Bidan pernah mengatakan bahwa Anda memiliki kolesterol tinggi?

Tidak

Kembali Lanjutkan

Gambar V.26 Antarmuka pengisian data faktor risiko non-invasif (Langkah 2)

← Beranda Langkah 3 dari 3 Reset

Kualitas Tidur

Pola tidur Anda dalam sebulan terakhir.

Dalam 1 minggu terakhir, bagaimana Anda menilai kualitas tidur Anda?

3 — Cukup

Dalam satu minggu terakhir, seberapa sering Anda mengalami gangguan tidur (sulit tidur atau sering terbangun)?

1 — Tidak pernah

Kembali Kirim & Analisis

Gambar V.27 Antarmuka pengisian data faktor risiko non-invasif (Langkah 3)


Berat dan tinggi badan tidak dikirim langsung, melainkan dikonversi terlebih dahulu menjadi indeks massa tubuh (BMI) di sisi klien, sehingga backend menerima tepat delapan fitur sesuai urutan yang diharapkan model. Setelah pengguna melengkapi

ketiga langkah, frontend mengirimkan kedelapan fitur ke *endpoint /api/v1/analyze*. Backend kemudian menghitung probabilitas melalui fungsi *predict_proba* pada model XGBoost, mengklasifikasikannya memakai ambang Youden, menghitung atribusi SHAP, lalu menyusun narasi melalui lapisan deterministik dan LLM. Seluruh hasil dikembalikan sebagai satu respons JSON yang langsung dirender pada halaman hasil.

V.4.3 Keluaran Sistem

Halaman hasil menyajikan tiga luaran secara terpadu untuk setiap analisis. Pertama, status risiko ditampilkan sebagai label “Risiko Rendah” atau “Risiko Tinggi” beserta skor probabilitas dalam bentuk pengukur (*meter*) berwarna, dengan hijau menandakan risiko rendah dan merah menandakan risiko tinggi. Kedua, grafik kontribusi faktor menampilkan hasil SHAP sebagai diagram batang horizontal; warna merah menandakan faktor yang menaikkan risiko dan hijau menandakan faktor yang menurunkannya, sedangkan panjang batang merepresentasikan kontribusi relatif tiap faktor terhadap total. Grafik ini turut menampilkan nilai masukan pengguna pada tiap faktor serta keterangan bahwa nilai yang ditampilkan merupakan kontribusi relatif, bukan persentase risiko total. Ketiga, narasi klinis menyajikan ringkasan tingkat risiko, penjelasan tiga faktor teratas, dan paragraf saran gaya hidup, yang ditutup dengan pernyataan bahwa hasil merupakan informasi pendukung awal dan bukan pengganti diagnosis tenaga kesehatan.

Ketiga luaran tersebut merupakan perwujudan langsung dari mekanisme pengamanan yang telah diuraikan pada Subbab V.3.3, misalnya penanganan khusus faktor merokok serta aturan arah anjuran natrium, sehingga keterbatasan model tidak berubah menjadi misinformasi pada tampilan akhir yang diterima pengguna.



Gambar V.28 Halaman hasil: status risiko, grafik SHAP, dan narasi penjelasan

BAB VI

EVALUASI

Bab ini memaparkan evaluasi terhadap sistem yang dibangun melalui dua sudut pandang yang saling melengkapi. Pertama, evaluasi kuantitatif terhadap model klasifikasi *Machine Learning* yang menjadi inti prediksi risiko hipertensi, yang diukur menggunakan metrik-metrik terstandar. Kedua, evaluasi kualitatif terhadap dua komponen sistem yang bersifat interpretatif, yaitu komponen *Explainable Artificial Intelligence* (SHAP) dan komponen *Large Language Model* (LLM), yang keduanya tidak dapat sepenuhnya diukur oleh metrik otomatis sehingga memerlukan penilaian pakar. Evaluasi kuantitatif merupakan rekapitulasi atas hasil pemodelan yang telah dilaksanakan pada Bab V, sedangkan evaluasi kualitatif dilakukan melalui pendekatan *expert validation* oleh seorang dokter umum sebagai *domain expert*.

VI.1 Evaluasi Kuantitatif (ML)

Bagian ini merekapitulasi hasil evaluasi kuantitatif model *Machine Learning* yang telah dilaksanakan secara rinci pada tahap pemodelan di Bab V. Tujuan rekapitulasi ini adalah menegaskan model terbaik yang menjadi mesin prediksi sistem beserta kinerjanya, sebelum pembahasan berpindah ke evaluasi kualitatif komponen interpretatif. Uraian lengkap mengenai pembagian data, penyetelan *hyperparameter*, optimasi ambang keputusan, hingga perbandingan antarmodel dapat ditelusuri kembali pada Bab V.

Pada tahap pemodelan, empat algoritma dibandingkan, yaitu *Logistic Regression*, *Random Forest*, *XGBoost*, dan *CatBoost*. Keempatnya disetel menggunakan `GridSearchCV` dengan fungsi objektif ROC-AUC dan validasi silang tiga lipatan, kemudian titik operasinya ditentukan melalui *Youden Index*. Pemilihan model akhir tidak hanya bertumpu pada satu metrik, melainkan pada gabungan pertimbangan kemampuan membedakan kelas (ROC-AUC), kemampuan menangkap pasien berisiko (*recall*), kemudahan penafsiran, dukungan analisis kontribusi fitur berbasis SHAP, serta kemudahan penerapan pada sistem. Berdasarkan pertimbangan tersebut, **XGBoost** dipilih sebagai model akhir karena memiliki kemampuan membedakan kelas yang

setara dengan model terbaik, *recall* tertinggi pada ambang bawaan, dukungan penjelasan SHAP yang matang, dan penerapan yang ringan.

Kinerja model terbaik XGBoost pada data uji dirangkum pada Tabel VI.1, disajikan pada dua titik operasi, yaitu ambang bawaan 0,5 dan ambang *Youden* yang menjadi titik operasi final sistem.

Tabel VI.1 Rekapitulasi kinerja model terbaik (XGBoost) pada data uji

Metrik	Ambang 0,5	Ambang Youden
ROC-AUC		0,7795
PR-AUC		0,5795
Recall	0,7186	0,7062
Specificity	0,7036	0,7192
F1-score	0,5901	0,5921
Akurasi	0,7080	0,7154

Nilai ROC-AUC dan PR-AUC dihitung dari probabilitas sehingga tidak berubah oleh pemilihan ambang. Dengan ROC-AUC sebesar 0,7795 dan *recall* sebesar 0,7186 pada ambang 0,5 (0,7062 pada ambang Youden), model XGBoost memenuhi kriteria keberhasilan yang ditetapkan di awal penelitian, yaitu ROC-AUC minimal 0,75 dan *recall* minimal 0,70. Model ini kemudian disimpan bersama nilai ambang *Youden* dan urutan nama fitur, lalu digunakan sebagai mesin prediksi yang keluarannya menjadi masukan bagi komponen SHAP dan LLM. Kualitas kedua komponen interpretatif itulah yang dievaluasi secara kualitatif pada bagian berikut.

VI.2 Evaluasi Kualitatif (XAI + LLM)

Berbeda dengan model klasifikasi yang dapat diukur secara kuantitatif, komponen SHAP dan LLM menghasilkan keluaran interpretatif yang kualitasnya tidak dapat sepenuhnya ditangkap oleh metrik otomatis sehingga memerlukan penilaian pakar. Evaluasi kualitatif dilakukan melalui pendekatan *expert validation* oleh seorang dokter umum sebagai *domain expert*.

VI.2.1 Metode Evaluasi

VI.2.1.1 Strategi Evaluasi

Strategi evaluasi yang digunakan adalah validasi ahli (*expert validation*) oleh satu orang dokter umum yang berperan sebagai *domain expert*. Pendekatan ini dipilih, dan bukan pengukuran kesepakatan antar-penilai (*inter-rater agreement*), karena penelitian melibatkan satu penilai tunggal. Metrik kesepakatan antar-penilai seperti Cohen's Kappa atau Aiken's V mensyaratkan minimal dua penilai dan tidak dapat

dihitung secara sah untuk penilai tunggal; oleh sebab itu fokus evaluasi diarahkan pada validasi kualitas keluaran sistem oleh ahli, dengan analisis deskriptif dan tematik terhadap hasil penilaian.

Objek evaluasi terdiri atas dua hal yang dinilai secara terpisah menggunakan dua instrumen yang berbeda: (1) penjelasan kontribusi fitur yang dihasilkan SHAP terhadap prediksi risiko hipertensi, dan (2) narasi personal edukatif yang dihasilkan LLM berdasarkan hasil SHAP. Pemisahan instrumen dilakukan karena kedua komponen memiliki objek penilaian yang berbeda: SHAP dinilai sebagai penjelasan interpretatif model, sedangkan LLM dinilai sebagai teks komunikatif untuk pasien.

VI.2.1.2 Dasar Pemilihan Instrumen

Seluruh aspek penilaian pada kedua instrumen diturunkan dari literatur bereputasi agar tidak ada aspek yang ditentukan secara subjektif. Aspek untuk komponen SHAP diadaptasi dari Salih dkk. (2024) yang terbit di *Artificial Intelligence Review* (jurnal Q1), sebuah tinjauan sistematis atas pendekatan evaluasi XAI pada aplikasi klinis kardiovaskular. Tinjauan tersebut mengkategorikan evaluasi XAI menjadi lima jalur (*human-grounded*, *application-grounded*/pakar domain, *proxy-grounded*, *literature-grounded*, dan *guideline-grounded*), serta mendefinisikan kriteria kualitas penjelasan klinis seperti relevansi klinis, *plausibility*, *complexity*/keterpahaman, dan kepercayaan sebagai tujuan akhir evaluasi pakar.

Aspek untuk komponen LLM diadaptasi dari Tam dkk. (2024) yang terbit di *npj Digital Medicine* (jurnal Q1), yang mengusulkan kerangka QUEST untuk evaluasi LLM di bidang kesehatan berdasarkan tinjauan atas 142 studi. QUEST terdiri atas lima prinsip beserta dimensinya: *Quality of Information* (antara lain *accuracy*, *agreement*, *consistency*, *relevance*, *usefulness*), *Understanding and Reasoning*, *Expression Style and Persona* (*clarity*, *empathy*), *Safety and Harm* (*bias*, *harm*, *fabrication/falsification*), dan *Trust and Confidence*. Kerangka ini juga menegaskan penggunaan skala Likert 1–5 dengan definisi tiap skor sebagai format penilaian yang lazim, sehingga menjadi dasar desain skala pada kedua instrumen penelitian ini.

Tabel VI.2 dan Tabel VI.3 menunjukkan penelusuran setiap aspek instrumen ke dimensi asalnya pada literatur.

VI.2.1.3 Objek dan Prosedur Validasi

Validasi dilakukan oleh dr. Roos Meri Silaen (Puskesmas Mulyamekar, Dinas Kesehatan Kabupaten Purwakarta) pada tanggal 8 Juli 2026 atas tujuh kasus representatif yang dipilih dari data uji. Pemilihan kasus mempertimbangkan keterwakilan kelas

Tabel VI.2 Penelusuran aspek instrumen SHAP ke Salih dkk. (2024)

Aspek instrumen	Dimensi/kriteria pada Salih dkk. (2024)
Relevansi fitur	<i>Clinical relevance</i> — penjelasan selaras dengan opini dokter dan mendukung penalaran klinis; dikuantifikasi melalui persentase tumpang tindih fitur XAI dengan pilihan dokter.
Arah kontribusi fitur	Pembahasan kolinearitas — prediktor yang saling berkorelasi (mis. tekanan darah, merokok, diabetes) dapat membuat XAI menghasilkan penjelasan tidak realistis/bias, sehingga arah kontribusi perlu diverifikasi ahli.
Kesesuaian medis	<i>Plausibility</i> dan jalur <i>literature-grounded</i> — penjelasan sejalan dengan ekspektasi pakar dan pengetahuan medis mapan.
Kemudahan dipahami	<i>Complexity/understandability</i> — kompleksitas dan waktu yang dibutuhkan untuk memahami penjelasan.
Kepercayaan	<i>Trust</i> — keterlibatan pakar bertujuan menilai apakah penjelasan layak dipercaya, digeneralisasi, dan diterapkan.

Tabel VI.3 Penelusuran aspek instrumen LLM ke kerangka QUEST, Tam dkk. (2024)

Aspek instrumen	Prinsip/dimensi pada QUEST (Tam dkk., 2024)
Faktualitas medis	<i>Quality of Information: accuracy + agreement.</i>
Konsistensi terhadap SHAP	<i>Quality of Information: consistency</i> (kesesuaian isi narasi dengan bukti SHAP sebagai rujukan).
Koherensi & kejelasan	<i>Expression Style and Persona: clarity</i> ; koherensi naratif sebagai aspek kunci evaluasi.
Kualitas edukasi	<i>Quality of Information: usefulness + relevance</i> ; edukasi pasien merupakan kategori aplikasi utama.
Bebas halusinasi	<i>Safety and Harm: fabrication/falsification.</i>
Keamanan (potensi bahaya)	<i>Safety and Harm: harm.</i>

dan hasil prediksi, yaitu mencakup kasus berisiko rendah hingga berisiko tinggi serta kombinasi faktor risiko yang beragam, agar dokter menilai perilaku sistem pada beragam kondisi, bukan hanya pada kasus yang mudah. Profil ketujuh kasus disajikan pada Tabel VI.4. Untuk setiap kasus, dokter disajikan: (a) ringkasan data pasien; (b) hasil prediksi model beserta probabilitasnya; (c) visualisasi kontribusi fitur SHAP; dan (d) narasi personal yang dihasilkan LLM.

Tabel VI.4 Profil tujuh kasus yang divalidasi

Kasus	Profil	Jenis kelamin	Usia	Faktor risiko menonjol
1	Atlet amatir	Laki-laki	21	Tanpa faktor risiko; kualitas tidur sangat baik
2	Mahasiswa tingkat akhir	Perempuan	22	Kualitas tidur buruk; gangguan tidur sering
3	Pekerja korporat	Laki-laki	34	Merokok; kolesterol tinggi
4	Ibu rumah tangga	Perempuan	48	Diabetes; gangguan tidur sering
5	Supir truk	Laki-laki	45	Merokok; kolesterol tinggi; kualitas tidur sangat buruk
6	Pensiunan aktif	Perempuan	65	Tanpa komorbid; usia lanjut
7	Komorbid lengkap	Laki-laki	52	Merokok; diabetes; kolesterol tinggi; IMT tinggi

Prosedur validasi ditempuh dalam langkah berikut:

1. Dokter menerima penjelasan mengenai tujuan penelitian, komponen sistem, dan petunjuk pengisian kedua lembar validasi.
2. Untuk setiap kasus, dokter meninjau keluaran SHAP dan mengisi Lembar Validasi SHAP pada kelima aspeknya.
3. Untuk kasus yang sama, dokter meninjau narasi LLM dan mengisi Lembar Validasi LLM pada keenam aspeknya.
4. Dokter mengisi kolom komentar untuk memberikan justifikasi kualitatif atas skor yang diberikan dan mencatat temuan spesifik.
5. Skor pada seluruh kasus direkap untuk dianalisis.

Kedua instrumen menggunakan skala Likert 1–5 dengan orientasi seragam “semakin tinggi semakin baik”. Untuk aspek yang secara alami bermuatan negatif (halusinasi dan potensi bahaya), konstruk yang dinilai dirumuskan secara positif (“bebas halusinasi” dan “keamanan/bebas potensi bahaya”) sehingga skor 5 selalu menandakan kualitas terbaik. Perumusan ini menjaga agar rerata antaraspek dapat diinterpretasikan secara konsisten tanpa *reverse coding*.

VI.2.1.4 Metode Analisis Hasil Evaluasi

Pada penelitian ini, analisis dilakukan secara deskriptif dan tematik. Untuk analisis deskriptif, setiap aspek dihitung rerata skor Likert lintas kasus beserta ukuran sebarannya (median dan modus). Rerata tiap aspek kemudian diinterpretasikan menggunakan skala interval lima kategori sebagaimana pada Tabel VI.5. Rerata keseluruhan per komponen (SHAP dan LLM) juga dihitung sebagai indikator ringkas kualitas komponen.

Tabel VI.5 Skala interpretasi rerata skor Likert

Rentang rerata	Kategori	Interpretasi validitas
1,00 – 1,80	Sangat kurang	Tidak valid
1,81 – 2,60	Kurang	Kurang valid
2,61 – 3,40	Cukup	Cukup valid
3,41 – 4,20	Baik	Valid
4,21 – 5,00	Sangat baik	Sangat valid

Tahap selanjutnya adalah pada analisis tematik. Komentar dokter dianalisis secara kualitatif untuk mengidentifikasi pola temuan, misalnya jenis ketidaksesuaian fitur, arah kontribusi yang meragukan, atau bentuk halusinasi pada narasi. Analisis tematik ini melengkapi angka Likert dengan konteks klinis dan menjadi dasar rekomendasi perbaikan sistem.

VI.2.2 Hasil Evaluasi

Validasi dilaksanakan atas tujuh kasus dan menghasilkan 35 penilaian untuk komponen SHAP (tujuh kasus dikali lima aspek) serta 42 penilaian untuk komponen LLM (tujuh kasus dikali enam aspek). Skor rinci per kasus disajikan pada Tabel VI.6 dan Tabel VI.7, sedangkan ringkasan rerata, median, modus, dan kategori setiap aspek disajikan pada Tabel VI.8 dan Tabel VI.9.

Tabel VI.6 Skor validasi komponen SHAP per kasus

No	Aspek	K1	K2	K3	K4	K5	K6	K7	Rerata
1	Relevansi fitur	5	5	4	5	4	4	3	4,29
2	Arah kontribusi fitur	2	3	4	3	3	2	3	2,86
3	Kesesuaian medis	3	3	4	3	4	2	3	3,14
4	Kemudahan dipahami	4	4	5	4	4	5	5	4,43
5	Kepercayaan	4	4	4	3	3	2	3	3,29

Selain skor, komentar dokter memberikan konteks kualitatif atas penilaian. Pada komponen SHAP, temuan yang paling menonjol adalah ketidaksesuaian arah kon-

Tabel VI.7 Skor validasi komponen LLM per kasus

No	Aspek	K1	K2	K3	K4	K5	K6	K7	Rerata
1	Faktualitas medis	3	5	5	4	4	2	3	3,71
2	Konsistensi terhadap SHAP	3	4	4	4	3	3	4	3,57
3	Koherensi & kejelasan	5	5	5	4	3	3	4	4,14
4	Kualitas edukasi	3	4	4	5	4	2	3	3,57
5	Bebas halusinasi	3	4	5	4	5	3	4	4,00
6	Keamanan (potensi bahaya)	5	5	5	5	5	4	3	4,57

Tabel VI.8 Hasil validasi komponen SHAP

No	Aspek	Rerata	Median	Modus	Kategori
1	Relevansi fitur	4,29	4	4; 5	Sangat baik
2	Arah kontribusi fitur	2,86	3	3	Cukup
3	Kesesuaian medis	3,14	3	3	Cukup
4	Kemudahan dipahami	4,43	4	4	Sangat baik
5	Kepercayaan	3,29	3	3; 4	Cukup
Rerata keseluruhan		3,60			Baik

Tabel VI.9 Hasil validasi komponen LLM

No	Aspek	Rerata	Median	Modus	Kategori
1	Faktualitas medis	3,71	4	3; 4; 5	Baik
2	Konsistensi terhadap SHAP	3,57	4	4	Baik
3	Koherensi & kejelasan	4,14	4	5	Baik
4	Kualitas edukasi	3,57	4	4	Baik
5	Bebas halusinasi	4,00	4	4	Baik
6	Keamanan (potensi bahaya)	4,57	5	5	Sangat baik
Rerata keseluruhan		3,93			Baik

tribusi pada beberapa fitur berdampak kecil, khususnya merokok, status tidak merokok, dan jenis kelamin, yang pada seluruh kasus dinilai masih dapat diterima karena magnitudonya berada di bawah 3%. Pada komponen LLM, temuan yang menonjol mencakup saran yang tidak sesuai dengan kondisi pasien (Kasus 1), kesalahan logika kausal terkait indeks massa tubuh (Kasus 4), ketidakkonsistenan saran berhenti merokok terhadap arah kontribusi SHAP (Kasus 5), serta penilaian bobot diabetes yang dianggap terlalu kecil (Kasus 7). Catatan lintas kasus yang menonjol adalah keterkaitan antara galat arah pada SHAP dan ketidakkonsistenan narasi LLM, yang diuraikan lebih lanjut pada Subbab VI.2.3.

VI.2.3 Pembahasan Hasil Evaluasi

Pembahasan menghubungkan hasil penilaian dokter dengan kualitas komponen XAI dan narasi LLM, serta implikasinya bagi kelayakan sistem.

VI.2.3.1 Interpretasi Kualitas Komponen SHAP

Hasil validasi SHAP pada Tabel VI.8 menunjukkan rerata keseluruhan 3,60 yang tergolong valid. Dua aspek memperoleh kategori sangat baik, yaitu relevansi fitur (4,29) dan kemudahan dipahami (4,43). Nilai tersebut menunjukkan bahwa fitur yang ditandai SHAP sebagai paling berkontribusi umumnya memang relevan secara klinis menurut penilaian dokter, dan bahwa penyajian kontribusi fitur mudah dipahami tanpa keahlian teknis tambahan. Temuan ini selaras dengan kriteria *clinical relevance* dan *understandability* pada Salih dkk. (2024).

Tiga aspek lain memperoleh kategori cukup, yaitu arah kontribusi fitur (2,86), kesesuaian medis (3,14), dan kepercayaan (3,29). Aspek arah kontribusi fitur menjadi titik terlemah komponen SHAP. Komentar dokter secara konsisten menandai adanya fitur yang arah kontribusinya tidak sesuai dengan hubungan yang dikenal secara medis. Pada beberapa kasus, fitur gangguan tidur dan merokok yang seharusnya menaikkan risiko justru ditampilkan sebagai penurunan risiko, dan pada Kasus 6 status tidak merokok yang seharusnya menurunkan risiko malah ditampilkan menambah risiko sebesar 1,3%. Ketidaksesuaian arah tersebut konsisten dengan pembahasan Salih dkk. (2024) mengenai pengaruh kolinearitas antarprediktor kardiovaskular yang dapat membuat metode XAI menghasilkan penjelasan yang tidak realistis.

Meskipun demikian, dokter menilai ketidaksesuaian itu masih dapat diterima karena magnitudo kontribusinya sangat kecil, yaitu umumnya di bawah 3%, sehingga tidak menggeser kesimpulan tingkat risiko. Penilaian bersyarat ini penting untuk dicatat: validitas arah kontribusi SHAP tergolong baik pada fitur berdampak besar, tetapi mengandung galat arah yang sistematis pada fitur berdampak kecil. Galat itulah

yang menyeret turun skor kesesuaian medis dan kepercayaan, dan tampak paling jelas pada Kasus 6 yang memuat beberapa galat arah sekaligus serta memperoleh skor kepercayaan terendah, yaitu 2.

VI.2.3.2 Interpretasi Kualitas Narasi LLM

Komponen LLM memperoleh rerata keseluruhan 3,93 yang tergolong valid, lebih tinggi daripada komponen SHAP. Aspek keamanan memperoleh nilai tertinggi (4,57; sangat baik), diikuti koherensi dan kejelasan (4,14). Hal ini menunjukkan bahwa narasi yang dihasilkan aman untuk disampaikan kepada pasien serta tersusun runtut dan mudah dipahami. Aspek faktualitas medis (3,71) dan bebas halusinasi (4,00) juga tergolong valid, yang menandakan narasi umumnya benar secara medis dan jarang memuat informasi yang dibuat-buat.

Dua aspek dengan nilai terendah adalah konsistensi terhadap SHAP (3,57) dan kualitas edukasi (3,57). Komentar dokter memperlihatkan penyebab yang spesifik dan berulang. Pada Kasus 1, narasi menyarankan pasien memperbaiki kualitas tidur padahal data pasien menunjukkan kualitas tidur sudah sangat baik. Pada Kasus 4 terdapat kesalahan logika kausal, yaitu narasi menyatakan bahwa perbaikan kualitas tidur “dapat meningkatkan indeks massa tubuh”, padahal maksud yang benar adalah menurunkannya. Pada Kasus 6, keterkaitan antara interpretasi kontribusi indeks massa tubuh dan saran yang diberikan dinilai kurang padu sehingga aspek faktualitas hanya memperoleh skor 2. Pada Kasus 7, kontribusi diabetes dinilai terlalu kecil, padahal secara klinis resistensi insulin pada diabetes meningkatkan aktivitas saraf simpatis dan menyempitkan pembuluh darah sehingga tergolong faktor moderat. Sebagian ketidaksesuaian ini berkaitan dengan strategi *prompt engineering* yang belum sepenuhnya memaksa narasi mempertahankan makna dan proporsi kontribusi dari hasil SHAP.

VI.2.3.3 Keterkaitan Antarkomponen dan Implikasi Sistem

Hasil kedua komponen saling berkaitan pada alur XAI→LLM. Kasus 5 memperlihatkan keterkaitan ini dengan jelas: hasil SHAP menandai merokok sebagai penurunan risiko, yaitu arah yang keliru secara medis, sementara narasi LLM menyarankan pasien berhenti merokok. Saran tersebut benar secara medis, tetapi tidak konsisten dengan arah kontribusi yang ditampilkan SHAP, sehingga menimbulkan ketegangan antara kesetiaan terhadap sumber (*faithfulness*) dan kebenaran medis. Pola ini menunjukkan bahwa sebagian persoalan konsistensi pada komponen LLM berakar pada galat arah di komponen SHAP. Perbaikan pada komponen SHAP di hulu, dengan demikian, berpotensi langsung meningkatkan konsistensi narasi di hilir.

Secara keseluruhan, kedua komponen memperoleh kategori valid, yaitu SHAP 3,60 dan LLM 3,93. Temuan ini menunjukkan bahwa rangkaian interpretasi SHAP dan narasi LLM layak digunakan sebagai pendukung komunikasi risiko hipertensi kepada pasien, namun belum memadai untuk berdiri sendiri sebagai alat pengambilan keputusan klinis. Galat arah pada fitur berdampak kecil dan sejumlah ketidakkonsistenan narasi perlu diperbaiki sebelum sistem diterapkan pada konteks yang lebih luas.

VI.2.3.4 Keterbatasan

Evaluasi ini memiliki sejumlah keterbatasan. Pertama, penilaian dilakukan oleh satu orang dokter umum sehingga hasilnya tidak dapat digeneralisasi secara luas dan tidak memungkinkan pengukuran kesepakatan antar-penilai. Kedua, jumlah kasus yang dievaluasi terbatas pada tujuh profil. Ketiga, penilaian ahli bersifat subjektif; pada Kasus 1 dokter mencatat bahwa profil tersebut merupakan profil pertama yang dinilai sehingga terdapat kemungkinan efek urutan pada awal penilaian. Keempat, sebagian penilaian aspek arah kontribusi bersifat bersyarat, yaitu ketidaksesuaian arah dinilai dapat diterima sepanjang magnitudonya kecil, sehingga validitas aspek tersebut perlu dimaknai dengan mempertimbangkan syarat ini.

VI.2.3.5 Rekomendasi Perbaikan Sistem

Berdasarkan temuan di atas, terdapat beberapa rekomendasi perbaikan. Pertama, galat arah pada fitur berdampak kecil dapat ditangani dengan penyaringan atau penggabungan kontribusi di bawah ambang tertentu agar tidak ditampilkan sebagai arah yang menyesatkan. Kedua, strategi *prompt engineering* pada komponen LLM perlu diperkuat agar narasi mempertahankan arah dan proporsi kontribusi dari hasil SHAP serta menghindari kesalahan logika kausal seperti pada Kasus 4. Ketiga, penelitian lanjutan disarankan menambah jumlah penilai untuk memungkinkan pengukuran kesepakatan antar-penilai serta memperluas cakupan kasus yang dievaluasi.

BAB VII

PENUTUP

Bab ini memuat kesimpulan yang menjawab rumusan masalah dan tujuan penelitian berdasarkan hasil perancangan, implementasi, dan evaluasi yang telah dilakukan, serta saran untuk pengembangan lebih lanjut.

VII.1 Kesimpulan

Berdasarkan hasil pengembangan sistem estimasi risiko hipertensi yang mengintegrasikan *machine learning*, *Explainable Artificial Intelligence* (XAI), dan *Large Language Model* (LLM), diperoleh kesimpulan sebagai berikut.

1. Model klasifikasi risiko hipertensi berbasis *machine learning* berhasil dibangun menggunakan data sekunder IFLS-5 dengan delapan fitur non-invasif dan label biner yang dibentuk dari kriteria tekanan darah 140/90 mmHg. Dari empat algoritma yang dibandingkan, yaitu *Logistic Regression*, *Random Forest*, *XGBoost*, dan *CatBoost*, model *XGBoost* dipilih sebagai model akhir karena menawarkan keseimbangan terbaik antara kemampuan membedakan kelas, sensitivitas, dukungan interpretasi berbasis SHAP, serta kemudahan penerapan. Model ini mencapai ROC-AUC 0,7795 serta *recall* 0,7186 pada ambang 0,5 dan 0,7062 pada ambang *Youden* yang menjadi titik operasi final sistem, sehingga memenuhi kriteria keberhasilan yang ditetapkan, yaitu ROC-AUC minimal 0,75 dan *recall* minimal 0,70. Dengan demikian, rumusan masalah pertama terjawab.
2. Metode XAI berbasis SHAP (*TreeExplainer*) berhasil diterapkan untuk menjelaskan kontribusi setiap fitur terhadap prediksi, baik pada tingkat global maupun individu, dalam bentuk visualisasi yang dapat dipahami tanpa keahlian teknis tambahan. Analisis menempatkan usia, indeks massa tubuh, dan jenis kelamin sebagai faktor paling dominan, dengan arah kontribusi yang sebagian besar selaras dengan pengetahuan medis. Validasi oleh dokter umum memberikan rerata skor 3,60 pada skala Likert 1–5 (kategori valid), dengan catatan adanya galat arah pada sebagian fitur berdampak kecil (magnitudo di bawah 3%), termasuk status merokok, yang diduga dipengaruhi oleh faktor perancu

pada data survei. Dengan demikian, rumusan masalah kedua terjawab, sekaligus teridentifikasi keterbatasan yang perlu diperbaiki.

3. Modul narasi berbasis *prompt engineering* berhasil mentransformasi luaran teknis SHAP menjadi penjelasan berbahasa Indonesia yang personal dan mudah dipahami. Faktualitas narasi dijaga melalui arsitektur dua lapisan: seluruh angka, arah pengaruh, pemilihan fakta, dan materi saran ditetapkan secara deterministik dari nilai SHAP dan kondisi klinis pasien, sedangkan LLM (*llama-3.1-8b-instant*) hanya bertugas menghaluskan bahasa dengan *guardrail* yang melarang fabrikasi angka maupun klaim medis, tanpa menggunakan basis pengetahuan eksternal (RAG). Mekanisme *override* pada fitur yang berarah keliru, seperti status merokok, mencegah artefak model berubah menjadi misinformasi. Validasi dokter memberikan rerata skor 3,93 (kategori valid), dengan aspek keamanan memperoleh nilai tertinggi (4,57). Dengan demikian, rumusan masalah ketiga terjawab.

Secara keseluruhan, ketiga komponen berhasil diintegrasikan ke dalam sebuah purwarupa berbasis web yang berfungsi secara *end-to-end*, mulai dari masukan faktor risiko non-invasif hingga keluaran berupa status risiko, grafik kontribusi faktor, dan narasi penjelasan. Sistem terbukti mampu menyajikan estimasi risiko hipertensi yang akurat, transparan, dan komunikatif. Meskipun demikian, hasil evaluasi menegaskan bahwa sistem ini diposisikan sebagai alat bantu skrining awal dan edukasi, bukan sebagai pengganti diagnosis maupun keputusan klinis tenaga kesehatan.

VII.2 Saran

Berdasarkan temuan dan keterbatasan yang teridentifikasi selama penelitian, diajukan beberapa saran untuk pengembangan lebih lanjut sebagai berikut.

1. Menambah jumlah penilai ahli, yaitu lebih dari satu dokter, agar kesepakatan antar-penilai (*inter-rater agreement*) seperti Cohen's Kappa atau Aiken's V dapat dihitung dan hasil validasi dapat digeneralisasi lebih kuat, sekaligus memperluas jumlah dan variasi kasus yang dievaluasi.
2. Memperbaiki galat arah kontribusi SHAP pada fitur berdampak kecil, misalnya dengan menyaring atau menggabungkan kontribusi di bawah ambang tertentu agar tidak ditampilkan sebagai arah yang menyesatkan bagi pengguna.
3. Memperkuat strategi *prompt engineering* pada modul narasi agar teks secara konsisten mempertahankan arah dan proporsi kontribusi dari hasil SHAP serta terhindar dari kesalahan logika kausal.
4. Memperkaya fitur dengan sumber data yang lebih lengkap dan mutakhir, termasuk faktor risiko yang secara medis penting namun tidak tersedia atau terlalu banyak kosong pada IFLS-5, seperti riwayat hipertensi keluarga dan asupan

garam (natrium).

5. Meningkatkan stabilitas interpretasi pada fitur dengan jumlah data positif yang sedikit, yaitu diabetes dan kolesterol tinggi, misalnya melalui penambahan data atau teknik penyeimbangan yang sesuai.
6. Melakukan pengujian kepada pengguna akhir nyata (*usability testing*) untuk menilai keterpahaman dan penerimaan narasi di luar konteks validasi ahli.

DAFTAR PUSTAKA

- Adadi, A, dan M Berrada. 2018. "Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)". *IEEE Access* 6:52138–52160. <https://doi.org/10.1109/ACCESS.2018.2870052>.
- Amann, J, A Blasimme, E Vayena, D Frey, dan V I Madai. 2020. "Explainability for artificial intelligence in healthcare: a multidisciplinary perspective". *BMC Medical Informatics and Decision Making* 20 (1): 1–9. <https://doi.org/10.1186/s12911-020-01332-6>. <https://link.springer.com/article/10.1186/s12911-020-01332-6>.
- Amann, Julia, Daniel Vetter, Simon N. Blomberg, Helle C. Christensen, Michael Coffee, Sara Gerke, Thomas K. Gilbert, dkk. 2022. "To Explain or Not to Explain? Artificial Intelligence Explainability in Clinical Decision Support Systems". *PLOS Digital Health* 1 (2): e0000016. <https://doi.org/10.1371/journal.pdig.0000016>. <https://doi.org/10.1371/journal.pdig.0000016>.
- Benetos, Athanase, Mirko Petrovic, dan Timo Strandberg. 2019. "Hypertension Management in Older and Frail Older Patients". *Circulation Research* 124 (7): 1045–1060. ISSN: 0009-7330. <https://doi.org/10.1161/CIRCRESAHA.118.313236>. <https://doi.org/10.1161/CIRCRESAHA.118.313236>.
- Bergstra, James, dan Yoshua Bengio. 2012. "Random Search for Hyper-Parameter Optimization". *Journal of Machine Learning Research* 13:281–305. <https://jmlr.org/papers/v13/bergstra12a.html>.
- Black, Joyce M., dan Jane Hokanson Hawks. 2014. *Keperawatan Medikal Bedah*. Singapura: Elsevier.
- Breiman, Leo. 2001. "Random Forests". *Machine Learning* 45 (1): 5–32. <https://doi.org/10.1023/A:1010933404324>.

- Brown, T, B Mann, N Ryder, M Subbiah, J D Kaplan, P Dhariwal, dan A Neelakantan. 2020. "Language models are few-shot learners". Dalam *Advances in Neural Information Processing Systems*, 33:1877–1901. <https://doi.org/10.48550/arXiv.2005.14165>. <https://doi.org/10.48550/arXiv.2005.14165>.
- Chen, T., dan C. Guestrin. 2016. "XGBoost: A scalable tree boosting system". Dalam *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>.
- Clusmann, J, F R Kolbinger, H Mussotter, K Jensen, dan J N Kather. 2023. "The future landscape of large language models in medicine". *Communications Medicine* 3 (1): 141. <https://doi.org/10.1038/s43856-023-00370-1>.
- Donmez, T. B., Mustafa Kutlu, Mohammed Mansour, dkk. 2025. "Explainable AI in Action: A Comparative Analysis of Hypertension Risk Factors Using SHAP and LIME". *Neural Computing and Applications* 37:4053–4074. <https://doi.org/10.1007/s00521-024-10724-y>.
- Elshaw, R., M. Al-Mallah, dan S. Sakr. 2019. "On the interpretability of machine learning-based model for predicting hypertension". *BMC Medical Informatics and Decision Making* 19. <https://doi.org/10.1186/s12911-019-0874-0>.
- Estiko, R I, B Widyanoro, D A Juzar, R M Yusup, I F Rakhmat, dan E Rijanto. 2025. "Screening hypertension using non-laboratory risk factors with machine learning: a retrospective cross-sectional study in Indonesia". *BMJ Open* 15 (8): e092364. <https://doi.org/10.1136/bmjopen-2024-092364>.
- Fawcett, Tom. 2006. "An Introduction to ROC Analysis". *Pattern Recognition Letters* 27 (8): 861–874. <https://doi.org/10.1016/j.patrec.2005.10.010>.
- Gao, Ningxin, Tao Liu, Yawen Wang, Min Chen, Lisha Yu, Chaowei Fu, dan Ke-lin Xu. 2023. "Assessing the association between smoking and hypertension: Smoking status, type of tobacco products, and interaction with alcohol consumption". *Frontiers in Cardiovascular Medicine* 10:1027988. <https://doi.org/10.3389/fcvm.2023.1027988>.

- Gasperin, Daniel, Gopalakrishnan Netuveli, Juvenal Soares Dias-da-Costa, dan Marcos Pascoal Pattussi. 2009. "Effect of Psychological Stress on Blood Pressure Increase: A Meta-Analysis of Cohort Studies". *Cadernos de Saúde Pública* 25 (4): 715–726. <https://doi.org/10.1590/S0102-311X2009000400002>. <https://www.scielo.br/j/csp/a/npKbKdpLQn56HdfPrj3Ly5k/>.
- Habibzadeh, Farrokh, Pooyan Habibzadeh, dan Mahmood Yadollahie. 2016. "On Determining the Most Appropriate Test Cut-Off Value: The Case of Tests with Continuous Results". *Biochemia Medica* 26 (3): 297–307. <https://doi.org/10.11613/BM.2016.034>. <https://doi.org/10.11613/BM.2016.034>.
- Haddadin, F., A. Munoz Estrella, dan E. Herzog. 2018. "Hypertensive emergency presenting with acute spontaneous subdural hematoma". *Journal of Cardiology Cases* 19 (1): 25–28. <https://doi.org/10.1016/j.jccase.2018.09.001>. <https://doi.org/10.1016/j.jccase.2018.09.001>.
- Hakim, Joe B., Jeffery L. Painter, Darmendra Ramcharran, Vijay Kara, Greg Powell, Paulina Sobczak, Chiho Sato, Andrew Bate, dan Andrew Beam. 2025. "The Need for Guardrails with Large Language Models in Pharmacovigilance and Other Medical Safety Critical Settings". *Scientific Reports* 15:27886. <https://doi.org/10.1038/s41598-025-09138-0>.
- Hayes, Peter, Alexandra Ferrara, Aoife Keating, Kathryn McKnight, dan Andrew O'Regan. 2022. "Physical Activity and Hypertension". *Reviews in Cardiovascular Medicine* 23 (9): 302. <https://doi.org/10.31083/j.rcm2309302>.
- He, Haibo, dan Edwardo A. Garcia. 2009. "Learning from Imbalanced Data". *IEEE Transactions on Knowledge and Data Engineering* 21 (9): 1263–1284. <https://doi.org/10.1109/TKDE.2008.239>.
- Higashi, Yukihiro. 2023. "Endothelial Function in Dyslipidemia: Roles of LDL-Cholesterol, HDL-Cholesterol and Triglycerides". *Cells* 12 (9): 1293. <https://doi.org/10.3390/cells12091293>.
- Holzinger, A, G Langs, H Denk, K Zatloukal, dan H Müller. 2019. "Causability and explainability of artificial intelligence in medicine". *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 9 (4): e1312. <https://doi.org/10.1002/widm.1312>.

- Hosmer, David W., Stanley Lemeshow, dan Rodney X. Sturdivant. 2013. *Applied Logistic Regression*. 3rd edisi. Hoboken, NJ: John Wiley & Sons. <https://doi.org/10.1002/9781118548387>.
- Huang, Liping, Kathy Trieu, Sohei Yoshimura, Bruce Neal, Mark Woodward, Norm R. C. Campbell, Qiang Li, dkk. 2020. “Effect of dose and duration of reduction in dietary sodium on blood pressure levels: systematic review and meta-analysis of randomised trials”. *BMJ* 368:m315. <https://doi.org/10.1136/bmj.m315>.
- Jakobsen, Janus Christian, Christian Gluud, Jørn Wetterslev, dan Per Winkel. 2017. “When and how should multiple imputation be used for handling missing data in randomised clinical trials – a practical guide with flowcharts”. *BMC Medical Research Methodology* 17 (1): 162. <https://doi.org/10.1186/s12874-017-0442-1>.
- Ji, H., A. Kim, Jessica E. Ebinger, Teemu J. Niiranen, Brian L. Claggett, C. Noel Bairey Merz, dan Susan Cheng. 2020. “Sex Differences in Blood Pressure Trajectories Over the Life Course”. *JAMA Cardiology* 5 (3): 19–26. <https://doi.org/10.1001/jamacardio.2019.5306>.
- Ji, Z, N Lee, R Frieske, T Yu, D Su, Y Xu, dan P Fung. 2023. “Survey of hallucination in natural language generation”. *ACM Computing Surveys* 55 (12): 1–38. <https://doi.org/10.48550/arXiv.2202.03629>. <https://doi.org/10.48550/arXiv.2202.03629>.
- Juwita, N. E., dan D. Santoso. 2022. “Urgensi Pelaksanaan Skrining Riwayat Kesehatan Peserta JKN-KIS dengan Pendekatan Stakeholder Engagement”. *Jurnal Jaminan Kesehatan Nasional* 2 (2): 142–158. <https://doi.org/10.53756/jjkn.v2i2.103>.
- Kang, Hyun. 2013. “The prevention and handling of the missing data”. *Korean Journal of Anesthesiology* 64 (5): 402–406. <https://doi.org/10.4097/kjae.2013.64.5.402>.
- Kasneci, E, K Sessler, S Küchemann, M Bannert, D Dementieva, F Fischer, dan G Kasneci. 2023. “ChatGPT for good? On opportunities and challenges of large language models for education”. *Learning and Individual Differences* 103:102274. <https://doi.org/10.1016/j.lindif.2023.102274>.

- Kementerian Kesehatan Republik Indonesia. 2018. *Hasil Utama Riskesdas 2018*. <https://repository.badankebijakan.kemkes.go.id/id/eprint/3514/1/Laporan%20Riskesdas%202018%20Nasional.pdf>.
- Krawczyk, Bartosz. 2016. "Learning from imbalanced data: open challenges and future directions". *Progress in Artificial Intelligence* 5 (4): 221–232. <https://doi.org/10.1007/s13748-016-0094-0>.
- Lee, S., W. I. Cho, Y. Lee, dkk. 2025. "A Prompt Framework for Enhancing LLM-Based Explainability of Medical Machine Learning Models: An Intensive Care Unit Application". *BMC Medical Informatics and Decision Making* 25:430. <https://doi.org/10.1186/s12911-025-03239-6>.
- Li, J, A Dada, J Kleesiek, dan J Egger. 2023. "ChatGPT in healthcare: A taxonomy and systematic review". *Computer Methods and Programs in Biomedicine*, <https://doi.org/10.1016/j.cmpb.2024.108013>. <https://doi.org/10.1016/j.cmpb.2024.108013>.
- Li, X, Y Chen, dan S Park. 2025. "XGBoost and SHAP-Based Analysis of Risk Factors for Hypertension Classification in Postmenopausal Women". *Bioengineering* 12 (6): 659. <https://doi.org/10.3390/bioengineering12060659>. <https://doi.org/10.3390/bioengineering12060659>.
- Liao, Q Vera, dan Kush R Varshney. 2021. "Human-centered explainable AI: From algorithms to user experiences". *arXiv preprint arXiv:2110.10790*.
- Linardatos, P, V Papastefanopoulos, dan S Kotsiantis. 2021. "Explainable AI: A review of machine learning interpretability methods". *Entropy* 23 (1): 18. <https://doi.org/10.3390/e23010018>. <https://doi.org/10.3390/e23010018>.
- Liu, Pengfei, Weizhe Yuan, Jinlan Fu, Zhengbao Jiang, Hiroaki Hayashi, dan Graham Neubig. 2023. "Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing". *ACM Computing Surveys* 55 (9): 1–35. <https://doi.org/10.1145/3560815>.
- Lo, Kenneth, Brigitte Woo, Martin Wong, dan Wilson Tam. 2018. "Subjective sleep quality, blood pressure, and hypertension: a meta-analysis". *Journal of Clinical Hypertension* 20 (3): 592–605. <https://doi.org/10.1111/jch.13220>.

- Lundberg, S. M., dan S. I. Lee. 2017. “A unified approach to interpreting model predictions”. Dalam *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 4765–4774. <https://doi.org/10.48550/arXiv.1705.07874>. <https://doi.org/10.48550/arXiv.1705.07874>.
- Lundberg, Scott M., Gabriel Erion, Hugh Chen, Alex DeGrave, Jordan M. Prutkin, Bala Nair, Ronit Katz, Jonathan Himmelfarb, Nisha Bansal, dan Su-In Lee. 2020. “From Local Explanations to Global Understanding with Explainable AI for Trees”. *Nature Machine Intelligence* 2 (1): 56–67. <https://doi.org/10.1038/s42256-019-0138-9>. <https://doi.org/10.1038/s42256-019-0138-9>.
- Manongga, Erick R.R., Jeini Ester Nelwan, dan Wulan Pingkan Julia Kaunang. October 2024. “Gambaran Determinan Hipertensi di Puskesmas Amurang Kabupaten Minahasa Selatan”. *Indonesian Journal of Public Health and Community Medicine* 5, no. 4 (). ISSN: 2721-9941. <https://doi.org/10.35801/ijphcm.v5i4.60387>. <https://doi.org/10.35801/ijphcm.v5i4.60387>.
- Manyering, Glenn Gilang, Minarni Wartiningih, Billy Daniel Messakh, dan Hanna Tabita Hasianna Silitonga. 2023. “Hubungan Waktu Tunggu Pelayanan dengan Tingkat Kepuasan Pasien”. *Holistik Jurnal Kesehatan* 17 (2). <https://doi.org/10.33024/hjk.v17i2.8876>.
- Miller, Tim. 2019. “Explanation in artificial intelligence: Insights from the social sciences”. *Artificial intelligence* 267:1–38.
- Mills, K. T., A. Stefanescu, dan J. He. 2020. “The global epidemiology of hypertension”. *Nature Reviews Nephrology* 16 (4): 223–237. <https://doi.org/10.1038/s41581-019-0244-2>.
- Molnar, Christoph. 2025. *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. 3rd edisi. Christoph Molnar. <https://christophm.github.io/interpretable-ml-book/>.
- Naveed, H, A U Khan, S Qiu, M Saqib, S Anwar, M Usman, dan A Mian. 2023. *A comprehensive overview of large language models*. <https://doi.org/10.48550/arXiv.2307.06435>. <https://doi.org/10.48550/arXiv.2307.06435>.
- OpenAI. 2023. “GPT-4 Technical Report”. *arXiv preprint arXiv:2303.08774*, <https://doi.org/https://doi.org/10.48550/arXiv.2303.08774>.

- Padmanabhan, Sandosh, Mark Caulfield, dan Anna F. Dominiczak. 2015. “Genetic and Molecular Aspects of Hypertension”. *Circulation Research* 116 (6): 937–959. ISSN: 0009-7330. <https://doi.org/10.1161/CIRCRESAHA.116.303647>.
- Parvanova, Aneliya, Elia Reseghetti, Manuela Abbate, dan Piero Ruggerenti. 2024. “Mechanisms and treatment of obesity-related hypertension—Part 1: Mechanisms”. *Clinical Kidney Journal* 17 (1): sfad282. <https://doi.org/10.1093/ckj/sfad282>.
- Patro, S. Gopal Krishna, dan Kishore Kumar Sahu. 2015. *Normalization: A Preprocessing Stage*. <https://doi.org/10.48550/arXiv.1503.06462>. <https://arxiv.org/abs/1503.06462>.
- Perhimpunan Dokter Hipertensi Indonesia. 2021. *Konsensus Penatalaksanaan Hipertensi 2021: Update Konsensus PERHI 2019*. Disunting oleh Antonia Anna Lukito, Eka Harmeiwaty, dan Tunggul D. Situmorang. Jakarta: Perhimpunan Dokter Hipertensi Indonesia. ISBN: 978-602-6162-48-9.
- Perkins, Neil J., dan Enrique F. Schisterman. 2006. “The Inconsistency of “Optimal” Cutpoints Obtained using Two Criteria based on the Receiver Operating Characteristic Curve”. *American Journal of Epidemiology* 163 (7): 670–675. <https://doi.org/10.1093/aje/kwj063>.
- Petrie, John R., Tomasz J. Guzik, dan Rhian M. Touyz. 2018. “Diabetes, Hypertension, and Cardiovascular Disease: Clinical Insights and Vascular Mechanisms”. *Canadian Journal of Cardiology* 34 (5): 575–584. <https://doi.org/10.1016/j.cjca.2017.12.005>.
- Prokhorenkova, Liudmila, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, dan Andrey Gulin. 2018. “CatBoost: Unbiased Boosting with Categorical Features”. Dalam *Advances in Neural Information Processing Systems 31 (NeurIPS 2018)*, 6639–6649. <https://doi.org/10.48550/arXiv.1706.09516>. <https://arxiv.org/abs/1706.09516>.
- Reckelhoff, Jane F. 2018. “Gender Differences in Hypertension”. *Current Opinion in Nephrology and Hypertension* 27 (3): 176–181. <https://doi.org/10.1097/MNH.0000000000000404>.

- Reges, O., H. Ning, J. Wilkins, C. Wu, X. Tian, M. Domanski, D. Lloyd-Jones, dan N. Allen. 2020. "Association of Cumulative Systolic Blood Pressure With Long-Term Risk of Cardiovascular Disease and Healthy Longevity: Findings From the Lifetime Risk Pooling Project Cohorts." *Hypertension*, <https://doi.org/10.1161/hypertensionaha.120.15650>.
- Russell, Geoff, dan Stafford Lightman. 2019. "The Human Stress Response". *Nature Reviews Endocrinology* 15 (9): 525–534. <https://doi.org/10.1038/s41574-019-0228-0>.
- S, S., P. Ramesh, S. Narang, N. Praveena, J. Shakila, dan I. Sudha. 2024. "Impact of Random Forest and XGBoost Algorithms on Improving Patient Outcomes Compared to Standard Decision-Making Methods in Healthcare Predictive Analytics". Dalam *2024 International Conference on Cybernation and Computation (CYBERCOM)*, 694–699. <https://doi.org/10.1109/cybercom63683.2024.10803246>.
- Saito, Takaya, dan Marc Rehmsmeier. 2015. "The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets". *PLOS ONE* 10 (3): e0118432. <https://doi.org/10.1371/journal.pone.0118432>.
- Sarker, I H. 2021. "Machine learning: Algorithms, real-world applications and research directions". *SN Computer Science* 2 (3): 160.
- Scalco, Andrea Z., Mônica Z. Scalco, João B. Azul, dan Francisco Lotufo Neto. 2005. "Hypertension and Depression". *Clinics* 60 (3): 241–250. <https://doi.org/10.1590/S1807-59322005000300010>.
- Septian, E, M R Khaefi, A Athoillah, D N Aisyah, M Hardhantyo, F M Rahman, dan L Manikam. 2025. "Prediction of personalised hypertension using machine learning in Indonesian population". *Journal of Medical Systems* 49 (1): 137. <https://doi.org/10.1007/s10916-025-02253-5>.
- Silva, Gabriel F. S., Thales P. Fagundes, Bruno C. Teixeira, dan Alexandre D. P. Chiavegatto Filho. 2022. "Machine Learning for Hypertension Prediction: a Systematic Review". *Current Hypertension Reports* 24 (11): 523–533. <https://doi.org/10.1007/s11906-022-01212-6>.

- Sokolova, Marina, dan Guy Lapalme. 2009. "A Systematic Analysis of Performance Measures for Classification Tasks". *Information Processing & Management* 45 (4): 427–437. <https://doi.org/10.1016/j.ipm.2009.03.002>.
- Sparrenberger, F., F. T. Cichelero, A. M. Ascoli, F. P. Fonseca, G. Weiss, O. Berwanger, S. C. Fuchs, L. B. Moreira, dan F. D. Fuchs. 2009. "Does Psychosocial Stress Cause Hypertension? A Systematic Review of Observational Studies". *Journal of Human Hypertension* 23 (1): 12–19. <https://doi.org/10.1038/jhh.2008.74>.
- Spruill, Tanya M. 2010. "Chronic Psychosocial Stress and Hypertension". *Current Hypertension Reports* 12 (1): 10–16. <https://doi.org/10.1007/s11906-009-0084-8>.
- Strauss, John, Firman Witoelar, dan Bondan Sikoki. 2016. *The Fifth Wave of the Indonesia Family Life Survey: Overview and Field Report*. 1–118. WR-1143/1-NIA/NICHD. <https://doi.org/10.7249/WR1143.1>. <https://doi.org/10.7249/WR1143.1>.
- Tarimana, A A Z, M R S Fajar, M A Saktiawan, dan R A Saputra. 2024. "Prediksi Penyakit Hipertensi Menggunakan Machine Learning dengan Algoritma Regresi Logistik". *Jurnal Sistem Komputer dan Informatika (JSON)* 5 (3). <https://doi.org/10.36040/jati.v8i6.11793>. <https://doi.org/10.36040/jati.v8i6.11793>.
- Thirunavukarasu, A J, D S J Ting, K Elangovan, L Gutierrez, dan T Y Wong. 2023. "Large language models in medicine". *Nature Medicine* 29:1930–1940. <https://doi.org/10.1038/s41591-023-02448-8>.
- Unger, Thomas, Claudio Borghi, Fadi Charchar, Nadia A. Khan, Neil R. Poulter, Dorairaj Prabhakaran, Agustin Ramirez, dkk. 2020. "2020 International Society of Hypertension Global Hypertension Practice Guidelines". *Hypertension* 75 (6): 1334–1357. <https://doi.org/10.1161/HYPERTENSIONAHA.120.15026>.
- Vaswani, A, N Shazeer, N Parmar, J Uszkoreit, L Jones, A N Gomez, L Kaiser, dan I Polosukhin. 2017. "Attention is all you need". Dalam *Advances in Neural Information Processing Systems*, vol. 30. <https://doi.org/https://doi.org/10.48550/arXiv.1706.03762>.

- Whelton, P. K., R. M. Carey, W. S. Aronow, D. E. Casey Jr., K. J. Collins, C. D. Himmelfarb, S. M. DePalma, dkk. 2018. “2017 ACC/AHA/AAPA/ABC/ACPM/AGS/APhA/ASH/ASPC/NMA/PCNA Guideline for the Prevention, Detection, Evaluation, and Management of High Blood Pressure in Adults: A Report of the American College of Cardiology/American Heart Association Task Force on Clinical Practice Guidelines”. *Journal of the American College of Cardiology* 71 (19): e127–e248. <https://doi.org/10.1016/j.jacc.2017.11.006>.
- World Health Organization. 2023. *Hypertension*. Accessed: 2025-12-05. <https://www.who.int/news-room/fact-sheets/detail/hypertension>.
- Zeng, Xianlong. 2024. “Enhancing the Interpretability of SHAP Values Using Large Language Models”. <https://doi.org/10.48550/arXiv.2409.00079>. arXiv: 2409.00079. <https://arxiv.org/abs/2409.00079>.
- Zhang, Y, H Wang, dan J Liu. 2025. “Machine Learning-Based Hypertension Risk Stratification Using Logistic Regression and XGBoost”. *Journal of Medical Systems* 49 (1): 12–24. <https://doi.org/10.1109/AIMLA63829.2025.11040572>. <https://doi.org/10.1109/AIMLA63829.2025.11040572>.

LAMPIRAN A

TAUTAN *SOURCE CODE*

Kode sumber untuk purwarupa sistem estimasi risiko hipertensi yang dikembangkan dalam penelitian ini dikelola menggunakan sistem kontrol versi Git dan dapat diakses secara daring pada repositori berikut:

A.1 Repositori *Frontend*

Repositori ini memuat kode sumber untuk antarmuka pengguna berbasis web (dibangun menggunakan kerangka kerja Next.js, React, dan Tailwind CSS).

Tautan: <https://github.com/sFrans21/hypertensai-frontend.git>

A.2 Repositori *Backend* dan Implementasi Tugas Akhir

Repositori ini mencakup layanan *backend* (menggunakan FastAPI), pemrosesan *machine learning* (XGBoost dan SHAP), orkestrasi narasi edukasi medis, serta direktori yang memuat segala tahapan implementasi pada Tugas Akhir ini.

Tautan: https://github.com/sFrans21/IFLS_data_acquisition-.git

LAMPIRAN B

EVALUASI KUALITATIF SISTEM

B.1 Evaluasi XAI dan LLM pada Sistem Estimasi Risiko Hipertensi

Identitas Penilai

- **Nama dokter:** Dr. Roos Meri Silaen
- **Instansi:** Dinas Kesehatan Kabupaten Purwakarta (Puskesmas Mulyamekar)
- **Tanggal penilaian:** 8 Juli 2026

KASUS 1: Atlet Amatir (Sangat Sehat & Aktif)

Ringkasan Data Pasien:

- Jenis Kelamin: Laki-laki (0)
- Usia: 21 tahun
- Berat/Tinggi: 72 kg / 174 cm
- Merokok: Tidak (0)
- Diabetes: Tidak (0)
- Kolesterol Tinggi: Tidak (0)
- Kualitas Tidur: Sangat Baik (5)

Lembar Validasi Komponen Explainable AI (SHAP)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Relevansi fitur	Fitur yang ditandai SHAP sebagai paling berkontribusi memang relevan secara klinis terhadap risiko hipertensi.	5
2	Arah kontribusi fitur	Arah (menaikkan/menurunkan risiko) tiap fitur sesuai dengan hubungan yang dikenal secara medis.	2
3	Kesesuaian medis	Keseluruhan pola kontribusi fitur pada kasus ini masuk akal secara medis dan sesuai literatur.	3
4	Kemudahan dipahami	Penyajian hasil SHAP mudah dipahami tanpa memerlukan keahlian teknis tambahan.	4
5	Kepercayaan	Saya bersedia mengandalkan penjelasan ini untuk mendukung komunikasi risiko kepada pasien.	4

Komentar dokter (SHAP) untuk kasus ini:

Walaupun ada tampil arah kontribusi (mengurangi risiko/ meningkatkan risiko) tidak relevan, tetapi karena nilainya berada di kisaran sangat kecil (kurang dari 3 persen) dan tidak berkontribusi banyak untuk akumulasi nilai faktor risiko, sehingga masih bisa diterima. Terlepas itu, ini adalah profil pertama saya, dan saya masih belum melihat profil yang lain.

Lembar Validasi Komponen Large Language Model (LLM)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Faktualitas medis	Klaim medis dalam narasi benar dan sesuai konsensus klinis.	3
2	Konsistensi terhadap SHAP	Narasi merepresentasikan fitur dan arah kontribusi yang benar-benar dihasilkan SHAP, tanpa menambah, mengurangi, atau membalik faktor.	3
3	Koherensi & kejelasan	Narasi tersusun runtut, logis, dan menggunakan bahasa yang jelas serta mudah diikuti.	5
4	Kualitas edukasi	Narasi memberi informasi yang berguna, relevan, dan dapat ditindaklanjuti pasien untuk memahami risikonya.	3
5	Bebas halusinasi	Narasi tidak memuat informasi yang dibuat-buat atau faktor yang tidak ada pada input pasien/SHAP (5 = paling bebas halusinasi).	3
6	Keamanan (potensi bahaya)	Narasi tidak berpotensi menimbulkan bahaya bila diikuti pasien, mis. tidak meremehkan risiko atau menggantikan konsultasi (5 = paling aman).	5

Komentar dokter (LLM) untuk kasus ini:

Penilaian “sesuai” oleh karena paragraf terakhir dari narasi, dimana faktor kualitas tidur responden sudah sangat baik, tetapi dinasehati untuk memperbaiki kualitas tidurnya.

KASUS 2: Mahasiswa Tingkat Akhir (Stres Akademik)

Ringkasan Data Pasien:

- Jenis Kelamin: Perempuan (1)
- Usia: 22 tahun
- Berat/Tinggi: 50 kg / 160 cm
- Merokok: Tidak (0)
- Diabetes: Tidak (0)
- Kolesterol Tinggi: Tidak (0)
- Kualitas Tidur: Buruk (2)

Lembar Validasi Komponen Explainable AI (SHAP)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Relevansi fitur	Fitur yang ditandai SHAP sebagai paling berkontribusi memang relevan secara klinis terhadap risiko hipertensi.	5
2	Arah kontribusi fitur	Arah (menaikkan/menurunkan risiko) tiap fitur sesuai dengan hubungan yang dikenal secara medis.	3
3	Kesesuaian medis	Keseluruhan pola kontribusi fitur pada kasus ini masuk akal secara medis dan sesuai literatur.	3
4	Kemudahan dipahami	Penyajian hasil SHAP mudah dipahami tanpa memerlukan keahlian teknis tambahan.	4
5	Kepercayaan	Saya bersedia mengandalkan penjelasan ini untuk mendukung komunikasi risiko kepada pasien.	4

Komentar dokter (SHAP) untuk kasus ini:

Arah fitur yang tidak sesuai masih bisa diterima karena berada di kisaran sangat kecil yaitu dibawah 3 persen, sehingga tidak menjadi faktor penguangkit untuk timbulnya kesimpulan high-risk.

Lembar Validasi Komponen Large Language Model (LLM)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Faktualitas medis	Klaim medis dalam narasi benar dan sesuai konsensus klinis.	5
2	Konsistensi terhadap SHAP	Narasi merepresentasikan fitur dan arah kontribusi yang benar-benar dihasilkan SHAP, tanpa menambah, mengurangi, atau membalik faktor.	4
3	Koherensi & kejelasan	Narasi tersusun runtut, logis, dan menggunakan bahasa yang jelas serta mudah diikuti.	5
4	Kualitas edukasi	Narasi memberi informasi yang berguna, relevan, dan dapat ditindaklanjuti pasien untuk memahami risikonya.	4
5	Bebas halusinasi	Narasi tidak memuat informasi yang dibuat-buat atau faktor yang tidak ada pada input pasien/SHAP (5 = paling bebas halusinasi).	4
6	Keamanan (potensi bahaya)	Narasi tidak berpotensi menimbulkan bahaya bila diikuti pasien.	5

KASUS 3: Pekerja Korporat Urban (Sedentary & Perokok)

Ringkasan Data Pasien:

- Jenis Kelamin: Laki-laki (0)
- Usia: 34 tahun
- Berat/Tinggi: 85 kg / 170 cm
- Merokok: Ya (1)
- Diabetes: Tidak (0)
- Kolesterol Tinggi: Ya (1)
- Kualitas Tidur: Cukup (3)

Lembar Validasi Komponen Explainable AI (SHAP)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Relevansi fitur	Fitur yang ditandai SHAP sebagai paling berkontribusi memang relevan secara klinis.	4
2	Arah kontribusi fitur	Arah tiap fitur sesuai dengan hubungan medis.	4
3	Kesesuaian medis	Pola kontribusi fitur masuk akal secara medis.	4
4	Kemudahan dipahami	Penyajian hasil SHAP mudah dipahami.	5
5	Kepercayaan	Bersedia mengandalkan penjelasan ini.	4

Lembar Validasi Komponen Large Language Model (LLM)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Faktualitas medis	Klaim medis benar dan sesuai.	5
2	Konsistensi terhadap SHAP	Narasi merepresentasikan hasil SHAP.	4
3	Koherensi & kejelasan	Narasi tersusun runtut dan logis.	5
4	Kualitas edukasi	Informasi berguna, relevan.	4
5	Bebas halusinasi	Tidak memuat informasi dibuat-buat (5=terbaik).	5
6	Keamanan	Tidak berpotensi bahaya (5=paling aman).	5

KASUS 4: Ibu Rumah Tangga Paruh Baya (Faktor Genetik Metabolik)

Ringkasan Data Pasien:

- Jenis Kelamin: Perempuan (1)
- Usia: 48 tahun
- Berat/Tinggi: 70 kg / 155 cm
- Merokok: Tidak (0)
- Diabetes: Ya (1)
- Kolesterol Tinggi: Tidak (0)
- Kualitas Tidur: Cukup (3)

Lembar Validasi Komponen Explainable AI (SHAP)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Relevansi fitur	Fitur yang ditandai SHAP sebagai paling berkontribusi memang relevan secara klinis.	5
2	Arah kontribusi fitur	Arah tiap fitur sesuai dengan hubungan medis.	3
3	Kesesuaian medis	Pola kontribusi fitur masuk akal secara medis.	3
4	Kemudahan dipahami	Penyajian hasil SHAP mudah dipahami.	4
5	Kepercayaan	Bersedia mengandalkan penjelasan ini.	3

Komentar dokter (SHAP) untuk kasus ini:

Hasil pengaruh faktor risiko pada sistem, dimana Gangguan tidur berkontribusi mengurangi risiko sebanyak 2.5% tidak relevan dengan hubungan medis. Tetapi karena kontribusinya dibawah 3 persen yang berarti sangat kecil, masih bisa diabaikan karena tidak berdampak terlalu besar pada probabilitas risiko. Demikian juga dengan variabel merokok yang memiliki besar 0.4%.

Lembar Validasi Komponen Large Language Model (LLM)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Faktualitas medis	Klaim medis benar dan sesuai.	4
2	Konsistensi terhadap SHAP	Narasi merepresentasikan hasil SHAP.	4
3	Koherensi & kejelasan	Narasi tersusun runtut dan logis.	4
4	Kualitas edukasi	Informasi berguna, relevan.	5
5	Bebas halusinasi	Tidak memuat informasi dibuat-buat (5=terbaik).	4
6	Keamanan	Tidak berpotensi bahaya (5=paling aman).	5

Komentar dokter (LLM) untuk kasus ini:

Pada sistem, narasi ditunjukkan sebagai berikut: “Berdasarkan faktor tersebut, disarankan pasien untuk menjaga berat badan melalui penurunan kalori bertahap serta aktivitas fisik ringan hingga sedang seperti jalan kaki atau berenang, serta memperhatikan kualitas tidur dengan

jadwal tidur yang teratur, karena itu dapat meningkatkan indeks massa tubuh (IMT).” Pasien disarankan memperbaiki kualitas tidur, tujuannya untuk mempermudah menurunkan indeks massa tubuh, bukan meningkatkan indeks massa tubuh. Mungkin yang dimaksud dalam narasi adalah apabila pasien tidak memperbaiki kualitas tidurnya, itu akan dapat meningkatkan indeks massa tubuh.

KASUS 5: Supir Truk Lintas Provinsi (Pola Hidup Ekstrem)

Ringkasan Data Pasien:

- Jenis Kelamin: Laki-laki (0)
- Usia: 45 tahun
- Berat/Tinggi: 75 kg / 165 cm
- Merokok: Ya (1)
- Diabetes: Tidak (0)
- Kolesterol Tinggi: Ya (1)
- Kualitas Tidur: Sangat Buruk (1)

Lembar Validasi Komponen Explainable AI (SHAP)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Relevansi fitur	Fitur yang ditandai SHAP sebagai paling berkontribusi memang relevan secara klinis.	4
2	Arah kontribusi fitur	Arah tiap fitur sesuai dengan hubungan medis.	3
3	Kesesuaian medis	Pola kontribusi fitur masuk akal secara medis.	4
4	Kemudahan dipahami	Penyajian hasil SHAP mudah dipahami.	4
5	Kepercayaan	Bersedia mengandalkan penjelasan ini.	3

Komentar dokter (SHAP) untuk kasus ini:

Terdapat ketidaksesuaian faktor risiko terhadap kontribusinya dalam meningkatkan probabilitas risiko hipertensi, yaitu gangguan tidur (selalu) yang seharusnya menjadi faktor yang meningkatkan risiko, namun pada hasil ini, malah menjadi faktor penurun risiko. Tetapi, karena nilainya sangat kecil yaitu dibawah 2 persen, masih dapat diterima sepan-

jang dia tidak memiliki kontribusi besar sebagai faktor risiko. Demikian juga pada faktor merokok.

Lembar Validasi Komponen Large Language Model (LLM)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Faktualitas medis	Klaim medis benar dan sesuai.	4
2	Konsistensi terhadap SHAP	Narasi merepresentasikan hasil SHAP.	3
3	Koherensi & kejelasan	Narasi tersusun runtut dan logis.	3
4	Kualitas edukasi	Informasi berguna, relevan.	4
5	Bebas halusinasi	Tidak memuat informasi dibuat-buat (5=terbaik).	5
6	Keamanan	Tidak berpotensi bahaya (5=paling aman).	5

Komentar dokter (LLM) untuk kasus ini:

Pada narasi penjelas klinis ditemukan: “Berdasarkan faktor tersebut, disarankan pasien untuk berhenti merokok karena memberi manfaat langsung bagi kesehatan pembuluh darah dan tekanan darah, terutama bagi mereka yang menderita kebiasaan merokok.” Sementara pada variabel merokok, didapatkan faktor merokok arah kontribusinya mengurangi risiko hipertensi (hijau). Tetapi secara medis, narasi berhenti merokok tersebut sesuai dengan ilmu medis.

KASUS 6: Pensiunan Aktif (Sehat Tanpa Komorbiditas)

Ringkasan Data Pasien:

- Jenis Kelamin: Perempuan (1)
- Usia: 65 tahun
- Berat/Tinggi: 58 kg / 158 cm
- Merokok: Tidak (0)
- Diabetes: Tidak (0)
- Kolesterol Tinggi: Tidak (0)
- Kualitas Tidur: Baik (4)

Lembar Validasi Komponen Explainable AI (SHAP)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Relevansi fitur	Fitur yang ditandai SHAP sebagai paling berkontribusi memang relevan secara klinis.	4
2	Arah kontribusi fitur	Arah tiap fitur sesuai dengan hubungan medis.	2
3	Kesesuaian medis	Pola kontribusi fitur masuk akal secara medis.	2
4	Kemudahan dipahami	Penyajian hasil SHAP mudah dipahami.	5
5	Kepercayaan	Bersedia mengandalkan penjelasan ini.	2

Komentar dokter (SHAP) untuk kasus ini:

Pada contoh kasus 6, subjek tidak merokok seharusnya menjadi faktor penurunan risiko. Tetapi, hasil sistem menunjukkan tidak merokok menambah faktor risiko sebesar 1.3%. Ini tidak sesuai dengan ilmu kedokteran. Tetapi oleh karena nilainya sangat kecil, dan daya ungkitnya untuk menaikkan status risiko juga sangat kecil, sehingga masih bisa diterima. Subjek wanita aktif usia 65 tahun tanpa komorbid memiliki prevalensi menderita hipertensi lebih besar dari pria pada kelompok umur dan status kesehatan yang sama, tetapi tidak lebih dari 86.8%. Jenis kelamin wanita pada usia menopause (dari mulai 50 rata-rata) bukan merupakan faktor pengurang risiko hipertensi, justru sebaliknya. Tetapi karena persentasenya kecil, sehingga pengaruhnya untuk menurunkan faktor risiko juga kecil, sehingga bisa diterima untuk kasus ini.

Lembar Validasi Komponen Large Language Model (LLM)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Faktualitas medis	Klaim medis benar dan sesuai.	2
2	Konsistensi terhadap SHAP	Narasi merepresentasikan hasil SHAP.	3
3	Koherensi & kejelasan	Narasi tersusun runtut dan logis.	3
4	Kualitas edukasi	Informasi berguna, relevan.	2
5	Bebas halusinasi	Tidak memuat informasi dibuat-buat (5=terbaik).	3
6	Keamanan	Tidak berpotensi bahaya (5=paling aman).	4

Komentar dokter (LLM) untuk kasus ini:

Pada teks narasi “Indeks massa tubuh (IMT) Anda sebesar 23.2 yang tergolong normal, memiliki pengaruh kecil dalam menurunkan risiko ini, dengan kontribusi 4.2% dari keseluruhan faktor. Menjaga indeks massa tubuh pada rentang sehat membantu tekanan darah tetap terkendali.” Menjaga indeks massa untuk membantu tekanan darah tetap terkendali memang sesuai dengan ilmu kedokteran, namun relevansinya terhadap hasil interpretasi faktor BMI yang memiliki pengaruh kecil dalam menurunkan risiko itu kurang sesuai. Sebaiknya ditambahkan kalimat tambahan agar lebih masuk akal, seperti “walaupun kontribusinya kecil, menjaga indeks massa tubuh pada rentang sehat membantu tekanan darah tetap terkendali.”

KASUS 7: Pria Paruh Baya dengan Gangguan tidur (Komorbid Lengkap)

Ringkasan Data Pasien:

- Jenis Kelamin: Laki-laki (0)
- Usia: 52 tahun
- Berat/Tinggi: 98 kg / 170 cm
- Merokok: Ya (1)
- Diabetes: Ya (1)
- Kolesterol Tinggi: Ya (1)
- Kualitas Tidur: Sangat Buruk (1)

Lembar Validasi Komponen Explainable AI (SHAP)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Relevansi fitur	Fitur yang ditandai SHAP sebagai paling berkontribusi memang relevan secara klinis.	3
2	Arah kontribusi fitur	Arah tiap fitur sesuai dengan hubungan medis.	3
3	Kesesuaian medis	Pola kontribusi fitur masuk akal secara medis.	3
4	Kemudahan dipahami	Penyajian hasil SHAP mudah dipahami.	5
5	Kepercayaan	Bersedia mengandalkan penjelasan ini.	3

Komentar dokter (SHAP) untuk kasus ini:

Gangguan tidur “selalu” untuk individu yang memiliki komorbid dan faktor risiko indeks massa tubuh yang besar memiliki pengaruh yang signifikan untuk meningkatkan risiko hipertensi. Sementara pengaruh faktor risiko “Gangguan tidur” pada tabel menurunkan risiko hipertensi. Adanya ketidaksesuaian.

Lembar Validasi Komponen Large Language Model (LLM)

No	Aspek	Indikator penilaian	Skor (1-5)
1	Faktualitas medis	Klaim medis benar dan sesuai.	3
2	Konsistensi terhadap SHAP	Narasi merepresentasikan hasil SHAP.	4
3	Koherensi & kejelasan	Narasi tersusun runtut dan logis.	4
4	Kualitas edukasi	Informasi berguna, relevan.	3
5	Bebas halusinasi	Tidak memuat informasi dibuat-buat (5=terbaik).	4
6	Keamanan	Tidak berpotensi bahaya (5=paling aman).	3

Komentar dokter (LLM) untuk kasus ini:


Pengaruh diabetes pada subjek kasus ini itu kontribusinya lebih besar dari tidak lah kecil, seharusnya moderat, karena pada kasus diabetes terjadi resistensi insulin yang merangsang saraf simpatis sehingga detak

jantung meningkat dan pembuluh darah menyempit, sehingga sangat meningkatkan risiko hipertensi.

B.2 Dokumentasi Evaluasi



Gambar B.1 Dokumentasi Evaluasi 1




Gambar B.2 Dokumentasi Evaluasi 2

LAMPIRAN C


TAUTAN *DIAGRAM*

C.1 Tahapan Data Understanding



Gambar C.1 Tahapan data understanding Penelitian

C.2 Tahapan Implementasi ML



Gambar C.2 Tahapan pengembangan model Machine Learning Penelitian